

Tópicos de Lógica Fuzzy e Biomatemática

**Coleção IMECC
Textos Didáticos**

5

Laécio Carvalho de Barros

Rodney Carlos Bassanezi

**Tópicos de Lógica Fuzzy
e
Biomatemática**

Coleção IMECC

Textos Didáticos

Volume 5

Grupo de Biomatemática

Instituto de Matemática, Estatística e Computação Científica

Universidade Estadual de Campinas

FICHA CATALOGRÁFICA ELABORADA PELA
BIBLIOTECA DO IMECC

B278t	Barros, Laécio Carvalho de. Tópicos de lógica fuzzy e biomatemática/ Laécio Carvalho de Barros, Rodney Carlos Bassanezi – Campinas, SP: UNICAMP/IMECC, 2006. 354p.: il. – (Coleção IMECC – Textos didáticos; v.5) 1. Conjuntos difusos. 2. Lógica difusa. 3. Sistemas difusos. 4. Biomatemática. I. Bassanezi, Rodney Carlos. II. Título. 511.322 574.0151 ISBN 85-87185-05-5
-------	--

Índices para Catálogo Sistemático

- | | |
|----------------------|----------|
| 1. Conjuntos difusos | 511.322 |
| 2. Lógica difusa | 511.322 |
| 3. Sistemas difusos | 511.322 |
| 4. Biomatemática | 574.0151 |

Copyright© by Instituto de Matemática, Estatística e Computação
Científica

Produção Editorial: *Comissão de Publicações – IMECC*

Editoração e Macros $\text{\LaTeX}$: Luiz Rafael dos Santos
2006

Grupo de Biomatemática

Instituto de Matemática, Estatística e Computação Científica (IMECC)

Universidade Estadual de Campinas (Unicamp)

C.P. 6065 – Cidade Universitária – Barão Geraldo

CEP 13973-970 – Campinas – SP – Brasil

Sumário

Apresentação	1
Prefácio	3
1 Conjunto fuzzy como modelador de incerteza	7
1.1 Incerteza	7
1.2 Subconjuntos Fuzzy	14
1.3 Operações com subconjuntos fuzzy	21
1.4 O conceito de α -nível	30
2 O Princípio de Extensão e Números Fuzzy	37
2.1 O Princípio de Extensão de Zadeh	37
2.2 Números Fuzzy	43
2.2.1 Operações aritméticas com números fuzzy	47
3 Relações Fuzzy	61
3.1 Relações Fuzzy	61
3.1.1 Formas de representação e propriedades	65
3.2 Composição entre Relações Fuzzy Binárias	69
4 Noções da Lógica Fuzzy	77
4.1 Conectivos Básicos da Lógica Clássica	79
4.2 Conectivos básicos da Lógica Fuzzy	83
4.2.1 Operações t-norma e t-conorma	84
4.3 Raciocínio Aproximado e Variáveis Linguísticas	91

4.4	Modus Ponens e Modus Ponens Generalizado	93
4.5	Modificadores Linguísticos	100
4.6	Independência e Não-Interatividade	106
4.6.1	Independência e Não-Interatividade Probabilística	107
4.6.2	Independência e Não-Interatividade Possibilística .	109
4.6.3	As distribuições Condicionais e o Modus Ponens: Uma Visão Bayesiana	110
5	Sistemas Baseados em Regras Fuzzy	113
5.1	Base de Regras Fuzzy	115
5.2	Controlador Fuzzy	117
5.3	O Método de Mamdani	120
5.4	Métodos de Defuzzificação	126
5.4.1	Centro de gravidade	126
5.4.2	Centro dos Máximos	127
5.4.3	Média dos Máximos	128
5.5	Método de Inferência de TSK	128
5.6	Aplicações	135
5.6.1	Salinidade em Cananeia e Ilha Comprida	135
5.6.2	Transferência de Soropositivos	143
5.6.3	Controle de Pulgões	152
6	Equações Relacionais Fuzzy e Aproximação	159
6.1	Composições Generalizadas de Relações Fuzzy	160
6.2	Equações Relacionais Fuzzy	163
6.2.1	Equações Relacionais com max–min	164
6.2.2	Equações Relacionais com sup–t	167
6.2.3	Modelagem Matemática: Diagnóstico Médico . . .	169
6.3	Aproximação Universal	174
6.3.1	Capacidade de Aproximar	176
6.4	Controladores Fuzzy aplicado a Sistemas Dinâmicos . . .	181

7	Medidas, Integrais e Eventos Fuzzy	185
7.1	Medidas Clássicas e Medidas Fuzzy	186
7.1.1	Medida de probabilidade	186
7.1.2	Medidas Fuzzy	190
7.1.3	Medida de possibilidade	193
7.1.4	Transformação Probabilidade/Possibilidade	200
7.2	Integrais Fuzzy	203
7.2.1	Integral de Lebesgue	204
7.2.2	Integral de Choquet	207
7.2.3	Integral de Sugeno	208
7.3	Eventos Fuzzy	220
7.3.1	Probabilidade de Eventos Fuzzy	221
7.3.2	Independência de Eventos Fuzzy	227
7.3.3	Variável Aleatória Linguística	229
8	Sistemas Dinâmicos Fuzzy	239
8.1	Sistemas Dinâmicos Fuzzy Contínuos	239
8.1.1	Derivada e Integral de Função Fuzzy	242
8.1.2	Problema de Valor Inicial Fuzzy	246
8.1.3	Problema de Valor Inicial Fuzzy Generalizado	252
8.2	Sistemas Dinâmicos Fuzzy Discretos	266
8.2.1	Modelo Malthusiano Fuzzy Discreto	268
8.2.2	O Modelo Logístico Fuzzy Discreto	272
9	Modelagem em Biomatemática: Fuzziness Demográfica	279
9.1	Fuzziness Demográfica: modelagem discreta	283
9.1.1	Regras Fuzzy com Oposição Semântica	284
9.1.2	Equilíbrio e Estabilidade dos Sistemas p-fuzzy Discretos Unidimensionais	287
9.1.3	Modelo tipo presa-predador p-fuzzy discreto	294
9.2	Fuzziness Demográfica: modelagem contínua	298
9.2.1	Características de um sistema p-fuzzy contínuo	298

9.2.2	Métodos numéricos para soluções do PVI p-fuzzy contínuo	299
9.2.3	Estudo do modelo p-fuzzy de Montroll	304
9.2.4	Modelos Bidimensionais: modelo presa-predador p-fuzzy de Lotka-Volterra	308
10	Modelagem em Biomatemática: Fuzziness ambiental	321
10.1	Esperança de Vida $\times$ Pobreza	322
10.1.1	O Modelo	323
10.1.2	Esperança Estocástica: $E[n(t)]$	324
10.1.3	Esperança Fuzzy: $EF \left[\frac{n(t)}{n(0)} \right]$	326
10.1.4	Aplicação: Esperança de vida de um grupo de metalúrgicos de Recife	328
10.1.5	Comparação das Esperanças Clássica e Fuzzy	330
10.2	O Modelo Epidemiológico SI	333
10.2.1	O Modelo SI Fuzzy	335
10.2.2	Esperança fuzzy do número de indivíduos infectados	338
10.2.3	Esperança clássica do número de infectados	342
10.2.4	Solução das médias $(I(EF[V], t)) \times$ Média das soluções $(EF[I(V, t)])$	344
10.2.5	Controle da Epidemia e Valor de Reprodutibilidade Basal	346
10.3	Modelo da Transferência de HIV ⁺	349
10.3.1	O modelo clássico	349
10.3.2	O Modelo Fuzzy	350
10.3.3	Esperança fuzzy do número de indivíduos assintomáticos	352
10.4	Dinâmica populacional e migração de moscas varejeiras	355
	Referências Bibliográficas	365

Para Cristina, Otávio e Luiza.

*Para meus netos,
Mariana, Pedro, Anna e André.*

Apresentação

A obra dos Professores Laécio e Rodney reúne duas importantes características muito raras de aparecerem simultaneamente em um livro de matemática. Em primeiro lugar é um livro didático que apresenta um escopo abrangente e moderno da teoria da lógica fuzzy desde as definições mais básicas até alguns resultados mais sofisticados da teoria atual, contendo o material adequado para uso em várias etapas de um curso sobre lógica fuzzy. Em segundo lugar é um livro que apresenta bastantes resultados de pesquisa corrente sobre as aplicações da teoria estudada em problemas de biologia e sistemas dinâmicos o que suscita sempre a discussão e aparecimento de nova pesquisa. Assim, mesmo um pesquisador da área em questão encontrará neste livro um material muito interessante, com pontos de vista originais que certamente motivarão trabalhos futuros.

Apesar do livro apontar para as aplicações em biomatemática por ser a área dos autores, a apresentação reúne o núcleo central da teoria de lógica fuzzy, apresentando a teoria de conjuntos fuzzy, das relações fuzzy, conectivos e inferência com sistemas de regras fuzzy.

Os tópicos específicos são introduzidos com motivações intuitivas e conforme se façam necessários para as aplicações dos capítulos. Esta parte teórica é apresentada com um formalismo matemático necessário para que as possibilidades de aplicações não se limitem àquelas apresentadas no texto.

O rigor e a estrutura limpa do texto refletem a maturidade dos pesquisadores da UNICAMP que há mais de dez anos trabalham neste

assunto orientando várias teses e dissertações. Considero muito importante a contribuição deste livro como material de apoio a pesquisadores de várias áreas que usam a lógica fuzzy, e como material didático para utilização em cursos introdutórios.

Pedro A. Tonelli

Prefácio

A Teoria dos Conjuntos Fuzzy, recente do ponto de vista de historiografia, vem se desenvolvendo e ganhando espaço e, cada vez mais, está sendo usada como ferramenta para a formulação de modelos nos vários campos das ciências. A primeira publicação sobre conjuntos fuzzy é devida a L. Zadeh [129, 1965] e o desenvolvimento da teoria e suas aplicações vêm apresentando uma evolução muito rápida, permeada de críticas severas de alguns matemáticos e estatísticos ortodoxos e de efusivos elogios de seus adeptos e usuários que estão distribuídos pelas mais diversas modalidades e áreas de pesquisa. Podemos dizer que a Lógica Fuzzy¹ já tem um lugar de destaque, com aplicações práticas cada vez mais bem sucedidas, e que nós também temos explorado bastante seu potencial na modelagem de fenômenos biológicos. A ideia de contrapor modelos determinísticos a modelos mais flexíveis, que contemplam uma certa dose de incerteza tratada com a Lógica Fuzzy, tem sido a linha de nossas pesquisas. Formular matematicamente a subjetividade própria de fenômenos naturais, ou de como os vemos, para tentar previsões coerentes é um de nossos desafios.

A maior crítica ao uso, cada vez mais abrangente, da Lógica Fuzzy recai sobre o fato de que as soluções obtidas por meio deste processo são, quase sempre, menos rigorosas quando comparadas às soluções “exatas” da teoria clássica. Muitos matemáticos acreditam que a falta de rigor dos processos fuzzy poderia causar uma perda irremediável para o avanço da matemática, desenvolvida ao longo dos séculos e entendida como

¹Lógica Fuzzy – Área de estudo que envolve Conjuntos Fuzzy e suas operações.

uma evolução do pensamento lógico. Alguns acreditam que a Lógica Fuzzy passa a ser perniciosa no sentido que oferece um afrouxamento do pensamento lógico – “*O perigo da Lógica Fuzzy é que ela encoraja toda espécie de pensamento impreciso, causando assim muitos problemas*” (veja em Kosko [76]). Em oposição, há aqueles defensores da lógica fuzzy a ponto de criticar a rigidez de alguns métodos da lógica clássica [112]. Esse é um debate que, embora salutar, não será esgotado aqui. Para resumir essa polêmica, deixe-nos citar uma reflexão de Zadeh:

“Embora algumas das primeiras controvérsias tenham diminuído, com respeito à aplicabilidade da lógica fuzzy, há ainda vozes influentes que são críticas e/ou céticas. Alguns tomam a posição de que qualquer coisa que pode ser feita com lógica fuzzy, pode ser feita igualmente sem ela. Alguns são tentados a provar que a lógica fuzzy está errada. E alguns ficam aborrecidos porque perceberam ter expectativas exageradas. Este último pode bem ser o caso. Entretanto, como disse Julio Verne na virada do século, o progresso científico é guiado por expectativas exageradas” [58, Introdução].

A nosso ver, a matemática clássica continuará tendo um papel fundamental no desenvolvimento da humanidade. Apenas acreditamos que a teoria dos conjuntos fuzzy seja um argumento a mais para a continuidade e evolução desta ciência, por mais paradoxal que possa parecer, a primeira vista, tal afirmação. Temos observado que as soluções previstas pela matemática clássica, num certo sentido, fazem parte das soluções obtidas a partir da Lógica Fuzzy. Isso pode ser entendido considerando-se a matemática clássica como uma espécie de limite da fuzzy quando as incertezas são eliminadas ou tendem a zero. Como veremos no texto, os conceitos que aparecem na Teoria dos Conjuntos Fuzzy são rigorosamente definidos a partir da ideia abstrata de número. Intuitivamente, podemos dizer, em se tratando de *matemática fuzzy* ou *matemática clássica* que o “ou” não deve ser exclusivo, não deve haver

oposição nesta questão. Nos parece, isso sim, tratar-se de um exemplo típico de *pensamento dialético* em que um complementa o outro na busca do conhecimento.

Embora nossa formação inicial em Lógica Fuzzy tenha sido maior do ponto de vista teórico, influenciados que fomos pelo entusiasmo de G. Greco (Università di Trento, IT), que nos introduziu nesta teoria, optamos por não apresentar uma discussão puramente teórica neste texto. Nosso objetivo principal foi explorar o potencial de aplicação da Lógica Fuzzy a fenômenos ligados às Ciências Naturais, com ênfase em Biomatemática, a partir dos sistemas dinâmicos aqui tratados. Entretanto, o leitor que se interessar pelo aprofundamento da teoria poderá encontrar material adequado em excelentes publicações existentes e que elencamos nas referências bibliográficas.

O conteúdo do livro é o resultado de seminários realizados no IME-USP há mais de dez anos e de cursos de pós-graduação no IMECC-UNICAMP nos quais a colaboração de nossos alunos foi decisiva. Destacamos as participações do João, da Magda, da Marina, do Moiseis e do Jamil. Agradecimentos especiais ao Rafael que se empenhou na editoração e produção das figuras. Agradecemos também aos colegas Dr. Pedro A. Tonelli (IME-USP), Dr. Júlio C. R. Pereira (Faculdade de Saúde Pública-USP) e Dr. Eduardo Massad (Faculdade de Medicina-USP) que se prontificaram a ler e opinar sobre o texto.

Os Autores

Capítulo 1

Conjunto fuzzy como modelador de incerteza

“O homem é a medida de todas as coisas; das coisas que são o que são, e das coisas que não são o que não são.”

(Protágoras – Sec.V a.C.)

1.1 Incerteza

Questionamentos a respeito de incertezas têm sido preocupações de filósofos e de pesquisadores ao longo dos tempos. A busca da verdade, do que é e do que existe, é uma questão debatida desde a Grécia Antiga, quando os gregos colocaram explicitamente a questão “Transformação ou Permanência?”, referindo-se às duas dimensões do pensamento, separadas e até opostas.

Os filósofos pré-socráticos procuravam fazer afirmações sintetizando seus pensamentos sobre o universo na tentativa de explicar as coisas que nele existem.

Heráclito de éfeso (VI - V a.C.): “*panta hei*”, que significa “tudo corre”. Para ilustrar, dizia que ninguém banha-se no mesmo rio duas vezes. Crátilo, seu discípulo, levou o pensamento de seu mestre ao extremo afirmando que não podemos nos banhar nem mesmo uma vez no rio, pois, se atribuímos identidade ou nomeamos as coisas, já estamos

dando-lhes estabilidade que, a seu ver, estão sempre mudando.

Contrapondo-se a Heráclito, surge a escola eleática questionando o movimento. Parmênides de Eleia (VI - V a.C.): “a única coisa que existe é o ser - que é o mesmo que pensar”. O ser é imutável e imóvel, uno e contínuo, idêntico a si mesmo. Zenão, seu principal seguidor, justifica a tese do mestre negando a compreensão do movimento dada na época, com o famoso paradoxo da tartaruga e do Aquiles [33].

Os sofistas interpretam Parmênides concluindo a impossibilidade do discurso falso. Protágoras (V a.C): “o homem é a medida de todas as coisas”. Não existem falsidades ou verdades absolutas. Para os sofistas o homem deve buscar soluções para questões práticas. O critério do verdadeiro ou falso tem relação com questões teóricas e, por isso, deve ser substituído por padrões de melhor ou pior. A retórica é o caminho para se buscar tais padrões.

A maioria dos filósofos pré-socráticos – com exceção de Heráclito – acreditavam que havia algo eterno e imutável por detrás do vir-a-ser, e que esse eterno era a origem, a sustentação e o fim de todos os seres. Tales pensava que era a água; para Anaxímenes, o ar; Pitágoras pensava serem os números; Demócrito acreditava que eram os átomos e o vazio. Esse algo eterno e imutável que sustentava todas as coisas era chamado pelos gregos de *arché*.

A certeza e a incerteza foram amplamente debatidas pelos filósofos gregos. Os sofistas (de *sophistes*, sábios) ficaram conhecidos por ensinar a arte retórica. Protágoras, principal sofista juntamente com Górgias, ensinava a seus alunos como transformar argumentos fracos em fortes. A retórica expressa a postura que os sofistas têm diante do conhecimento, ou seja, um total ceticismo em relação a qualquer tipo de conhecimento absoluto, objetivo. Não interessa saber como as coisas são, pois tudo é relativo e depende de quem emite juízo a respeito delas. Górgias dizia que a retórica ultrapassa todas as outras artes, sendo a melhor, pois ela faz de todas as coisas suas escravas por submissão espontânea e não por

violência.

Como é sabido, Sócrates confrontava os sofistas de sua época, e a questão principal era formulada pela pergunta “o que é?” (Ti Estin).

Inicialmente Platão, seguidor de Sócrates, compartilhou com as ideias de Heráclito, principalmente a de que tudo está mudando, está no fluxo do vir-a-ser. Porém, se tudo estava em movimento não seria possível o conhecimento. Para não cair num ceticismo, Platão pensou no “mundo das ideias”. Em tal mundo não haveria mudanças, as coisas seriam eternas para além da dimensão espaço-temporal. O assim chamado “mundo sensível” seria o mundo do vir-a-ser, ou seja, o mundo percebido pelos cinco sentidos. O “mundo das ideias” seria o verdadeiro ser que estaria por detrás do vir-a-ser do “mundo sensível”. Porém, para Platão o mais importante não era um conceito final, mas o caminho para se chegar até ele. O “mundo das ideias” não é acessível pelos sentidos, apenas pela intuição intelectual e a *dialética* é o movimento de ascense em busca da verdade. Com isso Platão promove uma síntese de Heráclito e Parmênides.

Já para Aristóteles, não existe o mundo das ideias e as essências estão contidas nas próprias coisas. O conhecimento universal está vinculado à sua *Lógica* (de Lógos, o mesmo que razão, princípio de ordem, estudo das consequências) e ao *Silogismo*, mecanismo de dedução formal. A partir de certas premissas gerais, o conhecimento deve seguir uma ordem rigorosamente demonstrativa utilizando-se do silogismo.

De maneira resumida, e talvez ingênua, podemos pensar que a diferença fundamental entre Aristóteles e os sofistas, consiste no fato de que, para Aristóteles, existe uma verdade objetiva, eterna, imutável, que independe dos seres humanos, ao passo que para os sofistas não existe nenhuma verdade absoluta, eterna e imutável e, sim, apenas o conhecimento relativo aos nossos sentidos. Para Platão e Aristóteles, respectivamente, a *dialética* e o *silogismo* devem ser empregados em busca da verdade. Os sofistas adotam a *retórica*, que é a arte da persuasão,

como convencimento em busca do melhor e não para buscar a verdade, pois esta não existe de maneira absoluta.

Entendendo que a subjetividade, assim como a imprecisão, a incerteza, a vaguesa são inerentes a certos termos da linguagem, Górgias negou a verdade absoluta: *mesmo que algo existisse seria incompreensível ao homem; mesmo que fosse compreensível a um homem, não seria comunicável a outro*. No sentido de provocar reflexões a respeito deste aspecto de incerteza (da linguagem) vamos, através de um exemplo, tentar fazer uma conciliação, ainda que imatura, entre os sofistas e Platão–Aristóteles.

É comum propormos um encontro com outra pessoa, dizendo:

— Vamos nos encontrar às quatro horas.

Pois bem, o conceito abstrato, “quatro horas”, que indica uma medida, é uma necessidade para se estabelecer uma comunicação e possibilitar a realização do evento. Se assim não fosse, como deveríamos nos comunicar para marcar o encontro? (ponto para Platão). Por outro lado, se levarmos ao pé da letra, o encontro jamais seria realizado dado que os relógios não atingiriam, simultaneamente, quatro horas, ainda que estivessem sincronizados, dado que não conseguiríamos chegar ao lugar marcado com todas as precisões nas horas, minutos, segundos, milionésimos de segundos (ponto para Górgias). Admitindo que frequentemente nós nos encontramos para nossos compromissos no lugar marcado, parece que precisamos tanto das *verdades* abstratas quanto dos *padrões de melhor* para vivermos aqui neste mundo sensível.

Os pensamentos comentados acima são colocados no sentido de justificar a dificuldade de se falar a respeito de *certeza* ou *incerteza*. Se procurarmos num dicionário os sinônimos de *incerteza* vamos encontrar termos como, por exemplo, as palavras *subjetividade*, *imprecisão*, *aleatoriedade*, *dúvida*, *indecisão*, *ambiguidade*, *imprevisibilidade*.

Historicamente, e parece que sabiamente por parte dos pesquisadores, o que temos percebido no tratamento quantitativo é uma distinção dos

vários tipos de incertezas.

A incerteza proveniente da aleatoriedade de eventos está bem desenvolvida e hoje ocupa um lugar de destaque na galeria da Matemática. A Física Quântica tem se utilizado das teorias estocásticas e uma série de fórmulas procuram expressar “relações de incertezas”. Uma das mais difundidas e conhecidas é denominada “Princípio da Incerteza”, devida ao físico W. Heisenberg (1927), que relaciona a posição e a velocidade de uma partícula. Sucintamente, esse *Princípio da Incerteza* diz que não se pode conhecer com certeza, e ao mesmo tempo, a posição e a velocidade de uma partícula subatômica.

Diferentemente da aleatoriedade, certas variáveis utilizadas em nosso cotidiano, transmitidas e perfeitamente compreendidas linguisticamente entre interlocutores, têm invariavelmente permanecido fora do tratamento matemático tradicional. Este é o caso de variáveis linguísticas oriundas da necessidade de se distinguir qualificações por meio de gradações.

Para descrever certos fenômenos relacionados ao mundo sensível, temos utilizado graus que representam qualidades ou verdades parciais ou ainda padrões do melhor (na linguagem sofista). Esse é o caso, por exemplo, dos conceitos de *alto*, *fumante*, *infeccioso*, *presa etc.*

É precisamente neste tipo de incerteza que a Lógica Fuzzy tem dado suas principais contribuições. Usando uma linguagem conjuntista poderíamos nos referir, respectivamente, aos “conjuntos” das pessoas *altas*, *fumantes* ou *infecciosas*. Estes são exemplos típicos de “conjuntos” cujas fronteiras podem ser consideradas incertas, isto é, definidas por meio de propriedades subjetivas ou atributos imprecisos.

A seguir vamos nos fixar apenas no exemplo das pessoas *altas*. Uma proposta para formalizar matematicamente tal conjunto poderia ter pelo menos duas abordagens. A primeira (clássica), distinguindo a partir de que valor da altura um indivíduo é considerado *alto*. Nesse caso, o conjunto está bem definido. A segunda, menos convencional, é dada de

maneira que todos os indivíduos sejam considerados altos com mais ou menos intensidade, ou seja, existem elementos que pertenceriam mais à classe dos altos que outros. Isto significa que quanto menor for a medida da altura do indivíduo, menor será seu grau de pertinência a esta classe. Desse modo, podemos dizer que todos os indivíduos pertencem à classe das pessoas *altas*, com mais ou menos intensidade. Pois bem, é essa segunda abordagem que pretendemos discutir neste texto.

Foi a partir de desafios como esse, no qual a propriedade que define o conjunto é incerta, que surgiu a **Teoria dos Conjuntos Fuzzy**, que tem crescido consideravelmente em nossos dias, tanto do ponto de vista teórico como nas aplicações em diversas áreas de estudo, sobretudo em tecnologia.

A palavra “*fuzzy*”, de origem inglesa, significa incerto, vago, impreciso, subjetivo, nebuloso, difuso, etc. Porém, como pudemos apurar até agora, nenhuma dessas traduções é tão fiel ao sentido amplo dado pela palavra *fuzzy* em inglês. Além disso, temos observado que quase todos os países têm usado a palavra *fuzzy*, sem traduzi-la para sua língua pátria, com algumas exceções como na França, que traduziu-o por *nebule* ou em alguns países latinos onde o termo empregado é *borroso*. De nossa parte, achamos por bem conservar o termo *fuzzy* e não o traduzimos para o português.

A Teoria dos Conjuntos Fuzzy foi introduzida em 1965 pelo matemático Lotfi Asker Zadeh [129] com a principal intenção de dar um tratamento matemático a certos termos linguísticos subjetivos, como “*aproximadamente*”, “*em torno de*”, dentre outros. Esse seria um primeiro passo no sentido de se programar e armazenar conceitos vagos em computadores, tornando possível a produção de cálculos com informações imprecisas, a exemplo do que faz o ser humano. Por exemplo, todos nós somos unânimes em dizer que o dobro de uma quantidade “*em torno de 3*” resulta em outra “*em torno de 6*”.

Para obter a formalização matemática de um conjunto fuzzy, Zadeh

baseou-se no fato de que qualquer conjunto clássico pode ser caracterizado por uma função: sua *função característica*, cuja definição é dada a seguir.

Definição 1.1. Seja U um conjunto e A um subconjunto de U . A *função característica* de A é dada por

$$\chi_A(x) = \begin{cases} 1 & \text{se } x \in A \\ 0 & \text{se } x \notin A \end{cases}.$$

Desta forma, χ_A é uma função cujo domínio é U e a imagem está contida no conjunto $\{0, 1\}$, com $\chi_A(x) = 1$ indicando que o elemento x está em A , enquanto $\chi_A(x) = 0$ indica que x não é elemento de A . Assim, a função característica descreve completamente o conjunto A já que tal função indica quais elementos do conjunto universo U são elementos também de A . Entretanto, existem casos em que a pertinência entre elementos e conjuntos não é precisa, isto é, não sabemos dizer se um elemento pertence efetivamente a um conjunto ou não. O que é plausível é dizer qual elemento do conjunto universo se enquadra “melhor” ao termo que caracteriza o subconjunto. Por exemplo, consideremos o subconjunto dos números reais “*próximos de 2*”.

$$A = \{x \in \mathbb{R} : x \text{ é próximo de } 2\}.$$

Pergunta: O número 7 e o número 2,001 pertencem a A ?

A resposta a esta pergunta é incerta pois não sabemos até que ponto podemos dizer objetivamente quando um número está próximo de 2. A única afirmação razoável, neste caso, é que 2,001 está mais próximo de 2 do que 7.

A seguir vamos iniciar as formalizações matemáticas dos conceitos de Lógica Fuzzy que serão tratados neste texto, começando com o de subconjunto fuzzy.

1.2 Subconjuntos Fuzzy

Permitindo uma espécie de “relaxamento” no conjunto imagem da função característica de um conjunto foi que Zadeh sugeriu a formalização matemática de imprecisões, como a citada acima, usando os subconjuntos fuzzy.

Definição 1.2. Seja U um conjunto (clássico); um *subconjunto fuzzy* F de U é caracterizado por uma função

$$\varphi_F : U \longrightarrow [0, 1],$$

pré-fixada, chamada *função de pertinência* do subconjunto fuzzy F . O índice F na função de pertinência é usado em analogia à função característica de subconjunto clássico, conforme Definição 1.1.

O valor $\varphi_F(x) \in [0, 1]$ indica o grau com que o elemento x de U está no conjunto fuzzy F ; $\varphi_F(x) = 0$ e $\varphi_F(x) = 1$ indicam, respectivamente, a não pertinência e a pertinência completa de x ao conjunto fuzzy F .

Do ponto de vista formal, a definição de subconjunto fuzzy foi obtida simplesmente ampliando-se o contra-domínio da função característica, que é o conjunto $\{0, 1\}$, para o intervalo $[0, 1]$. Nesse sentido, podemos dizer que um conjunto clássico é um caso particular de um dado conjunto fuzzy, cuja função de pertinência φ_F é sua função característica χ_F . Um subconjunto clássico, na linguagem fuzzy, costuma ser denominado por *subconjunto crisp*.

Um subconjunto fuzzy F é composto de elementos x de um conjunto clássico U , providos de um valor de pertinência a F , dado por $\varphi_F(x)$. Podemos dizer que um subconjunto fuzzy F de U é dado por um conjunto (clássico) de pares ordenados:

$$F = \{(x, \varphi_F(x)) \mid x \in U\}.$$

O subconjunto clássico de U definido por

$$\text{supp } F = \{x \in U : \varphi_F(x) > 0\}$$

é denominado suporte de F e tem papel fundamental na interrelação entre as teorias de conjuntos clássica e fuzzy.

É interessante notar que, diferentemente do subconjunto fuzzy, o suporte de um subconjunto crisp coincide com o próprio conjunto. As Figuras 1.1(a) e 1.1(b) ilustram esse fato.




Figura 1.1: Ilustração de Subconjuntos Fuzzy e Crisp.

Na literatura é comum denotar a função de pertinência φ_F do subconjunto fuzzy F simplesmente por F . Optamos, neste texto, por distinguir F de φ_F .

Na teoria clássica, sempre que nos referimos a um determinado conjunto A estamos considerando, na verdade, um subconjunto de algum conjunto universo U mas, por simplicidade ou comodismo, dizemos *conjunto* A mesmo sendo A um *subconjunto*. No caso fuzzy o mesmo acontece com o uso destes nomes e, neste texto usaremos indistintamente ambos os termos.

A seguir serão apresentados alguns exemplos de conjuntos fuzzy.

Exemplo 1.1 (Números pares). Considere o conjunto dos números natu-

rais pares:

$$P = \{n \in \mathbb{N}^* : n \text{ é par}\}.$$

O conjunto P tem função característica $\chi_P(n) = 1$ se n é par e $\chi_P(n) = 0$ se n é ímpar. Portanto, o conjunto dos números pares é um particular conjunto fuzzy já que $\chi_P(n) \in [0, 1]$. Neste caso foi possível descrever todos os elementos de P a partir da função característica porque todo número natural ou é par ou é ímpar. O mesmo não pode ser dito para outros conjuntos com fronteiras imprecisas.

Exemplo 1.2 (Números próximos de 2). Considere o subconjunto F dos números reais *próximos de 2*:

$$F = \{x \in \mathbb{R} : x \text{ é próximo de } 2\}.$$

Se definirmos a função $\varphi_F : \mathbb{R} \rightarrow [0, 1]$, que associa cada x real ao valor de proximidade ao ponto 2 pela expressão

$$\varphi_F(x) = \begin{cases} (1 - |x - 2|) & \text{se } 1 \leq x \leq 3 \\ 0 & \text{se } x \notin [1, 3] \end{cases},$$

então o subconjunto fuzzy F dos pontos *próximos de 2*, caracterizado por φ_F , é tal que $\varphi_F(2,001) = 0,999$ e $\varphi_F(7) = 0$. Neste caso, dizemos que $x = 2,001$ é um ponto próximo de 2 com grau de proximidade 0,999, e $x = 7$ não é próximo de 2.

Por outro lado, alguém poderia sugerir outra função de proximidade a 2. Por exemplo, se a função de proximidade a 2 fosse definida por

$$\nu_F(x) = \exp \left[-(x - 2)^2 \right],$$

com $x \in \mathbb{R}$, então os elementos do conjunto fuzzy F , caracterizado pela função ν_F , teriam outros graus de pertinência: $\nu_F(2,001) = 0,999999$ e $\nu_F(7) = 1,388 \times 10^{-11}$.

Como podemos ver, a caracterização de proximidade é subjetiva e

depende da função de pertinência que pode ser dada por uma infinidade de maneiras diferentes, dependendo de como se quer avaliar o termo “próximo”. Observe que poderíamos também definir *próximo de 2* por um conjunto clássico com função de pertinência $\varphi_{\varepsilon F}$, considerando, por exemplo, um valor de ε suficientemente pequeno e a função característica do intervalo $(2 - \varepsilon, 2 + \varepsilon)$, conforme a expressão abaixo

$$\varphi_{\varepsilon F}(x) = \begin{cases} 1 & \text{se } |x - 2| < \varepsilon \\ 0 & \text{se } |x - 2| \geq \varepsilon \end{cases}.$$

Note que, ser *próximo de 2* significa estar numa vizinhança pré determinada de 2. A subjetividade está exatamente na escolha do raio da vizinhança. Especificamente, neste caso todos os valores desta vizinhança estão próximos de 2 com o mesmo grau de pertinência que é 1.

Exemplo 1.3 (Números naturais pequenos). Considere o subconjunto fuzzy F dos *números naturais pequenos*

$$F = \{n \in N : n \text{ é pequeno}\}.$$

O número 0 (zero) pertence a esse conjunto? E o número 1000? No espírito da lógica fuzzy poderíamos dizer que ambos pertencem a F , porém com diferentes graus, dependendo da função de pertinência φ_F que caracteriza o subconjunto fuzzy F . A função de pertinência associada a F deve ser “construída” de forma coerente com o termo “*pequeno*”. Uma possibilidade para a função de pertinência de F é

$$\varphi_F(n) = \frac{1}{n + 1}.$$

Logo, poderíamos dizer que o número 0 pertence a F com grau de pertinência $\varphi_F(0) = 1$, enquanto que 1000 pertence a F com grau de pertinência $\varphi_F(1000) = 0,001$.

Claro que a escolha da função φ_F neste caso foi feita de maneira totalmente arbitrária, levando-se em conta apenas o significado da palavra “pequeno”. Para modelar matematicamente o conceito de “*número natural pequeno*”, isto é, associar ao subconjunto fuzzy F uma função de pertinência, poderíamos escolher qualquer sequência monótona decrescente, começando em 1 (*um*) e convergente para 0 (*zero*):

$$\{\mu_n\}_{n \in \mathbb{N}}, \text{ com } \mu_0 = 1.$$

Por exemplo,

$$\begin{aligned} \mu_F(n) &= e^{-n}; \\ \mu_F(n) &= \frac{1}{n^2 + 1}; \\ \mu_F(n) &= \frac{1}{\ln(n + e)}. \end{aligned}$$

Claro que a função a ser adotada, para representar o conjunto fuzzy em questão, depende de fatores que estão relacionados com o contexto do problema a ser estudado. Do ponto de vista estrito da lógica fuzzy, qualquer uma das funções de pertinência anteriores pode representar o conceito subjetivo em questão. Porém, o que deve ser notado é que cada uma destas funções produz conjuntos fuzzy distintos.

Nos exemplos ilustrados acima, o conjunto universo U de cada conjunto fuzzy está claramente especificado. No entanto, nem sempre é este o caso. Em boa parte dos casos interessantes em modelagem é preciso decidir qual conjunto universo, ou mesmo qual suporte deve ser considerado. Para esclarecer melhor vejamos alguns exemplos.

Exemplo 1.4 (Conjunto fuzzy dos jovens). Consideremos os habitantes de uma determinada cidade. A cada indivíduo desta população podemos associar um número real correspondente à sua idade. Considere o conjunto universo das idades o intervalo $U = [0, 120]$, onde $x \in U$ é

interpretado como a idade de um indivíduo. Um subconjunto fuzzy J , de U , dos *jovens* desta cidade poderia ser caracterizado pelas seguintes funções de pertinência

$$\varphi_J(x) = \begin{cases} 1 & \text{se } x \leq 10 \\ \frac{80-x}{70} & \text{se } 10 < x \leq 80 \\ 0 & \text{se } x > 80 \end{cases}$$

ou

$$\varphi_J(x) = \begin{cases} \left(\frac{40-x}{40}\right)^2 & \text{se } 0 \leq x \leq 40 \\ 0 & \text{se } 40 < x \leq 120 \end{cases}.$$

A escolha de qual função adotar para representar o conceito de *jovem* depende muito do modelador e/ou do contexto analisado.

Observe que a adoção de $U = [0, 120]$ está ligada ao fato de termos escolhido a idade para indicar o quanto um indivíduo é jovem. Se fosse adotada outra característica como o número de cabelos grisalhos, ou o número de filhos, ou de netos para indicar o grau de jovialidade, o conjunto universo seria outro.

O exemplo a seguir ilustra um pouco mais a força da teoria dos conjuntos fuzzy na modelagem matemática de conceitos incertos. Neste exemplo apresentaremos um tratamento matemático que possibilita quantificar e explorar um termo de grande interesse social: *pobreza*. Tal conceito poderia ser modelado baseando-se em muitas variáveis: consumo de calorias, consumo de vitaminas, de ferro, no volume de lixo produzido ou mesmo na renda de cada indivíduo, dentre tantas outras características disponíveis. Entretanto, optamos por definir pobreza supondo que a única variável disponível seja a renda. Um modelo matemático possível para o conceito de *pobreza* é apresentado a seguir.

Exemplo 1.5 (Conjunto fuzzy dos pobres). Considerando que o conceito de pobre seja baseado no nível de renda r , é razoável supor que quanto

menor for a renda, maior é a pobreza de um indivíduo. Assim, o subconjunto fuzzy A_k dos *pobres* de uma determinada localidade pode ser dado pela função de pertinência:

$$\varphi_{A_k}(r) = \begin{cases} \left\{ 1 - \left[\left(\frac{r}{r_0} \right)^2 \right] \right\}^k & \text{se } r \leq r_0 \\ 0 & \text{se } r > r_0 \end{cases}.$$




Figura 1.2: Função de pertinência do subconjunto fuzzy dos pobres A_k .

O parâmetro k indica alguma característica do grupo estudado como por exemplo o ambiente destes indivíduos. O parâmetro r_0 é um valor de renda a partir do qual acredita-se não haver mais interferência no fenômeno estudado.

Como ilustrado na Figura 1.2 temos que: se $k_1 \geq k_2$ então $\varphi_{A_{k_1}}(\bar{r}) \leq \varphi_{A_{k_2}}(\bar{r})$, o que quer dizer que um indivíduo do grupo k_1 , com nível de renda $\bar{r}$, seria mais pobre se, com esta mesma renda, estivesse no grupo k_2 . Podemos dizer ainda que, quanto à renda, é mais fácil viver nas localidades de maior k . Portanto, intuitivamente, k indica se o ambiente em que o grupo vive é mais ou menos favorável à vida. O parâmetro k pode dar uma ideia do grau de “saturação” do ambiente e, por isso, pode ser chamado de *parâmetro ambiental*.

1.3 Operações com subconjuntos fuzzy

Nesta seção estudaremos as operações típicas de conjuntos como união, intersecção e complementação.

Sejam A e B dois subconjuntos fuzzy de U , com funções de pertinência indicadas por φ_A e φ_B , respectivamente.

Dizemos que A é subconjunto fuzzy de B , e escrevemos $A \subset B$, se $\varphi_A(x) \leq \varphi_B(x)$ para todo $x \in U$.

Lembramos que a função de pertinência do conjunto vazio ($\emptyset$) é dada por $\varphi_{\emptyset}(x) = 0$, enquanto que o conjunto universo (U) tem função de pertinência $\varphi_U(x) = 1$, para todo $x \in U$. Assim, podemos dizer que $\emptyset \subset A$ e que $A \subset U$ para todo A .

Definição 1.3 (União). A *união* entre A e B é o subconjunto fuzzy de U cuja função de pertinência é dada por

$$\varphi_{(A \cup B)}(x) = \max\{\varphi_A(x), \varphi_B(x)\}, \quad x \in U.$$

Observamos que esta definição é uma extensão do caso clássico. De fato, quando A e B são subconjuntos clássicos de U temos:

$$\begin{aligned} \max\{\chi_A(x), \chi_B(x)\} &= \begin{cases} 1 & \text{se } x \in A \text{ ou } x \in B \\ 0 & \text{se } x \notin A \text{ e } x \notin B \end{cases} \\ &= \begin{cases} 1 & \text{se } x \in A \cup B \\ 0 & \text{se } x \notin A \cup B \end{cases} \\ &= \chi_{A \cup B}(x), \quad x \in U. \end{aligned}$$

Definição 1.4 (Intersecção). A *intersecção* entre A e B é o subconjunto fuzzy de U cuja função de pertinência é dada por

$$\varphi_{(A \cap B)}(x) = \min\{\varphi_A(x), \varphi_B(x)\}, \quad x \in U.$$

Definição 1.5 (Complementar de subconjuntos fuzzy). O *complementar* de A é o subconjunto fuzzy A' de U cuja função de pertinência é dada por

$$\varphi_{A'}(x) = 1 - \varphi_A(x), \quad x \in U.$$




Figura 1.3: Operações com subconjuntos fuzzy: (a) união; (b) intersecção; (c) complemento.

Exercício 1.1. Suponha que A e B sejam subconjuntos clássicos de U .

- (a) Verifique que $\min\{\chi_A(x), \chi_B(x)\} = \begin{cases} 1 & \text{se } x \in A \cap B \\ 0 & \text{se } x \notin A \cap B \end{cases}$.
- (b) Verifique que $\chi_{A \cap B}(x) = \chi_A(x)\chi_B(x)$. Note que essa identidade não é válida se A e B forem subconjuntos fuzzy.
- (c) Verifique que $\chi_{A \cap A'}(x) = 0$ ($A \cap A' = \emptyset$) e que $\chi_{A \cup A'}(x) = 1$ ($A \cup A' = U$), para todo $x \in U$.

Diferentemente da situação clássica, no contexto fuzzy (Figura 1.3 e Exemplo 1.7) podemos ter

- $\varphi_{A \cap A'}(x) \neq 0 = \varphi_{\emptyset}(x)$ ou seja $A \cap A' \neq \emptyset$;

- $\varphi_{A \cup A'}(x) \neq 1 = \varphi_U(x)$ ou seja $A \cup A' \neq U$.

No exemplo a seguir pretendemos explorar as particularidades apresentadas no complemento de um conjunto fuzzy.

Exemplo 1.6 (Conjunto fuzzy dos idosos). O conjunto fuzzy I dos *idosos* deve refletir uma situação oposta da relacionada com o conjunto dos *jovens* quando consideramos a idade dos seus elementos. Enquanto que para o conjunto de *jovens* a função de pertinência deve ser decrescente com a idade, para *idosos* deve ser crescente. Uma possibilidade para a função de pertinência de I é

$$\varphi_I(x) = 1 - \varphi_J(x),$$

onde φ_J é a função de pertinência do subconjunto fuzzy dos “jovens”. Desta forma, o conjunto fuzzy I é o complementar fuzzy de J . Nesse exemplo, se adotarmos para os jovens a função de pertinência dada no Exemplo 1.4a, então

$$\varphi_I(x) = 1 - \varphi_J(x) = \begin{cases} 0 & \text{se } x \leq 10 \\ \frac{x-10}{70} & \text{se } 10 < x \leq 80 \\ 1 & \text{se } x > 80 \end{cases}.$$

Uma representação gráfica para I e J é dada na Figura 1.4.




Figura 1.4: Subconjunto fuzzy dos jovens e dos idosos.

Note que esta operação de complemento permuta os graus de pertinência dos subconjunto fuzzy I e J . Esta é a propriedade que caracteriza o complementar fuzzy, isto é, enquanto $\varphi_A(x)$ indica o grau de compatibilidade de x com o conceito linguístico em questão, $\varphi_{A'}(x)$ expressa a incompatibilidade de x com tal conceito.

Uma consequência da imprecisão dos conjuntos fuzzy é que há uma sobreposição do conjunto e seu complemento fuzzy. No Exemplo 1.6, um indivíduo que pertence ao conjunto fuzzy dos *jovens* J com grau 0,8, pertence também ao seu complementar I com grau 0,2.

Observe ainda que um elemento pode pertencer a um conjunto e ao seu complementar com o mesmo grau de pertinência (na Figura 1.4 esse valor é 45), indicando que quanto mais dúvida se tem da pertinência de um elemento a um conjunto, mais próximo de 0,5 é seu grau de pertinência a este conjunto. Esta é uma grande diferença da teoria clássica de conjuntos, na qual um elemento, excludentemente, ou pertence a um conjunto ou ao seu complementar.

Convém salientar que podemos definir *jovens* e *idosos*, termos linguísticos reconhecidamente de significados opostos, por meio de conjuntos fuzzy que não são necessariamente complementares.

Por exemplo, poderíamos ter

$$\varphi_J(x) = \begin{cases} \left(\frac{40-x}{40}\right)^2 & \text{se } 0 \leq x \leq 40 \\ 0 & \text{se } 40 < x \leq 120 \end{cases}$$

e

$$\varphi_I(x) = \begin{cases} \left(\frac{x-40}{80}\right)^2 & \text{se } 40 < x \leq 120 \\ 0 & \text{se } x \leq 40 \end{cases}.$$

Exercício 1.2. Considere que o conjunto fuzzy dos *jovens* seja dado por

$$\varphi_J(x) = \begin{cases} \left[1 - \left(\frac{x}{120}\right)^2\right]^4 & \text{se } x \in [10, 120] \\ 0 & \text{se } x \notin [10, 120] \end{cases}$$

- (a) Defina um conjunto fuzzy dos *idosos*.
- (b) Determine a idade de um indivíduo de “meia idade”, isto é, grau 0,5 tanto de jovialidade como de velhice, supondo que o conjunto fuzzy dos *idosos* seja o complemento fuzzy dos *jovens*.
- (c) Esboce os gráficos dos *jovens* e *idosos* do item anterior e compare com o Exemplo 1.6.

A seguir vamos estender o conceito de complemento para $A \subseteq B$, em que A é subconjunto fuzzy de B , ambos com universo U . Nesse caso, o complemento de A em B é o subconjunto fuzzy A'_B , cuja função de pertinência é

$$\varphi_{A'_B}(x) = \varphi_B(x) - \varphi_A(x), \quad x \in U.$$

Note que o complementar de A em U é um caso particular do complementar de A em B , já que $\varphi_U(x) = 1$.

No exemplo a seguir procuramos explorar um pouco mais o conceito de complemento fuzzy com os subconjuntos definidos no Exemplo 1.5.

Exemplo 1.7 (Conjunto fuzzy dos pobres). Se o ambiente em que um grupo vive sofrer alguma degradação, pelo que vimos no Exemplo 1.5, isto implicará na diminuição do parâmetro ambiental, passando de k_1 para um valor menor k_2 , de tal modo que um indivíduo que tenha renda r em k_1 tem grau de pobreza $\varphi_{A_{k_1}}(r)$ inferior à de outro $\varphi_{A_{k_2}}(r)$ com mesma renda em k_2 .

$$\varphi_{A_{k_1}}(r) < \varphi_{A_{k_2}}(r) \iff A_{k_1} \subset A_{k_2}.$$

Tal dano pode levar a condição de *pobre* para *paupérrimo*, representado por A_{k_2} .

O complemento fuzzy de A_{k_1} em A_{k_2} é o subconjunto fuzzy dado por

$$(A'_{k_1})_{A_{k_2}}$$

(não vazio), cuja função de pertinência é

$$\varphi_{(A'_{k_1})_{A_{k_2}}} = \varphi_{A_{k_2}}(r) - \varphi_{A_{k_1}}(r), \quad r \in U.$$

Uma recompensa honesta, ao grupo que sofreu tal dano, deve devolver o mesmo *status* de pobre que antes, ou seja, dada uma renda r_1 , o grupo deve ter uma renda r_2 (após o dano) de modo que

$$\varphi_{A_{k_2}}(r_2) - \varphi_{A_{k_1}}(r_1) = 0.$$

Portanto, $r_2 - r_1 > 0$ e a recompensa deve ser $r_2 - r_1$ (ver Figura 1.5).




Figura 1.5: Recompensa por mudança de ambiente.

Faremos a seguir alguns comentários e consequências importantes das operações entre conjuntos fuzzy.

Se A e B forem conjuntos clássicos, então as funções características das respectivas operações também satisfazem as definições dadas no caso

fuzzy, mostrando coerência entre tais conceitos.

Por exemplo, se A é um subconjunto (clássico) de U , então a função característica $\chi_{A'}(x)$ do seu complementar é tal que

$$\begin{aligned}\chi_{A'}(x) &= 0 \text{ se } \chi_A(x) = 1 \iff x \in A; \\ \chi_{A'}(x) &= 1 \text{ se } \chi_A(x) = 0 \iff x \notin A.\end{aligned}$$

Neste caso, ou $x \in A$ ou $x \notin A$ enquanto que na teoria dos conjuntos fuzzy não temos necessariamente essa dicotomia. Como vimos no Exemplo ??, nem sempre é verdade que $A \cap A' = \emptyset$, assim como pode não ser verdade que $A \cup A' = U$. O exemplo a seguir reforça tais fatos.

Exemplo 1.8 (Conjuntos fuzzy dos febris e/ou com mialgia). Suponha que o conjunto universo U seja composto pelos pacientes de uma clínica, identificados pelos números 1, 2, 3, 4 e 5. Sejam A e B os subconjuntos fuzzy que representam os pacientes com febre e mialgia¹, respectivamente. A Tabela 1.1 abaixo ilustra as operações união, intersecção e complemento.

Paciente	Febre: A	Mialgia: B	$A \cup B$	$A \cap B$	A'	$A \cap A'$	$A \cup A'$
1	0,7	0,6	0,7	0,6	0,3	0,3	0,7
2	1,0	1,0	1,0	1,0	0,0	0,0	1,0
3	0,4	0,2	0,4	0,2	0,6	0,4	0,6
4	0,5	0,5	0,5	0,5	0,5	0,5	0,5
5	1,0	0,2	1,0	0,2	0,0	0,0	1,0

Tabela 1.1: Ilustração das operações entre subconjuntos fuzzy

Os valores das colunas, exceto os da primeira, indicam os graus com que cada paciente pertence aos conjuntos fuzzy $A, B, A \cup B, A \cap B, A', A \cap A', A \cup A'$, respectivamente, onde A e B são supostamente dados. Na coluna $A \cap A'$, o valor 0,3 indica que o paciente 1 está tanto no grupo dos febris como no dos não febris. Como dissemos antes, este é um fato inadmissível na teoria clássica de conjuntos na qual tem-se a lei

¹Dor muscular.

do terceiro excluído, isto é, $A \cap A' = \emptyset$.

Definição 1.6. Os subconjuntos fuzzy A e B de U são *iguais* se suas funções de pertinência coincidem, isto é, se $\varphi_A(x) = \varphi_B(x)$ para todo $x \in U$.

Listaremos a seguir as principais propriedades das operações definidas nessa seção.

Proposição 1.1. *As operações entre subconjuntos fuzzy satisfazem as seguintes propriedades:*

- $A \cup B = B \cup A$
- $A \cap B = B \cap A$
- $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
- $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- $A \cup A = A$
- $A \cap A = A$
- $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
- $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- $A \cap \emptyset = \emptyset$ e $A \cup \emptyset = A$
- $A \cap U = A$ e $A \cup U = U$
- $(A \cup B)' = A' \cap B'$ e $(A \cap B)' = A' \cup B'$ (leis de DeMorgan).

Demonstração. A demonstração de cada propriedade é uma aplicação imediata das propriedades de máximo e mínimo entre funções, isto é,

$$\begin{aligned} \max[\varphi(x), \psi(x)] &= \frac{1}{2} [\varphi(x) + \psi(x) + |\varphi(x) - \psi(x)|] \\ \min[\varphi(x), \psi(x)] &= \frac{1}{2} [\varphi(x) + \psi(x) - |\varphi(x) - \psi(x)|] \end{aligned}$$

onde, φ e ψ são funções com imagens em $\mathbb{R}$.

Vamos demonstrar apenas uma das leis de DeMorgan, as outras propriedades são demonstradas de maneira análoga.

Seja φ_A a função de pertinência associada ao subconjunto A . Temos:

$$\begin{aligned}
 \varphi_{A' \cup B'}(u) &= \max[1 - \varphi_A(u), 1 - \varphi_B(u)] \\
 &= \frac{1}{2}[(1 - \varphi_A(u)) + (1 - \varphi_B(u)) + |\varphi_A(u) - \varphi_B(u)|] \\
 &= \frac{1}{2}[2 - (\varphi_A(u) + \varphi_B(u) - |\varphi_A(u) - \varphi_B(u)|)] \\
 &= 1 - \frac{1}{2}[\varphi_A(u) + \varphi_B(u) - |\varphi_A(u) - \varphi_B(u)|] \\
 &= 1 - \min[\varphi_A(u), \varphi_B(u)] = 1 - \varphi_{A \cap B}(u) = \varphi_{(A \cap B)'}(u),
 \end{aligned}$$

para todo $u \in U$. ■

Exercício 1.3. Considere o subconjunto fuzzy das *peças altas* (em metros) do Brasil, definido por

$$\varphi_A(x) = \begin{cases} 0 & \text{se } x \leq 1,4 \\ \frac{1}{0,4}(x - 1,4) & \text{se } 1,4 < x \leq 1,8 \\ 1 & \text{se } x > 1,8 \end{cases}$$

e das peças de estatura mediana por

$$\varphi_B(x) = \begin{cases} 0 & \text{se } x \leq 1,4 \\ \frac{1}{0,2}(x - 1,4) & \text{se } 1,4 < x \leq 1,6 \\ 1 & \text{se } 1,6 < x \leq 1,7 \\ \frac{1}{0,1}(1,8 - x) & \text{se } 1,7 < x \leq 1,8 \\ 0 & \text{se } x > 1,8 \end{cases}$$

onde x é a altura em metros.

Obtenha $(A \cup B)'$ e $A' \cup B'$ e dê uma interpretação para estas operações.

Para finalizar este capítulo estudaremos uma classe especial de conjuntos crisps que está estreitamente relacionada com cada subconjunto fuzzy. Tais conjuntos crisps indicam limites das incertezas representa-

das por cada conjunto fuzzy.

1.4 O conceito de α -nível

Um subconjunto fuzzy A de U é “formado” por elementos de U com uma certa hierarquia (ordem) que é traduzida através da classificação por graus. Um elemento x de U está em uma classe se seu grau de pertinência é maior que um determinado valor limiar ou nível $\alpha \in [0, 1]$ que define aquela classe. O conjunto clássico de tais elementos é um α -nível de A , denotado por $[A]^\alpha$.

Definição 1.7 (α -nível). Seja A um subconjunto fuzzy de U e $\alpha \in [0, 1]$. O α -nível de A é o subconjunto clássico de U definido por

$$[A]^\alpha = \{x \in U : \varphi_A(x) \geq \alpha\} \text{ para } 0 < \alpha \leq 1.$$


O nível zero de um subconjunto fuzzy A é definido como sendo o menor subconjunto (clássico) fechado de U que contém o conjunto suporte de A . Numa linguagem matemática, $[A]^0$ é o fecho do suporte de A e é indicado por $\overline{\text{supp}} A$. Esta consideração torna-se imprescindível para atender certas situações teóricas que irão aparecer neste texto. Note que o conjunto $\{x \in U : \varphi_A(x) \geq 0\} = U$ não é necessariamente igual a $[A]^0 = \overline{\text{supp}} A$.

Exemplo 1.9. Seja $U = \mathbb{R}$ o conjunto dos números reais, e A um subconjunto fuzzy de $\mathbb{R}$ com a seguinte função de pertinência

$$\varphi_A(x) = \begin{cases} x - 1 & \text{se } 1 \leq x \leq 2 \\ 3 - x & \text{se } 2 < x < 3 \\ 0 & \text{se } x \notin [1, 3) \end{cases}.$$


Nesse caso, temos:

$$[A]^\alpha = [\alpha + 1, 3 - \alpha] \text{ para } 0 < \alpha \leq 1 \quad \text{e} \quad [A]^0 = \overline{]1, 3[} = [1, 3].$$

Figura 1.6: α -níveis: $[A]^\alpha$ e $[A]^0 \neq U$

Exemplo 1.10. Sejam $U = [0, 1]$ e A o subconjunto fuzzy de U cuja função de pertinência é dada por $\varphi_A(x) = 4(x - x^2)$. Então,

$$[A]^\alpha = \left[\frac{1}{2}(1 - \sqrt{1 - \alpha}), \frac{1}{2}(1 + \sqrt{1 - \alpha}) \right] \text{ para todo } \alpha \in [0, 1].$$

Figura 1.7: α -níveis: $[A]^\alpha$ e $[A]^0 = U$

Observamos que se x é um elemento de $[A]^\alpha$, então x pertence ao conjunto fuzzy A com, no mínimo, grau α . Temos também que

$$\text{se } \alpha \leq \beta \text{ então } [A]^\beta \subset [A]^\alpha.$$

O teorema seguinte mostra que a família de conjuntos clássicos $[A]^\alpha$ determina completamente o conjunto fuzzy A . Aqui também se utiliza a Definição 1.6.

Teorema 1.2. *Sejam A e B subconjuntos fuzzy de U . Uma condição necessária e suficiente para que $A = B$ é que $[A]^\alpha = [B]^\alpha$, para todo $\alpha \in [0, 1]$.*

Demonstração. É claro que $A = B \Rightarrow [A]^\alpha = [B]^\alpha$ para todo $\alpha \in [0, 1]$. Suponhamos agora que $[A]^\alpha = [B]^\alpha$ para todo $\alpha \in [0, 1]$. Se $A \neq B$ então existe $x \in U$ tal que $\varphi_A(x) \neq \varphi_B(x)$. Logo, temos que $\varphi_A(x) < \varphi_B(x)$ ou $\varphi_A(x) > \varphi_B(x)$. Supondo $\varphi_A(x) > \varphi_B(x)$, podemos concluir que $x \in [A]^{\varphi_A(x)}$ e $x \notin [B]^{\varphi_A(x)}$ e, portanto, $[A]^{\varphi_A(x)} \neq [B]^{\varphi_A(x)}$, o que contradiz a hipótese $[A]^\alpha = [B]^\alpha$ para todo $\alpha \in [0, 1]$. De maneira análoga chegamos a uma contradição se admitirmos que $\varphi_A(x) < \varphi_B(x)$. ■

Uma consequência deste teorema é a relação existente entre a função de pertinência de um subconjunto fuzzy e as funções características de seus α -níveis.

Corolário 1.3. *A função de pertinência φ_A de um conjunto fuzzy A pode ser expressa em termos de funções características de seus α -níveis, isto é,*

$$\varphi_A(x) = \sup_{\alpha \in [0,1]} \min[\alpha, \chi_{[A]^\alpha}(x)], \text{ onde } \chi_{[A]^\alpha}(x) = \begin{cases} 1 & \text{se } x \in [A]^\alpha \\ 0 & \text{se } x \notin [A]^\alpha \end{cases}.$$

O teorema a seguir é de extrema importância no estudo da teoria dos conjuntos fuzzy e indica uma condição suficiente para que uma família de subconjuntos clássicos de U seja formada por α -níveis de um subconjunto fuzzy de U .

Teorema 1.4 (Teorema de Representação de Negoita e Ralescu). *Seja A_α , $\alpha \in [0, 1]$, uma família de subconjuntos clássicos de U de modo que se verifiquem*

$$(i) \bigcup A_\alpha \subset A_0 \text{ com } \alpha \in [0, 1];$$

- (ii) $A_\alpha \subset A_\beta$ se $\beta \leq \alpha$;
- (iii) $A_\alpha = \bigcap_{k \geq 0} A_{\alpha_k}$ se α_k convergir para α com $\alpha_k \leq \alpha$.

Nestas condições existe um único subconjunto fuzzy A de U cujos α -níveis são exatamente os subconjuntos clássicos A_α , isto é,

$$[A]^\alpha = A_\alpha.$$

Demonstração. A ideia da demonstração é construir, para cada $x \in U$, a função de pertinência de A como sendo

$$\varphi_A(x) = \sup\{\alpha \in [0, 1] : x \in A_\alpha\}.$$

Para uma prova completa ver Negoita e Ralescu [92]. ■

Usando a definição de α -nível podemos elencar as seguintes propriedades:

$$\begin{aligned} [A \cup B]^\alpha &= [A]^\alpha \cup [B]^\alpha, \\ [A \cap B]^\alpha &= [A]^\alpha \cap [B]^\alpha. \end{aligned}$$

Por outro lado, como em geral $[A]^\alpha \cup [A']^\alpha \neq U$, então $[A']^\alpha \neq ([A]^\alpha)'$.

Definição 1.8. Um subconjunto fuzzy é dito *normal* se todos seus α -níveis forem não vazios, ou seja, se $[A]^1 \neq \emptyset$.

Lembrando que o suporte do subconjunto fuzzy A é o conjunto clássico

$$\text{supp } A = \{x \in U : \varphi_A(x) > 0\},$$

é comum descrever A com a seguinte notação

$$A = \varphi_A(x_1)/x_1 + \varphi_A(x_2)/x_2 + \dots = \sum_{i=1}^{\infty} \varphi_A(x_i)/x_i,$$

quando o subconjunto fuzzy A tem suporte enumerável, e

$$A = \varphi_A(x_1)/x_1 + \varphi_A(x_2)/x_2 + \cdots + \varphi_A(x_n)/x_n = \sum_{i=1}^n \varphi_A(x_i)/x_i,$$

se A tem suporte finito, isto é, $\text{supp } A = \{x_1, x_2, \dots, x_n\}$.

Vale observar que a notação $\varphi_A(x_i)/x_i$ não indica “divisão”. É apenas uma forma de visualizar um elemento x_i e seu respectivo grau de pertinência $\varphi_A(x_i)$. Também, aqui, o símbolo “+” na notação não significa “adição”, bem como $\sum$ não significa somatório. É apenas uma forma de conectar os elemento de U que estão em A com seus respectivos graus.

Exemplo 1.11 (Conjunto fuzzy finito). Seja A o subconjunto fuzzy dos reais representado por

$$A = \sum_{i=1}^n \varphi_A(x_i)/x_i = 0,1/1 + 0,2/2 + 0,25/3 + 0,7/5 + 0,9/8 + 1/10.$$

Então,

$$A' = \sum_{i=1}^n [1 - \varphi_A(x_i)]/x_i = 0,9/1 + 0,8/2 + 0,75/3 + 0,3/5 + 0,1/8 + 0/10.$$

Neste caso, temos, por exemplo, que o 0,15-nível de A e de seu complementar A' são, respectivamente,

$$[A]^{0,15} = \{2, 3, 5, 8, 10\} \quad \text{e} \quad [A']^{0,15} = \{1, 2, 3, 5\}.$$

Exemplo 1.12 (Conjunto fuzzy de lobos). Seja A uma alcateia de lobos específica com n indivíduos. O grau de predação de cada lobo pode estar associado com a sua idade $x \in]0, 15]$, supondo que a idade máxima de um lobo seja 15 anos. A quantidade de lobos sendo finita acarreta que se tenha apenas um número finito de idades dos lobos desta alcatéia. Vamos denotar o conjunto destas idades ainda por $A = \{x_1, x_2, \dots, x_n\}$

e definir o *grau de predação* $\varphi_P(x)$ de um lobo, considerando que os lobos muito *jovens* predam menos que os *adultos* e que os *velhos* tenham sua capacidade de predação diminuída. Desta forma o subconjunto fuzzy dos predadores dessa alcatéia pode ser dado pela função de pertinência

$$\varphi_P(x) = \begin{cases} 0,5 & \text{se } 0 \leq x \leq 2 \\ 1 & \text{se } 2 < x < 10 \\ 0,2(15 - x) & \text{se } 10 \leq x \leq 15 \end{cases}.$$

Com a notação acima, o subconjunto fuzzy finito P é convenientemente denotado por

$$P = \varphi_P(x_1)/x_1 + \varphi_P(x_2)/x_2 + \cdots + \varphi_P(x_n)/x_n,$$

significando que $\varphi_P(x_j)$ é a capacidade de predação de um indivíduo de idade x_j .

Capítulo 2

O Princípio de Extensão e Números Fuzzy

“Todas as coisas têm números e nada se pode compreender sem o número.”

(Filolao, pitagórico – Séc.VI a.C.)

Neste capítulo estudaremos o *Princípio de Extensão* que, como o próprio nome diz, é um método utilizado para estender operações típicas dos conjuntos clássicos. Também, à luz do que preconizou Filolao, introduziremos o conceito de números fuzzy, o qual faz-se necessário para podermos quantificar predicados qualitativos e fazer contas com os mesmos.

2.1 O Princípio de Extensão de Zadeh

Estender conceitos da teoria de conjuntos clássica para a teoria de conjuntos fuzzy é uma necessidade constante. O método de extensão proposto por Zadeh, também conhecido como *Princípio de Extensão*, é uma das ideias básicas que promove a extensão de conceitos matemáticos não-fuzzy em fuzzy.

O Princípio da Extensão de Zadeh para uma função $f : X \longrightarrow Z$ tem por objetivo indicar como deve ser a imagem de um subconjunto

fuzzy A de X por meio de f . É de se esperar que esta imagem seja um subconjunto fuzzy de Z .

Definição 2.1 (Princípio de Extensão de Zadeh). Sejam f uma função tal que $f : X \longrightarrow Z$ e A um subconjunto fuzzy de X . A *extensão de Zadeh* de f é a função $\widehat{f}$ que, aplicada a A , fornece o subconjunto fuzzy $\widehat{f}(A)$ de Z , cuja função de pertinência é dada por

$$\varphi_{\widehat{f}(A)}(z) = \begin{cases} \sup_{f^{-1}(z)} \varphi_A(x) & \text{se } f^{-1}(z) \neq \emptyset \\ 0 & \text{se } f^{-1}(z) = \emptyset \end{cases}. \quad (2.1)$$

onde $f^{-1}(z) = \{x; f(x) = z\}$ denomina-se a *pré-imagem* de z .

Podemos observar que se f for uma função bijetora, então

$$\{x : f(x) = z\} = \{f^{-1}(z)\},$$

em que f^{-1} é a função inversa de f .

Observamos que se A é um subconjunto fuzzy de X , com função de pertinência φ_A , e se f é bijetora então, a função de pertinência de $\widehat{f}(A)$ é dada por

$$\varphi_{\widehat{f}(A)}(z) = \sup_{\{x: f(x)=z\}} \varphi_A(x) = \sup_{\{x \in f^{-1}(z)\}} \varphi_A(x) = \varphi_A(f^{-1}(z)). \quad (2.2)$$

O processo gráfico para a obtenção da extensão $\widehat{f}$ de f está ilustrado a seguir (Figura 2.1), no caso em que f for bijetora.

Note que se f for injetora então $z = f(x)$ pertence ao subconjunto fuzzy $\widehat{f}(A)$, com o mesmo grau α com que x pertence a A . Isto pode não ocorrer se f não for injetora.

Seja $f : X \rightarrow Z$ uma função injetora e A um subconjunto fuzzy de X ,

enumerável (ou finito), e dado por

$$A = \sum_{i=1}^{\infty} \varphi_A(x_i) / x_i.$$

Então, o Princípio de Extensão garante que $\widehat{f}(A)$ é um subconjunto fuzzy de Z , dado por

$$\widehat{f}(A) = \widehat{f}\left(\sum_{i=1}^{\infty} \varphi_A(x_i) / x_i\right) = \sum_{i=1}^{\infty} \varphi_A(x_i) / f(x_i).$$

Portanto, a imagem de A por f pode ser deduzida do conhecimento das imagens de x_i por f . O grau de pertinência de $z_i = f(x_i)$ em $\widehat{f}(A)$ é o mesmo de x_i em A .




Figura 2.1: Imagem de um subconjunto fuzzy a partir do princípio de extensão para uma função f .

Exemplo 2.1. Sejam $f(x) = x^2$, $x \geq 0$ e A um conjunto fuzzy com suporte enumerável. Então

$$\widehat{f}(A) = \sum_{i=1}^{\infty} \varphi_A(x_i) / f(x_i) = \sum_{i=1}^{\infty} \varphi_A(x_i) / x_i^2.$$

O Princípio de Extensão estende o conceito de uma função aplicada a um subconjunto clássico de X . De fato, sejam $f : X \rightarrow Z$ e A um subconjunto (clássico) de X . A função de pertinência de A é sua função

característica. A extensão de Zadeh de f aplicada a A , é o subconjunto $\widehat{f}(A)$ de Z , cuja função característica é

$$\begin{aligned}\varphi_{\widehat{f}(A)}(z) &= \sup_{\{x:f(x)=z\}} \chi_A(x) = \begin{cases} 1 & \text{se } z \in f(A) \\ 0 & \text{se } z \notin f(A) \end{cases} \\ &= \chi_{f(A)}(z) \text{ para todo } z.\end{aligned}$$

Portanto, a função de pertinência do conjunto fuzzy $\widehat{f}(A)$ coincide com a função característica do conjunto crisp $f(A)$, isto é, o conjunto fuzzy $\widehat{f}(A)$ coincide com o conjunto clássico $f(A)$:

$$\widehat{f}(A) = f(A) = \{f(a) : a \in A\}.$$

Podemos ainda observar que, se A for um conjunto clássico então, $[A]^\alpha = A$ para todo $\alpha \in]0, 1]$. Conseqüentemente

$$[\widehat{f}(A)]^\alpha = [f(A)]^\alpha = f(A) = f([A]^\alpha).$$

Para $\alpha = 0$ estamos entendendo que $[A]^0$ é o fecho do suporte de A , isto é, o menor conjunto fechado que contém o suporte de A . Este resultado, enunciado como Teorema 2.1, vale também para um subconjunto fuzzy de X [12].

Teorema 2.1. *Sejam $f : X \longrightarrow Z$ uma função contínua e A um subconjunto fuzzy de X . Então, para todo $\alpha \in [0, 1]$ vale*

$$[\widehat{f}(A)]^\alpha = f([A]^\alpha). \quad (2.3)$$

Este resultado indica que os α -níveis do conjunto fuzzy, obtidos pelo Princípio de Extensão de Zadeh, coincidem com as imagens dos α -níveis pela função crisp (vide Figura 2.2).

Exemplo 2.2. Considere o subconjunto fuzzy A de números reais cuja

função de pertinência é dada por

$$\varphi_A(x) = \begin{cases} 4(x - x^2) & \text{se } x \in [0, 1] \\ 0 & \text{se } x \notin [0, 1] \end{cases}.$$

Os α -níveis de A são os intervalos

$$[A]^\alpha = \left[\frac{1}{2}(1 - \sqrt{1 - \alpha}), \frac{1}{2}(1 + \sqrt{1 - \alpha}) \right].$$

Consideremos a função real $f(x) = x^2$ para $x \geq 0$. Como f é crescente, temos

$$\begin{aligned} f([A]^\alpha) &= \left[f\left(\frac{1}{2}(1 - \sqrt{1 - \alpha})\right), f\left(\frac{1}{2}(1 + \sqrt{1 - \alpha})\right) \right] \\ &= \left[\frac{1}{4}(1 - \sqrt{1 - \alpha})^2, \frac{1}{4}(1 + \sqrt{1 - \alpha})^2 \right]. \end{aligned}$$

A Figura 2.2 ilustra o subconjunto fuzzy $\hat{f}(A)$.




Figura 2.2: Subconjunto $\hat{f}(A)$ do Exemplo 2.2.

Exercício 2.1. Considere f e A do Exemplo 2.2. Obtenha $[\hat{f}(A)]^\alpha$ para $\alpha = 0$, $\alpha = 3/4$ e $\alpha = 1$.

Objetivando as operações entre números fuzzy – que veremos na seção seguinte – vamos enunciar o Princípio de Extensão para funções com

duas variáveis.

Definição 2.2. Sejam $f : X \times Y \longrightarrow Z$ e, A e B subconjuntos fuzzy de X e Y , respectivamente. A *extensão* $\widehat{f}$ de f , aplicada a A e B , é o subconjunto fuzzy $\widehat{f}(A, B)$ de Z , cuja função de pertinência é dada por:

$$\varphi_{\widehat{f}(A, B)}(z) = \begin{cases} \sup_{f^{-1}(z)} \min[\varphi_A(x), \varphi_B(y)] & \text{se } f^{-1}(z) \neq \emptyset \\ 0 & \text{se } f^{-1}(z) = \emptyset \end{cases}, \quad (2.4)$$

onde $f^{-1}(z) = \{(x, y) : f(x, y) = z\}$.

Exemplo 2.3. Seja $f : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$ a função dada por $f(x, y) = x + y$. Considere os subconjuntos fuzzy finitos de $\mathbb{R}$

$$\begin{aligned} A &= 0,4/3 + 0,5/4 + 1/5 + 0,5/6 + 0,2/7 \\ B &= 0,2/6 + 0,5/7 + 1/8 + 0,5/9 + 0,2/10. \end{aligned}$$

Vamos determinar o grau de pertinência de $z = 10$ em $\widehat{f}(A, B)$:

$$\begin{aligned} \varphi_{\widehat{f}(A, B)}(10) &= \sup_{\{x+y=10\}} \min[\varphi_A(x), \varphi_B(y)] = \\ &= \max\{\min[\varphi_A(3), \varphi_B(7)], \min[\varphi_A(4), \varphi_B(6)]\} \\ &= \max\{0,4; 0,2\} = 0,4. \end{aligned}$$

Exercício 2.2. Refaça o Exemplo 2.3:

- Tomando $f(x, y) = x^2 + y$, determine $\widehat{f}(A, B)$ e os graus de pertinências de $z = 10$ e $z = 25$ em $\widehat{f}(A, B)$.
- Agora tomando $f(x, y) = 2x + y$, determine $\widehat{f}(A, B)$ e o grau de pertinência de $z = 18$ em $\widehat{f}(A, B)$.

2.2 Números Fuzzy

De um modo geral podemos dizer que, em um problema concreto, muitos números são idealizações de informações imprecisas, envolvendo valores numéricos. Estes são os casos de frases como “em torno de”. Por exemplo, quando se mede a estatura de um indivíduo, o que se obtém é um valor numérico carregado de imprecisões. Tais imprecisões podem ter sido causadas pelos instrumentos de medidas, pelos indivíduos que estão tomando as medidas, pelo indivíduo que está sendo medido etc. Finalmente opta-se por um valor preciso (um número real) h para indicar a estatura. No entanto, seria mais prudente dizer que a estatura é *em torno de* h ou que a estatura é *aproximadamente* h . Neste caso, matematicamente, indica-se a expressão *em torno de* h por um subconjunto fuzzy A cujo domínio da função de pertinência φ_A é o conjunto dos números reais. Também é razoável esperar que $\varphi_A(h) = 1$. A escolha dos números reais como domínio é porque, teoricamente, os possíveis valores para a *estatura* são números reais.

Definição 2.3 (Número fuzzy). Um subconjunto fuzzy A é chamado de *número fuzzy* quando o conjunto universo no qual φ_A está definida, é o conjunto dos números reais $\mathbb{R}$ e satisfaz às condições:

- (i) todos os α -níveis de A são não vazios, com $0 \leq \alpha \leq 1$;
- (ii) todos os α -níveis de A são intervalos fechados de $\mathbb{R}$;
- (iii) $\text{supp } A = \{x \in \mathbb{R} : \varphi_A(x) > 0\}$ é limitado.

Vamos denotar os α -níveis do número fuzzy A por

$$[A]^\alpha = [a_1^\alpha, a_2^\alpha].$$

Observamos que todo número real r é um número fuzzy particular cuja função de pertinência é a sua função característica:

$$\chi_r(x) = \begin{cases} 1 & \text{se } x = r \\ 0 & \text{se } x \neq r \end{cases}.$$

Denotaremos $\chi_r(x)$ apenas por $\hat{r}$.

A família dos números fuzzy será indicada por $\mathcal{F}(\mathbb{R})$ e, de acordo com o observado acima, o conjunto de números reais $\mathbb{R}$ é um subconjunto (clássico ou crisp) de $\mathcal{F}(\mathbb{R})$.

Os números fuzzy mais comuns são os *triangulares*, *trapezoidais* e os *em forma de sino*.

Exemplo 2.4. O número fuzzy $\hat{2}$ pode ser representado conforme a Figura 2.3.




Figura 2.3: Representação do número fuzzy $\hat{2}$.

Definição 2.4. Um número fuzzy A é dito *triangular* se sua função de pertinência é da forma

$$\varphi_A(x) = \begin{cases} 0 & \text{se } x \leq a \\ \frac{x-a}{u-a} & \text{se } a < x \leq u \\ \frac{x-b}{u-b} & \text{se } u < x \leq b \\ 0 & \text{se } x \geq b \end{cases}. \quad (2.5)$$

O gráfico da função de pertinência de um número fuzzy triangular tem a forma de um triângulo, tendo como base o intervalo $[a, b]$ e, como único vértice fora desta base, o ponto $(u, 1)$.

Deste modo, os números reais a, u e b definem o número fuzzy triangular A que será denotado pela terna ordenada $(a; u; b)$ ou por $a/u/b$.

Os α -níveis desses números fuzzy têm a seguinte forma simplificada

$$[a_1^\alpha, a_2^\alpha] = [(u - a)\alpha + a, (u - b)\alpha + b] \quad (2.6)$$

para todo $\alpha \in [0, 1]$.

Note que um número fuzzy triangular não é necessariamente simétrico já que $b - u$ pode ser diferente de $u - a$, porém, $\varphi_A(u) = 1$. Podemos dizer que o número fuzzy A é um modelo matemático razoável para a expressão linguística “*perto de u*”. Para a expressão “*em torno de u*” espera-se uma simetria. A imposição de simetria acarreta uma simplificação na definição de número fuzzy triangular. De fato, seja u simétrico em relação a a e b , isto é, $u - a = b - u = \delta$. Neste caso,

$$\varphi_A(x) = \begin{cases} 1 - \frac{|x-u|}{\delta} & \text{se } u - \delta \leq x \leq u + \delta \\ 0 & \text{caso contrário} \end{cases}.$$

Exemplo 2.5. A expressão *em torno das quatro horas* pode ser modelada matematicamente pelo número fuzzy triangular simétrico A , cuja função de pertinência é dada por

$$\varphi_A(x) = \begin{cases} 1 - \frac{|x-4|}{0,2} & \text{se } 3,8 \leq x \leq 4,2 \\ 0 & \text{caso contrário} \end{cases}.$$

e está representada na Figura 2.4.




Figura 2.4: Número fuzzy “em torno de 4”.

De (2.6) obtemos os α -níveis desse subconjunto fuzzy, que são os in-

tervalos $[a_1^\alpha, a_2^\alpha]$, onde

$$a_1^\alpha = 0,2\alpha + 3,8 \text{ e } a_2^\alpha = -0,2\alpha + 4,2.$$

Definição 2.5. Um número fuzzy A é dito *trapezoidal* se sua função de pertinência tem a forma de um trapézio e é dada por

$$\varphi_A(x) = \begin{cases} \frac{x-a}{b-a} & \text{se } a \leq x < b \\ 1 & \text{se } b \leq x \leq c \\ \frac{d-x}{d-c} & \text{se } c < x \leq d \\ 0 & \text{caso contrário} \end{cases}.$$

Os α -níveis de um conjunto fuzzy trapezoidal são os intervalos

$$[a_1^\alpha, a_2^\alpha] = [(b-a)\alpha + a, (c-d)\alpha + d] \quad (2.7)$$

para todo $\alpha \in [0, 1]$.

Exemplo 2.6. O conjunto fuzzy dos *adolescentes* pode ser representado pelo número fuzzy trapezoidal, dado pela função de pertinência da equação abaixo e mostrado na Figura 2.5.

$$\varphi_A(x) = \begin{cases} \frac{x-11}{3} & \text{se } 11 \leq x < 14 \\ 1 & \text{se } 14 \leq x \leq 17 \\ \frac{20-x}{3} & \text{se } 17 < x \leq 20 \\ 0 & \text{caso contrário} \end{cases}.$$




Figura 2.5: Número fuzzy trapezoidal.

A Equação (2.7) fornece os α -níveis para este exemplo

$$[3\alpha + 11, -3\alpha + 20], \text{ com } \alpha \in [0, 1].$$

Definição 2.6. Um número fuzzy tem *forma de sino* se a função de pertinência for suave e simétrica em relação a um número real. A seguinte função de pertinência tem estas propriedades para u , a e δ dados (veja Figura 2.6).

$$\varphi_A(x) = \begin{cases} \exp\left(-\left(\frac{x-u}{a}\right)^2\right) & \text{se } u-\delta \leq x \leq u+\delta \\ 0 & \text{caso contrário} \end{cases}.$$




Figura 2.6: Número fuzzy em forma de sino.

Os α -níveis dos números fuzzy em forma de sino são os intervalos:

$$[a_1^\alpha, a_2^\alpha] = \begin{cases} \left[u - \sqrt{\ln\left(\frac{1}{\alpha a^2}\right)}, u + \sqrt{\ln\left(\frac{1}{\alpha a^2}\right)} \right] & \text{se } \alpha \geq \bar{\alpha} = e^{-\left(\frac{\delta}{a}\right)^2} \\ [u - \delta, u + \delta] & \text{se } \alpha < \bar{\alpha} = e^{-\left(\frac{\delta}{a}\right)^2} \end{cases}. \quad (2.8)$$

Apresentaremos a seguir as operações aritméticas para números fuzzy, ou seja, as operações que permitem realizar as “contas” com conjuntos fuzzy.

2.2.1 Operações aritméticas com números fuzzy

As operações aritméticas envolvendo números fuzzy estão estreitamente ligadas às operações aritméticas intervalares. Vamos listar algumas des-

tas operações para intervalos fechados da reta real $\mathbb{R}$.

Operações aritméticas intervalares

Considere λ um número real e, A e B dois intervalos fechados da reta dados por

$$A = [a_1, a_2] \text{ e } B = [b_1, b_2].$$

Definição 2.7 (Operações Intervalares). As operações aritméticas entre intervalos podem ser definidas como:

(a) A *soma* entre A e B é o intervalo

$$A + B = [a_1 + b_1, a_2 + b_2].$$

(b) A *diferença* entre A e B é o intervalo

$$A - B = [a_1 - b_2, a_2 - b_1].$$

(c) A *multiplicação* de A por um escalar λ é o intervalo

$$\lambda A = \begin{cases} [\lambda a_1, \lambda a_2] & \text{se } \lambda \geq 0 \\ [\lambda a_2, \lambda a_1] & \text{se } \lambda < 0 \end{cases}.$$

(d) A *multiplicação* de A por B é o intervalo

$$A.B = [\min P, \max P],$$

onde $P = \{a_1 b_1, a_1 b_2, a_2 b_1, a_2 b_2\}$.

(e) A *divisão* de A por B , se $0 \notin B$, é o intervalo

$$A/B = [a_1, a_2] \cdot \left[\frac{1}{b_2}, \frac{1}{b_1} \right].$$

Exercício 2.3. Obtenha os resultados das operações definidas acima para os intervalos

$$A = [-1, 2] \text{ e } B = [5, 6].$$

Note que as operações aritméticas para intervalos estendem as respectivas operações para números reais. Para tanto, basta ver que cada número real pode ser considerado como um intervalo fechado com extremos iguais.

Também as funções características de cada um dos intervalos obtidos, por meio das operações aritméticas intervalares, podem ser obtidas diretamente das respectivas operações para números reais. Tal procedimento é resultado da aplicação do *princípio de extensão*, que será a ferramenta utilizada para se obter as operações aritméticas dos números fuzzy.

Consideremos uma operação binária “ $\otimes$ ” qualquer entre números reais. Sejam χ_A e χ_B as funções características dos intervalos A e B , respectivamente.

O teorema a seguir fornece as operações aritméticas intervalares a partir das respectivas operações para números reais, via *princípio de extensão*.

Teorema 2.2 (Princípio de extensão para intervalos da reta). *Sejam A e B dois intervalos fechados de $\mathbb{R}$, e $\otimes$ uma das operações aritméticas entre números reais. Então*

$$\chi_{A \otimes B}(x) = \sup_{\{(y,z): y \otimes z = x\}} \min[\chi_A(y), \chi_B(z)]$$

Demonstração. É muito simples verificar que

$$\min(\chi_A(y), \chi_B(z)) = \begin{cases} 1 & \text{se } y \in A \text{ e } z \in B \\ 0 & \text{se } y \notin A \text{ ou } z \notin B \end{cases}.$$

Assim, para o caso da soma ($\otimes = +$), temos

$$\sup_{\{(y,z):y+z=x\}} \min[\chi_A(y), \chi_B(z)] = \begin{cases} 1 & \text{se } x \in A + B \\ 0 & \text{se } x \notin A + B \end{cases}.$$

Os demais casos podem ser obtidos de maneira análoga. ■

Uma consequência importante do Teorema 2.2, para as operações com números fuzzy, é o seguinte corolário:

Corolário 2.3. *Os α -níveis do conjunto crisp $A + B$, com função característica $\chi_{(A+B)}$, são dados por*

$$[A + B]^\alpha = A + B$$

para todo $\alpha \in [0, 1]$.

Demonstração. Lembrando que os intervalos A e B são particulares subconjuntos fuzzy da reta real, o resultado é uma consequência imediata da definição de função característica de um conjunto clássico. ■

As operações aritméticas para números fuzzy serão definidas a partir do Princípio de Extensão para conjuntos fuzzy. Na verdade, são casos particulares do Princípio de Extensão em que as funções a serem estendidas são as operações tradicionais para números reais.

Operações aritméticas com números fuzzy

As definições que seguem podem ser vistas como casos particulares do princípio de extensão, tanto para funções de uma como de duas variáveis.

Definição 2.8. Sejam A e B dois números fuzzy e λ um número real.

(a) A *soma* dos números fuzzy A e B é o número fuzzy, $A + B$, cuja

função de pertinência é

$$\varphi_{(A+B)}(z) = \begin{cases} \sup_{\phi(z)} \min[\varphi_A(x), \varphi_B(y)] & \text{se } \phi(z) \neq 0 \\ 0 & \text{se } \phi(z) = 0 \end{cases},$$

onde $\phi(z) = \{(x, y) : x + y = z\}$.

(b) A *multiplicação* de λ por A é o número fuzzy λA , cuja função de pertinência é

$$\varphi_{\lambda A}(z) = \begin{cases} \sup_{\{x:\lambda x=z\}} [\varphi_A(x)] & \text{se } \lambda \neq 0 \\ \chi_{\{0\}}(z) & \text{se } \lambda = 0 \end{cases} = \begin{cases} \varphi_A(\lambda^{-1}z) & \text{se } \lambda \neq 0 \\ \chi_{\{0\}}(z) & \text{se } \lambda = 0 \end{cases},$$

onde $\chi_{\{0\}}$ é a função característica de $\{0\}$.

(c) A *diferença* $A - B$ é o número fuzzy cuja função de pertinência é dada por:

$$\varphi_{(A-B)}(z) = \begin{cases} \sup_{\phi(z)} \min[\varphi_A(x), \varphi_B(y)] & \text{se } \phi(z) \neq 0 \\ 0 & \text{se } \phi(z) = 0 \end{cases},$$

onde $\phi(z) = \{(x, y) : x - y = z\}$.

(d) A *multiplicação* de A por B é o número fuzzy $A \cdot B$, cuja função de pertinência é dada por:

$$\varphi_{(A \cdot B)}(z) = \begin{cases} \sup_{\phi(z)} \min[\varphi_A(x), \varphi_B(y)] & \text{se } \phi(z) \neq 0 \\ 0 & \text{se } \phi(z) = 0 \end{cases},$$

onde $\phi(z) = \{(x, y) : x \cdot y = z\}$.

(e) A *divisão* é o número fuzzy A/B cuja função de pertinência é

$$\varphi_{(A/B)}(z) = \begin{cases} \sup_{\phi(z)} \min[\varphi_A(x), \varphi_B(y)] & \text{se } \phi(z) \neq 0 \\ 0 & \text{se } \phi(z) = 0 \end{cases},$$

onde $\phi(z) = \{(x, y) : x/y = z\}$.

O Teorema 2.4 a seguir garante que o resultado das operações aritméticas entre números fuzzy é um número fuzzy. Mais ainda, generaliza o Corolário 2.3, relacionando, por meio dos α -níveis, as operações aritméticas para números fuzzy com as respectivas operações aritméticas para intervalos.

Teorema 2.4. *Os α -níveis do conjunto fuzzy $A \otimes B$ são dados por*

$$[A \otimes B]^\alpha = [A]^\alpha \otimes [B]^\alpha$$

para todo $\alpha \in [0, 1]$, sendo $\otimes$ qualquer uma das operações aritméticas mencionadas anteriormente.

A prova deste teorema foge do propósito deste texto e não será feita aqui. O leitor interessado na mesma pode encontrá-la nos livros clássicos de Klir e Yuan [72], Nguyen [95], Pedrycz e Gomide [100] ou mais geralmente em Fuller [51].

A combinação dos Teoremas 2.1 e 2.4 produz “métodos práticos” para se obter os resultados de cada operação entre números fuzzy. Observamos mais uma vez que o α -níveis de um número fuzzy é sempre um intervalo fechado de $\mathbb{R}$, dado por:

$$[A]^\alpha = [a_1^\alpha, a_2^\alpha], \text{ com } a_1^\alpha = \min\{\varphi_A^{-1}(\alpha)\} \text{ e } a_2^\alpha = \max\{\varphi_A^{-1}(\alpha)\},$$

sendo $\varphi_A^{-1}(\alpha) = \{x \in \mathbb{R} : \varphi_A(x) = \alpha\}$ a pré-imagem de α .

A seguir ilustraremos tais “métodos práticos” na forma de propriedades.

Proposição 2.5. *Sejam A e B números fuzzy com α -níveis dados, respectivamente, por $[A]^\alpha = [a_1^\alpha, a_2^\alpha]$ e $[B]^\alpha = [b_1^\alpha, b_2^\alpha]$. Então valem as seguintes propriedades:*

(a) *A soma entre A e B é o número fuzzy $A + B$ cujos α -níveis são*

$$[A + B]^\alpha = [A]^\alpha + [B]^\alpha = [a_1^\alpha + b_1^\alpha, a_2^\alpha + b_2^\alpha].$$

(b) *A diferença entre A e B é o número fuzzy $A - B$ cujos α -níveis são*

$$[A - B]^\alpha = [A]^\alpha - [B]^\alpha = [a_1^\alpha - b_2^\alpha, a_2^\alpha - b_1^\alpha].$$

(c) *A multiplicação de λ por A é o número fuzzy λA cujos α -níveis são*

$$[\lambda A]^\alpha = \lambda[A]^\alpha = \begin{cases} [\lambda a_1^\alpha, \lambda a_2^\alpha] & \text{se } \lambda \geq 0 \\ [\lambda a_2^\alpha, \lambda a_1^\alpha] & \text{se } \lambda < 0 \end{cases}.$$

(d) *A multiplicação de A por B é o número fuzzy $A \cdot B$ cujos α -níveis são*

$$[A \cdot B]^\alpha = [A]^\alpha [B]^\alpha = [\min P, \max P],$$

onde $P = \{a_1^\alpha b_1^\alpha, a_1^\alpha b_2^\alpha, a_2^\alpha b_1^\alpha, a_2^\alpha b_2^\alpha\}$.

(e) *A divisão de A por B , se $0 \notin \text{supp } B$, é o número fuzzy cujos α -níveis são*

$$\left[\frac{A}{B} \right]^\alpha = \frac{[A]^\alpha}{[B]^\alpha} = [a_1^\alpha, a_2^\alpha] \left[\frac{1}{b_2^\alpha}, \frac{1}{b_1^\alpha} \right].$$

Exemplo 2.7. Considere os números fuzzy triangulares A e B que indicam, respectivamente, *aproximadamente 2* e *aproximadamente 4*, dados por

$$A = (1; 2; 3) \text{ e } B = (3; 4; 5).$$

Os resultados de $A \otimes B$ para cada uma das operações aritméticas entre números fuzzy são mostrados a seguir.

Primeiro, observemos que, de acordo com a fórmula (2.6)

$$[A]^\alpha = [1 + \alpha, 3 - \alpha] \text{ e } [B]^\alpha = [3 + \alpha, 5 - \alpha],$$

então pela Proposição 2.5 obtemos

$$(a) \quad [A + B]^\alpha = [A]^\alpha + [B]^\alpha = [4 + 2\alpha, 8 - 2\alpha]. \text{ Assim, } A + B = (4; 6; 8);$$

$$(b) \quad [A - B]^\alpha = [A]^\alpha - [B]^\alpha = [-4 + 2\alpha, -2\alpha]. \text{ Assim, } A - B = (-4; -2; 0);$$

$$(c) \quad [4 \cdot A]^\alpha = 4[A]^\alpha = [4 + 4\alpha, 12 - 4\alpha]. \text{ Assim, } 4A = (4; 8; 12);$$

$$(d) \quad [A \cdot B]^\alpha = [A]^\alpha [B]^\alpha = [(1 + \alpha)(3 + \alpha), (3 - \alpha)(5 - \alpha)];$$

$$(e) \quad \left[\frac{A}{B}\right]^\alpha = \frac{[A]^\alpha}{[B]^\alpha} = [(1 + \alpha)/(5 - \alpha), (3 - \alpha)/(3 + \alpha)].$$

Note que os números fuzzy obtidos em (d) e (e) não são triangulares. Entretanto, é fácil verificar que com números fuzzy triangulares, a soma, a diferença e a multiplicação por escalar resulta em um número fuzzy triangular. Para ver isto, basta considerar os números $A = (a_1; u; a_2)$ e $B = (b_1; v; b_3)$. Então, a partir da Equação (2.6) temos

$$\begin{aligned} [A]^\alpha &= [(u - a_1)\alpha + a_1, (u - a_2)\alpha + a_2] \\ [B]^\alpha &= [(v - b_1)\alpha + b_1, (v - b_2)\alpha + b_2]. \end{aligned}$$

Assim

$$[A + B]^\alpha = [A]^\alpha + [B]^\alpha$$

e, portanto,

$$[A + B]^\alpha = [\{(u + v) - (a_1 + b_1)\}\alpha + (a_1 + b_1), \{(u + v) - (a_2 + b_2)\}\alpha + (a_2 + b_2)].$$

Usando novamente a Equação (2.6), esses intervalos são os α -níveis do número fuzzy triangular

$$((a_1 + b_1); (u + v); (a_2 + b_2)).$$

De forma análoga conclui-se que λA é triangular se A o for.

Finalmente, é possível concluir que $(A - B) + B \neq A$ e portanto, segue que $A - A \neq 0$. Isto é, essa operação de adição não dá ao espaço dos números fuzzy a estrutura de espaço vetorial. Trata-se de um defeito que acaba imperrando várias áreas da matemática fuzzy, como por exemplo as equações diferenciais fuzzy (ver Capítulo 8).

Exercício 2.4. Refaça o Exemplo 2.7 a partir do Princípio de Extensão.

O próximo exemplo apresenta uma forma explícita para a obtenção da função $\widehat{f}$ no caso em que f é linear

Exemplo 2.8. Seja $f : \mathbb{R} \rightarrow \mathbb{R}$ a função $f(x) = \lambda x$, com $\lambda \neq 0$. Se A é um número fuzzy com função de pertinência φ_A então, de acordo com a Definição 2.1, a função de pertinência de $\widehat{f}(A)$ é dada por

$$\begin{aligned} \varphi_{\widehat{f}(A)}(z) &= \sup_{\{x:f(x)=z\}} \varphi_A(x) = \sup_{\{x:\lambda x=z\}} \varphi_A(x) \\ &= \sup_{\{z/\lambda\}} \varphi_A(x) = \varphi_A(z/\lambda) = \varphi_A(\lambda^{-1}z), \end{aligned}$$

que, de acordo com a Definição 2.9b, é a função de pertinência de λA .

Assim, se $f(x) = \lambda x$, então $\widehat{f} : \mathcal{F}(\mathbb{R}) \rightarrow \mathcal{F}(\mathbb{R})$ é dada por $\widehat{f}(A) = \lambda A$.

Um exercício interessante é verificar que se $f(x) = \lambda x + b$, com $\lambda \neq 0$, então, para qualquer número fuzzy A , o conjunto fuzzy $\widehat{f}(A)$ tem função de pertinência dada por

$$\varphi_{\widehat{f}(A)}(z) = \varphi_A(\lambda^{-1}(z - b)).$$

Exercício 2.5. A partir do Teorema 2.1 e das propriedades das operações aritméticas, mostre que a Extensão de Zadeh de uma função linear afim, $f(x) = ax + b$, é a função linear afim $\widehat{f}(X) = aX + \widehat{b}$ se $X \in \mathcal{F}(\mathbb{R})$.

Vamos usar o Princípio de Extensão para calcular a imagem de um número fuzzy triangular por uma função conhecida. A exemplo do que

vimos nas operações de produto e quociente, também a imagem de um número triangular pode não ser triangular mesmo que a função seja contínua.

Exemplo 2.9. Consideremos a função $f(x) = e^x$ e o número fuzzy triangular dado pela terna $A = (0; \ln 2; \ln 3)$.

De acordo com o Teorema 1.2, $\hat{f}(A)$ fica determinada pelos seus α -níveis. A partir de (2.6), é fácil ver que os α -níveis de A são os intervalos

$$[A]^\alpha = [(\ln 2)\alpha, (\ln 2 - \ln 3)\alpha + \ln 3] = \left[\ln 2^\alpha, \ln \left(3 \left(\frac{2}{3} \right)^\alpha \right) \right],$$

com $\alpha \in [0, 1]$.

Vamos agora obter os α -níveis de $\hat{f}(A)$ por meio do Teorema 2.1, ou seja,

$$[\hat{f}(A)]^\alpha = f([A]^\alpha) = f\left(\left[\ln 2^\alpha, \ln 3 \left(\frac{2}{3}\right)^\alpha\right]\right) = \left[2^\alpha, 3 \left(\frac{2}{3}\right)^\alpha\right],$$

com $\alpha \in [0, 1]$. A Figura 2.7 ilustra $\hat{f}(A)$ deste exemplo.




Figura 2.7: Extensão de Zadeh do número fuzzy triangular $A = (0; \ln 2; \ln 3)$ para $f(x) = e^x$.

Portanto,

- se $\alpha = 0$ então $[\widehat{f}(A)]^0 = [1, 3]$;
- se $\alpha = \frac{1}{2}$ então $[\widehat{f}(A)]^{\frac{1}{2}} = [\sqrt{2}, \sqrt{6}]$;
- se $\alpha = 1$ então $[\widehat{f}(A)]^1 = \{2\}$.

Agora é fácil verificar que os pontos $(1, 0)$; $(\sqrt{2}, \frac{1}{2})$ e $(2, 1)$ não estão alinhados.

Logo $\widehat{f}(A)$ não é número fuzzy triangular.

No contexto fuzzy é muito comum o uso da diferença de Hukuhara. Essa, como no caso clássico, preserva a ideia de que a diferença é uma operação oposta à adição.

Definição 2.9 (Diferença de Hukuhara: $A -_H B$). Sejam A e B dois números fuzzy. Se existir um número fuzzy C tal que $A = B + C$, então C é chamado de Diferença de Hukuhara de A e B e a denotamos por $A -_H B$.

Em α -níveis, isto equivale a dizer que

$$[A -_H B]^\alpha = [a_1^\alpha - b_1^\alpha, a_2^\alpha - b_2^\alpha] \quad \forall \alpha \in [0, 1].$$

Como

$$[A - B]^\alpha = [a_1^\alpha - b_2^\alpha, a_2^\alpha - b_1^\alpha],$$

segue que

$$A - B = A -_H B \Leftrightarrow b_1^\alpha = b_2^\alpha,$$

ou seja,

$$A - B = A -_H B \Leftrightarrow B \in \mathbb{R}.$$

Note que

$$A - B = A + (-1)B \neq A -_H B.$$

Essa diferença foi utilizada para se estudar, pela primeira vez, a derivada de funções fuzzy (ver Capítulo 8).

Antes de encerrar esse capítulo, vamos traçar um pequeno paralelo entre o princípio de extensão e a teoria de probabilidades.

Considere as tabelas:

$X = x_j$	$\varphi_X(x_j)$	$P_X(x_j)$
2	0,5	0,5
3	0,5	0,5

Tabela 2.1: Distribuições de pertinências e de probabilidades de X .

$Y = y_k$	$\varphi_Y(y_k)$	$P_Y(y_k)$
3	0,5	0,5
4	0,5	0,5

Tabela 2.2: Distribuições de pertinências e de probabilidades de Y .

A questão é: como obter a distribuição de incerteza para $Z = X + Y$?

Claro que os “possíveis” valores para $Z = X + Y$ são os elementos do conjunto $\{5, 6, 7\}$. A tabela a seguir apresenta os valores de $\varphi_{X+Y}(z_i)$ e $P_{X+Y}(z_i)$,

$Z = X + Y$	$\varphi_{X+Y}(z_i)$	$P_{X+Y}(z_i)$
5	0,5	0,25
6	0,5	0,50
7	0,5	0,25

Tabela 2.3: Distribuições de pertinências e de probabilidades de $X + Y$.

de acordo com as fórmulas

$$\varphi_{X+Y}(z_i) = \sup_{x_j+y_k=z_i} \min(\varphi_A(x_j), \varphi_B(y_k)) \quad (2.9)$$

e

$$P_{X+Y}(z_i) = \sum_{x_j+y_k=z_i} P_{(X,Y)}(X = x_j, Y = y_k), \quad (2.10)$$

onde $P_{(X,Y)}(X = x_j, Y = y_k)$ é a distribuição de probabilidades conjunta do vetor aleatório (X, Y) (ver [31]).

A principal observação que colocamos aqui é que, para obter a probabilidade de $X + Y$, precisamos acrescentar a hipótese de independência. Já para calcular a distribuição de pertinência a $X + Y$, de acordo com o princípio de extensão, hipótese análoga a essa não é necessária.

Vale a pena ressaltar que, se X e Y forem independentes, as fórmulas (2.9) e (2.10) possuem certa semelhança, trocando **sup** por Σ e **min** por **produto**.

Finalmente, observemos que as duas últimas colunas da Tabela (2.3) representa, respectivamente, “pertinência” e “ocorrência” de cada elemento da primeira coluna ao conjunto soma. Intuitivamente, era de se esperar maior probabilidade do valor 6, já que sua “ocorrência” é maior que as das demais. Por outro lado, do ponto de vista da teoria de conjuntos fuzzy, que é uma extensão da teoria clássica de conjuntos, o valor 6 pertence ao conjunto soma com mesma pertinência que os demais. O número de vezes em que ele “ocorre” não importa.

Capítulo 3

Relações Fuzzy

“Tudo que existe na natureza é devido à chance e à necessidade.”

(Demócrito – Séc. V – a.C.)

Será que os indivíduos de uma espécie concordam com Demócrito: eles se relacionam para “construírem” as trajetórias no curso de suas vidas, buscando apenas a sobrevivência, aparentemente sem interesse em otimizar algo? Ou será que buscam o máximo de rendimento com o mínimo esforço, como preconiza Leibniz ao dizer que vivemos no melhor dos mundos? Talvez a diferença entre os dois seja apenas uma questão de verdade gradual.

Estudos de associações, relações ou interações entre os elementos de diversas classes, é de grande interesse na análise e compreensão de muitos fenômenos do mundo real e a matemática sempre se preocupou em estabelecer tais relações. Veremos neste capítulo que as relações fuzzy são, de alguma forma, uma extensão natural das relações matemáticas clássicas.

3.1 Relações Fuzzy

O conceito de relação em matemática é formalizado a partir da teoria de conjuntos. Intuitivamente, pode-se dizer que a relação será *fuzzy*

quando optamos pela teoria dos conjuntos fuzzy, e será *crisp* quando usamos a teoria clássica de conjuntos para conceituar a relação em estudo. A adoção do tipo de relação, dentre estas duas, depende muito do fenômeno estudado. Porém, a opção pela teoria dos conjuntos fuzzy tem sempre maior robustez no sentido que esta inclui a teoria clássica de conjuntos (lembramos que um conjunto clássico – conjunto *crisp* – é, em particular, um conjunto fuzzy).

Uma relação clássica indica se há ou não alguma associação entre dois objetos, enquanto que uma relação fuzzy, além de indicar se há ou não tal associação, indica também o grau desta relação.

Definição 3.1. Uma *relação* (clássica) $\mathcal{R}$ sobre $U_1 \times U_2 \times \dots \times U_n$, é qualquer subconjunto (clássico) do produto cartesiano $U_1 \times U_2 \times \dots \times U_n$. Se o produto cartesiano for formado por apenas dois conjuntos $U_1 \times U_2$, a relação é denominada *relação binária* sobre $U_1 \times U_2$. Se $U_1 = U_2 = \dots = U_n = U$, diz-se que $\mathcal{R}$ é uma *relação* sobre U .

Como a relação $\mathcal{R}$ é um subconjunto do produto cartesiano, então ela pode ser representada por sua função característica

$$\chi_{\mathcal{R}} : U_1 \times U_2 \times \dots \times U_n \longrightarrow \{0, 1\},$$

com

$$\chi_{\mathcal{R}}(x_1, x_2, \dots, x_n) = \begin{cases} 1 & \text{se } (x_1, x_2, \dots, x_n) \in \mathcal{R} \\ 0 & \text{se } (x_1, x_2, \dots, x_n) \notin \mathcal{R} \end{cases}. \quad (3.1)$$

O conceito matemático de relação fuzzy é formalizado a partir do produto cartesiano usual entre conjuntos, estendendo a função característica de uma relação clássica para uma função de pertinência.

Definição 3.2. Uma *relação fuzzy* $\mathcal{R}$ sobre $U_1 \times U_2 \times \dots \times U_n$ é qualquer subconjunto fuzzy de $U_1 \times U_2 \times \dots \times U_n$. Assim, uma relação fuzzy $\mathcal{R}$ é definida por uma função de pertinência $\varphi_{\mathcal{R}} : U_1 \times U_2 \times \dots \times U_n \longrightarrow [0, 1]$.

Se o produto cartesiano for formado por apenas dois conjuntos $U_1 \times U_2$, a relação é chamada de *fuzzy binária* sobre $U_1 \times U_2$.

Se os conjuntos U_i , $i = 1, 2, \dots, n$, forem todos iguais a U , dizemos que $\mathcal{R}$ é uma *relação fuzzy n-ária sobre U* . Por exemplo, uma relação fuzzy binária sobre U é uma relação fuzzy $\mathcal{R}$ sobre $U \times U$.

Se a função de pertinência da relação fuzzy $\mathcal{R}$ for indicada por $\varphi_{\mathcal{R}}$, então o número

$$\varphi_{\mathcal{R}}(x_1, x_2, \dots, x_n) \in [0, 1]$$

indica o grau com que os elementos x_i , que compõem a *n-upla* $(x_1, x_2, \dots, x_n)$, estão relacionados segundo a relação $\mathcal{R}$.

Do ponto de vista de projeção (inferência), com o objetivo de se tomar decisão, uma relação fuzzy de grande importância, principalmente na teoria dos controladores fuzzy (como veremos no Capítulo 5), é o produto cartesiano. Tecnicamente, na teoria dos conjuntos fuzzy tal operação é similar à intersecção, vista no Capítulo 1, Seção 1.3. A grande diferença está nos conjuntos universos envolvidos: enquanto na intersecção os subconjuntos fuzzy são de um mesmo universo, no produto cartesiano eles podem ser diferentes, como veremos na definição a seguir.

Definição 3.3. O *produto cartesiano fuzzy* dos subconjuntos fuzzy $A_1, A_2, \dots, A_n$ de $U_1, U_2, \dots, U_n$, respectivamente, é a relação fuzzy $A_1 \times A_2 \times \dots \times A_n$, cuja função de pertinência é dada por

$$\varphi_{A_1 \times A_2 \times \dots \times A_n}(x_1, x_2, \dots, x_n) = \varphi_{A_1}(x_1) \wedge \varphi_{A_2}(x_2) \wedge \dots \wedge \varphi_{A_n}(x_n),$$

onde $\wedge$ representa o mínimo.

Observemos que se $A_1, A_2, \dots, A_n$ forem conjuntos clássicos, então o produto cartesiano clássico $A_1 \times A_2 \times \dots \times A_n$ pode ser obtido pela Definição 3.3, substituindo as funções de pertinência pelas respectivas funções características dos conjuntos $A_1, A_2, \dots, A_n$. O exemplo a seguir ilustra o poder de aplicação do produto cartesiano.

Exemplo 3.1. Consideremos novamente a Tabela 1.1 do Exemplo 1.8 que relaciona os diagnósticos de 5 pacientes com dois sintomas, febre e mialgia.

Paciente	F : Febre	M : Mialgia
1	0,7	0,6
2	1,0	1,0
3	0,4	0,2
4	0,5	0,5
5	1,0	0,2

Para diagnosticar um paciente, o médico parte de certas avaliações de sintomas (ou sinais) que são característicos de cada doença. Várias doenças podem apresentar sintomas como febre e mialgia com intensidades e medições diversas. Para a gripe, por exemplo, o paciente apresenta sintomas de “febre” e de “mialgia” com intensidades que, se representadas por subconjuntos fuzzy, devem ter universos distintos. O universo indicador de febre pode ser dado pelas temperaturas possíveis de um indivíduo, enquanto que a mialgia pode ser avaliada pelo número de regiões doloridas.

Para indicar o quanto um indivíduo tem gripe tomamos um grau de pertinência ao conjunto do sintoma febre e ao conjunto mialgia. O paciente 1 da Tabela 1.1, por exemplo, tem uma temperatura x cuja pertinência ao conjunto febre F é $\varphi_F(x) = 0,7$ e tem um valor y de mialgia que faz com que $\varphi_M(y) = 0,6$. O diagnóstico do paciente 1 para a doença gripe é dado então por:

$$\text{Paciente 1: } \varphi_{\text{gripe}}(x, y) = \varphi_F(x) \wedge \varphi_M(y) = 0,7 \wedge 0,6 = 0,6.$$

Isto significa que o paciente 1 está no subconjunto fuzzy dos febris com mialgia, tendo grau de pertinência 0,6; que coincide com o grau de seu diagnóstico para gripe.

Esse número pode dar suporte para, a partir daí, o especialista tomar

decisão quanto ao tratamento a ser adotado. É claro que, do ponto de vista teórico, o produto cartesiano clássico também poderia ser adotado para o diagnóstico. Nesse caso, apenas seria indicado gripe (grau um) ou não gripe (grau zero) e, para o exemplo, apenas o paciente 2 da Tabela 1.1 seria considerado gripado.

No Capítulo 6, Subseção 6.2.3, será apresentado um estudo mais completo a respeito de diagnóstico médico.

Exercício 3.1. Compare o Exemplo 3.1 com o Exemplo 1.8.

Exercício 3.2. Investigue mais um sintoma típico de gripe (coriza, por exemplo) e inclua-o, como subconjunto fuzzy, na Tabela 1.1 para diagnosticar os pacientes com gripe.

3.1.1 Formas de representação e propriedades das relações binárias

Neste texto serão destacadas apenas as formas de representação e algumas propriedades das relações binárias e fuzzy binárias, as quais serão ilustradas por meio de alguns exemplos.

O exemplo a seguir servirá de apoio para ilustrar as principais representações que veremos aqui.

Exemplo 3.2. Suponhamos um determinado ecossistema U , no qual interagem as populações de *águias* (a), *cobras* (c), *insetos* (i), *lebres* (l) e *sapos* (s). Um estudo de interesse, entre os indivíduos destas populações, é o processo de predação, isto é, a relação do tipo *presa-predador*.

Se desejamos estudar a relação entre dois indivíduos deste ecossistema, esta relação pode ser modelada matematicamente por uma *relação binária* $\mathcal{R}$, com $\varphi_{\mathcal{R}}(x, y) = 0$ se y não é predador de x e $\varphi_{\mathcal{R}}(x, y) \neq 0$ se y é predador de x , onde x e y representam indivíduos do conjunto U .

A seguir serão discutidos dois possíveis casos do emprego da relação clássica e da relação fuzzy para esse exemplo.

- Se o interesse sobre a relação for apenas indicar quem é predador e quem é presa neste conjunto U , então podemos optar pela teoria clássica e $\mathcal{R}$ será uma relação binária clássica. Nesse caso,

$$\varphi_{\mathcal{R}}(x, y) = \chi_{\mathcal{R}}(x, y) = \begin{cases} 1 & \text{se } y \text{ for predador de } x \\ 0 & \text{se } y \text{ não for predador de } x \end{cases}.$$

Uma representação gráfica para esta relação, colocando os animais em ordem alfabética em um par de eixos, seria como a da Figura 3.1.




Figura 3.1: Representação da relação clássica entre os predadores e suas presas.

Os pontos destacados na Figura 3.1 indicam os pares que fazem parte da relação $\mathcal{R}$, ou seja, a relação $\mathcal{R}$ simplesmente revela quem é predador de quem, de acordo com algum especialista.

- Se houver interesse em saber, por exemplo, a preferência graduada de um predador por alguma presa na comunidade U , então uma boa opção é que $\mathcal{R}$ seja uma relação fuzzy. Neste caso, $\varphi_{\mathcal{R}}(x, y)$ indica o grau com que y tem preferência por x . Supondo que não haja diferença nos graus de predação dentro de cada espécie, uma possibilidade para $\varphi_{\mathcal{R}}(x, y)$, também de acordo com um especi-

alista, para este exemplo, está ilustrada na Figura 3.2, onde no terceiro eixo (eixo vertical) estão representados os diversos graus $\varphi_{\mathcal{R}}(x, y)$.




Figura 3.2: Relação fuzzy e os diversos graus de preferência

As formas mais comuns de se representar uma relação fuzzy binária em $X \times Y$, quando X e Y são finitos, são a tabular e a matricial.

Sejam $X = \{x_1, x_2, \dots, x_m\}$, $Y = \{y_1, y_2, \dots, y_n\}$ e a relação fuzzy $\mathcal{R}$ sobre $X \times Y$, com função de pertinência dada por $\varphi_{\mathcal{R}}(x_i, y_j) = r_{ij}$, para $1 \leq i \leq m$ e $1 \leq j \leq n$.

As representações de $\mathcal{R}$ podem ser na forma de tabela ou de matriz conforme abaixo.

$\mathcal{R}$	y_1	y_2	$\dots$	y_n
x_1	r_{11}	r_{12}	$\dots$	r_{1n}
x_2	r_{21}	r_{22}	$\dots$	r_{2n}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
x_m	r_{m1}	r_{m2}	$\dots$	r_{mn}

ou $\mathcal{R} =$

$$\begin{bmatrix} r_{11} & r_{12} & \dots & r_{1n} \\ r_{21} & r_{22} & \dots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ r_{m1} & r_{m2} & \dots & r_{mn} \end{bmatrix}.$$

Para exemplificar, as representações na forma de tabela e matricial da relação fuzzy do Exemplo 3.2 são, respectivamente

	p	r	e	d	a	d	o	r
	$\mathcal{R}$	a	c	i	l	s		
p	a	0	0	0	0	0		
r	c	1	0,2	0	0	0		
e	i	0,1	0	0,3	0	1		
s	l	1	0,8	0	0	0		
a	s	0,2	1	0	0	0,1		

e

$$\mathcal{R} = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 1 & 0,2 & 0 & 0 & 0 \\ 0,1 & 0 & 0,3 & 0 & 1 \\ 1 & 0,8 & 0 & 0 & 0 \\ 0,2 & 1 & 0 & 0 & 0,1 \end{bmatrix}.$$

Para um melhor entendimento deste texto faz-se necessária a seguinte definição.

Definição 3.4. Seja $\mathcal{R}$ uma relação fuzzy binária definida em $X \times Y$. A *relação fuzzy binária inversa*, $\mathcal{R}^{-1}$, definida em $Y \times X$, tem função de pertinência $\varphi_{\mathcal{R}^{-1}} : Y \times X \longrightarrow [0, 1]$ dada por $\varphi_{\mathcal{R}^{-1}}(y, x) = \varphi_{\mathcal{R}}(x, y)$.

Note que a matriz de $\mathcal{R}^{-1}$ coincide com a transposta de $\mathcal{R}$, já que $\varphi_{\mathcal{R}^{-1}}(y, x) = \varphi_{\mathcal{R}}(x, y)$. Por esse motivo muitos textos de lógica fuzzy adotam o termo relação transposta no lugar de inversa (veja Pedrycz e Gomide [100]).

Assim, se $\mathcal{R}$ é a relação fuzzy do Exemplo 3.2, então a representação matricial de sua inversa $\mathcal{R}^{-1}$ é dada pela sua transposta

$$\mathcal{R}^{\top} = \begin{bmatrix} 0 & 1 & 0,1 & 1 & 0,2 \\ 0 & 0,2 & 0 & 0,8 & 1 \\ 0 & 0 & 0,3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0,1 \end{bmatrix}.$$

Neste caso, $\mathcal{R}^{-1}$ indica que x é predado por y , enquanto que por $\mathcal{R}$ temos que y é predador de x .

3.2 Composição entre Relações Fuzzy Binárias

A composição entre relações é de importância fundamental nas aplicações. Essa operação será mais explorada no Capítulo 6, onde aparecem as principais aplicações em diagnóstico médico. Também no Capítulo 6 estudaremos diversos tipos de composições entre relações fuzzy. Aqui nesta seção apresentaremos apenas a composição mais tradicional em lógica fuzzy.

Definição 3.5. Considere $\mathcal{R}$ e $\mathcal{S}$ duas relações fuzzy binárias em $U \times V$ e $V \times W$, respectivamente. A *composição* $\mathcal{R} \circ \mathcal{S}$ é uma relação fuzzy binária em $U \times W$ cuja função de pertinência é dada por

$$\varphi_{\mathcal{R} \circ \mathcal{S}}(x, z) = \sup_{y \in V} [\min(\varphi_{\mathcal{R}}(x, y), \varphi_{\mathcal{S}}(y, z))]. \quad (3.2)$$

Quando os conjuntos U , V e W são finitos, então a forma matricial da relação $\mathcal{R} \circ \mathcal{S}$, dada pela composição [max–min], é obtida como uma multiplicação de matrizes, substituindo-se o produto pelo mínimo e a soma pelo máximo. De fato, suponha que

$$U = \{u_1, u_2, \dots, u_m\}; \quad V = \{v_1, v_2, \dots, v_n\} \quad \text{e} \quad W = \{w_1, w_2, \dots, w_p\}$$

e que

$$\mathcal{R} = \begin{bmatrix} r_{11} & r_{12} & \dots & r_{1n} \\ r_{21} & r_{22} & \dots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ r_{m1} & r_{m2} & \dots & r_{mn} \end{bmatrix}_{m \times n} \quad \text{e} \quad \mathcal{S} = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1p} \\ s_{21} & s_{22} & \dots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{n1} & s_{n2} & \dots & s_{np} \end{bmatrix}_{n \times p}.$$

De acordo com a Definição 3.5, a relação fuzzy binária dada pela

composição [max–min] tem a forma matricial

$$\mathcal{T} = \mathcal{R} \circ \mathcal{S} = \begin{bmatrix} t_{11} & t_{12} & \dots & t_{1p} \\ t_{21} & t_{22} & \dots & t_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ t_{m1} & t_{m2} & \dots & t_{mp} \end{bmatrix}_{m \times p},$$

onde

$$t_{ij} = \sup_{1 \leq k \leq n} [\min(\varphi_R(u_i, v_k), \varphi_S(v_k, w_j))] = \sup_{1 \leq k \leq n} [\min(r_{ik}, s_{kj})]. \quad (3.3)$$

O caso especial da composição [max–min], que faremos a seguir, será utilizado de uma forma mais geral no Capítulo 6.

Definição 3.6 (Regra de composição de inferência). Sejam U e V dois conjuntos, $\mathcal{F}(U)$ e $\mathcal{F}(V)$ as classes dos subconjuntos fuzzy de U e V respectivamente, e $\mathcal{R}$ uma relação binária sobre $U \times V$.

- (i) A relação $\mathcal{R}$ define um funcional de $\mathcal{F}(U)$ em $\mathcal{F}(V)$ que, a cada elemento $A \in \mathcal{F}(U)$, faz corresponder o elemento $B \in \mathcal{F}(V)$ cuja função de pertinência é dada por

$$\varphi_B(y) = \varphi_{\mathcal{R}(A)}(y) = \sup_{x \in U} [\min(\varphi_{\mathcal{R}}(x, y), \varphi_A(x))]. \quad (3.4)$$

Essa composição é conhecida como *regra de composição de inferência*, a qual dará origem a outras regras, como veremos nos Capítulos 4 e 5.

- (ii) A relação $\mathcal{R}$ também define um funcional de $\mathcal{F}(V)$ em $\mathcal{F}(U)$ da seguinte forma: a cada $B \in \mathcal{F}(V)$ faz corresponder o elemento $A \in \mathcal{F}(U)$ cuja função de pertinência é

$$\varphi_A(x) = \varphi_{\mathcal{R}^{-1}(B)}(x) = \sup_{y \in V} [\min(\varphi_{\mathcal{R}^{-1}}(y, x), \varphi_B(y))]. \quad (3.5)$$

A é denominado *imagem inversa* de B por $\mathcal{R}$.

Note que a fórmula (3.4) pode ser reescrita como

$$\varphi_B(y) = \varphi_{\mathcal{R}(A)}(y) = \sup_{x \in U} [\min(\varphi_A(x), \varphi_{\mathcal{R}}(x, y))].$$

Assim, de acordo com (3.2),

$$B = \mathcal{R}(A) = A \circ \mathcal{R}.$$

De forma análoga, a imagem inversa é dada por

$$A = B \circ \mathcal{R}^{-1}.$$

Exercício 3.3. Suponha que os conjuntos universos envolvidos U e V sejam finitos, de maneira que A , B e $\mathcal{R}$ tenham representações na forma de matriz. A partir da observação acima, verifique que

$$B = A \circ \mathcal{R} \quad \text{e} \quad A = B \circ \mathcal{R}^\top$$

onde A e B são as formas matriciais em linha dos respectivos conjuntos fuzzy, cujos elementos são obtidos a partir de (3.3).

Para um melhor estudo de relações binárias, destacam-se algumas importantes definições as quais serão feitas primeiramente para relações binárias clássicas, e em seguida, para as relações fuzzy binárias.

As definições para as relações binárias clássicas $\mathcal{R}$ serão feitas por meio de suas funções características $\chi_{\mathcal{R}} : U \times U \longrightarrow \{0, 1\}$, visando um melhor entendimento para o caso fuzzy.

Definição 3.7. Seja $\mathcal{R}$ uma relação binária (clássica) sobre U . Então, para quaisquer x , y e z de U , a relação $\mathcal{R}$ é

- (i) *reflexiva* se $\chi_{\mathcal{R}}(x, x) = 1$;

- (ii) *simétrica* se $\chi_{\mathcal{R}}(x, y) = 1$ implica $\chi_{\mathcal{R}}(y, x) = 1$;
- (iii) *transitiva* se $\chi_{\mathcal{R}}(x, y) = \chi_{\mathcal{R}}(y, z) = 1$ implica $\chi_{\mathcal{R}}(x, z) = 1$;
- (iv) *anti-simétrica* se $\chi_{\mathcal{R}}(x, y) = \chi_{\mathcal{R}}(y, x) = 1$ implica $x = y$.

Observe que as definições acima retratam exatamente cada uma das definições usadas tradicionalmente em teoria de conjuntos. A opção feita pelo uso da função característica foi apenas um “artifício” para facilitar o entendimento destes conceitos no caso fuzzy.

Há algumas pequenas diferenças nas extensões dos conceitos dados na Definição 3.7, quando adaptados para o caso fuzzy, principalmente o conceito de transitividade (veja [72, 95]).

Definição 3.8. Seja $\mathcal{R}$ uma relação fuzzy binária sobre U , cuja função de pertinência é $\varphi_{\mathcal{R}}$. Então, para quaisquer x , y e z de U , a relação fuzzy $\mathcal{R}$ é

- (i) *reflexiva* se $\varphi_{\mathcal{R}}(x, x) = 1$;
- (ii) *simétrica* se $\varphi_{\mathcal{R}}(x, y) = \varphi_{\mathcal{R}}(y, x)$;
- (iii) *transitiva* se $\varphi_{\mathcal{R}}(x, z) \geq \varphi_{\mathcal{R}}(x, y) \wedge \varphi_{\mathcal{R}}(y, z)$, onde $\wedge = \text{mínimo}$.
- (iv) *antissimétrica* se $\varphi_{\mathcal{R}}(x, y) > 0$ e $\varphi_{\mathcal{R}}(y, x) > 0$ implica $x = y$.

A relação reflexiva é aquela em que todo indivíduo tem relação máxima consigo próprio; a simétrica é caracterizada pela reciprocidade, com mesma intensidade, entre seus indivíduos; a transitiva indica que a relação entre dois indivíduos quaisquer não deve ser, simultaneamente, inferior à relação de cada um destes dois com os demais e a relação antissimétrica é aquela que não admite qualquer reciprocidade entre indivíduos distintos.

Relações que satisfazem simultaneamente as quatro propriedades anteriores são, de um modo geral, muito artificiais principalmente quando

se exige que cumpram (ii) e (iv). Por exemplo, se U for constituído de um único elemento x , o produto cartesiano $U \times U = \{(x, x)\}$, satisfaz as propriedades de (i) a (iv) da Definição 3.8.

Relações que satisfazem apenas as três primeiras condições são chamadas de *relações de equivalência*.

Os conceitos anteriores podem ser observados no seguinte exemplo:

Exemplo 3.3. Intuitivamente, a relação de hierarquia militar ($\mathcal{M}$): “*é superior a*” é baseada na patente do indivíduo, isto é, x está relacionado com y se x é superior a y . Então, $\mathcal{M}$ é reflexiva, transitiva e antissimétrica mas não é simétrica.

A relação ($\mathcal{A}$): “*é amigo de*” é reflexiva, simétrica mas não é transitiva.

As relações $\mathcal{M}$ e $\mathcal{A}$ não são necessariamente fuzzy. Porém, se houver interesse em indicar o grau com que x é superior a y , embasado não na diferença entre as patentes mas em fatores subjetivos, então $\mathcal{M}$ deve ser uma relação fuzzy. O mesmo pode ser dito a respeito da relação $\mathcal{A}$.

Para finalizar este capítulo, vamos apresentar algumas aplicações interessantes na obtenção de estampas de tecidos, por meio de operações entre matrizes de relações fuzzy. É uma exploração ainda bastante ingênua do ponto de vista matemático, mas com resultados práticos relevantes.

Os teares modernos usam composição de padrões para formar novos tecidos. A composição pode ser simplesmente uma operação de soma entre as matrizes que caracterizam uma padronagem ou então podem ser usadas composições típicas da lógica fuzzy com max e min.

Exemplo 3.4. A principal característica na formação do tecido é a ordenação de dois sistemas de fios que se cruzam perpendicularmente, chamados de urdume (fios no sentido longitudinal) e trama (fios que estão na transversal ou largura). As ligações ou cruzamentos destes fios são denominados padronagem (Figura 3.3).

Para a confecção de um tecido usam-se combinações de padrões (raport) fundamentais: tela, sarja e cetim – que podem ser expressos em




Figura 3.3: Formação de uma padronagem.

papéis quadriculados, conforme Figura 3.4.




Figura 3.4: Padrões fundamentais.

Quando estes padrões são modelados por matrizes, consideramos cada ponto cheio como valor 1 (fio de urdume levantado com a trama passando por baixo deste fio), caso contrário seu valor será 0. Desta forma, os padrões fundamentais são modelados pelas matrizes:

$$T = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad S = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \quad \text{e} \quad C = \begin{bmatrix} 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{bmatrix}.$$

As composições clássicas entre estas matrizes resultam nos padrões existentes de todos os tecidos. Entretanto, se optarmos por operações típicas das relações fuzzy podemos obter novos padrões como veremos a

seguir.

Vamos considerar inicialmente a “soma” de tela T e sarja S definida por: $T \oplus S = \max \{t_{ij}, s_{ij}\}$. Como o mínimo múltiplo comum (MMC) das ordens das matrizes T e S é igual a 6, tomamos os múltiplos de cada padrão. Então se

$$T = \begin{bmatrix} 0 & 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 \end{bmatrix} \text{ e } S = \begin{bmatrix} 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \end{bmatrix} \Rightarrow$$

$$\Rightarrow T \oplus S = \begin{bmatrix} 0 & 1 & 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 & 1 & 0 \end{bmatrix}$$

A matriz resultante fornece um raport novo que pode ser usado para obtenção de outros raports, considerando as composições das simetrias (translações, rotações e reflexões – veja Figura 3.5).




Figura 3.5: Composições com o raport obtido de $T \oplus S$.

Exercício 3.4. Defina $T \ominus S = \min \{t_{ij}, s_{ij}\}$ e obtenha a “diferença” a partir do raport determinado pela operação. Use também estas operações com a composição entre sarja e cetim.

Exercício 3.5. Considere as matrizes

$$A = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \end{bmatrix} \text{ e } B = \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix},$$

e faça a composição $A \circ B = [\text{max-min}]$ para obter um novo raport.

Salientamos que outras composições entre relações fuzzy serão definidas no Capítulo 6 onde apresentaremos também uma aplicação específica em diagnóstico médico.

Capítulo 4

Noções da Lógica Fuzzy

“A finalidade da ciência teórica é a verdade.”

(Aristóteles – Séc. IV – a.C.)

Para Aristóteles, o compromisso do conhecimento é com a verdade, sem preocupações práticas. Em contrapartida, para os sofistas o conhecimento deve ter compromisso com a prática e, por isso mesmo, substitui o padrão de verdadeiro ou falso pelo de melhor ou pior. No decorrer deste e dos dois próximos capítulos, estes padrões serão melhor entendidos, principalmente quando tratarmos do que é conhecido como *modus ponens generalizado*.

Na literatura, o termo “lógica fuzzy” é utilizado de duas formas: a primeira para representar e manipular informações inexatas com o propósito de tomar decisões, lançando mão da teoria dos conjuntos fuzzy, de suas funções de pertinência e suas álgebras em geral. A segunda refere-se à extensão da lógica clássica, que é o objetivo deste capítulo.

Fazendo um breve histórico, a lógica desenvolveu-se a partir dos estudos sobre silogismo de Aristóteles (IV a.C.), os quais buscavam uma melhor compreensão da verdade. Através das leituras dos trabalhos de Platão, que por sua vez foi discípulo de Sócrates, é que Aristóteles percebe a existência de leis que regem o pensamento no propósito da busca do conhecimento e da verdade, sem dar margem às interpretações. Um

exemplo de verdade é dado pelo método de investigação de Sócrates:

“Todo homem é mortal
Sócrates é homem
Logo, Sócrates é mortal”

O silogismo acima tem estrutura tipicamente da *Lógica* que possibilita o verdadeiro conhecimento defendido por Aristóteles.

A lógica aristotélica volta a ter grande desenvolvimento somente no século XVI, quando Leibniz cria a lógica simbólica. No século XIX Boole desenvolve uma álgebra para esta lógica simbólica. Tal ferramenta passa a ser largamente utilizada em controle de circuitos, na primeira metade do século XX, e posteriormente em linguagem de computadores. Ainda no século XX, a lógica foi objeto de pesquisa para grandes matemáticos como Peano, Frège, Whitehead, Russel e Gödel dentre outros. Também, durante a primeira metade do século XX, surgem vários estudiosos que estendem a *lógica de dois valores* para lógicas com vários valores, a *lógica multivaluada*. Dentre estas destacamos a de Lukasiewicz, que de certo modo, é considerada a precursora da lógica fuzzy [58, 95]. Porém, só na década de 1960 surge o primeiro trabalho que dá origem à lógica fuzzy [129].

Como já comentamos no Capítulo 1, é importante salientar que embora as premissas e conclusões obtidas através da lógica fuzzy sejam subjetivas, isso não significa nenhum tipo de retrocesso, de modo a se debater novamente com aquelas questões de interpretações pré-aristotélicas. A lógica fuzzy é de fato uma lógica (área do conhecimento que estuda consequências) com suas metodologias próprias [58]. Ela não lida com questões ambíguas. As incertezas das quais a lógica fuzzy trata são do tipo monotônicas no sentido que quanto menos incertas forem as premissas, menos incertas serão as conclusões. Nesse sentido, intuitivamente, podemos dizer que a lógica clássica é uma espécie de limite da lógica fuzzy quando as incertezas tendem a zero.

O principal sucesso da lógica fuzzy é devido ao seu caráter prático, já que possibilita conclusões a partir de proposições incertas. A área que lida com as formalizações destas proposições é conhecida como **raciocínio aproximado** cuja arquitetura tem a forma do método de investigação proposto por Sócrates:

Gripe forte provoca febre alta;

Febre alta provoca dores de cabeça frequentemente;

Conclusão: Gripe forte provoca dores de cabeça frequentemente.

A última sentença (conclusão) é uma dedução obtida a partir das premissas. Porém, alguns dos predicados não são termos precisos, a saber: *forte*, *alta* e *frequentemente* e, por esse motivo, a lógica clássica não trata destas sentenças.

Na próxima seção serão relacionados alguns conceitos da lógica tradicional que servirão de base para o desenvolvimento da lógica fuzzy.

4.1 Conectivos Básicos da Lógica Clássica

Os primeiros passos em lógica matemática são realizados com o estudo dos conectivos: “e”, “ou”, “não” e “implicação”. Tais conectivos são tipicamente usados na modelagem matemática em sentenças do tipo:

$$\begin{array}{l} \text{“Se } a \text{ está em } A \text{ e } b \text{ está em } B, \\ \text{então } c \text{ está em } C \text{ ou } d \text{ não está em } D\text{”} \end{array} \quad (4.1)$$

Os valores lógicos para cada conectivo são estudados por meio de tabelas verdades. Assim, o valor lógico de uma sentença, formada a partir de duas ou mais proposições, é obtido por meio de composições das tabelas verdades dos conectivos presentes nesta sentença.

Supondo que A e B sejam conjuntos, a proposição

$$“a \text{ está em } A \text{ e } b \text{ está em } B”$$

é verdadeira apenas se for verdade que a pertença a A e também que b pertença a B . O valor lógico desta sentença é uma consequência da tabela verdade clássica para o conectivo **e**.

Na lógica clássica, sentenças verdadeiras têm valor lógico **1**, enquanto sentenças falsas têm valor lógico **0**. Pensando na extensão para o caso fuzzy, usaremos a notação $\wedge$ (mínimo) para a conjunção **e**; $\vee$ (máximo) para **ou**; $\neg$ para a **negação** e $\implies$ para a **implicação**.

Sejam p e q duas proposições. As tabelas verdades para os conectivos apresentados são dadas a seguir:

p	q	$p \wedge q$
1	1	1
1	0	0
0	1	0
0	0	0

Tabela 4.1: Tabela verdade de $\wedge$.

p	q	$p \vee q$
1	1	1
1	0	1
0	1	1
0	0	0

Tabela 4.2: Tabela verdade de $\vee$.

p	$\neg p$
1	0
0	1

Tabela 4.3: Tabela verdade de $\neg$.

p	q	$p \implies q$
1	1	1
1	0	0
0	1	1
0	0	1

Tabela 4.4: Tabela verdade de $\implies$.

Podemos notar que em cada tabela verdade, p e q assumem apenas os valores 0 ou 1. Por isso, a lógica clássica é, às vezes, chamada de “lógica a dois valores”.

Cada um dos conectivos lógicos acima pode ser visto como operador matemático, cujos valores coincidem com os das respectivas tabelas verdade, e é esse fato que justifica as notações $\wedge$ para o **e** e $\vee$ para o **ou**.

Com exceção da negação, os demais conectivos são operações binárias:

- Conectivo **e**: $\wedge$

$$\begin{aligned}\wedge : \{0, 1\} \times \{0, 1\} &\longrightarrow \{0, 1\} \\ (p, q) &\longmapsto \wedge(p, q) = p \wedge q = \min\{p, q\}.\end{aligned}$$

Assim,

$$\begin{aligned}\wedge(1, 1) &= 1 \wedge 1 = 1; \\ \wedge(1, 0) &= 1 \wedge 0 = 0; \\ \wedge(0, 1) &= 0 \wedge 1 = 0; \\ \wedge(0, 0) &= 0 \wedge 0 = 0.\end{aligned}$$

- Conectivo **ou**: $\vee$

$$\begin{aligned}\vee : \{0, 1\} \times \{0, 1\} &\longrightarrow \{0, 1\} \\ (p, q) &\longmapsto \vee(p, q) = p \vee q = \max\{p, q\}.\end{aligned}$$

Portanto,

$$\begin{aligned}\vee(1, 1) &= 1 \vee 1 = 1; \\ \vee(1, 0) &= 1 \vee 0 = 1; \\ \vee(0, 1) &= 0 \vee 1 = 1; \\ \vee(0, 0) &= 0 \vee 0 = 0.\end{aligned}$$

- A negação pode ser considerada como uma operação unária: $\neg$

$$\begin{aligned}\neg : \{0, 1\} &\longrightarrow \{0, 1\} \\ p &\longmapsto \neg p,\end{aligned}$$

onde, $\neg 1 = 0$ e $\neg 0 = 1$. É interessante notar que $\neg p = 1 - p$.

- Implicação: $\implies$

$$\begin{aligned} \implies &: \{0, 1\} \times \{0, 1\} \longrightarrow \{0, 1\} \\ (p, q) &\longmapsto \implies (p, q) = (p \implies q). \end{aligned}$$

A partir dos conectivos anteriores é possível obter pelo menos três fórmulas básicas que reproduzem a tabela verdade da implicação:

- (1) $(p \implies q) = (\neg p) \vee q$;
- (2) $(p \implies q) = (\neg p) \vee (p \wedge q)$;
- (3) $(p \implies q) = \max\{x \in \{0, 1\} : p \wedge x \leq q\}$.

Vamos verificar que “não p ou q ” é a implicação “ p implica q ”, isto é, $(\neg p) \vee q = (p \implies q)$ é de fato uma implicação:

$$\begin{aligned} \implies \quad (1, 1) &= (1 \implies 1) = (\neg 1) \vee 1 = 1; \\ \implies \quad (1, 0) &= (1 \implies 0) = (\neg 1) \vee 0 = 0; \\ \implies \quad (0, 1) &= (0 \implies 1) = (\neg 0) \vee 1 = 1; \\ \implies \quad (0, 0) &= (0 \implies 0) = (\neg 0) \vee 0 = 1. \end{aligned}$$

Fica como exercício para o leitor verificar os outros dois casos.

Embora cada um dos operadores (1), (2) e (3), defina a mesma implicação clássica, isso não ocorrerá quando estendermos cada uma destas três fórmulas para o caso fuzzy, como veremos posteriormente.

Voltemos à sentença (4.1). Tal sentença pode ter uma avaliação lógica por meio dos valores lógicos dos conectivos. Como supostamente os conjuntos que lá aparecem são clássicos, essa avaliação somente pode tomar os valores 0 ou 1.

De fato, considere

$$\underbrace{\underbrace{\text{“Se } a \text{ está em } A \text{ e } b \text{ está em } B\text{”}}_p}_P, \text{ então } \underbrace{\underbrace{c \text{ está em } C}_r \text{ ou } \underbrace{d \text{ não está em } D}_s}_Q.$$

Os valores de cada uma das expressões p , q , r e s podem ser apenas 0 ou 1, dependendo se cada elemento pertence ou não ao conjunto indicado. Por exemplo, $p = 1$ se a está em A e $p = 0$ se $a \notin A$. Analogamente, temos os valores para q , r e s .

É fácil avaliar a sentença (4.1) para cada situação. Por exemplo, se

$$a \in A(p = 1); b \notin B(q = 0); c \in C(r = 1) \text{ e } d \notin D(s = 1),$$

então o valor lógico da sentença (4.1) é

$$(0 \wedge 1) \implies (1 \vee 1) = (0 \implies 1) = 1.$$

Pensando no caso fuzzy, observamos que o valor lógico da sentença p : “ a está em A ” coincide com o valor obtido com a função característica do conjunto A em a , isto é, o valor de p é dado por $\chi_A(a)$. Da mesma forma, χ_B dá o valor lógico de q , χ_C o de r e o valor de s é dado por $1 - \chi_D$.

A seção seguinte é dedicada à formulação matemática de (4.1), admitindo que os conjuntos agora sejam fuzzy.

4.2 Conectivos básicos da Lógica Fuzzy

Observamos que, para avaliar logicamente a expressão (4.1) por meio dos conectivos, admitimos que a mesma somente poderia assumir os valores 0 ou 1. Esta suposição é coerente com o fato dos conjuntos relacionados serem clássicos. Agora, se admitirmos que os conjuntos em (4.1) possam ser fuzzy, como avaliar logicamente tal expressão?

Inicialmente, devemos atribuir um valor que indique o quanto a proposição “ a está em A ” é verdadeira, com A fuzzy, sabendo que um elemento a pode pertencer a A com valores no intervalo $[0, 1]$.

Para realizar a avaliação lógica dos conectivos no sentido fuzzy, devemos estendê-los. Tais extensões são obtidas por meio das normas e

conormas triangulares. Esses operadores têm origem nos estudos de Espaços Métricos Estatísticos (Menger, 1942 [85]). Suas denominações advêm da generalização da propriedade triangular para tais espaços [71].

4.2.1 Operações t-norma e t-conorma

Definição 4.1 (t-norma). O operador $\Delta : [0, 1] \times [0, 1] \longrightarrow [0, 1]$, $\Delta(x, y) = x \Delta y$, é uma *t-norma*, se satisfizer as seguintes condições:

- $t_1)$ *elemento neutro*: $\Delta(1, x) = 1 \Delta x = x$;
- $t_2)$ *comutativa*: $\Delta(x, y) = x \Delta y = y \Delta x = \Delta(y, x)$;
- $t_3)$ *associativa*: $x \Delta (y \Delta z) = (x \Delta y) \Delta z$;
- $t_4)$ *monotonicidade*: se $x \leq u$ e $y \leq v$, então $x \Delta y \leq u \Delta v$.

A operação *t-norma* estende o operador $\wedge$ que modela o conectivo “e”.

Exemplo 4.1. Consideremos o operador

$$\Delta_1(x, y) = \min \{x, y\} = x \wedge y.$$

É fácil ver que este operador reproduz a tabela verdade de $\wedge$ (a demonstração deste fato fica como exercício para o leitor).

Outros exemplos de t-norma são:

$$\begin{aligned} \Delta_2(x, y) &= xy; \\ \Delta_3(x, y) &= \max \{0, x + y - 1\}; \\ \Delta_4(x, y) &= \begin{cases} x & \text{se } y = 1 \\ y & \text{se } x = 1 \\ 0 & \text{caso contrário} \end{cases}. \end{aligned}$$

Exercício 4.1. Verifique que $\Delta_3 \leq \Delta_2 \leq \Delta_1$.

Definição 4.2 (t-conorma). O operador $\nabla(x, y) = x \nabla y$ é uma *t-conorma* se satisfizer as seguintes condições:

- $c_1)$ *elemento neutro*: $\nabla(0, x) = 0 \nabla x = x$;
- $c_2)$ *comutativa*: $\nabla(x, y) = x \nabla y = y \nabla x = \nabla(y, x)$;
- $c_3)$ *associativa*: $x \nabla (y \nabla z) = (x \nabla y) \nabla z$;
- $c_4)$ *monotonicidade*: se $x \leq u$ e $y \leq v$, então $x \nabla y \leq u \nabla v$.

O operador *t-conorma* $\nabla : [0, 1] \times [0, 1] \longrightarrow [0, 1]$ estende o operador $\vee$ do conectivo “ou”.

Exemplo 4.2. O operador

$$\nabla_1(x, y) = \max \{x, y\} = x \vee y.$$

é uma *t-conorma* que reproduz a tabela verdade do conectivo $\vee$.

Outros exemplos de t-conorma são (verifique):

$$\begin{aligned}\nabla_2(x, y) &= \min \{1, x + y\}; \\ \nabla_3(x, y) &= x + y - xy.\end{aligned}$$

A operação seguinte estende a tabela verdade da negação:

Definição 4.3 (negação). Uma aplicação $\eta : [0, 1] \longrightarrow [0, 1]$ é uma negação se satisfizer as seguintes condições:

- $n_1)$ *fronteiras*: $\eta(0) = 1$ e $\eta(1) = 0$;
- $n_2)$ *involução*: $\eta(\eta(x)) = x$;
- $n_3)$ *monotonicidade*: η é decrescente.

As aplicações

$$\eta_1(x) = 1 - x \text{ e } \eta_2 = \frac{1 - x}{1 + x}$$

reproduzem a tabela verdade da negação $\neg$.

Observamos que as operações $\Delta = \wedge$, $\nabla = \vee$ e $\eta = 1 - x$, satisfazem as leis de De Morgan, isto é, para todo par (x, y) de $[0, 1] \times [0, 1]$ valem

$$\begin{aligned}\eta(x \wedge y) &= \eta(x) \vee \eta(y) \\ \eta(x \vee y) &= \eta(x) \wedge \eta(y).\end{aligned}$$

Exercício 4.2. Prove que para quaisquer t-norma Δ , t-conorma ∇ e negação η as leis de De Morgan são equivalentes.

Dizemos que a t-norma Δ e a t-conorma ∇ são **duais** em relação a uma negação η se satisfazem a uma das duas leis de De Morgan.

Exercício 4.3. Verifique em quais dos sistemas dados abaixo, as t-normas e t-conormas são duais em relação à negação $\eta(x) = 1 - x$:

$$1) \begin{cases} x \Delta y = \max\{x + y - 1, 0\} \\ x \nabla y = \min\{x + y, 1\} \end{cases};$$

$$2) \begin{cases} x \Delta y = xy \\ x \nabla y = x + y - xy \end{cases};$$

$$3) \begin{cases} x \Delta y = \max\{x + y - 1, 0\} \\ x \nabla y = x + y - xy \end{cases};$$

$$4) \begin{cases} x \Delta_H y = \frac{xy}{a + (1 - a)(x + y - xy)} \\ x \nabla_H y = \frac{(a - 2)xy + x + y}{1 + (a - 1)xy} \end{cases}, \quad a \geq 0;$$

Δ_H e ∇_H são denominadas t-norma e t-conorma de Hamacher.

$$5) \begin{cases} x \Delta_F y = \log_a \left[1 + \frac{(a^x - 1)(a^y - 1)}{a - 1} \right] \\ x \nabla_F y = 1 - \log_a \left[1 + \frac{(a^{1-x} - 1)(a^{1-y} - 1)}{a - 1} \right] \end{cases}, \quad a > 0 \text{ e } a \neq 1.$$

Δ_F e ∇_F são denominadas t-norma e t-conorma de Frank.

Um estudo aprofundado sobre t-normas e t-conormas o leitor pode encontrar em [71].

Definição 4.4 (Implicação fuzzy). Um operador $\Rightarrow: [0, 1] \times [0, 1] \rightarrow [0, 1]$ é uma implicação fuzzy se satisfizer as seguintes condições:

1. reproduzir a tabela da implicação clássica;
2. for decrescente na primeira variável, ou seja, para cada $x \in [0, 1]$ tem-se

$$(a \Rightarrow x) \leq (b \Rightarrow x) \text{ se } a \geq b;$$

3. for crescente na segunda variável, ou seja, para cada $x \in [0, 1]$ tem-se

$$(x \Rightarrow a) \geq (x \Rightarrow b) \text{ se } a \geq b.$$

Assim, a classe das implicações fuzzy consiste de todas as aplicações do quadrado $[0, 1] \times [0, 1]$ em $[0, 1]$, cuja restrição aos vértices coincide com os valores da implicação clássica; que sejam decrescentes com relação às abscissas e crescentes em relação às ordenadas.

Como comentamos durante a exposição da implicação clássica, esta pode ser representada por uma das fórmulas:

- (1) $(p \Rightarrow q) = (\neg p) \vee q;$
- (2) $(p \Rightarrow q) = (\neg p) \vee (p \wedge q);$
- (3) $(p \Rightarrow q) = \max\{x \in \{0, 1\} : p \wedge x \leq q\}.$

Para o caso fuzzy, tais fórmulas **não** produzem as mesmas implicações fuzzy (verifique esse fato). Assim, distinguiremos cada uma delas:

- (4) uma S -implicação tem a forma $(x \Rightarrow y) = \eta(x) \nabla y;$

S -implicações são construídas a partir de conormas e conormas são frequentemente chamadas de s -normas [71].

(5) uma Q -implicação tem a forma $(x \implies y) = \eta(x) \nabla (x \triangle y)$;

Q -implicações têm origem em mecânica quântica, daí a letra “ Q ”.

(6) uma R -implicação tem a forma

$$(x \implies y) = \sup\{z \in [0, 1] : x \triangle z \leq y\}.$$

O nome R -implicação vem de operação residual [71] e pode ser interpretado assim: $(x \implies y)$ é o maior valor com que y supera x segundo $\triangle$. Ou seja, é o resíduo de x em relação a y , segundo $\triangle$.

Veja que para o caso clássico, $(p \implies q)$ é o que “falta” para que p seja q segundo $\wedge$.

Exercício 4.4. Verifique que cada uma das operações S , Q e R , da Definição 4.4 são de fato implicações fuzzy, quaisquer que sejam as t -normas, t -conormas e negação.

Exemplo 4.3 (Implicações fuzzy). As seguintes operações são implicações fuzzy:

a) Implicação de Gödel:

$$(x \implies y) = g(x, y) = \begin{cases} 1 & \text{se } x \leq y \\ y & \text{se } x > y \end{cases}.$$

b) Implicação de Goguen:

$$(x \implies y) = g_n(x, y) = \begin{cases} 1 & \text{se } x \leq y \\ \frac{y}{x} & \text{se } x > y \end{cases}.$$

c) Implicação de Lukasiewicz:

$$(x \implies y) = \ell(x, y) = \min\{(1 - x + y), 1\}.$$

d) Implicação de Kleene-Dienes:

$$(x \implies y) = k_d(x, y) = \max \{ (1 - x), y \}.$$

e) Implicação de Reichenbach:

$$(x \implies y) = r(x, y) = (1 - x + xy).$$

f) Implicação de Zadeh:

$$(x \implies y) = z(x, y) = \max \{ (1 - x), \min(x, y) \}.$$

g) Implicação de Gaines-Rescher:

$$(x \implies y) = g_r(x, y) = \begin{cases} 1 & \text{se } x \leq y \\ 0 & \text{se } x > y \end{cases}.$$

h) Implicação de Wu:

$$(x \implies y) = w(x, y) = \begin{cases} 1 & \text{se } x \leq y \\ \min \{ 1 - x, y \} & \text{se } x > y \end{cases}.$$

Observe que a implicação de Zadeh é uma Q -implicação

$$(x \implies y) = (1 - x) \vee (x \wedge y) = \eta(x) \vee (x \wedge y).$$

Exercício 4.5. Resolva os itens abaixo.

- Verifique que as implicações de Gödel e de Goguen são R -implicações, supondo $\Delta = \min$ para Gödel e $\Delta = \text{produto}$ para Goguen.
- Dentre as implicações fuzzy acima, dê exemplos de S -implicações, de Q -implicações e de R -implicações, supondo $\eta(x) = 1 - x$.

c) Verifique que $g(x, y) \leq g_n(x, y)$ para x e y no intervalo $[0, 1]$.

Exercício 4.6. Esboce os gráficos das implicações do Exemplo 4.3.

O leitor interessado em aprofundar seus estudos em operadores lógicos e em cálculo proposicional fuzzy pode consultar Hajék [58], Nguyen [95], Klir e Yuan [72], Pedricz e Gomide [100], Wangning [125] e suas referências. Nosso interesse aqui está mais direcionado às manipulações e interpretações de fórmulas nas quais aparecem esses conectivos básicos.

Exemplo 4.4. Vamos voltar à expressão (4.1) e obter seu valor lógico quando considerarmos $\triangle = \wedge$, $\nabla = \vee$, $\eta(x) = 1 - x$ e a implicação de Gödel.

Inicialmente, para cada célula p, q, r e s , da expressão (4.1), tomamos seu valor lógico como o grau de pertinência de cada elemento ao conjunto relacionado. Consideremos, por exemplo, que tais valores sejam: $\varphi_A(a) = 0,6$; $\varphi_B(b) = 0,7$; $\varphi_C(c) = 0,4$ e $\varphi_D(d) = 0,7$. Então, temos:

$$\begin{aligned} p \triangle q &= \min(0,6; 0,7) = 0,6; \\ s &= 1 - \varphi_D(d) = 1 - 0,7 = 0,3; \\ r \nabla s &= \max(0,4; 0,3) = 0,4. \end{aligned}$$

Logo, o valor lógico de (4.1) é o resultado da aplicação

$$(p \triangle q) \implies (r \nabla s).$$

Supondo que a implicação seja a de Gödel, então

$$(p \triangle q) \implies (r \nabla s) = \begin{cases} 1 & \text{se } (p \triangle q) \leq (r \nabla s) \\ (r \nabla s) & \text{se } (p \triangle q) > (r \nabla s) \end{cases} = 0,4;$$

pois $(p \triangle q) = 0,6$ e $(r \nabla s) = 0,4$.

Assim, para as pertinências acima, a expressão (4.1) é verdade com grau 0,4.

Exercício 4.7. Refaça o Exemplo 4.4 para as outras implicações dadas no Exemplo 4.3.

Muitas das implicações do Exemplo 4.3 são obtidas a partir de combinações de t-normas e t-conormas e são utilizadas para modelar *proposições fuzzy* em *raciocínio aproximado*. Esse assunto tem grande interesse nos métodos de resoluções das *equações relacionais* e dos *sistemas baseados em regras fuzzy*, como os controladores de Mamdani. Estes tópicos serão ainda estudados nos Capítulos 5 e 6. O leitor interessado em mais detalhes sobre as implicações fuzzy, voltadas para modelagem de processos em engenharia, poderá consultar [72, 95, 100, 125].

4.3 Raciocínio Aproximado e Variáveis Linguísticas

O raciocínio aproximado refere-se ao processo onde se pode obter conclusões a partir de premissas incertas. Quando esta incerteza é considerada fuzzy, é frequente o uso do termo raciocínio fuzzy.

A seguinte forma de raciocínio é muito comum na vida diária:

$$\text{“Se a banana está amarela então a banana está madura”} \quad (4.2)$$

ou seja,

“Caso se tenha uma banana amarela, é automática sua classificação como madura”.

De uma forma mais geral podemos ter algo como:

$$\text{“Se } X \text{ é } \Diamond \text{ então } Y \text{ é } \Box\text{.”} \quad (4.3)$$

Neste caso, sabendo-se que X é $\Diamond$, conclui-se que Y é $\Box$.

Esta é uma generalização do conhecido método dedutivo **modus ponens**. A diferença para o modus ponens clássico está na subjetividade dos predicados envolvidos. As sentenças gerais (4.3) acima são

expressas em uma linguagem “natural” sem o formalismo da linguagem matemática. Nosso interesse é um modelo matemático para a mesma usando lógica fuzzy.

Voltando à nossa sentença (4.1), esta tem uma diferença substancial para a sentença (4.3), a saber, nesta última não há qualquer conjunto (clássico ou fuzzy) envolvido, e sim, qualificações a respeito das variáveis X e Y .

Para expressar formalmente sentenças com variáveis como em (4.3) é que se “unem” as teorias dos conjuntos fuzzy e a de lógica fuzzy. Para se obter uma avaliação lógica de (4.3) a ideia é reescrevê-la na forma da sentença (4.1) e, para isto, faz-se necessário o conceito de *variável linguística*.

Definição 4.5 (Variável linguística). Uma *variável linguística* X no universo U é uma variável cujos valores assumidos são subconjuntos fuzzy de U .

Intuitivamente, uma variável linguística é um substantivo, enquanto seus valores são adjetivos, representados por conjuntos fuzzy. Por exemplo, “gripe” é uma variável linguística que pode assumir os atributos “forte” ou “fraca”.

Sentenças em que aparecem variáveis linguísticas juntamente com seus valores subjetivos (atributos) são comumente chamadas de proposições fuzzy. Entretanto, o interesse aqui são aquelas variáveis cujos valores assumidos são **números fuzzy** onde o universo de discurso é o conjunto dos números reais. Neste caso, diz-se que o suporte da variável é o conjunto dos números reais e X é uma variável linguística real.

Convém observar que, dependendo das circunstâncias, devemos ler “ X é A ” ou “ X está em A ”, numa linguagem conjuntista (em inglês não há essa distinção). Também deve ser esclarecido que X é A (ou X está em A) significa “ $X = x$ é A ” (ou “ $X = x$ está em A ”). Dessa forma é que a sentença (4.3) pode ter seu valor lógico, a exemplo da sentença

(4.1).

O valor lógico de “ $X = x$ é A ” é o número $\varphi_A(x)$ que indica o quanto $X = x$ está em concordância com o termo linguístico modelado pelo conjunto fuzzy A . Por esse motivo, e para facilitar a notação, quando não houver dúvidas sobre as variáveis, usaremos apenas os valores de interesse assumidos por elas em cada proposição fuzzy, ou seja, usaremos “ x é A ” (ou “ x está em A ”), no lugar de “ $X = x$ é A ” (ou “ $X = x$ está em A ”).

A seguir usaremos a noção de variáveis linguísticas para formular os métodos dedutivos **modus ponens** para o caso fuzzy.

4.4 Modus Ponens e Modus Ponens Generalizado

Nosso interesse inicial é modelar matematicamente o **modus ponens fuzzy**:

$$\begin{array}{ll} p \implies q : & \text{“Se } x \text{ é } A \text{ então } y \text{ é } B\text{”} \\ \text{Fato:} & \text{“} x \text{ é } A\text{”} \\ \text{Conclusão:} & \text{“} y \text{ é } B\text{”} \end{array}$$

Note que $(p \implies q)$ é uma proposição fuzzy condicional que é modelada por uma relação fuzzy $\mathcal{R}$ de $U \times V$, cuja função de pertinência é

$$\varphi_{\mathcal{R}}(x, y) = [\varphi_A(x) \implies \varphi_B(y)],$$

onde x e y são valores de variáveis linguísticas de U e V , respectivamente.

Assim, o valor da sentença “Se x é A então y é B ” depende da implicação a ser escolhida.

A implicação clássica, isto é, $\varphi_A(x) \in \{0, 1\}$ e $\varphi_B(y) \in \{0, 1\}$, produz

a relação fuzzy cuja função de pertinência é dada por:

$$\begin{aligned}\varphi_{\mathcal{R}}(x, y) &= \chi_{\mathcal{R}}(x, y) = (\chi_A(x) \implies \chi_B(y)) = \\ &= \begin{cases} 1 & \text{se } (x \notin A \text{ e } y \text{ qualquer}) \text{ ou } (x \in A \text{ e } y \in B) \\ 0 & \text{se } x \in A \text{ e } y \notin B \end{cases}\end{aligned}$$

de modo que

$$\sup_{x \in U} [\chi_{\mathcal{R}}(x, y) \wedge \chi_A(x)] = \begin{cases} 1 & \text{se } y \in B \\ 0 & \text{se } y \notin B \end{cases} = \chi_B(y),$$

ou seja, para o caso clássico, o modus ponens pode ser escrito matematicamente por meio da fórmula:

$$\chi_B(y) = \sup_{x \in U} [\chi_{\mathcal{R}}(x, y) \wedge \chi_A(x)].$$

De acordo com a notação vista no Capítulo 3, o modus ponens clássico pode ser dado pela regra de composição de inferência $B = A \circ \mathcal{R}$, em que a relação $\mathcal{R}$ é obtida por meio de uma implicação fuzzy que modela a sentença condicional

“Se $x \in A$ então $y \in B$ ”.

Com o propósito de inferir conjuntos fuzzy, esta fórmula será estendida para situações fuzzy mais gerais tais como o **modus ponens fuzzy** e o **modus ponens fuzzy generalizado**.

O modus ponens fuzzy modela o seguinte silogismo:

Regra:	“Se a banana está amarela, então está madura”
Fato:	“A banana está amarela”
Conclusão:	“A banana está madura”

A lógica fuzzy revela seu grande potencial na modelagem de cada uma das sentenças acima. Os substantivos e seus atributos são modelados por

conjuntos fuzzy (por funções de pertinência) enquanto que os conectivos por operadores como t-normas e t-conormas, implicações e/ou negações. A conclusão, que deve ser um conjunto fuzzy, é obtida pela extensão da regra de composição de inferência

$$\chi_B(y) = \sup_{x \in U} [\chi_{\mathcal{R}}(x, y) \wedge \chi_A(x)], \quad (4.4)$$

substituindo as funções características por funções de pertinência e o operador $\wedge$ por alguma t-norma, ou seja,

$$\varphi_B(y) = \sup_{x \in U} [\varphi_{\mathcal{R}}(x, y) \triangle \varphi_A(x)]. \quad (4.5)$$

Em resumo, a fórmula (4.5) é a regra de inferência que modela o **modus ponens fuzzy**

Regra:	“Se x é A , então y é B ”
Fato:	“ x é A ”
Conclusão:	“ y é B ”

O lado direito da Equação (4.5) exige que a t-norma e a implicação fuzzy lá adotadas sejam escolhidas de modo que a saída coincida com $\varphi_B(y)$ para todo y .

Esse é um problema de equação relacional e pode trazer algumas dificuldades que foge de nosso interesse no estudo de raciocínio aproximado. Tal assunto será estudado no Capítulo 6. Por essa razão, estenderemos a Equação (4.5) admitindo uma entrada A^* no lugar de A e a flexibilizaremos deixando de exigir que a saída B^* seja B , para a entrada $A = A^*$. Neste caso, denominaremos o silogismo por **modus ponens fuzzy generalizado**, que tem a forma geral:

Regra:	“Se x é A , então y é B ”
Fato:	“ x é A^* ”
Conclusão:	“ y é B^* ”

A saída do **modus ponens fuzzy generalizado** é o conjunto fuzzy B^* , cuja função de pertinência é

$$\varphi_{B^*}(y) = \sup_{x \in U} [\varphi_{\mathcal{R}}(x, y) \triangle \varphi_{A^*}(x)], \quad (4.6)$$

que, por analogia à regra de composição de inferência vista no Capítulo 3, tem a forma

$$\mathcal{R}(A^*) = A^* \otimes^t \mathcal{R} = B^*,$$

onde $\otimes^t$ é uma operação análoga à “ $\circ$ ”, trocando-se a t-norma do mínimo por $\triangle$. Veremos essa operação com mais detalhes no Capítulo 6.

Vale a pena reforçar o seguinte comentário: no caso clássico, sempre temos $\mathcal{R}(A) = B$. Porém, no caso fuzzy, dependendo da t-norma e da implicação, nem sempre teremos $\mathcal{R}(A) = B$. Esse fato não desabona o uso das fórmulas (4.5) ou (4.6).

É bastante comum se obter um funcional teórico, sem que esse funcional reproduza os dados que o originaram. Esse é o caso do famoso método dos mínimos quadrados, cuja principal propriedade é obter o funcional com menor erro quadrático possível para o conjunto de dados. Métodos para obter funcionais que reproduzam exatamente os dados que o originaram costumam ser chamados de interpolação. Esse assunto aparecerá novamente em capítulos futuros e lá faremos novas observações.

Exemplo 4.5. Suponha a t-norma do produto, $x \triangle y = xy$, e a implicação

$$(x \implies y) = \begin{cases} 1 & \text{se } x = 0 \\ 1 \wedge \frac{y}{x} & \text{se } x \neq 0 \end{cases}.$$

Dados os números fuzzy A e B , temos

$$(\varphi_A(x) \implies \varphi_B(y)) \cdot \varphi_A(x) = \varphi_A(x) \wedge \varphi_B(y).$$

Assim,

$$\begin{aligned}\sup_{x \in U} [\varphi_R(x, y) \triangle \varphi_A(x)] &= \sup_{x \in U} [(\varphi_A(x) \implies \varphi_B(y)) \cdot \varphi_A(x)] \\ &= \sup_{x \in U} [\varphi_A(x) \wedge \varphi_B(y)] = \varphi_B(y).\end{aligned}$$

ou seja, $\mathcal{R}(A) = B$.

Exercício 4.8. Verifique se $R(A) = B$ para a t-norma do mínimo, $x \triangle y = x \wedge y$, considerando:

- a) implicação de Zadeh;
- b) implicação Wu.

Vamos analisar um caso em que os conjuntos envolvidos são finitos.

Exemplo 4.6. Consideremos os subconjuntos fuzzy:

$$A = 0,4/x_1 + 1,0/x_2 + 0,6/x_3 \quad \text{e} \quad B = 0,8/y_1 + 0,4/y_2,$$

a implicação de Lukasiewicz:

$$(x \implies y) = \min \{ (1 - x + y), 1 \}$$

e a t-norma $\triangle_1 = \wedge$.

Vamos obter as saídas a partir da fórmula (4.5) para cada entrada.

Lembrando que a implicação

$$\varphi_{\mathcal{R}}(x, y) = (\varphi_A(x) \implies \varphi_B(y))$$

é a de Lukasiewicz, temos

$$\begin{aligned}\mathcal{R} &= 1,0/(x_1, y_1) + 1,0/(x_1, y_2) + 0,8/(x_2, y_1) + \\ &\quad + 0,4/(x_2, y_2) + 1,0/(x_3, y_1) + 0,8/(x_3, y_2).\end{aligned}$$

Desta forma, para a entrada

$$A = 0,4/x_1 + 1,0/x_2 + 0,6/x_3 ,$$

temos a saída $\tilde{B}$ com função de pertinência

$$\begin{aligned}\varphi_{\tilde{B}}(y_1) &= \max_{x_i} [\varphi_{\mathcal{R}}(x_i, y_1) \wedge \varphi_A(x_i)] = \\ &= \max[\min(1, 0; 0,4); \min(0,8; 1, 0); \min(1, 0; 0,6)] = 0,8; \\ \varphi_{\tilde{B}}(y_2) &= \max_{x_i} [\varphi_{\mathcal{R}}(x_i, y_2) \wedge \varphi_A(x_i)] = \\ &= \max[\min(1, 0; 0,4); \min(0,4; 1, 0); \min(0,8; 0,6)] = 0,6.\end{aligned}$$

e, para a entrada

$$A^* = 0,6/x_1 + 0,9/x_2 + 0,7/x_3 ,$$

temos a saída B^* com função de pertinência

$$\begin{aligned}\varphi_{B^*}(y_1) &= \max_{x_i} [\varphi_{\mathcal{R}}(x_i, y_1) \wedge \varphi_{A^*}(x_i)] \\ &= \max[\min(1, 0; 0,6); \min(0,8; 0,9); \min(1, 0; 0,7)] = 0,8; \\ \varphi_{B^*}(y_2) &= \max_{x_i} [\varphi_{\mathcal{R}}(x_i, y_2) \wedge \varphi_{A^*}(x_i)] \\ &= \max[\min(1, 0; 0,6); \min(0,4; 0,9); \min(0,8; 0,7)] = 0,7.\end{aligned}$$

Desta forma, para este exemplo, as saídas obtidas pelo modus ponens fuzzy generalizado são

$$\mathcal{R}(A) = \tilde{B} = 0,8/y_1 + 0,6/y_2 \quad \text{e} \quad \mathcal{R}(A^*) = B^* = 0,8/y_1 + 0,7/y_2.$$

É interessante notar que $B \subset \tilde{B}$. Este fato é de interesse em raciocínio aproximado, pois indica que B poderia ser uma saída ótima em algum

sentido. Estudos para investigar propriedades como essa e/ou que $\tilde{B} = B$ serão vistos num contexto um pouco diferente no Capítulo 6.

O leitor interessado em se aprofundar neste assunto pode consultar [88, 89, 125, 128] e muitos outros artigos sobre raciocínio aproximado.

Método Prático

A partir da observação feita após a fórmula (4.6), temos

$$B^* = A^* \otimes^t \mathcal{R},$$

em que, para o caso de domínios finitos, A^* e B^* são escritos em linha e

$$[\mathcal{R}] = [\varphi_{\mathcal{R}}(x_i, y_j)]_{i \times j}$$

onde “ $\otimes^t$ ” é a composição sup-t (ver Capítulo 6).

No exemplo anterior temos

$$\mathcal{R} = [\varphi_{\mathcal{R}}(x_i, y_j)]_{3 \times 2} = \begin{bmatrix} 1,0 & 1,0 \\ 0,8 & 0,4 \\ 1,0 & 0,8 \end{bmatrix}_{3 \times 2},$$

$$A = \begin{bmatrix} 0,4 & 1,0 & 0,6 \end{bmatrix}$$

e a composição é a max-min, uma vez que $\Delta = \wedge$.

Logo,

$$\tilde{B} = A \circ \mathcal{R} = \begin{bmatrix} 0,4 & 1,0 & 0,6 \end{bmatrix} \circ \begin{bmatrix} 1,0 & 1,0 \\ 0,8 & 0,4 \\ 1,0 & 0,8 \end{bmatrix} = \begin{bmatrix} 0,8 & 0,6 \end{bmatrix},$$

ou seja,

$$\tilde{B} = \frac{0,8}{y_1} + \frac{0,6}{y_2}.$$

Nosso objetivo agora é usar o modus ponens generalizado para modelar situações em que a subjetividade pode ser ligeiramente modificada. Por exemplo, no caso da “banana”, se for observado que sua cor é *quase amarela*, esta cor pode ser considerada como sendo *amarela ligeiramente modificada*. Em casos como este são utilizados os operadores denominados modificadores.

4.5 Modificadores Linguísticos

Como o próprio nome sugere, modificadores linguísticos são frequentemente utilizados para alterar atributos, ou seja, modelar advérbios. A teoria dos conjuntos fuzzy, quando combinada com o modus ponens fuzzy generalizado, ajuda na produção de subconjuntos fuzzy que representam atributos de variáveis linguísticas. Neste caso, os modificadores linguísticos são denominados modificadores fuzzy.

Definição 4.6 (Modificador fuzzy). Um *modificador fuzzy* m sobre U é uma aplicação definida em $\mathcal{F}(U)$ com valores em $\mathcal{F}(U)$:

$$m : \mathcal{F}(U) \longrightarrow \mathcal{F}(U). \quad (4.7)$$

Os principais modificadores fuzzy são:

- (i) *Expansivo* se, para todo $A \in \mathcal{F}(U)$, $A \subseteq m(A)$, ou seja, $\varphi_A(x) \leq \varphi_{m(A)}(x)$;
- (ii) *Restritivo* se, para todo $A \in \mathcal{F}(U)$, $A \supseteq m(A)$, ou seja, $\varphi_A(x) \geq \varphi_{m(A)}(x)$.

Os modificadores fuzzy mais usados são do tipo potência. Um modificador é do tipo *potência* se para cada $A \in \mathcal{F}(U)$ tem-se

$$m_s(A) := (A)^s,$$

ou seja,

$$\varphi_{m(A)}(x) = (\varphi_A(x))^s,$$

para algum $s \in [0, \infty)$.

Podemos observar que se $s < 1$ então m_s é expansivo e se $s > 1$ então m_s é restritivo, já que $\varphi_A(x) \in [0, 1]$.

Exemplo 4.7. Consideremos o conjunto fuzzy dos indivíduos “jovens” definido pela função de pertinência

$$\varphi_J(x) = \begin{cases} 1 & \text{se } x \leq 25 \\ \left(1 + \frac{x - 25}{5}\right)^{-2} & \text{se } x > 25 \end{cases}.$$

Quando aplicamos modificadores fuzzy em termos primários como o adjetivo “jovem”, definimos novos termos fuzzy como “muito jovem”, por exemplo. Assim, se tomarmos para “muito jovem” o subconjunto fuzzy MJ , cuja função de pertinência é dada por

$$\varphi_{MJ}(x) = \varphi_{m(J)}(x) = (\varphi_J(x))^2,$$

teremos o modificador $m(A) = (A)^2$ e, para um indivíduo cuja idade é $x = 30$, seu grau de pertinência ao conjunto dos “jovens” é $\varphi_J(30) = 0,25$ enquanto que, para o conjunto modificado dos “muito jovens” temos $\varphi_{MJ}(30) = 0,25^2 = 0,0625 < \varphi_J(30)$.

Para estudos mais aprofundados, o leitor pode consultar [42, 72].

Exemplo 4.8. Vamos voltar ao caso das “bananas”, que motivou os estudos dessa seção.

Regra: “Se a banana está amarela, então está madura”

Fato: “A banana está amarela”

Conclusão: “A banana está madura”

Agora, a ideia é reescrever a condicional

“Se a banana está amarela então está madura”

na forma

“Se X é A então Y é B ,

daí obter a relação $\mathcal{R}$, dada por uma implicação fuzzy, cuja função de pertinência é

$$\varphi_{\mathcal{R}}(x, y) = (\varphi_A(x) \implies \varphi_B(y)).$$

O conceito de “amarelo” é representado aqui por um conjunto fuzzy, obtido a partir do cromatismo que apresenta diferentes tonalidades de amarelo, isto é, nem todo amarelo é igual. No caso de banana amarela, podemos traduzir o conceito de amarelo por uma função de pertinência obtida do espectro de cores que vai do verde ao amarelo, cujo comprimento de onda λ varia entre 530 nm a 597 nm. Adotamos que a tonalidade da banana é dada pela diferença entre seu comprimento de onda e o do verde 530 nm. Assim sendo, a função de pertinência que define “banana amarela” pode ser dada por:

$$\varphi_A(x) = \begin{cases} \frac{x}{60} & \text{se } 0 \leq x \leq 60 \\ 1 & \text{se } 60 < x \leq 67 \end{cases}.$$

Estamos supondo que, para x entre 60 nm e 67 nm as tonalidades do amarelo são indistinguíveis e, portanto, nesta faixa o grau de pertinência ao conjunto fuzzy “amarelo” será 1.




Figura 4.1: Função de pertinência do conjunto fuzzy “amarelo” em nanômetros.

A modelagem do termo “banana madura” é decorrente do valor percentual de açúcar existente na fruta. Especialistas dizem que uma banana está certamente madura quando a concentração de açúcar apresentada na mesma estiver entre 19% e 25%. Um meio de detectar o nível de açúcar é o próprio paladar humano.

A função de pertinência do conjunto fuzzy “banana madura” pode ser dada por

$$\varphi_B(y) = \begin{cases} \frac{y}{19} & \text{se } 0 \leq y \leq 19 \\ 1 & \text{se } 19 < x \leq 25 \end{cases}.$$




Figura 4.2: Função de pertinência do conjunto fuzzy “banana madura”.

Agora, vamos supor que o termo “quase amarelo” seja modelado por um subconjunto fuzzy A^* , que é obtido por meio da aplicação de um modificador fuzzy expansivo ao subconjunto fuzzy A :

$$\varphi_{A^*}(x) = \varphi_{m(A)}(x) = (\varphi_A(x))^s \text{ com } s \leq 1.$$

Finalmente, para obter a saída B^* que indica o termo “quase madura”, adotaremos um modus ponens generalizado com a implicação de Wu e a t-norma do mínimo: $x \triangle y = x \wedge y$.

Logo, $B^* = \mathcal{R}(A^*)$, cuja função de pertinência é dada por

$$\begin{aligned}
 \varphi_{B^*}(y) &= \varphi_{\mathcal{R}(A^*)}(y) = \varphi_{\mathcal{R}m(A)}(y) = \sup_x [\varphi_{\mathcal{R}}(x, y) \wedge \varphi_{m(A)}(x)] \\
 &= \sup_x [(\varphi_A(x) \Rightarrow \varphi_B(y)) \wedge \varphi_{m(A)}(x)] \\
 &= \max \left\{ \sup_{\varphi_A(x) \leq \varphi_B(y)} [\varphi_{m(A)}(x) \wedge 1], \sup_{\varphi_A(x) > \varphi_B(y)} [(1 - \varphi_A(x)) \wedge \varphi_B(y) \wedge \varphi_{m(A)}(x)] \right\} \\
 &= \max \left\{ \sup_{\varphi_A(x) \leq \varphi_B(y)} (\varphi_A(x))^s, \sup_{\varphi_A(x) > \varphi_B(y)} [(1 - \varphi_A(x)) \wedge \varphi_B(y) \wedge (\varphi_A(x))^s] \right\} \\
 &= \max \left\{ \sup_{\varphi_A(x) \leq \varphi_B(y)} (\varphi_A(x))^s, \sup_{\varphi_A(x) > \varphi_B(y)} (1 - \varphi_A(x)) \wedge \varphi_B(y) \right\} \\
 &= \max \{ (\varphi_B(y))^s, (1 - \varphi_B(y)) \wedge \varphi_B(y) \} = (\varphi_B(y))^s.
 \end{aligned}$$

Portanto,

$$\varphi_{B^*}(y) = (\varphi_B(y))^s \geq \varphi_B(y), \text{ para } s \in (0, 1].$$

Veja que $\mathcal{R}(A) = B$ ($s = 1$). A prova acima é válida porque $Im(\varphi_A) = [0, 1]$, ou seja, A é normal. Essa hipótese é necessária [72], pois caso contrário, tal prova não seria válida. Ver Exercício 4.8 (b), com dados do Exemplo 4.6

Numa linguagem conjuntista temos

$$B^* = m(B) \supset B.$$

O fato de B estar contido em $m(B)$ significa que uma banana quase madura será sempre menos madura (Figura 4.3). Uma banana amarela é madura, logo uma banana menos amarela será menos madura.

A conclusão ou saída dada pelo conjunto B^* “quase madura” ou “menos madura” pode ser visualizada na Figura 4.3 (b).

Para encerrar esse exemplo vamos explorar um pouco mais o fato que $B^* = m(B)$.





Figura 4.3: Conjuntos fuzzy modificados.

Observemos que

$$\mathcal{R}(m(A)) = \mathcal{R}(A^*) = B^* = m(B) = m(\mathcal{R}(A)),$$

ou na forma de diagrama da Figura 4.4.

Figura 4.4: Diagrama de comutação de $\mathcal{R}$ e m .

O fato de se obter $\mathcal{R}(m(A)) = m(\mathcal{R}(A))$ indica que o diagrama comuta e significa que *a saída de A modificado é a mesma que a modificação da saída de A*.

Para o nosso exemplo, a comutatividade do diagrama acima significa que o grau de modificação sofrido pela maturação da banana é o mesmo que grau de modificação de tonalidade da sua cor.

Em lógica fuzzy, comutatividade de diagrama é ainda pouco explorada

e o leitor está convidado a investigar tal propriedade, tanto do ponto de vista teórico quanto das aplicações.

Exercício 4.9. Refaça o Exemplo 4.8, considerando o modificador potência com $s > 1$ e verifique para este caso se $\mathcal{R}(m(A)) = m(\mathcal{R}(A))$. Em seguida, use outras implicações e t-normas para obter novos conjuntos fuzzy de saídas B^* .

4.6 Independência e Não-Interatividade

Nesta seção faremos uma breve introdução do conceito de não - interatividade possibilística, introduzido por Zadeh [131], o qual tem relação estreita com independência probabilística. O termo “possibilística” é usado aqui em referência à “pertinência”. Tal conceito será melhor formalizado na Seção 7.1.3.

Atualmente há um grande número de pesquisadores interessados nesse tema, com aplicações nas mais diversas áreas (ver [52, 32, 8, 2]). Nosso principal interesse nesse texto é apenas no conceito que, a nosso ver, está intimamente ligado ao Modus Ponens.

Intuitivamente, independência está associada à ideia de “não interferência” ao passo que interatividade está ligada à “ação mútua” entre duas ou mais coisas. Duas substâncias químicas, por exemplo, são não interativas se suas partículas são identificadas quando olhadas conjuntamente e separadamente: água e óleo.

Tanto a independência quanto a não-interatividade entre dois objetos dependem fortemente do que se pretende medir, bem como da medida adotada. Por exemplo, na mistura de duas substâncias químicas podemos estar interessados em observar alterações de suas densidades, vistas inicialmente separadas e depois conjuntamente. Por outro lado, podemos nos interessar na alteração da coloração, separadamente e conjuntamente. A densidade poderia estar associada à probabilidade enquanto

a coloração (que trata de identificação da cor) poderia ser associada à pertinência (ou possibilidade).

O comentário acima tem como único objetivo ilustrar ao leitor que em um mesmo experimento (mistura de duas substâncias) vários estudos podem ser feitos: densidade e coloração, e para cada um deles, devemos adotar ferramentas adequadas. No caso, probabilidade para medir densidade e possibilidade para medir coloração.

Com o intuito de traçar um paralelo com o tema que iremos estudar, apresentaremos a seguir o conceito de independência e não-interatividade probabilística.

4.6.1 Independência e Não-Interatividade Probabilística

Vamos aqui nos deter apenas ao caso discreto. O caso contínuo é análogo, substituindo a distribuição de probabilidades pela função densidade de probabilidades.

Sejam X e Y duas variáveis aleatórias discretas. Supondo que $P_{(X,Y)}$ seja a distribuição de probabilidades conjunta do vetor aleatório (X, Y) , é sabido [31, 72] que:

(p_1) as *distribuições marginais* de X e Y são dadas, respectivamente, por

$$P_X(x) = \sum_y P_{(X,Y)}(x, y) \quad \text{e} \quad P_Y(y) = \sum_x P_{(X,Y)}(x, y).$$

(p_2) X e Y são *não-interativas*, probabilisticamente, se

$$P_{(X,Y)}(x, y) = P_X(x) \cdot P_Y(y)$$

para todo par (x, y) . Caso contrário, são ditas *interativas* [72].

(p_3) as *distribuições condicionais* de X e Y são dadas, respectivamente,

por

$$P_{X|Y}(x|y) = \frac{P_{(X,Y)}(x,y)}{P_Y(y)} \Leftrightarrow P_{(X,Y)}(x,y) = P_{X|Y}(x|y) \cdot P_Y(y)$$

se $P_Y(y) \neq 0$ e

$$P_{Y|X}(y|x) = \frac{P_{(X,Y)}(x,y)}{P_X(x)} \Leftrightarrow P_{(X,Y)}(x,y) = P_{Y|X}(y|x) \cdot P_X(x)$$

se $P_X(x) \neq 0$.

(p_4) X e Y são *independentes*, probabilisticamente, se

$$P_{(X|Y)}(x|y) = P_X(x) \quad \text{e} \quad P_{(Y|X)}(y|x) = P_Y(y)$$

para todo par (x, y) . Caso contrário, são ditas *dependentes*.

É claro que os conceitos de independência (p_4) e não-interatividade probabilística (p_2) são equivalentes se as marginais não se anularem. Esse fato é consequência da operação matemática “multiplicação” utilizada para modelar tais conceitos.

No entanto, há autores que não defendem tal equivalência e assim se utilizam de operações matemáticas mais “gerais” para representar matematicamente esses conceitos. Essas operações são conhecidas na literatura como cópulas e têm relações estreitas com as t-normas. A propósito, como já sabemos, a operação de “multiplicação” utilizada em (p_2) e (p_4) é uma particular t-norma.

Um resultado geral que relaciona a distribuição de probabilidades conjunta com as marginais, via cópula, é devido a Sklar, o qual o leitor pode encontrar em [71].

4.6.2 Independência e Não-Interatividade Possibilística

Aqui os objetos matemáticos são conjuntos fuzzy ao invés de variáveis aleatórias. Consequentemente, o que temos são distribuições de possibilidades (ou de pertinências).

Diferentemente do caso probabilístico, em que a cópula mais utilizada na literatura é o produto, no caso fuzzy o operador mais comum para tratar a não-interatividade é o mínimo. No entanto, nesse texto usaremos uma t-norma geral para tratar matematicamente os conceitos envolvidos.

Suponha que $\varphi_{(A,B)}$ seja a distribuição de possibilidades conjunta dos conjuntos A e B .

(f_1) As *distribuições de possibilidades marginais* [52] de A e B são dadas, respectivamente, por

$$\varphi_A(x) = \sup_y \varphi_{(A,B)}(x, y) \quad \text{e} \quad \varphi_B(y) = \sup_x \varphi_{(A,B)}(x, y).$$

(f_2) A e B são possibilisticamente *não-interativos*, segundo a t-norma Δ , se

$$\varphi_{(A,B)}(x, y) = \varphi_A(x) \Delta \varphi_B(y),$$

para todo par (x, y) . A e B são ditos *não-interativos* se a t-norma for a do mínimo, isto é, se

$$\varphi_{(A,B)}(x, y) = \varphi_A(x) \wedge \varphi_B(y).$$

(f_3) As *distribuições de possibilidades condicionais* de A e B , segundo a t-norma Δ , de A e B são dadas, respectivamente, através das fórmulas

$$\varphi_{(A,B)}(x, y) = \varphi_{(A|B)}(x|y) \Delta \varphi_B(y)$$

e

$$\varphi_{(A,B)}(x, y) = \varphi_{(B|A)}(y|x) \triangle \varphi_A(x).$$

(f_4) A e B são possibilisticamente *independentes* se

$$\varphi_{(A|B)}(x|y) = \varphi_A(x) \quad \text{e} \quad \varphi_{(B|A)}(y|x) = \varphi_B(y).$$

para todo par (x, y) . Caso contrário, são ditas possibilisticamente *dependentes*.

Diferentemente do caso probabilístico, aqui a não-interatividade não equivale à independência. A independência implica a não-interatividade. Porém, a recíproca não é, em geral, verdadeira.

É interessante ressaltar que no dois casos - probabilístico e fuzzy - as marginais estão relacionadas com a conjunta por fórmulas semelhantes. Para o caso probabilístico usa-se a somatória, enquanto que para o caso fuzzy aparece o **sup** no lugar de $\sum$.

4.6.3 As distribuições Condicionais e o Modus Ponens: Uma Visão Bayesiana

A regra condicional

$$R: \text{“se } x \text{ é (está em) } A \text{ então } y \text{ é (está em) } B\text{”}$$

no modus ponens poderia ser interpretada como “ y é (está em) B com grau $\varphi_B(y)$, dado que x é (está em) A com grau $\varphi_A(x)$ ”. Sob essa ótica, a função de pertinência φ_R que representa a regra R é uma típica distribuição de pertinência condicional, isto é,

$$\varphi_R(x, y) = (\varphi_A(x) \Rightarrow \varphi_B(y)) = \varphi_{B|A}(y|x). \quad (4.8)$$

Com essa interpretação, temos uma fórmula para obter distribuições condicionais, isto é, para uma regra lógica de causalidade, temos uma

maneira de obter a distribuição condicional de pertinência. Para isto, basta conhecer a implicação fuzzy a ser adotada e, a partir daí, usar a fórmula (4.8).

Dessa forma, a fórmula (4.5) do modus ponens passa a ser

$$\varphi_{R(A)}(y) = \sup_x (\varphi_{B|A}(y|x) \triangle \varphi_A(x)). \quad (4.9)$$

Essa fórmula sugere que, numa linguagem bayesiana, φ_B seja a distribuição de possibilidades *priori* de B , enquanto que $\varphi_{R(A)}$ é a distribuição *posteriori* de B observado A .

Extrapolando essa ideia para o modus ponens generalizado, podemos dizer que $\varphi_{B^*}(y) = \varphi_{R(A^*)}(y)$ é a distribuição de possibilidades *posteriori* de B observado A^* e (4.6) toma a forma

$$\varphi_{R(A^*)}(y) = \sup_x (\varphi_{B|A}(y|x) \triangle \varphi_{A^*}(x)). \quad (4.10)$$

O leitor interessado nesse tema pode consultar ([120, 93, 60]).

Como dissemos acima, a partir da fórmula (4.8), temos uma maneira de obter a distribuição condicional $\varphi_{B|A}(y|x)$, que é própria para o modus ponens. Porém, em geral, não temos fórmula que forneça as distribuições condicionais a partir das marginais.

Vale observar que se a regra condicional

$$R : \text{“se } x \text{ é (está em) } A \text{ então } y \text{ é (está em) } B\text{”} \quad (4.11)$$

não for causal, como é o caso das que aparecem nos controladores fuzzy (ver Capítulo 5), em que R representa o produto cartesiano, ou seja, cada par (x, y) é um elemento do produto cartesiano, o qual costuma ser medelado pela t-norma do mínimo, então φ_R pode ser interpretada como distribuição conjunta (sugerida inicialmente por Zadeh [131]).

Assim sendo, temos (4.11) dada por

$$\varphi_R(x, y) = \varphi_{(A,B)}(x, y) = \varphi_A(x) \triangle \varphi_B(y),$$

sugerindo não-interatividade entre os conjuntos fuzzy A e B , segundo a t-norma $\triangle$. Especificamente no método de Mamdani (Capítulo 5), temos não-interatividade, já que nesse caso $\triangle = \wedge$.

Exercício 4.10. Verifique que independência possibilística é equivalente a não-interatividade se a t-norma adotada for a do produto.

Exercício 4.11. Verifique que se A e B forem não-interativos e $\triangle = \wedge$ em (4.9), então

$$\varphi_{B|A}(y|x) = \begin{cases} \varphi_B(y) & \text{se } \varphi_B(y) < \varphi_A(x) \\ \alpha \in [\varphi_A(x), 1] & \text{se } \varphi_B(y) \geq \varphi_A(x) \end{cases}.$$

Exercício 4.12. a) Dê exemplos, se possível, de conjuntos fuzzy A e B (discretos e contínuos - números fuzzy) em que B independe possibilisticamente de A , quando $\varphi_{B|A}(y|x)$ é dada pelo modus ponens, isto é, quando

$$\varphi_{B|A}(y|x) = (\varphi_A(x) \Rightarrow \varphi_B(y)).$$

b) Dê exemplos, se possível, de conjuntos fuzzy A e B não-interativos, mas que B dependa possibilisticamente de A .

Exercício 4.13. Considere os conjuntos fuzzy do Exemplo 4.6.

- Se a implicação for a de Gödel e $\triangle = \wedge$, verifique se as distribuições *priori* e *posteriori* de B coincidem;
- Idem para a implicação de Lukasiewicz e $\triangle = \wedge$;
- Idem para a implicação de Goguen e a t-norma do *produto*.

Capítulo 5

Sistemas Baseados em Regras Fuzzy

“Há e haverá muitas tarefas que os homens podem cumprir com facilidade, que vão além da capacidade de qualquer computador, qualquer máquina e qualquer sistema lógico que podemos conceber nos dias de hoje.”

(Lotfi A. Zadeh)

Intuitivamente, todos nós concordamos com o pensamento de Zadeh exposto acima. No entanto, como é bastante conhecido, foram os seus primeiros trabalhos sobre teoria dos conjuntos fuzzy que deram origem ao que hoje é chamado de lógica fuzzy, assunto este com grande aplicação na execução e controle de tarefas.

No cotidiano, as ações humanas controlam os mais diversos sistemas do mundo real por meio de informações imprecisas. Cada indivíduo funciona como uma “caixa preta”: recebe informações que são interpretadas segundo seus parâmetros e então decide qual atitude tomar. O controle e a execução de tarefas devem seguir uma sequência de “ordens” linguísticas, traduzidas por um conjunto de regras, capazes de serem decodificadas pelo controlador.

O exemplo a seguir tem como objetivo ilustrar o comentado acima.

Exemplo 5.1. Um especialista é capaz de lavar roupas a ponto de deixá-las limpas, segundo seu conceito de limpeza.

O esquema abaixo (Figura 5.1) representa, de uma maneira simplificada, as ações do especialista (controlador humano) na execução da tarefa de lavar roupas.




Figura 5.1: Esquema para um sistema de controle humano na tarefa de lavar roupa.

Nesse exemplo podemos observar um possível caminho para automação de tarefas. As ordens à serem enunciadas por regras, poderiam ser, por exemplo as regras dadas no Quadro 5.1.

R_1 :	Se a roupa é “ <i>grossa</i> ” e a sujeira é “ <i>difícil</i> ”, então lava-se “ <i>muito tempo</i> ”.
ou	
R_2 :	Se a roupa é “ <i>grossa</i> ” e a sujeira é “ <i>fácil</i> ”, então lava-se “ <i>em tempo médio</i> ”.
ou	
R_3 :	Se a roupa é “ <i> fina</i> ” e a sujeira é “ <i>fácil</i> ”, então lava-se “ <i>pouco tempo</i> ”.

Quadro 5.1: Regras de um sistema de automação na lavagem de roupas.

Uma tentativa de reproduzir a estratégia de um controlador humano é dada pelos **Controladores Fuzzy**, considerado aqui – a exemplo de tantos outros textos [72, 95, 94, 116] – como um caso típico de um **Sistema Baseado em Regras Fuzzy (SBRF)**, isto é, um sistema que se utiliza da lógica fuzzy para produzir saídas para cada entrada fuzzy.

Os *modus ponens*, vistos no Capítulo 4, são exemplos de sistemas baseados em regras fuzzy. A particularidade que tem os controladores fuzzy é apenas de interpretação. Nas primeiras aplicações dos **SBRF** que surgiram, cada saída representava a “ação” correspondente à “condição” ou entrada do SBRF. Quando as entradas e saídas têm esta conotação os SBRF são denominados *Controladores Fuzzy*.

Com o auxílio dos métodos que vimos em raciocínio aproximado, no Capítulo 4, torna-se possível traduzir temas linguísticos, constantemente empregados por especialistas com o intuito de controlar suas tarefas, em fórmulas matemáticas, possibilitando a automação de certas tarefas. Este é o ponto fundamental na distinção entre teoria de controle fuzzy e teoria clássica de controle. Neste último, o intuito principal é montar estratégias para que um sistema dinâmico otimize algum critério.

Em controladores fuzzy as tarefas são comandadas por meio de termos da linguagem usual, relacionados com alguma variável de interesse e, é neste aspecto que variáveis linguísticas desempenham papel fundamental. Estes termos, traduzidos por conjuntos fuzzy, são utilizados para transcrever a base de conhecimentos através de uma coleção de regras fuzzy, denominada **base de regras fuzzy**. A partir dessa base de regras obtém-se a relação fuzzy, a qual produzirá a saída (resposta, ação) para cada entrada (estado, condição).

5.1 Base de Regras Fuzzy

Uma base de regras fuzzy tem a forma

	R_1 :	“Proposição fuzzy 1”
ou		
	R_2 :	“Proposição fuzzy 2”
		
ou		
	R_r :	“Proposição fuzzy r ”

Quadro 5.2: Forma geral de uma base de regras fuzzy.

Nos sistemas baseados em regras fuzzy cada proposição fuzzy tem a forma

Se “estado” Então “reposta”

em que cada “estado” e cada “resposta” são valores assumidos por variáveis linguísticas, e esses por sua vez, são modelados por conjuntos fuzzy. Os conjuntos fuzzy que compõem o “estado” são chamados de *antecedentes*. Por outro lado, os conjuntos fuzzy que compõem a “reposta” são chamados *consequentes*. A particularidade dos controladores fuzzy, como já observamos, é que cada regra tem a forma

Se “condição” Então “ação”.

No Exemplo 5.1 acima estamos supondo que cada tarefa seja executada por um ser humano, não precisando pois, de qualquer ferramenta matemática. Esse não é o caso de controladores fuzzy. As variáveis de interesse são: roupa (**r**) à ser lavada; sua sujeira (**s**) e o controle adotado (**e**), e cada uma das classificações “grossa” ou “fina”, para roupa, e “fácil” ou “difícil” para a sujeira, “muito tempo”, “pouco tempo” ou “em tempo médio”, para a ação de lavar, devem ser modeladas por conjuntos fuzzy.

De forma semelhante à que vimos no Capítulo 4, cada uma das classificações das variáveis que constam na base de regras é modelada por um conjunto fuzzy. A lógica fuzzy é a outra parte utilizada na obtenção

da relação fuzzy que sintetiza as informações matemáticas contidas na base de regras.

A base de regras cumpre o papel de “traduzir” matematicamente as informações que formam a base de conhecimentos do sistema fuzzy. Num certo sentido, pode-se afirmar que quanto mais precisas forem tais informações, menos fuzzy (mais crisp) será a relação fuzzy que representa a base de conhecimentos. Numa situação ideal, tal relação pode mesmo ser uma função no sentido clássico.

A seção seguinte trata da metodologia de controladores fuzzy e indica os módulos básicos para a sua obtenção.

5.2 Controlador Fuzzy

Em geral, para um sistema fuzzy qualquer, a cada entrada fuzzy faz-se corresponder uma saída fuzzy. Os controladores fuzzy também têm essa característica. No entanto, se a entrada for crisp (ponto de $\mathbb{R}^n$), espera-se que a saída também seja crisp (ponto de $\mathbb{R}^m$). Neste caso, um sistema fuzzy é uma função de $\mathbb{R}^n$ em $\mathbb{R}^m$ construída de alguma maneira específica. Os módulos seguintes indicam um roteiro para construção desta função.

Módulo de fuzzificação

Este é o estágio onde as entradas do sistema são modeladas por conjuntos fuzzy com seus respectivos domínios. É nele que justifica-se a grande importância de especialistas do fenômeno a ser modelado. Juntamente com os especialistas, as funções de pertinência são formuladas para cada conjunto fuzzy envolvido no processo. Mesmo que a entrada seja crisp, essa será fuzzificada por meio de sua função característica.

Módulo da base de regras

Este pode ser considerado como um módulo que faz parte do “núcleo” do controlador fuzzy. Ele é composto pelas proposições fuzzy e cada

uma destas proposições é descrita na forma linguística

$$\begin{array}{ll} \text{Se} & x_1 \text{ é } A_1 \text{ e } x_2 \text{ é } A_2 \text{ e } \cdots \text{ e } x_n \text{ é } A_n \\ \text{Então} & u_1 \text{ é } B_1 \text{ e } u_2 \text{ é } B_2 \text{ e } \cdots \text{ e } u_m \text{ é } B_m \end{array}$$

de acordo com as informações de um especialista. É neste ponto que as variáveis e suas classificações linguísticas são catalogadas e, em seguida, modeladas por conjuntos fuzzy, isto é, funções de pertinência.

Métodos para se obter essas funções de pertinência são os mais variados: apelos intuitivos, ajustes de curvas, interpolações e até mesmo redes neurais [72, 100, 116].

Módulo de inferência fuzzy

É neste módulo que cada proposição fuzzy é “traduzida” matematicamente por meio das técnicas da lógica fuzzy. É onde se define quais t-normas, t-conormas e regras de inferência (que podem ser implicações fuzzy) serão utilizadas para se obter a relação fuzzy que modela a base de regras.

Este módulo tem tanta importância quanto o módulo da base de regras. Basicamente dele é que depende o sucesso do controlador fuzzy, já que ele fornecerá a saída (controle) fuzzy a ser adotada pelo controlador, a partir de cada entrada fuzzy.

Módulo de defuzzificação

Na teoria estocástica é comum indicar a *esperança matemática* (ou média) como o número que melhor representa uma variável aleatória (ou uma distribuição de dados). Outros valores como a *moda* e a *mediana* também são utilizados para representar a centralização de tal distribuição.

Na teoria dos conjuntos fuzzy, a defuzzificação é um processo que permite representar um conjunto fuzzy por um valor crisp (número real).

A Figura 5.2 representa um esquema geral de um controlador fuzzy.

A base de regras é modelada matematicamente por uma relação fuzzy




Figura 5.2: Esquema geral de um controlador fuzzy.

$\mathcal{R}$, a partir dos conjuntos fuzzy que a compõe e da lógica fuzzy adotada. A função de pertinência de $\mathcal{R}$ é dada por

$$\varphi_{\mathcal{R}}(x, u) = \nabla(\varphi_{R_i}(x, u)), \text{ com } 1 \leq i \leq r, \quad (5.1)$$

onde ∇ é uma t-conorma e R_i é uma relação fuzzy obtida da regra i , cuja função de pertinência φ_{R_i} é obtida de alguma forma – por meio de um *modus ponens* generalizado, por exemplo. Os valores x e u representam o estado e o controle, respectivamente.

A inferência, que representa o controle B para um estado A , é dada por uma regra de composição de inferência: $B = R(A)$ cuja função de pertinência é dada por

$$\varphi_B(u) = \sup_x (\varphi_R(x, u) \triangle \varphi_A(x)), \quad (5.2)$$

onde $\triangle$ é uma t-norma.

Como recurso didático, podemos ilustrar a obtenção da relação $\mathcal{R}$ de maneira análoga a um *modus ponens* generalizado, conforme o Quadro 5.3.

De acordo com a literatura, o trabalho pioneiro na automação para realizar e controlar tarefas, baseando-se em lógica fuzzy, foi proposto por

	R_1 : “Se x_1 é A_{11} e $\dots$ e x_n é A_{1n} então u_1 é B_{11} e $\dots$ e u_m é B_{1m} ”
ou	
	R_2 : “Se x_1 é A_{21} e $\dots$ e x_n é A_{2n} então u_1 é B_{21} e $\dots$ e u_m é B_{2m} ”
ou	
$\vdots$	$\vdots$
ou	
	R_r : “Se x_1 é A_{r1} e $\dots$ e x_n é A_{rn} então u_1 é B_{r1} e $\dots$ e u_m é B_{rm} ”
Fato:	$A = x_1 \text{ é } A_1 \text{ e } x_2 \text{ é } A_2 \text{ e } \dots \text{ e } x_n \text{ é } A_n.$
Conclusão:	$u \text{ é } B = \mathcal{R}(A).$

Quadro 5.3: Ilustração da obtenção da relação $\mathcal{R}$.

Mamdani e Assilian [82]. Seus experimentos foram na área de máquina a vapor. Eles basearam-se no fato que operadores humanos expressam suas estratégias de controle linguisticamente, e não de uma forma matematicamente precisa. Este trabalho influenciou outros pesquisadores a utilizar controladores fuzzy na teoria de controle. Este é o caso do controlador de Takagi–Sugeno no qual as saídas parciais (consequentes) de cada regra são dadas por meio de funções das entradas [123].

Atualmente controladores fuzzy são largamente utilizados em aparelhos eletrodomésticos, sendo o Japão o primeiro país a investir pesadamente na “indústria fuzzy”.

A seção a seguir ilustra o método de inferência de Mamdani.

5.3 O Método de Inferência de Mamdani

Do ponto de vista teórico, Mamdani propõe uma relação fuzzy binária $\mathcal{M}$ entre x e u para modelar matematicamente a base de regras.

O método de Mamdani é baseado na regra de composição de inferência max–min conforme o procedimento:

- Em cada regra R_j , da base de regras fuzzy, a condicional “se x é A_j então u é B_j ” é modelada pela aplicação $\wedge$ (mínimo) que, erroneamente, costuma ser denominada por implicação de Mamdani ($\wedge$ não é uma implicação fuzzy pois não preserva a tabela de uma implicação clássica);
- Adota-se a t-norma $\wedge$ (mínimo) para o conectivo lógico “e”;
- Para o conectivo lógico “ou” adota-se a t-conorma $\vee$ (máximo) que conecta as regras fuzzy da base de regras.

Formalmente, a relação fuzzy $\mathcal{M}$ é o subconjunto fuzzy de $X \times U$ cuja função de pertinência é dada por

$$\varphi_{\mathcal{M}}(x, u) = \max_{1 \leq j \leq r} (\varphi_{R_j}(x, u)) = \max_{1 \leq j \leq r} [\varphi_{A_j}(x) \wedge \varphi_{B_j}(u)], \quad (5.3)$$

onde r é o número de regras que compõem a base de regras e, A_j e B_j são os subconjuntos fuzzy da regra j . Cada um dos valores $\varphi_{A_j}(x)$ e $\varphi_{B_j}(u)$ são interpretados como os graus com que x e u estão nos subconjuntos fuzzy A_j e B_j , respectivamente, de maneira que $\mathcal{M}$ nada mais é que a união dos produtos cartesianos fuzzy entre os antecedentes e os consequentes de cada regra.

Observações:

- 1) É comum encontrar na literatura as siglas MISO (múltiplas entradas e uma saída) e MIMO (múltiplas entradas e múltiplas saídas). Estas siglas são abreviações de *multiple input and single output* e *multiple input and multiple output*, respectivamente.

- 2) Os subconjuntos fuzzy A_j e B_j que aparecem na fórmula (5.3), podem representar o produto cartesiano fuzzy de subconjuntos fuzzy A_{ji} e B_{jk} . Por exemplo, pode ocorrer

$$\varphi_{A_j}(x) = \varphi_{A_{j1}}(x_1) \wedge \varphi_{A_{j2}}(x_2) \quad \text{e} \quad \varphi_{B_j}(u) = \varphi_{B_{j1}}(u_1) \wedge \varphi_{B_{j2}}(u_2),$$

tratando-se pois de um controlador fuzzy MIMO de duas entradas e duas saídas.

O exemplo a seguir ilustra o método de inferência de Mamdani para o caso de um sistema fuzzy com duas entradas e uma saída.

Exemplo 5.2. Considere um controlador fuzzy com duas entradas e uma saída, cuja base de regras é dada pelo Quadro 5.4.

$R_1 : \text{Se } x_1 \text{ é } A_{11} \text{ e } x_2 \text{ é } A_{12} \text{ então } u \text{ é } B_1$
ou
$R_2 : \text{Se } x_1 \text{ é } A_{21} \text{ e } x_2 \text{ é } A_{22} \text{ então } u \text{ é } B_2$

Quadro 5.4: Base de regras para um controlador com duas entradas e uma saída.

Assim, para cada terna $t = (x_1, x_2, u)$ temos

$$\begin{aligned} \varphi_{\mathcal{M}}(t) &= \{\varphi_{A_{11}}(x_1) \wedge \varphi_{A_{12}}(x_2) \wedge \varphi_{B_1}(u)\} \vee \{\varphi_{A_{21}}(x_1) \wedge \varphi_{A_{22}}(x_2) \wedge \varphi_{B_2}(u)\} \\ &= \max \{\varphi_{A_{11}}(x_1) \wedge \varphi_{A_{12}}(x_2) \wedge \varphi_{B_1}(u), \varphi_{A_{21}}(x_1) \wedge \varphi_{A_{22}}(x_2) \wedge \varphi_{B_2}(u)\} \end{aligned}$$

representando a relação fuzzy obtida da base de regras pelo método de Mamdani.

Agora, para um dado conjunto fuzzy de entrada $A = A_1 \times A_2$, com A_1 e A_2 dois números fuzzy, o conjunto fuzzy de saída, que representa o controle a ser adotado para A pelo método de Mamdani, é dado por

$B = \mathcal{M} \circ A$, cuja função de pertinência é

$$\varphi_B(u) = (\varphi_{\mathcal{M} \circ A})(u) = \sup_x \{\varphi_{\mathcal{M}}(x, u) \wedge \varphi_A(x)\}.$$

Como $A = A_1 \times A_2$, então $\varphi_A(x_1, x_2) = \varphi_{A_1}(x_1) \wedge \varphi_{A_2}(x_2)$.

Desta forma

$$\begin{aligned} \varphi_B(u) &= \sup_x \{\varphi_{\mathcal{M}}(x, u) \wedge \varphi_A(x)\} \\ &= \sup_{(x_1, x_2)} \{\varphi_{\mathcal{M}}(x_1, x_2, u) \wedge [\varphi_{A_1}(x_1) \wedge \varphi_{A_2}(x_2)]\} \\ &= \sup_{(x_1, x_2)} \{[(\varphi_{A_{11}}(x_1) \wedge \varphi_{A_{12}}(x_2) \wedge \varphi_{B_1}(u)) \vee \\ &\quad (\varphi_{A_{21}}(x_1) \wedge \varphi_{A_{22}}(x_2) \wedge \varphi_{B_2}(u))] \wedge [\varphi_{A_1}(x_1) \wedge \varphi_{A_2}(x_2)]\} \\ &= \sup_{(x_1, x_2)} \{[\varphi_{A_1}(x_1) \wedge \varphi_{A_{11}}(x_1)] \wedge [\varphi_{A_2}(x_2) \wedge \varphi_{A_{12}}(x_2)] \wedge \varphi_{B_1}(u)\} \vee \\ &\quad \sup_{(x_1, x_2)} \{[\varphi_{A_1}(x_1) \wedge \varphi_{A_{21}}(x_1)] \wedge [\varphi_{A_2}(x_2) \wedge \varphi_{A_{22}}(x_2)] \wedge \varphi_{B_2}(u)\} \\ &= \varphi_{B_{R_1}}(u) \vee \varphi_{B_{R_2}}(u). \end{aligned}$$

onde B_{R_1} e B_{R_2} são as saídas parciais devido às regras R_1 e R_2 , respectivamente.

Da fórmula acima, podemos observar que a saída do método de Mamdani resulta da união entre as saídas parciais de cada regra. Para obter cada saída parcial, procede-se da seguinte forma: faz-se a interseção das entradas com cada antecedente da regra e em seguida, faz-se o produto cartesiano (universos distintos) dessas interseções com os consequentes da regra. A projeção desse produto cartesiano no espaço U é a saída parcial para o conjunto fuzzy de entrada A .

Graficamente tem-se a Figura 5.3.




Figura 5.3: Saídas parciais no método de Mamdani.

A saída geral é dada pela união das saídas parciais, conforme a Figura 5.4.




Figura 5.4: Saída final do controlador fuzzy de Mamdani.

Note que o último gráfico da Figura 5.4 representa a função de pertinência φ_B do controle B que foi obtido pelo conectivo $\vee$, que é a t-conorma do máximo.

O exemplo a seguir é um caso particular do anterior no sentido que a entrada A agora é crisp.

Exemplo 5.3. Considere no exemplo anterior o caso em que o conjunto fuzzy de entrada A é crisp e cuja função de pertinência está concentrada em um ponto $(x_0, y_0) \in \mathbb{R} \times \mathbb{R}$. Assim,

$$\varphi_A(x, y) = \begin{cases} 1 & \text{se } (x, y) = (x_0, y_0) \\ 0 & \text{se } (x, y) \neq (x_0, y_0) \end{cases},$$

ou seja,

$$A = A_1 \times A_2$$

onde

$$\varphi_{A_1}(x) = \begin{cases} 1 & \text{se } x = x_0 \\ 0 & \text{se } x \neq x_0 \end{cases} \quad \text{e} \quad \varphi_{A_2}(y) = \begin{cases} 1 & \text{se } y = y_0 \\ 0 & \text{se } y \neq y_0 \end{cases}.$$

Neste caso, o controle fuzzy B é obtido de acordo com o esquema gráfico da Figura 5.5.




Figura 5.5: Saídas parciais do controlador fuzzy de Mamdani para o Exemplo 5.3.

A saída B final está representada na Figura 5.6.




Figura 5.6: Saída final do controlador fuzzy de Mamdani para o Exemplo 5.3.

Pode ser visto, através do Exemplo 5.3, que a saída do controlador fuzzy, dada pelo método de inferência de Mamdani, é um subconjunto

fuzzy, mesmo para o caso de uma entrada crisp. Assim, se for necessário ter um número real devemos fazer uma defuzzificação do subconjunto fuzzy de saída para se obter um valor crisp que o represente.

5.4 Métodos de Defuzzificação

No controlador fuzzy, a cada entrada fuzzy o módulo de inferência produz uma saída fuzzy que indica o controle a ser adotado. No entanto, se a entrada for um número real, espera-se que a saída correspondente seja também um número real. Porém, isso em geral não ocorre em controladores fuzzy pois, mesmo para uma entrada crisp, a saída é fuzzy. Assim, deve-se indicar um método para defuzzificar a saída e obter um número real que, finalmente, indicará o controle a ser adotado.

São muitos os métodos de defuzzificação que podem ser adotados. A princípio, qualquer número real, que de alguma maneira possa representar razoavelmente o conjunto fuzzy B pode ser chamado de um defuzzificador de B . Aqui serão citados os mais comuns.

5.4.1 Centro de gravidade ($G(B)$), Centroide ou Centro de Área

Este método de defuzzificação é semelhante à média aritmética para uma distribuição de frequências de uma dada variável, com a diferença que os pesos aqui são os valores $\varphi_B(u_i)$, que indicam o grau de compatibilidade do valor u_i com o conceito modelado pelo conjunto fuzzy B .

O centro de gravidade dá a média das áreas de todas as figuras que representam os graus de pertinência de um subconjunto fuzzy. Entre todos os métodos de defuzzificação ele é o preferido, mesmo sendo talvez o mais complicado. As Equações (5.4) e (5.5) referem-se ao domínio discreto e domínio contínuo, respectivamente. A Figura 5.7 mostra o gráfico do defuzzificador $G(B)$.

$$G(B) = \frac{\sum_{i=0}^n u_i \varphi_B(u_i)}{\sum_{i=0}^n \varphi_B(u_i)}. \quad (5.4)$$

$$G(B) = \frac{\int_{\mathbb{R}} u \varphi_B(u) du}{\int_{\mathbb{R}} \varphi_B(u) du}. \quad (5.5)$$




Figura 5.7: Defuzzificador centro de gravidade $G(B)$.

5.4.2 Centro dos Máximos ($C(B)$)

Este é um procedimento radical, no sentido que são levados em conta apenas as regiões de maior possibilidade entre os possíveis valores da variável que modela o conceito fuzzy em questão. Neste caso tem-se:

$$C(B) = \frac{i + s}{2}, \quad (5.6)$$

onde

$$\begin{aligned} i &= \inf\{u \in \mathbb{R} : \varphi_B(u) = \max_u \varphi_B(u)\} \\ e \\ s &= \sup\{u \in \mathbb{R} : \varphi_B(u) = \max_u \varphi_B(u)\} \end{aligned} \quad (5.7)$$

A Figura 5.8 abaixo ilustra esse defuzzificador




Figura 5.8: Defuzzificador centro de máximo $C(B)$.

5.4.3 Média dos Máximos ($M(B)$)

Para domínio discreto é comum usar como defuzzificador a média dos máximos cuja definição é dada por

$$M(B) = \frac{\sum u_i}{n}, \quad (5.8)$$

onde n é dado e u_i , com $1 \leq i \leq n$, são os elementos de maior pertinência ao conjunto fuzzy B .

Como dissemos antes, via de regra, os controladores fuzzy são compostos de quatro módulos: fuzzificação, base de regras, inferência e defuzzificação. O método de Mamdani é um caso típico. No entanto, para algumas situações o módulo de defuzzificação pode ser suprimido. Este é o caso do método de inferência de Takagi-Sugeno-Kang que iremos descrever nesta seção.

5.5 Método de Inferência de Takagi - Sugeno - Kang (TSK)

As diferenças básicas entre o método de inferência de Takagi-Sugeno-Kang (doravante chamado TSK) e o de Mamdani estão na forma de escrever o consequente de cada regra e no procedimento de defuzzificação

para se obter a saída geral do sistema. Com o método TSK, o consequente de cada regra é dado explicitamente por uma função dos valores de entrada desta regra.

Como ilustração do método podemos imaginar uma base com r regras fuzzy, onde cada uma delas tem n entradas $(x_1, x_2, \dots, x_n) \in \mathbb{R}^n$, e uma saída $u \in \mathbb{R}$, conforme o Quadro 5.5, no qual A_{ij} são subconjuntos fuzzy de $\mathbb{R}$.

R_1 : Se x_1 é A_{11} e x_2 é A_{12} e $\dots$ e x_n é A_{1n} então u é $u_1 = g_1(x_1, x_2, \dots, x_n)$
ou
R_2 : Se x_1 é A_{21} e x_2 é A_{22} e $\dots$ e x_n é A_{2n} então u é $u_2 = g_2(x_1, x_2, \dots, x_n)$
ou
$\vdots$
ou
R_r : Se x_1 é A_{r1} e x_2 é A_{r2} e $\dots$ e x_n é A_{rn} então u é $u_r = g_r(x_1, x_2, \dots, x_n)$

Quadro 5.5: Base de regras para ilustrar o método TSK.

A saída geral do método é dada por

$$\begin{aligned}
 u &= f_r(x_1, x_2, \dots, x_n) \\
 &= \frac{\sum_{j=1}^r \omega_j \cdot g_j(x_1, x_2, \dots, x_n)}{\sum_{j=1}^r \omega_j} = \frac{\sum_{j=1}^r \omega_j \cdot u_j}{\sum_{j=1}^r \omega_j}, \quad (5.9)
 \end{aligned}$$

onde os pesos ω_j são dados por $\omega_j = \varphi_{A_{j1}}(x_1) \triangle \varphi_{A_{j2}}(x_2) \cdots \triangle \varphi_{A_{jn}}(x_n)$, e $\triangle$ é uma t-norma. O peso ω_j corresponde à contribuição da regra R_j para a saída geral. Os casos mais comuns de t-normas são o produto e o mínimo.

Para o caso de duas regras, cada uma com duas variáveis de entrada

e uma saída, o método TSK é ilustrado no Quadro 5.6 a seguir.

$R_1 : \text{“Se } x_1 \text{ é } A_{11} \text{ e } x_2 \text{ é } A_{12} \text{ então } u \text{ é } u_1 = g_1(x_1, x_2)\text{”}$ ou $R_2 : \text{“Se } x_1 \text{ é } A_{21} \text{ e } x_2 \text{ é } A_{22} \text{ então } u \text{ é } u_2 = g_2(x_1, x_2)\text{”}$
--

Quadro 5.6: Base de duas regras para o método TSK.

Supondo que Δ seja a t-norma mínimo, temos como saída geral, representando o controle para as ações x_1 e x_2 , o valor de u dado pela equação:

$$u = \frac{\omega_1 u_1 + \omega_2 u_2}{\omega_1 + \omega_2} = \frac{\omega_1 g_1(x_1, x_2) + \omega_2 g_2(x_1, x_2)}{\omega_1 + \omega_2} = f_r(x_1, x_2), \quad (5.10)$$

onde $\omega_i = \min[\varphi_{A_{i1}}(x_1), \varphi_{A_{i2}}(x_2)]$ corresponde ao peso da regra R_i na saída geral do processo.

Na literatura, o caso que aparece com maior frequência, devido à sua eficiência e aplicabilidade, é aquele em que os consequentes de cada regra são funções lineares afins, isto é, cada uma das funções g_i tem a forma

$$g_i(x_1, x_2) = a_i x_1 + b_i x_2 + c_i.$$

Este caso é comumente chamado de método de Takagi-Sugeno (TS).

Exemplo 5.4. Considere um controlador fuzzy com duas entradas e uma saída, onde os conjuntos fuzzy envolvidos, A_{ij} , são números fuzzy triangulares e as saídas de cada regra são dadas por funções g_i , lineares afins. Para cada par de entrada x_0 e y_0 , a Figura 5.9 é uma representação gráfica para a obtenção da saída, a qual representa o controle a ser adotado para tais entradas. Para este exemplo temos a base de regras dadas no Quadro 5.7

$R_1 : \text{“Se } x \text{ é } A_{11} \text{ e } y \text{ é } A_{12} \text{ então } u \text{ é } u_1 = g_1(x, y) = a_1x + b_1y + c_1\text{”}$ ou $R_2 : \text{“Se } x \text{ é } A_{21} \text{ e } y \text{ é } A_{22} \text{ então } u \text{ é } u_2 = g_2(x, y) = a_2x + b_2y + c_2\text{”}$
--

Quadro 5.7: Base de regras para o Exemplo 5.4

Neste caso o controle fuzzy, cuja obtenção gráfica está ilustrada na Figura 5.9, é dado por

$$u = \frac{\omega_1 u_1 + \omega_2 u_2}{\omega_1 + \omega_2} = \frac{\omega_1 g_1(x_0, y_0) + \omega_2 g_2(x_0, y_0)}{\omega_1 + \omega_2}.$$




Figura 5.9: Saída do controlador fuzzy TSK para o Exemplo 5.4.

Exemplo 5.5. Considere as regras

$R_1 : \text{“Se } x \text{ é baixo}(A_1) \text{ então } y_1 = x + 2\text{”}$ ou $R_2 : \text{“Se } x \text{ é alto}(A_2) \text{ então } y_2 = 2x\text{”}$
--

Quadro 5.8: Base de regras para o Exemplo 5.5

Suponha que o domínio seja $x \in [0, 4]$,

$$\varphi_{A_1}(x) = 1 - \frac{x}{4} \text{ e } \varphi_{A_2}(x) = \frac{x}{4}.$$

Logo, a saída do sistema pelo método de Takagi-Sugeno é

$$\begin{aligned} y &= \frac{\varphi_{A_1}(x) \cdot y_1 + \varphi_{A_2}(x) \cdot y_2}{\varphi_{A_1}(x) + \varphi_{A_2}(x)} = \varphi_{A_1}(x) \cdot y_1 + \varphi_{A_2}(x) \cdot y_2 \\ &= \frac{x^2}{4} + \frac{x}{2} + 2 \end{aligned}$$

que é uma parábola com concavidade voltada para cima, cujo vértice é $\left(-1, \frac{7}{4}\right)$.

O gráfico a seguir ilustra a saída (y) e a base de regras com as funções de pertinências φ_{A_1} e φ_{A_2} . Observe que tais funções estão representadas abaixo do eixo $\overline{OX}$.




Figura 5.10: Saída y e base de regras do Exemplo 5.5.

Exercício 5.1. Refaça o Exemplo 5.5, inclusive as representações gráficas, trocando os consequentes por $y_1 = x + 2$ e $y_2 = 4 - x$.

Exercício 5.2. Refaça o exercício anterior trocando as funções de pertinências por trapézios. O conjunto fuzzy A_1 dado pelo trapézio com base maior $[0, 3]$ e base menor $[0, 1]$. O conjunto fuzzy A_2 é o trapézio cuja base maior é $[1, 4]$ e base menor $[3, 4]$. A saída geral é uma função contínua?

Como já mencionamos antes, os controladores fuzzy têm a propriedade de modelar fenômenos (processos) por meio de um funcional com informações incertas dadas por variáveis linguísticas.

Supondo que certo fenômeno estudado possa ser modelado por um funcional, ao se admitir que a saída de cada regra é dada por uma função linear afim, podemos pensar que o funcional pode ser aproximado localmente por uma reta. Por exemplo, se soubermos a priori que o funcional tem alguma propriedade de suavidade, podemos eleger retas tangentes ao funcional para serem as funções consequentes de cada regra.

É interessante observar que se as funções g_i dos consequentes forem constantes, então os dois métodos, de Mamdani e Takagi-Sugeno, produzem as mesmas saídas, se a defuzzificação usada no método de Mamdani for o centro de gravidade. Isto é particularmente fácil de ver no Exemplo 5.4 em que a saída geral é

$$u = \frac{\omega_1 c_1 + \omega_2 c_2}{\omega_1 + \omega_2}$$

já que, neste caso, estamos admitindo que $a_1 = b_1 = a_2 = b_2 = 0$. Esta também é a saída no método de Mamdani para este caso particular, pois as funções de pertinência dos consequentes são as constantes c_1 e c_2 (verifique).

Queremos ressaltar que os controladores fuzzy têm propriedades matemáticas importantes como, por exemplo, a capacidade de aproximar funções contínuas. No Capítulo 6 mostraremos esse fato com maior detalhe para os controladores de Takagi-Sugeno-Kang. Finalmente, observamos que os controladores TSK podem ser bem mais gerais, no sentido

que as funções de cada consequente podem ter argumentos fuzzy, e os valores das entradas podem ser subconjuntos fuzzy.

A seguir apresentaremos algumas considerações a respeito dos dois métodos:

- (i) O método de Mamdani é mais simples e mais intuitivo que o de TSK;
- (ii) O método de Mamdani é menos eficiente que o de TSK quanto à rapidez computacional;
- (iii) O método de Mamdani tem menos propriedades matemáticas que o de TSK.

Atualmente, a teoria de controladores fuzzy está bastante avançada e existem textos específicos sobre este assunto [1, 3, 94, 108, 116, 126].

Atualmente temos nos utilizado dessa ferramenta para avaliar alguns coeficientes de equações diferenciais parciais, as quais representam a evolução temporal e espacial de certas epidemias [86, 56].

A partir dos estudos iniciados por Castanho [34], os quais se utilizam de controladores fuzzy para classificação do câncer de próstata, Silveira et al [119] produziram um software que tem como principal objetivo auxiliar profissionais da área de urologia a decidir o estadiamento do câncer em um paciente. Com base nos resultados do grau de Gleason, estado clínico e nível do PSA o software sugere o risco (probabilidade) do tumor se encontrar em uma das classificações: localizado, localmente avançado e metastático. O software foi registrado na INOVA-UNICAMP no ano de 2009.

A seção seguinte será dedicada às aplicações, algumas feitas por alguns de nossos alunos, ilustrando o potencial que os controladores fuzzy têm quando usados em Biomatemática.

5.6 Aplicações

Nos modelos que seguem, foram utilizados os métodos de Mamdani e TSK, no caso particular em que as condições iniciais (entradas) são críps, com o intuito de mostrar a potencialidade de aplicação da metodologia dos controladores fuzzy.

A eficiência das aplicações depende fundamentalmente das informações fornecidas pelos especialistas para a construção da base de regras fuzzy.

5.6.1 Modelo 1 – Previsão de salinidade no estuário de Cananeia e Ilha Comprida

Este modelo foi desenvolvido por Ranulfo Paiva Sobrinho junto à prefeitura de Ilha Comprida, utilizando controladores fuzzy. Seu objetivo era prever a variação da salinidade superficial em um ponto situado em frente à Ilha de Cananeia, tendo como variáveis de entrada a precipitação pluviométrica e a vazão do Rio Ribeira de Iguape [97].

O modelo proposto estima a variação da salinidade superficial até dois dias e abrange um raio de 80 Km, o que permite informar, com alguma antecedência, aos empreendedores da aquicultura de estuário para que tomem as devidas providências no sentido de não perderem seus organismos cultivados.

A Figura 5.11 ilustra a área de estudo no litoral sul do estado de São Paulo.




Figura 5.11: Área de estudo no litoral sul paulista.

Apresentação do fenômeno

O ecossistema estuarino lagunar que abrange as cidades de Cananéia, Iguape e Ilha Comprida está localizado no litoral sudeste do Estado de São Paulo numa região de relevante importância ecológica devido ao seu bom estado de conservação.

Ela foi classificada pela IUCN (International Union for the Nature Conservation) como o terceiro estuário do mundo com maior produtividade primária. Esse estuário tem conexão com o Oceano Atlântico na porção norte através da barra de Icapara e na parte sul pela barra de Cananeia. O aporte de água doce no estuário é fornecido por vários rios, sendo que o de maior volume é o Rio Ribeira. Suas águas entram no estuário pela parte norte, na cidade de Iguape, através de um canal denominado Valo Grande, construído artificialmente no final do século XIX.

A contribuição das águas do Rio Ribeira na região foi alterada em 1978 quando construiu-se uma barragem a 2 *km* da cidade de Iguape. Como consequência, o padrão de algumas variáveis ambientais, como a salinidade superficial, foi alterado.

O modelo

O modelo baseia-se em um sistema de controle fuzzy com o método de inferência de Mamdani. As variáveis de entrada são: *precipitação pluviométrica*, *salinidade inicial* e *vazão do Rio Ribeira*. A variável de saída é a *salinidade final*.

A arquitetura do modelo está colocada na Figura 5.12.




Figura 5.12: Arquitetura do modelo de previsão de salinidade no estuário de Cananeia e Ilha Comprida.

Para essas variáveis, atribuiu-se termos linguísticos, e cada um deles com funções de pertinência dos tipos triangular e trapezoidal (Figuras 5.13a, 5.13b e 5.13c).

Por meio da análise do conjunto dos dados envolvendo as variáveis mencionadas, pode-se estabelecer uma base de conhecimento com regras linguísticas, relacionando-as a fim de se estimar o valor da salinidade final, sendo esse estimado pelo processo de defuzzificação do centro de gravidade.




Figura 5.13: Funções de pertinência – (a) Chuva; (b) Salinidade Inicial e Final e (c) Vazão do Rio.

Base de regras

Cada uma das regras (veja Quadro 5.9) tem a forma dos exemplos seguintes:

R_4 - **SE** chuva acumulada em Cananeia no intervalo de 1 a 3 dias for baixa **E** a salinidade inicial do período for média baixa **E** a vazão do Rio Ribeira é alta **ENTÃO** a salinidade final é baixa.

R_{23} - **SE** chuva acumulada em Cananeia no intervalo de 1 a 3 dias for média alta **E** a salinidade inicial do período for média baixa **E** a vazão do Rio Ribeira for baixa **ENTÃO** a salinidade final é média baixa.

O Quadro 5.9 fornece todas as regras atingidas (base de regras com 3 entradas e uma saída) e a Tabela 5.1 mostra a legenda para a base de regras.

Como fizemos no Exemplo 5.3, vamos aqui ilustrar, passo a passo, o método de inferência de Mamdani para esta aplicação.

Se	Chuva Ac.	e	Sal. Inicial	e	Vazão	Então	Sal. Final
R_1	baixa		média baixa		média		média baixa
R_2	baixa		média		média alta		média baixa
R_3	baixa		média baixa		média alta		baixa
R_4	baixa		média baixa		alta		baixa
R_5	baixa		baixa		alta		média baixa
R_6	baixa		média		altíssima		baixa
R_7	baixa		média baixa		altíssima		média baixa
R_8	baixa		baixa		altíssima		média baixa
R_9	baixa		média		baixa		média
R_{10}	baixa		média		média		média baixa
R_{11}	baixa		baixa		baixa		baixa
R_{12}	média		média		baixa		média baixa
R_{13}	média		média baixa		baixa		média baixa
R_{14}	média		média		média		média baixa
R_{15}	média		média		média alta		média baixa
R_{16}	média		média baixa		média		baixa
R_{17}	média		alta		baixa		média
R_{18}	média		alta		média		média baixa
R_{19}	média		alta		média alta		baixa
R_{20}	média		baixa		média		baixa
R_{21}	média		baixa		baixa		baixa
R_{22}	média alta		média		baixa		média baixa
R_{23}	média alta		média baixa		baixa		média baixa
R_{24}	alta		média		baixa		média baixa
R_{25}	alta		média baixa		baixa		baixa
R_{26}	altíssima		média		baixa		baixíssima
R_{27}	altíssima		média baixa		baixa		baixíssima
R_{28}	altíssima		baixa		baixa		baixíssima

Quadro 5.9: Base de regras linguísticas para previsão de salinidade no estuário de Cananeia e Ilha Comprida

Chuva Acumulada	Salinidade Inicial	Vazão do Rio	Salinidade Final
baixa = C_b	baixa = SI_b	baixa = V_b	baixíssima = SF_{ba}
média = C_m	média baixa = SI_{mb}	média = V_m	baixa = SF_b
média alta = C_{ma}	média = SI_m	média alta = V_{ma}	média baixa = SF_{mb}
alta = C_a	alta = SI_a	alta = V_a	média = SF_m
altíssima = C_{at}		altíssima = V_{at}	

Tabela 5.1: Legenda a ser utilizada para resolução do modelo da salinidade no Rio Ribeira, conforme a base de regras do Quadro 5.9.

Inferência

O processo de inferência propicia o cálculo da variável resposta (saída) a partir dos valores das variáveis de entrada. Isso ocorre porque os valores dos graus de pertinência das variáveis de entrada são utilizados para se

obter o valor do grau de pertinência da variável resposta.

Para exemplificar o método de inferência de Mamdani, faremos o cálculo seguindo os seguintes passos:

- Consideramos os seguintes valores de entrada: **precipitação pluviométrica** = 23 mm, **salinidade inicial** = 23 ‰¹ e **vazão do Rio Ribeira** = 1454 m³/s, ou seja, as condições iniciais são crisp.
- Cada um dos valores iniciais possui um grau de pertinência em relação aos subconjuntos fuzzy que definem as 3 variáveis de entrada. Assim, o valor precipitação pluviométrica 23 mm pertence ao subconjunto fuzzy “baixa” com grau de pertinência $\varphi_{C_b}(23)$ conforme a Figura 5.13a, isto é, $\varphi_{C_b}(23) = \varphi_{\text{prec. baixa}}(23) = 1$.

O valor de salinidade inicial, 23, pertence aos subconjuntos fuzzy “média baixa” e “média” (Figura 5.13b), com graus de pertinência $\varphi_{SI_{mb}}(23) = 0,67$ e $\varphi_{SI_m}(23) = 0,25$, respectivamente.

O valor da vazão do Rio Ribeira de 1454 m³/s pertence ao conjunto fuzzy “média alta”, com grau de pertinência $\varphi_{V_{ma}}(1454) = 0,82$.

Cada combinação desses conjuntos acionados pelos valores de entrada ativam algumas regras na base de conhecimento. Nesse caso 2 regras foram acionadas, a saber, R_2 e R_3 da base de regras (Quadro 5.9).

R₂ Se a precipitação pluviométrica acumulada em Cananéia no período de 1 a 3 dias for *baixa* e a salinidade inicial do período for *média* e a vazão do Rio Ribeira for *média alta* **então** a salinidade final será *média baixa*.

R₃ Se a precipitação pluviométrica acumulada em Cananéia no período de 1 a 3 dias for *baixa* e a salinidade inicial do período for *média baixa* e a vazão do Rio Ribeira for *média alta* **então** a salinidade final será *baixa*.

¹Símbolo para “por mil”.

O método de inferência de Mamdani combina os graus de pertinência referentes a cada um dos valores de entrada através da t-norma do **mínimo**.

Assim para as regras R_2 e R_3 , tem-se, respectivamente

$$R_2 : \min \{ \varphi_{C_b}(23), \varphi_{SI_m}(23), \varphi_{V_{ma}}(1454) \} = \min[1; 0,25; 0,82] = 0,25.$$

$$R_3 : \min \{ \varphi_{C_b}(23), \varphi_{SI_{mb}}(23), \varphi_{V_{ma}}(1454) \} = \min[1; 0,67; 0,82] = 0,67.$$

Essa operação é feita para cada uma das regras acionadas.

O valor de pertinência encontrado em cada regra (0,25 para R_2 e 0,67 para R_3) será projetado à função de pertinência da variável resposta da regra em questão, de modo que só serão preservados os valores de pertinência da variável resposta que forem menores ou iguais ao valor encontrado pelo operador mínimo (ver regiões escuras na Figura 5.14).

Combinando as saídas parciais de cada regra ativada (observamos que nesse exemplo não são só essas duas) através da t-conorma do **máximo**, obtemos a saída geral do controlador pelo método de Mamdani, sem defuzzificação (Figura 5.14).

Finalmente, usando o método de defuzzificação do centro de gravidade na saída fuzzy, obtemos como saída crisp o valor 15,2 para representar a salinidade final.

Na Tabela 5.2 encontramos todos os valores das variáveis de entrada, os valores das salinidades observadas e os valores das salinidades resultantes do modelo.

Foi adotado o método do Valor Médio Absoluto para validar esse modelo e obteve-se um resultado considerado satisfatório na comparação com valores observados.

Resumo e Comentários finais

Por se tratar de um ecossistema de grande amplitude espacial, apresentando variáveis de entrada com padrões temporais dinâmicos, torna-se




Figura 5.14: Saída do controlador de Mamdani sem defuzzificação.

Precipitação acumulada (mm)	Salinidade inicial (‰)	Vazão do Rio (m ³ /s)	Salinidade Observada (‰)	Salinidade Modelada (‰)
13,6	14	2016	6	3,4
115	30	1163	18	17,7
148	24	763	18	17,6
31	18	1515	15	13,2
3	18	2273	8	7,6
320	26	687	5	3,4
110	20	938	13	14,4
180	18	800	16	15,8
102	25	584	25	23,5
123	30	469	26	24,2
23	23	1454	17	15,2

Tabela 5.2: Relação entre os valores de salinidade final observados e os estimados pelo modelo fuzzy.

difícil adotar os métodos convencionais de experimentação, com réplicas etc. Na modelagem fuzzy, apenas com alguns dados disponíveis e nível de conhecimento atual foi possível elaborar uma base de regras que permitiram fazer previsões de salinidades futuras. A base de regras poderá ser aperfeiçoada, conforme surjam novos dados experimentais e/ou diferentes situações a serem modeladas.

Os resultados significativos obtidos aqui neste exemplo mostram a potencialidade do uso de sistemas fuzzy na modelagem de fenômenos ligados à Ecologia, principalmente em situações em que os conhecimentos são relativamente vagos.

No próximo modelo usaremos o software *Toolbox Fuzzy do Matlab 6.5*[®], no qual se encontra implementado o Método de Mamdani com defuzzificação do Centro de Massa, bem como o método TSK.

5.6.2 Modelo 2 – Taxa de Transferência de Soropositivos (HIV⁺)

Para ilustrar a utilização de controladores fuzzy em fenômenos epidemiológicos vamos nos concentrar em um tema que hoje em dia faz parte dos programas de saúde pública de muitos governos, incluindo o do Brasil: a **AIDS**².


A metodologia que apresentaremos a seguir faz parte da tese de doutorado de Jafelice [65, 67] e foi desenvolvida com o intuito de obter o valor de um parâmetro para uma equação diferencial que modela a evolução, no tempo, do número de indivíduos sintomáticos numa população de soropositivos.

O interesse de pesquisadores no estudo da AIDS tem crescido consideravelmente nos últimos anos. Os modelos matemáticos para estudar a evolução da AIDS em uma população são, via de regra, dados por um sistema de equações diferenciais. Nos modelos clássicos mais sim-

²Sigla inglesa para Síndrome da Imunodeficiência Adquirida – SIDA

ples a população é compartimentada em assintomáticos e sintomáticos, cuja taxa de conversão é dada por um parâmetro λ , denominado *taxa de incidência* [65].

O diagrama abaixo representa tal sistema compartimental com taxa de conversão λ .



O ajuste de dados estatísticos é o método tradicional para se obter a taxa λ . Nossa intenção aqui é apresentar uma alternativa a esse método fazendo uso de um sistema fuzzy, o qual leva em conta os conhecimentos e principais procedimentos de especialistas da área no esforço de se apurar λ .

O estudo da AIDS por parte de especialistas da área de saúde leva em conta dois parâmetros básicos: a carga viral (V) e a concentração de $CD4^+$ (principal linfócito atacado pelo vírus) dos indivíduos soropositivo para, a partir daí, indicar alguma política de controle. Esses mesmos especialistas também são unânimes em dizer que a taxa λ depende fundamentalmente da carga viral e do nível de $CD4^+$ da população de soropositivos. Porém, o estabelecimento de tais dependências é bastante subjetivo. Nesse exemplo vamos sugerir uma maneira de se estabelecer esta relação, considerando a taxa de conversão λ como dependente da carga viral (v) e do nível (c) de $CD4^+$, de cada indivíduo da população de soropositivos, ou seja,

$$\lambda = \lambda(v, c).$$

Inicialmente vamos fazer algumas considerações a respeito da evolução do HIV em um indivíduo.

Na corrente sanguínea, o HIV ataca principalmente o linfócito T do tipo $CD4^+$. A baixa concentração de células de $CD4^+$ na corrente sanguínea tem implicações na evolução da infecção por HIV.

Quando a cápsula do vírus entra em contato com a membrana da

célula hospedeira, logo é injetado o RNA-viral. No citoplasma o RNA-vírus serve de modelo para a síntese de uma cadeia de DNA que, por sua vez, serve de modelo para outra complementar, formando-se, assim, uma molécula de DNA de dupla cadeia. Esta migra para o núcleo e incorpora-se ao patrimônio genético da célula.

O DNA estranho (pró-vírus) pode ficar inativo por tempo indeterminado e, com a multiplicação da célula hospedeira, uma cópia do mesmo é levada para células filhas.

Inesperadamente, o pró-vírus ativa-se e desencadeia a síntese de novas moléculas de RNA para a formação de novos vírus. Esse RNA, juntamente com proteases virais, orientam tanto a síntese das proteínas da cápsula como de enzimas características do vírus, seguindo-se, finalmente, a montagem de novos vírus. A célula hospedeira é destruída.

O sistema de defesa humano é formado por macrófagos (radares), localizados em vários pontos do organismo, sempre à procura de corpos estranhos. Ao detectá-los, enviam os primeiros sinais químicos de alerta, logo reconhecidos pelos linfócitos *T* do tipo $CD4^+$ que por sua vez, fazem “soar o alarme geral” e estimulam a ativação de células do sistema imune, os linfócitos B. Estes transformam-se em plasmócitos para a produção de anticorpos e os linfócitos $CD8$ (citotóxicos) reconhecem as células infectadas e as destroem. Como o vírus ataca preferencialmente os linfócitos $CD4^+$, o alarme geral, e a posterior ativação imune, deixa de ser dado. O sistema de defesa não é mobilizado e o sistema imunológico perde a sua eficácia.

A contagem de células $CD4^+$ em sangue periférico tem implicações prognósticas na evolução da infecção pelo HIV, pois é a marca registrada de déficit imunológico e se associa a certos parâmetros clínicos. A medida de imunocompetência celular é a mais útil, clinicamente, no acompanhamento de pacientes infectados pelo HIV e a mais amplamente aceita, embora não seja a única. Atualmente, acredita-se que a quantidade de células imunocompetentes regula de alguma forma a proliferação

do vírus e é responsável pelo retardo na transferência de assintomáticos para sintomáticos.

De maneira didática, divide-se a contagem de células $CD4^+$ por mililitro em sangue periférico em quatro faixas, e os estágios de infecciosidade por HIV são classificados de acordo com essas faixas de células $CD4^+$ na corrente sanguínea³.

- 1) Estágio de infecção por HIV com **baixo risco** de desenvolvimento da AIDS, quando $CD4^+ > 0,5$ cél/ml;
- 2) Estágio caracterizado pelo aparecimento de sinais e pequenos sintomas ou alterações constitucionais. O desenvolvimento de doenças oportunistas tem um **risco moderado**, neste caso. Este estágio ocorre quando $0,2 < CD4^+ < 0,5$ cél/ml;
- 3) Um **risco preocupante** pode ser considerado quando $0,05 < CD4^+ < 0,2$ cél/ml;
- 4) Se $CD4^+ < 0,05$ cél/ml, tem-se um **alto risco** de aparecimento das doenças oportunistas tais como sarcoma de Kaposi. Neste estágio, a possibilidade de sobrevivência é baixa.

Por outro lado, existe uma relação entre a carga viral de HIV e a possibilidade de desenvolver a AIDS. Cargas altas de HIV destroem grandes quantidades de linfócitos $CD4^+$ e o sistema imunológico perde sua eficácia. Carga viral baixa não tem condição de afetar substancialmente o sistema imunológico. Os seguintes dados são relevantes para a elaboração do modelo [65]:

- a) Existe um **baixo risco** de progressão da doença quando tem-se uma carga viral abaixo de 10000 pares de RNA/ml, isto é, $V < 10000$;

³Fonte: Ministério da Saúde – <http://www.aids.gov.br>

- b) Se a carga viral estiver entre 10 mil e 100 mil pares de RNA/ml, isto é, se $10.000 < V < 100.000$, então tem-se um **risco moderado** de progressão;
- c) O **risco** é considerado **alto** se $V > 100000$.

Note que nos parâmetros de interesse – carga viral (V) e nível de $CD4^+$ – não há quantificações exatas de seus valores e sim classificações dos mesmos por faixas. Ainda segundo especialistas, as fronteiras de cada uma destas classificações também não deveriam ser tão rígidas. Por exemplo, dizer que há um **risco preocupante** quando $0,05 < CD4^+ < 0,2$ cél/ml e **baixo risco** de desenvolvimento da AIDS quando $CD4^+ > 0,5$ cél/ml é um tanto rigoroso e não muito correto. Não é razoável que indivíduos com $CD4^+$ igual a 0,49 cél/ml devam ter tratamentos diferenciados daqueles com $CD4^+$ igual a 0,51 cél/ml?

Os comentários feitos acima a respeito das incertezas presentes na carga viral e nível de $CD4^+$ não são de natureza estocástica. Elas têm origem na linguagem, que se utiliza de gradações para expressar o conhecimento do especialista.

A carga viral V e o nível de $CD4^+$ são casos típicos de variáveis linguísticas, já que são classificadas por faixas com fronteiras incertas. Assim, os valores assumidos pela carga viral e o nível de $CD4^+$ são conjuntos fuzzy. Como consequência, a taxa de transferência deve ser também uma variável linguística Λ .

Embora λ (taxa de transferência defuzzificada) dependa dos valores numéricos v (da carga viral V) e c (do nível de $CD4^+$) não sabemos, a princípio, expressar essa dependência matematicamente, já que as informações sobre V e $CD4^+$ são linguísticas e não numéricas. Utilizamos então controladores fuzzy para avaliação dessa dependência que tem o esquema da Figura 5.15




Figura 5.15: Esquema do controlador TSK com 2 entradas e 1 saída.

Base de Regras Fuzzy

Em colaboração com especialistas em AIDS, obtemos a base de regras fuzzy apresentada no Quadro 5.10.

R_1 . Se V é baixa (B) e $CD4^+$ é muito baixo (MB) então Λ é forte (F);
R_2 . Se V é baixa (B) e $CD4^+$ é baixo (B) então Λ é médio (M);
R_3 . Se V é baixa (B) e $CD4^+$ é médio (M) então Λ é médio (M);
R_4 . Se V é baixa (B) e $CD4^+$ é médio alto (MA) então Λ é médio fraco (Mf);
R_5 . Se V é baixa (B) e $CD4^+$ é alto (A) então Λ é fraco (f);
R_6 . Se V é médio (M) e $CD4^+$ é muito baixo (b) então Λ é forte (F);
R_7 . Se V é médio (M) e $CD4^+$ é baixo (B) então Λ é forte (F);
R_8 . Se V é médio (M) e $CD4^+$ é médio (M) então Λ é médio (M);
R_9 . Se V é médio (M) e $CD4^+$ é médio alto (MA) então Λ é médio fraco (Mf);
R_{10} . Se V é médio (M) e $CD4^+$ é alto (A) então Λ é fraco (f);
R_{11} . Se V é alto (A) e $CD4^+$ é muito baixo (MB) então Λ é forte (F);
R_{12} . Se V é alto (A) e $CD4^+$ é baixo (B) então Λ é forte (F);
R_{13} . Se V é alto (A) e $CD4^+$ é médio (M) então Λ é médio (M);
R_{14} . Se V é alto (A) e $CD4^+$ é médio alto (MA) então Λ é médio (M);
R_{15} . Se V é alto (A) e $CD4^+$ é alto (A) então Λ é médio (M).

Quadro 5.10: Base de regras para o modelo de taxa de transferência de soropositivos.

Muitas vezes pode ser interessante apresentar a base de regras em uma maneira simplificada (Tabela 5.3).

		Nível de $CD4^+$				
		MB	B	M	MA	A
Carga Viral	B	F	M	M	Mf	f
	M	F	F	M	Mf	f
	A	F	F	M	M	M

Tabela 5.3: Taxa de transferência Λ

Para se obter $\lambda = \lambda(v, c)$ podemos utilizar tanto o método de Mamdani como o de Takagi-Sugeno-Kang. Para ilustração, optamos pelo segundo (TSK) com consequentes constantes, isto é, os valores para indicar cada classificação de Λ são números reais dados por especialistas (Tabela 5.4).

Nível de Λ	Classificação
$\Lambda = \lambda_1 = 0,00$	para f : fraco
$\Lambda = \lambda_2 = 0,15$	para Mf : médio fraco
$\Lambda = \lambda_3 = 0,65$	para M : médio
$\Lambda = \lambda_4 = 1,00$	para F : forte

Tabela 5.4: Classificação de Λ .

Funções de pertinências

As funções de pertinências dos subconjuntos fuzzy assumidos por cada uma das variáveis V , $CD4^+$ são do tipo trapezoidal enquanto que as taxas de conversão são crisps (Veja Figuras 5.16, 5.17 e 5.18).

Utilizando o Método TSK para obter λ , a partir da Base de Regras descrita anteriormente e das funções de pertinência, temos uma superfície (Figura 5.19).

A partir desta superfície, podemos sugerir uma expressão analítica para $\lambda = \lambda(v, c)$. Segundo informações médicas, o parâmetro mais usado para controlar e diagnosticar HIV^+ é o valor de $CD4^+$. Desta forma, numa primeira aproximação, poderíamos simplesmente utilizar $\lambda = \lambda(c)$




Figura 5.16: Carga viral.




Figura 5.17: Nível de $CD4^+$.

Figura 5.18: Subconjuntos fuzzy crisps "taxa de conversão".

Figura 5.19: Saída do controlador: superfície de $\lambda(v, c)$.

como taxa de transferência no modelo fuzzy.

De acordo com a Figura 5.19, para cada valor da carga viral $V = v$, temos $\lambda = \lambda(c)$, com configuração aproximadamente linear por partes como mostrado na Figura 5.20.




Figura 5.20: Taxa de conversão em função de $CD4^+$.

O parâmetro c_{min} representa o nível mínimo de $CD4^+$ para que o indivíduo se torne sintomático e, c_M representa o nível de $CD4^+$ a partir do qual a chance de se tornar sintomático é mínima.

Observamos ainda que se houvesse interesse em estudar a taxa de conversão como função da carga viral, $\lambda = \lambda(v)$, então isso seria possível, principalmente no caso particular em que não esteja havendo tratamento. Neste caso, há uma correlação entre V e $CD4^+$. Mais ainda, quanto maior é a carga viral, menor é o nível de $CD4^+$. Modelos simplistas da relação entre carga viral e nível de $CD4^+$ podem ser dados pelas equações:

$$c(v) = \frac{r}{a + \beta v} \quad \text{ou} \quad c(v) = \lambda_0 + ae^{-\beta v},$$

de maneira que, para este caso, temos $\lambda = \lambda(v)$.

Concluindo esse exemplo, queremos ressaltar que a taxa de transferência aqui obtida, a partir de informações incertas, dadas por especialistas a respeito dos estados de saúde de indivíduos dessa população, tem forte significado biológico já que depende de outros parâmetros específicos da doença (síndrome) em questão: carga viral V e nível de

$CD4^+$. Essa é uma grande diferença do caso clássico em que tal taxa é, via de regra, dada por algum tipo de ajuste ou simulações de dados amostrais.

5.6.3 Modelo 3 – Controle Fuzzy de Pulgões

Os pulgões são os principais vetores na disseminação das doenças das plantas perenes. Recentemente, uma doença denominada “morte súbita” (ver [21, 101]), causada por vírus transportados por pulgões, tem sido a grande ameaça dos laranjais paulistas. O controle da doença é baseado, sobretudo, no controle químico de pulgões com aplicações intermitentes de biocidas e com intensidade dependente da infestação da praga.

O que pretendemos aqui é simular qual deve ser a quantidade de veneno que deve ser aplicada em uma plantação, supondo conhecida a infestação bem como a variação da praga em um talhão.

O modelo

Adotamos como variáveis de entrada a *densidade de árvores infestadas de pulgões* P (número de árvores infestadas/total de árvores) e a *variação da densidade de infestação* ΔP , que é avaliada conforme a época do ano, a qual seria mais ou menos propícia para seu crescimento. Sabe-se que os pulgões proliferam mais na época das chuvas, quando as plantas têm novos brotos.

A variável P , dada em porcentagem p , varia de 0% à 100%. A variação de P que, neste caso, representa seu crescimento numa unidade de tempo, pode assumir valores entre 0% a 100% de p . Estas variáveis serão definidas em termos linguísticos e modeladas por subconjuntos fuzzy triangulares.

Variáveis

Nas Tabelas 5.5 e 5.6 abaixo encontram-se as denominações das variáveis linguísticas e seus valores em questão.

Dens. árvores infestadas : P	Var. da dens. de infestação : ΔP
densidade baixíssima(P_{bi})	variação de densidade quase nula(V_0)
densidade muito baixa(P_b)	variação de densidade muito baixa(V_{bi})
densidade baixa(P_m)	variação de densidade baixa(V_b)
densidade média(P_{ma})	variação de densidade média(V_m)
densidade média alta(P_a)	variação de densidade alta(V_a)
densidade alta(P_{at})	variação de densidade muito alta(V_{at})

Tabela 5.5: Variáveis de entrada do modelo.

Controle da Infestação: (C)
controle nulo (C_0)
controle muito baixo (C_{bi})
controle baixo (C_b)
controle médio (C_m)
controle médio alto (C_{ma})
controle alto (C_a)
controle muito alto (C_{at})

Tabela 5.6: Variável de saída do modelo.

Base de Regras

O Quadro 5.11 abaixo sintetiza a base de regras aqui utilizada. Por exemplo, se P é *densidade média alta* (P_{ma}) e ΔP é *variação densidade média* (V_m) então o controle é *médio alto* (C_{ma}).

$P \setminus \Delta P$	V_0	V_{bi}	V_b	V_m	V_a	V_{at}
P_{bi}	C_0	C_0	C_0	C_{bi}	C_{bi}	C_b
P_b	C_0	C_{bi}	C_{bi}	C_b	C_b	C_m
P_m	C_{bi}	C_b	C_b	$[C_m]$	$[C_m]$	C_{ma}
P_{ma}	C_b	C_m	C_m	$[C_{ma}]$	$[C_{ma}]$	C_a
P_a	C_m	C_{ma}	C_{ma}	C_a	C_a	C_{at}
P_{at}	C_{ma}	C_a	C_a	C_{at}	C_{at}	C_{at}

Quadro 5.11: Base de Regras para controle de pulgões. Em destaque temos os conjuntos atingíveis se p for 18% e Δp for 38%.

Todos os conjuntos fuzzy aqui utilizados são triangulares, exceto os

últimos para as entradas. As funções de pertinência de cada um deles estão representadas nas figuras seguintes.

As funções de pertinência dos subconjuntos fuzzy das densidades de infestação podem ser visualizados na Figura 5.21 (a). Na Figura 5.21 (b) estão apresentadas as funções de pertinência dos conjuntos fuzzy de variações de densidades de infestações e na Figura 5.21 (c) as funções de pertinência dos conjuntos fuzzy do controle podem ser visualizadas.

Com o único intuito de visualizar o processo de inferência fuzzy, vamos introduzir uma notação que, em um certo sentido, pode ser vista como uma extensão daquela apresentada na Seção 1.4, do Capítulo 1, para conjunto fuzzy finito.

Para cada p , algum valor da variável lingüística P é atingido, isto porque os subconjuntos fuzzy da variável P formam uma partição fuzzy do universo de P . Este fato será denotado aqui por


$$\varphi_P(p) = \frac{\varphi_{P_{bi}}(p)}{P_{bi}} \oplus \frac{\varphi_{P_b}(p)}{P_b} \oplus \frac{\varphi_{P_m}(p)}{P_m} \oplus \frac{\varphi_{P_{ma}}(p)}{P_{ma}} \oplus \frac{\varphi_{P_a}(p)}{P_a} \oplus \frac{\varphi_{P_{at}}(p)}{P_{at}}.$$

Para o nosso exemplo, no máximo dois conjuntos fuzzy são atingidos. Por exemplo, se $p = 18$, os únicos conjuntos fuzzy atingidos são P_m e P_{ma} , pois $p = 18$ está fora dos suportes dos demais subconjuntos fuzzy da variável P . Para achar o grau de pertinência de 18% aos conjuntos P_m e P_{ma} apelamos para as expressões analíticas das funções de pertinências φ_{P_m} e $\varphi_{P_{ma}}$ ou para as expressões (2.6) vistas no Capítulo 2. Por exemplo, o conjunto fuzzy P_m tem função de pertinência dada por



$$\varphi_{P_m}(p) = \begin{cases} \frac{p-5}{7,5} & \text{se } 5 \leq p < 12,5 \\ \frac{20-p}{7,5} & \text{se } 12,5 \leq p < 20 \\ 0 & \text{caso contrário} \end{cases}.$$

Para $p = 18$ temos $\varphi_{P_m}(18) = \frac{20-18}{7,5} = 0,27$.

Se optarmos pela fórmula (2.6) para P_m , esta fornece $p = (12,5 - 20)\alpha + 20$. Para $p = 18$ temos $18 = (12,5 - 20)\alpha + 20$. Logo, a pertinência



(a) Densidades de árvores infestadas de pulgões

(b) Variação de P 

(c) Grau de controle fuzzy

Figura 5.21: Funções de pertinência para o controle de pulgões.

de 18% a P_m é $\alpha = 0,27$. Analogamente, concluimos que a pertinência de 18 a P_{ma} é 0,6. Assim,

$$\varphi_P(18) = \frac{\varphi_{P_m}(18)}{P_m} \oplus \frac{\varphi_{P_{ma}}(18)}{P_{ma}} = \frac{0,27}{P_m} \oplus \frac{0,6}{P_{ma}}.$$

Observamos que na notação acima, $\frac{0,27}{P_m}$ indica que $p = 18\%$ pertence a P_m com grau 0,27. O símbolo $\oplus$ não indica qualquer tipo de adição, apenas conecta os conjuntos atingidos. Também, $\varphi_P(p)$ não indica pertinência de p a P , já que P não é conjunto fuzzy, e sim uma variável linguística.

Controle de Pulgões com Aplicação de Biocida

Se pretendemos adotar alguma estratégia de controle, devemos definir como variável de saída uma determinada ação, que irá influenciar na dinâmica populacional dos pulgões.

O controle está representado pelos valores no interior da Tabela 5.11.

Estamos supondo que o controle seja a capacidade de eliminação da praga (*kill rate*), isto é, $c = k$ significa que a aplicação deste biocida elimina $k\%$ de p .

Simulação do modelo para uma condição inicial dada

Vamos considerar uma determinada condição inicial (crisp), representando o estado atual da densidade populacional de árvores infestadas de pulgões num laranjal, e simular o controle a ser aplicado. Suponhamos que, no instante inicial, temos uma infestação de 18% do laranjal e que estamos em janeiro (período de chuvas e brotação das laranjeiras). Neste caso podemos considerar uma taxa de variação grande, por exemplo, $\Delta p = 38$. Como ilustrado na Figura 5.20(b), esse valor atinge apenas os conjuntos fuzzy V_m e V_a .

De maneira análoga a que vimos para a infestação, temos:

- a pertinência de $\Delta p = 38\%$ a V_m é a solução de

$$38 = (30 - 40)\alpha + 40 \Rightarrow \alpha = 0,2.$$

- a pertinência de $\Delta p = 38\%$ a V_a é a solução de

$$38 = (40 - 30)\alpha + 30 \Rightarrow \alpha = 0,8.$$

Portanto,

$$\varphi_{\Delta P}(38) = \frac{\varphi_{V_m}(38)}{V_m} \oplus \frac{\varphi_{V_a}(38)}{V_a} = \frac{0,2}{V_m} \oplus \frac{0,8}{V_a}.$$

Do estudo acima podemos observar que, para os valores $p = 18$ e $\Delta p = 38$, os conjuntos atingidos são P_m , P_{ma} , V_m e V_a , destacados na Tabela 5.11.

Agora, usando a base de regras para o controle e o método de inferência de Mamdani, obtemos o seguinte

$$\begin{aligned} \varphi_C(18, 38) &= \left(\frac{\min\{\varphi_{P_m}(18), \varphi_{V_m}(38)\}}{C_m} \oplus \frac{\min\{\varphi_{P_m}(18), \varphi_{V_a}(38)\}}{C_m} \right) \oplus \\ &= \oplus \left(\frac{\min\{\varphi_{P_{ma}}(18), \varphi_{V_m}(38)\}}{C_{ma}} \oplus \frac{\min\{\varphi_{P_{ma}}(18), \varphi_{V_a}(38)\}}{C_{ma}} \right) \\ &= \left(\frac{0,20}{C_m} \oplus \frac{0,27}{C_m} \right) \oplus \left(\frac{0,20}{C_{ma}} \oplus \frac{0,40}{C_{ma}} \right). \end{aligned} \quad (5.11)$$

No método de Mamdani os conjuntos atingidos são C_m e C_{ma} . Os conjuntos entre parênteses acima (ver expressão 5.11) representam as saídas parciais. Como a saída geral é dada pelo *máximo*, não se deve levar em conta $\frac{0,20}{C_m}$ nem $\frac{0,20}{C_{ma}}$, já que suas pertinências são menores que as outras duas, isto é, a saída geral é dada por

$$\varphi_C(18, 38) = \frac{0,27}{C_m} \oplus \frac{0,40}{C_{ma}}.$$

Finalmente, adotando-se como defuzzificador o centro de massa ($G(C)$), chegamos ao valor que deve ser tomado para o controle

$$G(C) = c = \frac{0,27 \times 30 + 0,40 \times 40}{0,27 + 0,40} = 35,97.$$

Este resultado indica que devemos aplicar um biocida que tenha poder de redução de 35,97% das árvores infestadas.

Como antes da aplicação tínhamos uma densidade de 18% de árvores infestadas e uma potencialidade de crescimento de 38%, vamos supor que a aplicação de biocida se dá imediatamente após tal crescimento. Assim, quando aplicarmos o biocida teremos uma densidade de infestação dada por:

$$\overline{p}_1 = p + 0,38p = 24,84.$$

Agora, aplicando o controle que reduz tal infestação em 35,97%, isto é, $c = 35,97$, teremos uma densidade de infestação resultante, dada por:

$$\tilde{p} = \overline{p}_1 - 0,3597\overline{p}_1 \simeq 16.$$

Se continuarmos o processo iterativamente, considerando $p = 16$ como sendo a nova condição inicial, vamos obter um sistema de controle continuado. Esta estratégia será desenvolvida no Capítulo 9.

Capítulo 6

Equações Relacionais Fuzzy e Aproximação Universal

“Todo conhecimento deve ser útil e ter compromisso com a prática.”

(Sofistas – Sec. V a.C.)

Este capítulo contém dois temas bastante distintos do ponto de vista teórico: *equações relacionais fuzzy* e *aproximação universal*. Podemos dizer que o primeiro tem como objetivo a ampliação do poder de aplicações do *modus ponens generalizados* visto no Capítulo 4. Já o segundo tem interesse mais teórico. Sua importância maior está no fato de “ligar” os sistemas baseados em regras fuzzy, úteis do ponto de vista prático, com os possíveis modelos teóricos de um fenômeno que se deseja investigar.

Os principais conceitos e resultados que apresentaremos na parte de equações relacionais, embora possam ser transportados para outras situações, foram escolhidos no sentido de se estudar *diagnóstico médico*. Por outro lado, os que se referem à aproximação universal são voltados para aproximar funcionais teóricos por controladores fuzzy. Esse fato tem grandes consequências no estudo de equações diferenciais ordinárias em que o campo de direções (ou campo de inclinações) não é explicitamente dado ou então é apenas parcialmente conhecido.

Nossa opção por apresentar esses dois temas em um mesmo capítulo foi, principalmente, por motivos didáticos, considerando que são consequências naturais do que vimos nos Capítulos 4 e 5, respectivamente. O leitor que tiver interesse em aprofundar seus estudos pode consultar uma vasta literatura da qual fazem parte as referências que indicaremos no decorrer do texto.

A composição *max-min* entre relações fuzzy binárias, vista no Capítulo 3, desempenhará papel fundamental nesta primeira parte do capítulo. Porém, para nosso propósito aqui, novas composições entre relações fuzzy serão necessárias. A seguir listaremos algumas delas a partir das t-normas, t-conormas, negações e implicações fuzzy.

6.1 Composições Generalizadas de Relações Fuzzy

Nas definições que seguem, $\mathcal{R}$ e $\mathcal{S}$ são relações fuzzy binárias definidas em $U \times V$ e $V \times W$, respectivamente; Δ é uma t-norma; ∇ é uma t-conorma e $\Rightarrow$ é uma implicação fuzzy.

Definição 6.1. A composição sup-t define uma relação fuzzy $\mathcal{R} \otimes^t \mathcal{S}$ em $U \times W$ cuja função de pertinência é dada por

$$\varphi_{\mathcal{R} \otimes^t \mathcal{S}}(x, z) = \sup_{y \in V} [\varphi_{\mathcal{R}}(x, y) \Delta \varphi_{\mathcal{S}}(y, z)].$$

Exemplo 6.1. Se $\Delta = \min$, temos a composição max-min:

$$\varphi_{\mathcal{R} \otimes^t \mathcal{S}}(x, z) = \varphi_{\mathcal{R} \circ \mathcal{S}}(x, z) = \max_{y \in V} [\varphi_{\mathcal{R}}(x, y) \wedge \varphi_{\mathcal{S}}(y, z)],$$

quando $\sup = \max$.

Definição 6.2. A composição inf-c define uma relação fuzzy $\mathcal{R} \otimes_c \mathcal{S}$ em $U \times W$ cuja função de pertinência é dada por

$$\varphi_{\mathcal{R} \otimes_c \mathcal{S}}(x, z) = \inf_{y \in V} [\varphi_{\mathcal{R}}(x, y) \nabla \varphi_{\mathcal{S}}(y, z)].$$

Exemplo 6.2. Se ∇ é a t-conorma do máximo temos a composição [inf–max]

$$\varphi_{\mathcal{R} \otimes_c \mathcal{S}}(x, z) = \inf_{y \in V} [\varphi_{\mathcal{R}}(x, y) \vee \varphi_{\mathcal{S}}(y, z)].$$

Definição 6.3. A composição inf–implicação define uma relação $\mathcal{R} \otimes \Rightarrow \mathcal{S}$ em $U \times W$ cuja função de pertinência é

$$\varphi_{\mathcal{R} \otimes \Rightarrow \mathcal{S}}(x, z) = \inf_{y \in V} [\varphi_{\mathcal{R}}(x, y) \Rightarrow \varphi_{\mathcal{S}}(y, z)].$$

Observamos que, para o caso da Definição 6.3, as composições de nosso interesse aqui são as R -implicações:

$$(x \Rightarrow y) = \sup\{z \in [0, 1] : x \triangle z \leq y\},$$

introduzidas no Capítulo 4 (Definição 4.4).

Exemplo 6.3. Um caso típico dessas implicações é a de Gödel

$$(x \Rightarrow y) = g(x, y) = \sup\{w \in [0, 1] : x \triangle w \leq y\} = \begin{cases} 1 & \text{se } x \leq y \\ y & \text{se } x > y \end{cases}$$

e, neste caso, como

$$\varphi_{\mathcal{R}}(x, y) \Rightarrow \varphi_{\mathcal{S}}(y, z) = \begin{cases} 1 & \text{se } \varphi_{\mathcal{R}}(x, y) \leq \varphi_{\mathcal{S}}(y, z) \\ \varphi_{\mathcal{S}}(y, z) & \text{se } \varphi_{\mathcal{R}}(x, y) > \varphi_{\mathcal{S}}(y, z) \end{cases},$$

temos $\varphi_{\mathcal{R} \otimes \Rightarrow \mathcal{S}}(x, z) \in \{1, \inf_{y \in V} [\varphi_{\mathcal{S}}(y, z)]\}$.

Analogamente ao que comentamos no Capítulo 3 para a composição max – min, vale a pena observar que, quando os universos forem finitos, as composições acima são obtidas como um produto de matrizes, substituindo a soma por máximo (ínfimo) e o produto por uma t-norma (t-conorma ou implicação).

Exercício 6.1. Considere as formas matriciais das relações fuzzy binárias

$$\mathcal{R} = \begin{bmatrix} 0,6 & 0,6 & 0,5 \end{bmatrix} \quad \text{e} \quad \mathcal{S} = \begin{bmatrix} 0,9 & 0,6 & 1,0 \\ 0,8 & 0,8 & 0,5 \\ 0,6 & 0,4 & 0,6 \end{bmatrix}.$$

Determine a forma matricial da relação $\mathcal{R} \otimes^t \mathcal{S}$ para cada t-norma Δ :

- (a) $\Delta(x, y) = x \wedge y$;
- (b) $\Delta(x, y) = xy$;
- (c) $\Delta(x, y) = \max(0, x + y - 1)$;
- (d) $\Delta(x, y) = \frac{xy}{x + y - xy}$;
- (e) $\Delta(x, y) = \frac{xy}{2 - (x + y - xy)}$;
- (f) $\Delta(x, y) = \begin{cases} x \wedge y & \text{se } \max(x, y) = 1 \\ 0 & \text{caso contrário} \end{cases}.$

Exercício 6.2. Para as relações do Exercício 6.1, determine as formas matriciais de $\mathcal{R} \otimes \Rightarrow \mathcal{S}$ para as implicações de:

- (a) Gödel: $(x \Rightarrow y) = g(x, y) = \begin{cases} 1 & \text{se } x \leq y \\ y & \text{se } x > y \end{cases};$
- (b) Goguen: $(x \Rightarrow y) = g_n(x, y) = \begin{cases} 1 & \text{se } x \leq y \\ \frac{y}{x} & \text{se } x > y \end{cases}.$

Lembre-se que as implicações acima são do tipo R -implicações

$$(x \Rightarrow y) = \sup\{w \in [0, 1] : x \Delta w \leq y\},$$

onde $\Delta = \min$, para o caso (a), e $\Delta = \text{produto}$ para o caso (b).

Exercício 6.3. Verifique que, para qualquer t-norma, vale a identidade

$$(\mathcal{R} \otimes^t \mathcal{S})^{-1} = \mathcal{S}^{-1} \otimes^t \mathcal{R}^{-1}$$

para quaisquer relações fuzzy binárias $\mathcal{R}$ e $\mathcal{S}$ quadradas.

A seguir estudaremos as equações relacionais propriamente ditas.

Começaremos com algumas equações relacionais particulares indicando, para estas, métodos de resolução. Também investigaremos condições necessárias para existência de soluções para tais equações.

As composições definidas na seção acima agora serão tratadas com a hipótese adicional de que os conjuntos universos envolvidos sejam finitos. Desta forma, as relações podem ser representadas na forma matricial.

6.2 Equações Relacionais Fuzzy

Vamos considerar

$$U = \{u_1, u_2, \dots, u_m\}, \quad V = \{v_1, v_2, \dots, v_n\} \quad \text{e} \quad W = \{w_1, w_2, \dots, w_p\}.$$

As equações relacionais tratam de achar a forma matricial de uma relação fuzzy binária, a partir de duas outras conhecidas.

As *Equações Relacionais Fuzzy* de interesse aqui têm a forma

$$\mathcal{R} * \mathcal{X} = \mathcal{T} \quad \text{ou} \quad \mathcal{X} * \mathcal{R} = \mathcal{T},$$

onde $\mathcal{R}$ e $\mathcal{T}$ são as formas matriciais das relações fuzzy binárias dadas, “*” uma composição entre relações fuzzy (não necessariamente max–min) e $\mathcal{X}$ a forma matricial de uma relação fuzzy incógnita a ser encontrada.

Assim, por exemplo, resolver a equação

$$\mathcal{R} * \mathcal{X} = \mathcal{T}$$

significa encontrar a forma matricial de uma relação fuzzy binária $\mathcal{X}$, em $V \times W$, supondo conhecidas as formas matricias $\mathcal{R}$ e $\mathcal{T}$ em $U \times V$ e $U \times W$, respectivamente.

6.2.1 Equações Relacionais Fuzzy com a composição max–min

Inicialmente vamos estudar o caso em que a operação “ $*$ ” é a composição max–min e a equação é dada por

$$\mathcal{R} \circ \mathcal{X} = \mathcal{T}. \quad (6.1)$$

Vamos supor que os universos envolvidos sejam finitos, de modo que as relações fuzzy tenham representações matriciais

$$\mathcal{R} = [r_{ij}], \quad \mathcal{X} = [x_{jk}] \quad \text{e} \quad \mathcal{T} = [t_{ik}]$$

onde $r_{ij} = \varphi_{\mathcal{R}}(u_i, v_j)$, $x_{jk} = \varphi_{\mathcal{X}}(v_j, w_k)$ e $t_{ik} = \varphi_{\mathcal{T}}(u_i, w_k)$.

Como a composição em questão é a max–min, resolver (6.1) significa encontrar $x_{jk} \in [0, 1]$ tais que

$$\max_{1 \leq j \leq n} [\min(r_{ij}, x_{jk})] = t_{ik}, \quad (6.2)$$

para cada $1 \leq i \leq m$ e $1 \leq k \leq p$.

Portanto, no sentido de investigar a solução de (6.1), a primeira providência a ser tomada é verificar se tal sistema de equações tem chance de ter solução.

De (6.2) temos

$$\max_{1 \leq j \leq n} [\min(r_{ij}, x_{jk})] = t_{ik} \implies \max_{1 \leq j \leq n} r_{ij} \geq t_{ik}$$

para todo i e todo k . Daí, segue imediatamente que se existir uma linha i de modo que

$$\max_{1 \leq j \leq n} r_{ij} < \max_{1 \leq k \leq p} t_{ik}, \quad (6.3)$$

então **não** haverá $\mathcal{X}$ que resolva a equação. Isto nos leva ao seguinte resultado:

Proposição 6.1. *Se a desigualdade (6.3) acima for verificada, então a equação relacional fuzzy (6.1) não terá solução.*

Exemplo 6.4. Considere a equação relacional

$$\mathcal{R} \circ \mathcal{X} = \mathcal{T} \iff \begin{bmatrix} 0,7 & 0,6 \\ 0,2 & 0,3 \end{bmatrix} \circ \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix} = \begin{bmatrix} 0,4 & 0,8 \\ 0,3 & 0,2 \end{bmatrix}.$$

Para achar $\mathcal{X}$ devemos resolver o sistema de quatro equações

$$\begin{cases} \max[\min(0, 7; x_{11}), \min(0, 6; x_{21})] = 0,4 \\ \max[\min(0, 2; x_{11}), \min(0, 3; x_{21})] = 0,3 \\ \max[\min(0, 7; x_{12}), \min(0, 6; x_{22})] = 0,8 \\ \max[\min(0, 2; x_{12}), \min(0, 3; x_{22})] = 0,2 \end{cases} \quad (6.4)$$

É fácil ver que o sistema (6.4) não tem solução, pois

$$\max[\min(0, 7; x_{12}), \min(0, 6; x_{22})] \leq \max[0, 7; 0, 6] = 0,7 < 0,8 = \max t_{ik},$$

e, de acordo com a Proposição 6.1, essa equação não tem solução.

Observe que as duas primeiras equações do sistema (6.4) contém apenas as incógnitas x_{11} e x_{21} , enquanto que as duas últimas têm como incógnitas as variáveis x_{12} e x_{22} . Isso nos permite concluir que a equação relacional

$$\begin{bmatrix} 0,7 & 0,6 \\ 0,2 & 0,3 \end{bmatrix} \circ \begin{bmatrix} x_{11} \\ x_{21} \end{bmatrix} = \begin{bmatrix} 0,4 \\ 0,3 \end{bmatrix}$$

tem uma solução, que é

$$\mathcal{X}_1 = \begin{bmatrix} 0,4 \\ 0,3 \end{bmatrix}.$$

O leitor também pode observar que, além de $\mathcal{X}_1$,

$$\mathcal{X}_2 = \begin{bmatrix} 0,1 \\ 0,4 \end{bmatrix} \text{ e } \mathcal{X}_3 = \begin{bmatrix} 0,4 \\ 0,4 \end{bmatrix}$$

também são soluções da mesma equação relacional. Desta forma, uma equação relacional pode ter várias soluções. Mais ainda, para esse caso, $\mathcal{X}_3$ é a maior delas no sentido que seus elementos são os maiores dentre aqueles que fazem parte de qualquer solução da equação dada.

Na literatura, soluções como $\mathcal{X}_3$, isto é, com x_{ij} maiores possíveis, são chamadas de *maximais*. A solução maximal é então a relação formada por elementos com maior grau de pertinência à solução da equação dada.

Exercício 6.4. Resolva a equação relacional

$$\begin{bmatrix} 0,2 & 0,9 & 0,1 \\ 0,1 & 0,2 & 0,8 \\ 0,9 & 0,1 & 0,2 \end{bmatrix} \circ \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0,8 \\ 0,2 \\ 0,3 \end{bmatrix}.$$

Verifique se há mais que uma solução. Caso exista, tente determinar a solução maximal.

Vamos encerrar essa seção observando que o método de solução de (6.1) pode ser usado para resolver equações relacionais quando a incógnita está no lado direito de $\mathcal{R}$:

$$\mathcal{Y} \circ \mathcal{R} = \mathcal{T}.$$

Do Exercício 6.3, temos que $(\mathcal{Y} \circ \mathcal{R})^{-1} = \mathcal{T}^{-1} \iff \mathcal{R}^{-1} \circ \mathcal{Y}^{-1} = \mathcal{T}^{-1}$. Então, a solução da equação $\mathcal{Y} \circ \mathcal{R} = \mathcal{T}$ é a relação inversa (matriz transposta) da solução de $\mathcal{R}^{-1} \circ \mathcal{X} = \mathcal{T}^{-1}$, onde $\mathcal{X} = \mathcal{Y}^{-1}$, que recai no caso típico (6.1).

Exercício 6.5. Resolva a equação

$$\begin{bmatrix} x_1 & x_2 \end{bmatrix} \circ \begin{bmatrix} 0,7 & 0,6 \\ 0,2 & 0,3 \end{bmatrix} = \begin{bmatrix} 0,5 & 0,5 \end{bmatrix}.$$

6.2.2 Equações Relacionais Fuzzy com a composição sup-t

Nesta subseção generalizaremos a Equação (6.1), no sentido de usar outras composições, além da max-min, e enunciaremos o principal resultado sobre equações relacionais estudadas neste texto.

Agora, qualquer uma das composições vistas na Seção 6.1 será estudada e a equação de interesse é então

$$\mathcal{R} \otimes^t \mathcal{X} = \mathcal{T}. \quad (6.5)$$

Inicialmente vamos observar que, como no caso max-min, as equações

$$\mathcal{X} \otimes^t \mathcal{R} = \mathcal{T}$$

podem ser resolvidas a partir do método que resolve (6.5) pois

$$(\mathcal{R} \otimes^t \mathcal{X})^{-1} = \mathcal{X}^{-1} \otimes^t \mathcal{R}^{-1}.$$

Assim, vamos apenas estudar as equações do tipo (6.5) em que as relações $\mathcal{R}$, em $U \times V$, e $\mathcal{T}$ em $U \times W$, são dadas e queremos encontrar uma relação binária em $V \times W$ de modo que valha a Equação (6.6) abaixo

$$\mathcal{R} \otimes^t \mathcal{X} = \mathcal{T}. \quad (6.6)$$

Diferentemente do que vimos no caso max-min, aqui não iremos investigar condições necessárias para existência de soluções para (6.5). Este estudo é análogo ao feito na Seção 6.2.1. Para Equação (6.5), queremos apenas enunciar um resultado que indicará como obter uma solução, quando essa existir.

Teorema 6.2. *Dada uma t-norma Δ e as relações fuzzy $\mathcal{R}$ e $\mathcal{T}$, definidas em $U \times V$ e $U \times W$, respectivamente, então, se a equação $\mathcal{R} \otimes^t \mathcal{X} = \mathcal{T}$ tem solução, sua solução maximal é $\mathcal{D} = \mathcal{R}^{-1} \otimes \Rightarrow \mathcal{T}$, onde a implicação é dada por*

$$(x \Rightarrow y) = \{z \in [0, 1] : x \Delta z \leq y\}.$$

Demonstração. A prova desse teorema o leitor pode encontrar em [72]. ■

Do teorema acima, seguem imediatamente os seguintes corolários.

Corolário 6.3. *Se $\mathcal{D} = \mathcal{R}^{-1} \otimes \Rightarrow \mathcal{T}$ não for solução da equação $\mathcal{R} \otimes^t \mathcal{X} = \mathcal{T}$, então essa equação não tem solução.*

Corolário 6.4. *Se existir solução de (6.5) para o caso em que $\Delta = \wedge$, ou seja, se existir solução para a equação $\mathcal{R} \circ \mathcal{X} = \mathcal{T}$, então sua solução maximal é $\mathcal{D} = \mathcal{R}^{-1} \otimes_g \mathcal{T}$, onde g é a implicação de Gödel.*

Corolário 6.5. *Se existir solução de (6.5) para o caso em que $\Delta =$ produto, ou seja, se existir solução para a equação $\mathcal{R} \otimes^t \mathcal{X} = \mathcal{T}$ e a t-norma é a do produto, então sua solução maximal é $\mathcal{D} = \mathcal{R}^{-1} \otimes_{g_n} \mathcal{T}$, onde g_n é a implicação de Goguen.*

Exercício 6.6. Usando os corolários acima, verifique se a equação relacional

$$\begin{bmatrix} 0,9 & 0,3 & 1,0 \\ 0,8 & 0,8 & 0,5 \\ 0,6 & 0,4 & 0,7 \end{bmatrix} \otimes^t \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0,6 \\ 0,4 \\ 0,5 \end{bmatrix}$$

tem solução. Caso tenha, exiba uma delas para cada t-norma Δ :

a) $\Delta = \min$


b) $\Delta =$ produto.

A subseção a seguir é dedicada à “construção” de um modelo de diagnóstico, indicando o grande potencial de aplicações das equações relacionais. Será precisamente o Corolário 6.4 que iremos usar para ilustrar tal potencial.

6.2.3 Modelagem Matemática: Diagnóstico Médico

Esta aplicação foi, na verdade, uma experiência que realizamos na tentativa de verificar até que ponto um modelo fuzzy para diagnóstico médico pode ser adequado para estabelecer um diagnóstico de doenças [25].

Para um diagnóstico médico, a ideia básica é relacionar os sintomas ou sinais de pacientes com possíveis doenças, de acordo com os conhecimentos médicos de um especialista. Esta aplicação pode ser resumida no sistema de entradas e saídas:



Considere os seguintes conjuntos universais:

U = conjunto dos pacientes;

V = conjunto dos sintomas;

W = conjunto das doenças.

Especificamente nesse caso, trata-se de doenças infantis das quais tem-se conhecimento que quatro pacientes P_1 , P_2 , P_3 e P_4 , com sintomas s_1 , s_2 , s_3 , s_4 , s_5 , s_6 , s_7 , s_8 , s_9 , s_{10} e s_{11} , apresentaram os diagnósticos d_1 , d_2 , d_3 e d_4 , onde:

s_1 = febre;	s_5 = gânglio;	s_9 = fotofobia;
s_2 = cefaleia;	s_6 = coriza;	s_{10} = tosse seca;
s_3 = garganta inflamada;	s_7 = conjuntivite;	s_{11} = vômito.
s_4 = exantema;	s_8 = língua de morango;	

e

$$d_1 = \text{escarlatina}; \quad d_2 = \text{rubéola}; \quad d_3 = \text{sarampo}; \quad d_4 = \text{gripe}.$$

Esses dados irão compor a base de conhecimentos que será expressa por meio de relações fuzzy.

O que desejamos obter é uma relação fuzzy $\mathcal{D}$ de modo que $\mathcal{S} \circ \mathcal{D} = \mathcal{T}$, onde $\mathcal{S}$ e $\mathcal{T}$ são, respectivamente, as representações matriciais das relações fuzzy dos sintomas e dos pacientes diagnosticados, dadas em $U \times V$ e $U \times W$, respectivamente.

BASE DE CONHECIMENTOS – Construção do Sistema Fuzzy

A base de conhecimentos é composta pelas relações fuzzy $\mathcal{S}$ e $\mathcal{T}$, cujas matrizes são dadas abaixo em forma de tabelas:

$P \backslash s$	s_1	s_2	s_3	s_4	s_5	s_6	s_7	s_8	s_9	s_{10}	s_{11}
P_1	0,8	0,4	0,5	0,8	0,2	0,1	0,1	0,9	0,1	0,1	0,4
P_2	0,3	0,1	0,4	0,8	0,9	0,2	0,1	0,1	0,1	0,1	0,3
P_3	0,8	0,3	0,5	0,8	0,1	0,2	0,9	0,1	0,6	0,3	0,6
P_4	0,8	0,7	0,7	0,2	0,1	0,9	0,1	0,1	0,1	0,9	0,4

Tabela 6.1: Matriz da Relação $\mathcal{S}$: pacientes e respectivos sintomas.

$P \backslash d$	d_1	d_2	d_3	d_4
P_1	0,9	0,3	0,4	0,2
P_2	0,3	0,9	0,1	0,1
P_3	0,4	0,1	0,9	0,3
P_4	0,2	0,1	0,3	0,9

Tabela 6.2: Matriz da Relação $\mathcal{T}$: padrão de diagnósticos.

Neste exemplo, os dados em cada uma das tabelas acima foram obtidos na literatura (fato que possibilita usar dados de doenças que por ventura já não tenha mais sido diagnosticada). No entanto, dados de especialistas podem (e devem) ser usados no modelo.

De acordo com o Corolário 6.4, e usando as matrizes das Tabelas 6.1 e 6.2 temos que $\mathcal{D} = \mathcal{S}^{-1} \otimes_g \mathcal{T}$, cuja matriz $\mathcal{D}$ é dada pela Tabela 6.3.

$s \backslash d$	d_1	d_2	d_3	d_4
s_1	0,2	0,1	0,1	0,1
s_2	0,2	0,1	0,3	0,2
s_3	0,2	0,1	0,1	0,1
s_4	0,3	0,1	0,1	0,1
s_5	0,3	1,0	0,1	0,1
s_6	0,2	0,1	0,1	0,1
s_7	0,4	0,1	1,0	0,3
s_8	1,0	0,3	0,4	0,2
s_9	0,4	0,1	1,0	0,3
s_{10}	0,2	0,1	0,3	1,0
s_{11}	0,2	0,1	0,1	0,1

Tabela 6.3: Matriz da Relação $\mathcal{D} = \mathcal{S}^{-1} \otimes_g \mathcal{T}$: sintomas e diagnósticos.

Dessa forma, cada elemento da relação $\mathcal{D}$ indica o grau de envolvimento de cada sintoma com as diversas doenças consideradas. Por exemplo, o valor $d_{23} = 0,3$ indica que, numa escala entre **zero** e **um**, o sintoma s_2 (cefaleia) está relacionado com a doença d_3 (sarampo) com grau 0,3.

É interessante notar que a *matriz de diagnóstico* $\mathcal{D} = \mathcal{S}^{-1} \otimes_g \mathcal{T}$ foi obtida a partir do Corolário 6.4 porque ela resolve a equação relacional $\mathcal{S} \circ \mathcal{X} = \mathcal{T}$.

Em outras palavras, o diagnóstico de cada um dos pacientes P_i que compõem a base de conhecimentos, traduzida matematicamente pelas matrizes $\mathcal{S}$ e $\mathcal{T}$, pode ser “recuperado” por meio da relação $\mathcal{D}$. Por exemplo, vamos usar a matriz $\mathcal{D}$ para obter o diagnóstico do paciente P_1 a partir de seus sintomas.

Como o modelo matemático que adotamos para diagnosticar foi $\mathcal{S} \circ \mathcal{D}$, então para obter o diagnóstico do primeiro paciente, de acordo com a fórmula (3.3), em que $\mathcal{P}_1$ é a matriz com os sintomas, basta calcularmos $\mathcal{P}_1 \circ \mathcal{D}$:

$$\mathcal{P}_1 \circ \mathcal{D} = \begin{bmatrix} 0,8 \\ 0,4 \\ 0,5 \\ 0,8 \\ 0,2 \\ 0,1 \\ 0,1 \\ 0,9 \\ 0,1 \\ 0,1 \\ 0,4 \end{bmatrix}^T \circ \begin{bmatrix} 0,2 & 0,1 & 0,1 & 0,1 \\ 0,2 & 0,1 & 0,3 & 0,2 \\ 0,2 & 0,1 & 0,1 & 0,1 \\ 0,3 & 0,1 & 0,1 & 0,1 \\ 0,3 & 1,0 & 0,1 & 0,1 \\ 0,2 & 0,1 & 0,1 & 0,1 \\ 0,4 & 0,1 & 1,0 & 0,3 \\ 1,0 & 0,3 & 0,4 & 0,2 \\ 0,4 & 0,1 & 1,0 & 0,3 \\ 0,2 & 0,1 & 0,3 & 1,0 \\ 0,2 & 0,1 & 0,1 & 0,1 \end{bmatrix} = \begin{bmatrix} 0,9 & 0,3 & 0,4 & 0,2 \end{bmatrix}.$$

onde v^T indica o vetor v em linha.

A matriz resultante é formada pelos graus de cada uma das doenças apresentadas pelo primeiro paciente, pois a matriz $\mathcal{P}_1$ é uma relação em $U \times V$ (pacientes $\times$ sintomas), $\mathcal{D}$ é uma relação em $V \times W$ (sintomas $\times$ doenças) e, portanto, a composição resulta em uma relação em $U \times W$ (pacientes $\times$ doenças).

Da mesma maneira obtém-se os diagnósticos para os demais pacientes.

Exercício 6.7. Resolva os itens abaixo.

- (a) Mostre que, se o modelo matemático para diagnosticar for dado pela equação $\mathcal{S} \otimes^t \mathcal{X} = \mathcal{T}$, onde a t-norma é a do produto, então a matriz de diagnóstico é obtida por $\mathcal{D} = \mathcal{S}^{-1} \otimes_{g_n} \mathcal{T}$, em que g_n é a implicação de Goguen (sugestão: use Corolário 6.5)
- (b) Use o item (a) e refaça a aplicação acima trocando a t-norma do produto pela t-norma do mínimo.
- (c) Compare os resultados do item (b) com aqueles obtidos na aplicação acima, a partir da operação *max-min*.

O leitor interessado em ver mais aplicações pode consultar [103, 104].

Duas importantes propriedades da relação fuzzy $\mathcal{D}$ serão ressaltadas a seguir.

Seja $\mathcal{D} = \mathcal{S}^{-1} \circ \mathcal{T}$. Então valem as seguintes propriedades:

- (p_1) $\mathcal{D}$ “recupera” os diagnósticos dos pacientes que compõem a base de conhecimentos.
- (p_2) À medida que se tem diagnósticos de novos pacientes, estes podem ser incluídos na base de conhecimentos e assim, aumentar a capacidade de se obter mais diagnósticos por meio da relação fuzzy $\mathcal{D}$, tal como acontece com um médico experiente.

Essas duas propriedades da relação fuzzy $\mathcal{D}$ valorizam o seu uso na formulação de diagnósticos.

A propriedade (p_1) é a principal característica dos chamados *Sistemas Especialistas*. Os sistemas especialistas são aqueles que **imitam** especialistas humanos. Por outro lado, a propriedade (p_2), que concede a atualização da base de conhecimentos, é o que caracteriza as chamadas *Redes Neurais*. Redes neurais são sistemas que **aprendem** no sentido de incorporarem novas situações na sua base de conhecimentos sendo pois, análogos aos sistemas humanos (veja [29, 132]).

Queremos encerrar essa seção, e também a parte de equações relacionais, lembrando que muitas vezes a equação relacional dada não tem solução, principalmente porque a condição necessária, dada pela desigualdade (6.3), não é verificada. Para esses casos usa-se a noção de solução aproximada para a equação dada (veja [72, 125]).

Fundamentalmente, uma solução aproximada da equação (6.1) é uma solução de outra equação relacional fuzzy em que a relação $\mathcal{R}$ é ligeiramente aumentada e a $\mathcal{T}$, ligeiramente diminuída, a ponto de tornar a desigualdade (6.3) satisfeita.

Para o caso do diagnóstico médico, estudado acima, podemos dizer (ainda que apenas intuitivamente) que a equação relacional utilizada

satisfará a desigualdade (6.3) sempre que a matriz $\mathcal{T}$ (base de dados) for formada por, pelo menos um representante de cada doença, isto é, sempre que em cada coluna de $\mathcal{T}$ haja pelo menos um valor próximo de 1.

Para o nosso caso, o paciente P_1 teve escarlatina, P_2 rubéola, P_3 sarampo e P_4 gripe.

Como a matriz de diagnóstico $\mathcal{D}$ é o resultado de uma implicação fuzzy, em que $\mathcal{T}$ é implicada — $\mathcal{D} = \mathcal{S}^{-1} \otimes \Rightarrow \mathcal{T}$ ($\mathcal{D} = \mathcal{S}^{-1} \Rightarrow \mathcal{T}$) — intuitivamente a condição (6.3) é automaticamente satisfeita, ou seja, os maiores valores de $\mathcal{D}$ não são menores que os maiores valores de $\mathcal{T}$ (os valores de uma implicação são, pelo menos, iguais aos valores implicados).

Finalmente, a escolha da equação relacional $\mathcal{S} \otimes^t \mathcal{X} = \mathcal{T}$ para modelar diagnóstico médico foi feita apenas com o intuito de manter a coerência lógica: sintomas implicam tratamento, ou conduta ($\mathcal{S}^{-1} \Rightarrow \mathcal{T}$), daí escolhermos a equação cuja solução é $\mathcal{D} = \mathcal{S}^{-1} \otimes \Rightarrow \mathcal{T}$.

Um estudo mais detalhado desses assuntos pode ser encontrado em Klir e Yuan [72], Pedrycz [99], Pedrycz e Gomide [100], Sanchez [114], Wergenkecht e Hartmann [127] e Wangning [125] dentre muitos que tratam das equações relacionais fuzzy.


A seção a seguir trata de aproximação em um outro sentido, diferente da que comentamos acima para equações relacionais.

6.3 Aproximação Universal

Via de regra, os processos matemáticos que possibilitam conclusões (*saídas*: y), a partir de dadas informações (*entradas*: x), são dados por funcionais: $y = f(x)$. Estes processos referem-se apenas a dados e funcionais matematicamente “precisos”. No entanto, o uso dos conjuntos fuzzy, combinados com a lógica fuzzy, permite ampliar estes sistemas de entrada e saída. Como exemplo típico deste processo temos os con-

troladores fuzzy vistos anteriormente.

Um sistema de entradas e saídas pode ser basicamente representado pelo diagrama



A modelagem matemática mais comum para um sistema de entradas e saídas é aquela cujas entradas e saídas são números reais e a base de conhecimentos é dada por meio de um funcional.

Exemplo 6.5. A função que relaciona o lado l de um quadrado com seu perímetro p é dada por $p = 4l$. Neste caso, temos os seguintes valores de entradas e saídas, em metros:

Entradas (l)	Saídas (p)
1	4
2	8
3	12

Esse exemplo trata de uma situação ideal, no sentido que o processo que “transforma” cada entrada numa saída é dado por uma função matemática. Neste caso, a base de conhecimentos é resumida pela função: $p(l) = 4l$. Porém, mesmo neste caso simples, cada saída só será obtida para entradas precisas (números reais). Por exemplo, qual seria o perímetro de um quadrado (saída) que tem o lado “*em torno de 3 m*” (entrada)? A impossibilidade no fornecimento de uma saída pelo modelo adotado (função) é devido à sua ineficiência na manipulação de informações imprecisas, no caso, a entrada. Para contemplar situações deste tipo, temos duas alternativas: ou adotamos um número real para representar a entrada, isto é, defuzzificamos a entrada – na linguagem fuzzy, e neste caso, optamos pela matemática clássica, ou “aumentamos”

a base de conhecimentos a fim de incluir tal entrada. Por exemplo, com o auxílio de um especialista, alguém poderia dar uma saída linguística, e dizer que a mesma é “*em torno de 12 m*”.

As imprecisões comentadas acima estão presentes exclusivamente na entrada e/ou na saída, e não na base de conhecimentos, que deve ser apenas ajustada de modo a “entender” cada entrada imprecisa. No entanto, há situações para as quais a própria base de conhecimentos está carregada de imprecisões, por ser parcialmente desconhecida ou depender fortemente de informações de um especialista. Este é o caso em que o sistema é construído por meio de termos linguísticos.

Quando as imprecisões são modeladas matematicamente valendo-se de ferramentas fuzzy, como conjuntos fuzzy e a lógica fuzzy, então o sistema de entradas e saídas é chamado de **Sistema Fuzzy**.

Se no Exemplo 6.5 as entradas fossem da forma “*em torno de*” e modeladas por números fuzzy triangulares, como vistos no Capítulo 2, poderíamos utilizar o princípio de extensão de Zadeh, ou mesmo da multiplicação de número real por números fuzzy (que, neste caso, formariam a base de conhecimentos), para obter como saída um número fuzzy, também da forma “*em torno de*”. Porém, ainda assim a base de conhecimentos seria dada pela função $\hat{p} = 4\hat{l}$, onde $\hat{l}$ indica o número fuzzy “*em torno de l*”.

A lógica fuzzy mostra de fato a sua grande contribuição nas situações em que a base de conhecimentos, que produz as saídas, tem estruturas qualitativas que podem ser descritas por uma coleção de regras da forma *se ... então ...*. É precisamente neste ponto que os conectivos, implicações e relações fuzzy mostram sua grande utilidade.

6.3.1 Capacidade de Aproximar

Consideremos um sistema fuzzy que, a cada entrada $x \in X$, faz corresponder uma única saída $y \in Y$. No Capítulo 5 vimos vários exemplos de sistemas fuzzy, com destaque para os controladores fuzzy. O Exem-

plo 5.3 é um sistema de duas entradas e uma saída: a cada par (x, y) de números reais é associado um número real u . O sistema fuzzy define portanto uma função $f^* : \mathfrak{D} \subset \mathbb{R}^2 \longrightarrow \mathbb{R}$. Também o Modelo 5.6.2 (HIV) tem estas características. Já o controlador do Modelo 5.6.1 (Salinidade) induz a uma função $g^* : \mathfrak{D} \subset \mathbb{R}^3 \longrightarrow \mathbb{R}$.

O que queremos salientar com esses exemplos é que, cada um deles produz uma função que mapeia um domínio de entradas X em um contradomínio de saídas Y . Esta é uma característica dos sistemas baseados em regras fuzzy e é a que queremos explorar aqui com o propósito de aproximar um possível funcional (teórico) modelador de determinado fenômeno.

A grande utilidade dos sistemas fuzzy (controladores fuzzy) no estudo de aproximação está no fato de poder “substituir”, com alguma credibilidade, a tal função teórica, uma vez que esta pode apresentar muitas dificuldades de manipulação ou mesmo ser apenas conhecida parcialmente. Por exemplo, qual função teórica poderíamos propor para prever a salinidade superficial estudada no Modelo 5.6.1?

Em todos os exemplos citados aqui, foram adotados ou o método de inferência de Mamdani ou o TSK e, portanto, a t-norma é a do mínimo enquanto a t-conorma é a do máximo. Porém, outro tipo de controlador pode ser adotado e, neste caso, outras t-normas e t-conormas podem ser usadas. De um modo geral, cada uma das funções f^* , dadas por um sistema fuzzy, depende:

- (a) das funções de pertinência dos conjuntos fuzzy da base de regras;
- (b) da t-norma e t-conorma envolvidas;
- (c) do método de defuzzificação adotado.

Aqui vale uma observação que pode ajudar a compreender matematicamente o papel dos sistemas fuzzy (mais especificamente dos contro-

ladores fuzzy), principalmente para o leitor que tem certa familiaridade com os métodos matemáticos de simulação numérica.

Para cada conjunto de pares de dados (x_i, y_i) , $1 \leq i \leq r$, com $x_i \in X$ e $y_i \in Y$, o método de ajuste clássico dos *quadrados mínimos* fornece uma função $f_r^* : X \rightarrow Y$, com certas propriedades: se $y_i = f(x_i)$, onde f é uma função teórica desconhecida, isto é, conhecemos o valor da função apenas em cada x_i , que vale y_i , então a função ajustada f_r^* se aproxima de f à medida que o número de dados r aumenta.

Analogamente, no caso dos sistemas fuzzy, em vez de pares (x_i, y_i) , são dados pares (A_i, B_i) na forma “se x é A_i então y é B_i ”, onde A_i são subconjuntos fuzzy de X e B_i são subconjuntos fuzzy de Y . Levando-se em conta as características (a), (b) e (c) acima para a função ajustada, os sistemas fuzzy fornecem funções f_r^* , onde r é o número de regras da base de regras.

Antes de enunciar o principal resultado dessa seção, que tratará da aproximação da função teórica (f) por uma sequência de sistemas fuzzy, vamos observar que a base de regras deve “cobrir” totalmente o gráfico da função f .

Suponhamos que a base de regras seja dada pelo Quadro 6.1 abaixo.

	$R_1:$	“Se x é A_1 então y é B_1 ”
ou		
	$R_2:$	“Se x é A_2 então y é B_2 ”
ou		
	$\vdots$	$\vdots$
ou		
	$R_r:$	“Se x é A_r então y é B_r ”

Quadro 6.1: Base de regras para a aproximação da função teórica f .

A representação gráfica de cada uma das regras é conhecida por *grânulo*. A Figura 6.1 é uma representação gráfica dos grânulos das regras

acima, no plano cartesiano.




Figura 6.1: Grânulos e a função teórica f .

O gráfico na Figura 6.1 ilustra como um sistema fuzzy pode aproximar uma função. Como já dissemos acima, é importante que os grânulos da base de regras cubram o gráfico da função teórica f a ser aproximada.

Genericamente, uma classe **B** de objetos aproxima uma classe **A** se cada elemento de **A** tem um elemento de **B** “próximo” a ele. Neste caso, na linguagem matemática, diz-se que **B** é denso em **A**. Exemplos clássicos destes fatos são: o conjunto dos números racionais ($\mathbb{Q}$) é denso no conjunto dos reais ($\mathbb{R}$), o que significa que qualquer número real pode ser aproximado por um racional; o conjunto dos polinômios que é denso no conjunto das funções contínuas (esse é o famoso Teorema de Weierstrass); as redes neurais que aproximam funções contínuas (veja [132]).

A seguir vamos enunciar dois importantes resultados, do ponto de vista teórico, no estudo de aproximação de funções contínuas por sistemas fuzzy, mais precisamente por controladores fuzzy.

Para entender melhor os resultados, faz-se necessário a seguinte classe

$\mathcal{F}$ das funções $f_r^* : \mathbb{R}^n \longrightarrow \mathbb{R}$, obtidas a partir dos sistemas fuzzy:

$$f_r^*(x_1, x_2, \dots, x_n) = \frac{\sum_{j=1}^r y_j \triangle (\varphi_{A_{1j}}(x_1) \triangle \dots \triangle \varphi_{A_{nj}}(x_n))}{\sum_{j=1}^r \varphi_{A_{1j}}(x_1) \triangle \dots \triangle \varphi_{A_{nj}}(x_n)}, \quad (6.7)$$

onde r é o número de regras e $\varphi_{A_{1j}}, \dots, \varphi_{A_{nj}}$ são as funções de pertinência dos conjuntos fuzzy A_{ij} , $1 \leq i \leq n$ e $1 \leq j \leq r$ e $\triangle$ é uma t -norma.

Teorema 6.6 (Nguyen). *Se a t -norma $\triangle$ adotada no controlador fuzzy for a do mínimo (ou do produto) e as funções de pertinência forem do tipo gaussiana, então a classe $\mathcal{F}$, das funções f_r^* (obtida a partir dos sistemas fuzzy), é densa na classe das funções contínuas, definidas em um compacto (por exemplo, um intervalo fechado da reta).*

Este teorema pode ser entendido da seguinte forma: para cada função contínua (no nosso discurso, a função “teórica” f) existe uma sequência de funções f_r^* , produzidas por sistemas fuzzy, que estão suficientemente próximas da função teórica f .

Demonstração. A prova deste teorema pode ser encontrada em [10] ou [95]. ■

O teorema acima tem grande importância teórica nos controladores fuzzy do tipo TSK cuja saída não é defuzzificada e tem a forma das funções f_r^* definidas em (6.7).

Teorema 6.7 (Nguyen). *Suponhamos que as funções de pertinências que compõem a base de regras sejam contínuas e com valores nulos fora de intervalos (como por exemplo, as triangulares ou trapezoidais). Se a t -norma e a t -conorma são contínuas e for adotado um método de defuzzificação, como centro de gravidade ou média dos máximos, então*

a classe $\mathcal{F}$ das funções f_r^* é densa na classe das funções definidas e contínuas em conjuntos compactos.

Demonstração. A prova deste teorema pode ser encontrada em [10] ou [95]. ■

Por trás destes teoremas existe o seguinte fato: quanto maior for o número de regras (maior r) mais próxima do valor teórico esperado será a saída do controlador. Quanto mais regras, menores são os suportes dos conjuntos fuzzy da base de regras e assim, menores são os grânulos aos quais o gráfico da função teórica deve pertencer (veja Figura 6.1).

Este resultado é muito semelhante ao teorema de Weierstrass, trocando-se os graus dos polinômios aproximadores (n) pelo número de regras (r). Neste sentido, podemos dizer que os controladores fuzzy desempenham papel de fundamental importância em determinadas áreas da matemática como a **Análise Numérica**.

O leitor com interesse neste assunto pode consultar outros tipos de aproximações de funções na dissertação de mestrado de Bando [10].

A seguir vamos ilustrar o potencial de aplicação da capacidade de aproximação dos controladores fuzzy voltada para sistemas evolutivos específicos.

6.4 Controladores Fuzzy aplicado a Sistemas Dinâmicos

Esta seção encerra o Capítulo 6 destacando a propriedade de aproximação dos controladores fuzzy especificamente para sistemas dinâmicos. Além disso, proporemos uma metodologia para estimar soluções de sistemas dinâmicos tradicionais por meio dos controladores fuzzy.

Os sistemas dinâmicos tradicionais têm a forma

$$x_{t+1} = F(x_t) \iff x_{t+1} - x_t = f(x_t) \quad (6.8)$$

para o caso discreto, e

$$\frac{dx}{dt} = f(x) \quad (6.9)$$

para o caso contínuo.

O fato é que em ambos os casos o campo f representa **variação** e o sistema é estudado a partir deste. No entanto, se f não for dada explicitamente ou pior ainda, se por algum motivo ela é conhecida apenas parcialmente, com base nas características do fenômeno que se deseja modelar, então, como estudar a evolução do sistema? Tradicionalmente, em um primeiro momento, o que se faz é adotar uma expressão matemática para f que contemple tais características.

O que sugerimos aqui é a adoção de um modelo linguístico fuzzy cuja base de regras é “construída” a partir das características do fenômeno. Mais ainda, as **variáveis de estado** devem ser as entradas enquanto as saídas devem representar **variações dos estados**. Essa é a particularidade dos controladores fuzzy aplicados a sistemas dinâmicos.

Claro que, do ponto de vista de modelagem, tal procedimento faz sentido quando as informações disponíveis são de grande importância para o fenômeno. Como as regras são formuladas baseando-se no que se “conhece” do fenômeno, espera-se que a função f_r , dada pelo controlador (Seção 6.3.1) capte tal conhecimento.

Deste modo podemos “substituir” o campo teórico f pelo f_r , e estudar as soluções da equação de diferenças

$$x_{t+1} - x_t = f_r(x_t) \quad (6.10)$$

para o caso discreto; e da equação diferencial

$$\frac{dx}{dt} = f_r(x) \quad (6.11)$$

para o caso contínuo.

Dependendo das propriedades matemáticas de f (continuidade, por exemplo) e da metodologia escolhida para os controladores, espera-se que as soluções de (6.8) e de (6.9) convirjam para as soluções de (6.10) e (6.11) respectivamente, uma vez que f_r converge para f a medida que o número de regras (r) cresce. Há situações em que a função f_r é explicitamente conhecida (ver Teorema 6.6, [47, 117] e suas referências). Por exemplo, f_r pode ser dada na forma racional – quociente entre polinômios (ver [94] e suas referências). Nestes casos, (6.10) e/ou (6.11) podem ter soluções analíticas.

A seguir detalharemos um pouco mais a metodologia que pretendemos adotar neste texto. Um estudo mais aprofundado dos sistemas dinâmicos por meio de controladores fuzzy será feito no Capítulo 9.

Suponha que um determinado fenômeno seja modelado matematicamente pelo Problema de Valor Inicial (PVI)

$$\begin{cases} \frac{dx}{dt} = f(t, x) \\ x(t_0) = x_0 \end{cases} \quad (6.12)$$

cujas solução é

$$x(t) = x_0 + \int_{t_0}^t f(s, x(s)) ds. \quad (6.13)$$

Considere um controlador fuzzy com r regras que levam em conta características do campo f . Esta base de regras, via algum controlador fuzzy, define uma função f_r .

Suponha que $f_r \xrightarrow{r \rightarrow \infty} f$, como discutido na Seção 6.3.1. Suponha ainda que a função f_r tenha boas propriedades de modo que o PVI

$$\begin{cases} \frac{dx}{dt} = f_r(t, x) \\ x(t_0) = x_0 \end{cases} \quad (6.14)$$

tenha solução dada por

$$x_r(t) = x_0 + \int_{t_0}^t f_r(s, x(s)) ds. \quad (6.15)$$

A questão que se coloca é a seguinte:

Sob quais condições $x_r \xrightarrow{r \rightarrow \infty} x$ se $f_r \xrightarrow{r \rightarrow \infty} f$?

Isto é, sob quais condições a convergência das funções f_r para f implica na convergência de suas integrais para a integral de f ?

As respostas para essa questão são típicas da área de análise matemática, como os teoremas da convergência monótona ou da convergência dominada de Lebesgue. Uma resposta à questão acima, para compactos da reta, o leitor pode encontrar em [46].

Com o intuito de estudar a metodologia apresentada aqui, além de admitir que $x_r \xrightarrow{r \rightarrow \infty} x$, assumiremos que cada função f_r tenha propriedades que nos assegurem que o problema (6.14) está bem colocado e sua solução seja dada por (6.15).

Finalmente, como a função f_r do controlador fuzzy é usualmente dada na forma de tabela, usaremos métodos numéricos clássicos para obter soluções numéricas de (6.14), isto é, o método fornecerá uma sequência $\{x_r\}_n$ que estima x_r .

Como estamos admitindo que $x_r \xrightarrow{r \rightarrow \infty} x$, e que $\{x_r\}_n \xrightarrow{n \rightarrow +\infty} x_r$, esperamos que $\{x_r\}_n \xrightarrow[r \rightarrow \infty]{n \rightarrow \infty} x$. Basicamente, esta é a metodologia que queremos utilizar aqui para obter estimativas de soluções de equações diferenciais ordinárias a partir de controladores fuzzy quando só temos informações parciais sobre o campo de direções. Veja um primeiro exemplo na Seção 8.1.5 do Capítulo 8.

Além dessa metodologia para modelos contínuos, exploraremos também metodologia análoga para o caso discreto no Capítulo 9.

Capítulo 7

Medidas, Integrais e Eventos Fuzzy

“Por toda a parte, em todos os ramos do conhecimento, há a tendência para o quantitativo, para a medida, de modo tal que pode afirmar-se que o estudo propriamente científico de cada ramo começa quando nele se introduz a medida e o estudo da variação quantitativa como explicação da evolução qualitativa.”

(B. J. Caraça)

O objetivo neste capítulo é, prioritariamente, discutir questões relacionadas com certos tipos de subjetividades qualitativas e formulações matemáticas para suas mensurações. Procuramos discutir e esclarecer as diferenças/semelhanças básicas entre a probabilidade e a possibilidade, sendo esse último conceito exclusivo da teoria dos conjuntos fuzzy.

Intuitivamente, a probabilidade de um evento está relacionada à sua ocorrência. Já a pertinência relaciona-se com a identificação do mesmo. Num experimento aleatório, a incerteza termina a partir do momento em que o evento ocorreu. No caso fuzzy, a dúvida persiste. Aqui o evento não é claro; ele tem fronteiras incertas. Por exemplo, no caso probabilístico, após jogar uma moeda, não teremos dúvidas sobre o resultado: cara ou coroa. No caso fuzzy, pode haver dúvida na identificação da face

da moeda.

Para situar razoavelmente as questões de interesse, abordaremos alguns conceitos pertencentes à *Análise Fuzzy*, como medida fuzzy e integral fuzzy, que servirão para definir esperança fuzzy de uma variável incerta. Tais conceitos serão utilizados em aplicações nos capítulos seguintes.

7.1 Medidas Clássicas e Medidas Fuzzy

A Teoria da Medida é uma das grandes áreas da Análise Matemática. A noção de medida generaliza os conceitos habituais de comprimento, de área, de volume etc. A medida de probabilidade é um caso típico de uma medida, com a única restrição que seu contra-domínio é o intervalo $[0, 1]$. Como veremos, também as medidas fuzzy aqui estudadas têm esse contra-domínio. Por isso, a única medida clássica de interesse aqui é a de probabilidade.

O leitor interessado em Teoria Geral da Medida pode consultar, por exemplo, Bartle [20] ou Hönig [62], entre tantos outros livros interessantes.

7.1.1 Medida de probabilidade

Sempre foi uma das preocupações da humanidade avaliar fenômenos e, por meio da regularidade de suas ocorrências, fazer previsões. Em grande parte dos experimentos analisados, as ocorrências são aleatórias. Nesse caso, a abordagem estocástica associa cada experimento aleatório a um espaço amostral. Para cada espaço amostral existem os eventos, e para cada evento surge a necessidade de se avaliar sua ocorrência.

O interesse maior é saber como medir a chance de ocorrência do evento ou sua *probabilidade*, que é representada por um número. Considerando experimentos com um número finito de resultados, a probabilidade de um evento foi definida como sendo a razão entre o número de casos

favoráveis para sua ocorrência e o número de casos possíveis do espaço amostral. A definição axiomática de probabilidade foi posteriormente dada por Kolmogorov [75].

Como já dissemos, a ideia central na definição de probabilidade é identificar cada evento como um subconjunto de um espaço amostral e associar a esse conjunto um número para indicar a chance de sua ocorrência. Dessa forma, a probabilidade é simplesmente uma função real de conjuntos. Formalmente, uma função de conjuntos é uma probabilidade se satisfizer algumas propriedades, próprias de uma medida.

Definição 7.1. Uma probabilidade P em um espaço Ω é definida em uma família $\mathcal{A}$ de subconjuntos de Ω (que forma o domínio de P) chamada de σ -álgebra. Tal σ -álgebra deve satisfazer os seguintes axiomas:

(σ_1) O conjunto vazio $\emptyset$ está em $\mathcal{A}$;

(σ_2) Se um evento A pertence à $\mathcal{A}$, então seu complementar $A' = \Omega - A$ pertence à $\mathcal{A}$;

(σ_3) Se cada evento $A_1, A_2, \dots$ pertence à $\mathcal{A}$, então sua união pertence a $\mathcal{A}$.

Como consequência dos axiomas da σ -álgebra $\mathcal{A}$ tem-se:

(σ_4) O espaço amostral Ω pertence à $\mathcal{A}$;

(σ_5) Se cada evento $A_1, A_2, \dots$ pertence à $\mathcal{A}$, então a intersecção desses eventos pertence à $\mathcal{A}$.

Numa escrita mais formal, tem-se:

$$\left\{ \begin{array}{ll} (\sigma_1) & \emptyset \in \mathcal{A} \\ (\sigma_2) & A \in \mathcal{A} \implies A' \in \mathcal{A} \\ (\sigma_3) & A_1, A_2, \dots, A_i, \dots \in \mathcal{A} \implies \bigcup_{i \in \mathbb{N}} A_i \in \mathcal{A} \\ (\sigma_4) & \Omega \in \mathcal{A} \\ (\sigma_5) & A_1, A_2, \dots, A_i, \dots \in \mathcal{A} \implies \bigcap_{i \in \mathbb{N}} A_i \in \mathcal{A}. \end{array} \right. \quad (7.1)$$

Um exemplo de σ -álgebra é o conjunto de todos os subconjuntos de Ω , chamado de conjunto das partes de Ω : $\mathcal{P}(\Omega) = \{A : A \subset \Omega\}$.

Propriedade 7.2. Estabelecido o domínio $\mathcal{A}$ da probabilidade P , esta deve satisfazer os axiomas:

- (P_1) Para todo evento A de $\mathcal{A}$, a probabilidade $P(A)$ é um número real entre zero e um;
- (P_2) A probabilidade do espaço amostral Ω (evento certo) é 1 ;
- (P_3) A probabilidade da união de eventos, dois a dois disjuntos, é a soma de suas probabilidades.

Numa escrita mais formal

$$\left\{ \begin{array}{ll} (P_1) & \forall A \in \mathcal{A} \implies 0 \leq P(A) \leq 1; \\ (P_2) & P(\Omega) = 1; \\ (P_3) & \text{Se } A_1, A_2, \dots, A_i, \dots \in \mathcal{A} \text{ e } A_i \cap A_j = \emptyset, i \neq j, \\ & \text{então } P\left(\bigcup_{i \in \mathbb{N}} A_i\right) = \sum_{i \in \mathbb{N}} P(A_i) \end{array} \right. \quad (7.2)$$

A propriedade P_3 é denominada σ -aditividade.

Como consequência dos axiomas de probabilidades tem-se:

(P_4) $P(\emptyset) = 0$; isso porque $\Omega = \Omega \cup \emptyset \cup \emptyset \cup \dots$. Daí, segue que $P(\Omega) = P(\Omega) + \Sigma P(\emptyset)$. Portanto, $P(\emptyset) = 0$.

(P_5) Se $A \subseteq B$ então $P(A) \leq P(B)$ (*monotonicidade*);

(P_6) $\forall A \in \mathcal{A}$, $P(A') = 1 - P(A)$ (*complementar*), onde A' é o complementar de A ;

(P_7) $\forall A, B \in \mathcal{A}$, $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ (*aditividade*);

(P_8) Se $A_1 \subseteq A_2 \subseteq \dots \subseteq A_i \subseteq \dots$ então $P(\bigcup_{i \in \mathbb{N}} A_i) = \lim_{i \rightarrow \infty} P(A_i)$ (*continuidade*);

(P_9) Se $A_1 \supseteq A_2 \supseteq \dots \supseteq A_i \supseteq \dots$ então $P(\bigcap_{i \in \mathbb{N}} A_i) = \lim_{i \rightarrow \infty} P(A_i)$ (*continuidade*).

Na teoria de probabilidade, ou mais geralmente, em teoria de medida, P deve ser σ -aditiva. Entretanto, esta propriedade é muito forte e acaba excluindo, da teoria de medidas, conceitos que nos parecem passíveis de mensuração.

O exemplo a seguir ilustra melhor como é forte a exigência da σ -aditividade.

Exemplo 7.1. Suponha que deseja-se “medir” a produtividade de um grupo de trabalhadores de uma determinada indústria. Seja $\mu(A)$ a produtividade de um subconjunto A destes trabalhadores. Nesse caso, não é razoável que μ seja necessariamente aditiva, isto é, que $\mu(A \cup B) = \mu(A) + \mu(B)$, ainda que $A \cap B = \emptyset$. Pode ocorrer $\mu(A \cup B) < \mu(A) + \mu(B)$ se houver incompatibilidade entre as operações de A e B .¹

Como o exemplo acima, em muitas áreas existem fenômenos que devem ser “medidos” mas não é razoável esperar aditividade na medida sugerida. Ainda na década de 1950, Choquet [39] usou o conceito de

¹Adaptado de Murofushi [90]

medida de *capacidade* em problemas de mecânica. Tais medidas não requerem a σ -aditividade presente na definição de uma medida clássica.

Em resumo, se funções aditivas são admissíveis para “medir” incertezas, então deve haver espaço para as funções não aditivas também. A questão é: quais tipos de incertezas precisam de modelos matemáticos? Essa é uma questão genérica e por isso mesmo de difícil resposta. Uma coisa é certa, o homem cada vez mais procura respostas traduzidas por números para suas “incertezas”.

7.1.2 Medidas Fuzzy

Com o principal objetivo de flexibilizar a σ -aditividade, rígida propriedade exigida na medida clássica, Sugeno em 1974 [122] sugeriu o conceito de medida fuzzy, substituindo o axioma P_3 , da medida de probabilidade, pela propriedade P_7 da continuidade da medida. Aqui, em nosso texto, as medidas com essa mudança serão denominadas de *Medidas de Sugeno*.

Definição 7.3 (Medida de Sugeno). Seja $\mathcal{A}$ uma σ -álgebra de $\Omega \neq \emptyset$. Uma aplicação $\mu_S : \mathcal{A} \rightarrow [0, 1]$ é denominada uma *medida de Sugeno* se

- (i) $\mu_S(\emptyset) = 0$ e $\mu_S(\Omega) = 1$;
- (ii) $\forall A, B \in \mathcal{A}$, se $A \subseteq B$, então $\mu_S(A) \leq \mu_S(B)$;
- (iii) Se $A_1 \subseteq A_2 \subseteq \dots \subseteq A_i \subseteq \dots$ então $\mu_S(\bigcup_{i \in \mathbb{N}} A_i) = \lim_{i \rightarrow \infty} \mu_S(A_i)$;
- (iv) Se $A_1 \supseteq A_2 \supseteq \dots \supseteq A_i \supseteq \dots$ então $\mu_S(\bigcap_{i \in \mathbb{N}} A_i) = \lim_{i \rightarrow \infty} \mu_S(A_i)$.

Outra classe de medidas que desempenha papel de destaque na teoria dos conjuntos fuzzy são as chamadas *medidas fuzzy*.

A propriedade fundamental que uma medida deve ter, para a partir daí se fazer uma teoria de integração, é a monotonicidade. Com esta ferramenta disponível é possível ampliar o alcance da matemática na modelagem de problemas da realidade.

A definição de medida fuzzy nem sempre é a mesma na literatura. Por exemplo, é comum exigir apenas que tal medida seja monótona e positiva. No entanto, entre as diversas definições, o que há em comum é a exigência de monotonicidade e que a medida do vazio seja *zero*, a exemplo do que cumpre a medida de capacidade de Choquet (veja [39]). Nesse texto a definição que adotaremos para medida fuzzy é a seguinte:

Definição 7.4. Seja $\mathcal{A}$ uma σ -álgebra de $\Omega \neq \emptyset$. Uma aplicação $\mu : \mathcal{A} \longrightarrow [0, 1]$ é denominada uma *medida fuzzy* se

- (i) $\mu(\emptyset) = 0$ e $\mu(\Omega) = 1$;
- (ii) $\mu(A) \leq \mu(B)$ sempre que $A \subseteq B$.

Com essa definição, uma medida de Sugeno é uma particular medida fuzzy.

Exemplo 7.2. Sejam $\mathcal{A}$ uma σ -álgebra e a função de conjuntos $g_\lambda : \mathcal{A} \longrightarrow [0, 1]$ satisfazendo:

- (1) $g_\lambda(\Omega) = 1$;
- (2) $g_\lambda(A \cup B) = g_\lambda(A) + g_\lambda(B) + \lambda g_\lambda(A)g_\lambda(B)$, para algum $\lambda > -1$, se $A \cap B = \emptyset$.

Vamos mostrar que g_λ é uma medida fuzzy.

De fato, basta verificar que $g_\lambda(\emptyset) = 0$ e que $g_\lambda(A) \leq g_\lambda(B)$ se $A \subseteq B$.

$$\begin{aligned} \bullet \quad 1 &= g_\lambda(\Omega) = g_\lambda(\Omega \cup \emptyset) = g_\lambda(\Omega) + g_\lambda(\emptyset) + \lambda g_\lambda(\Omega)g_\lambda(\emptyset) = \\ &= 1 + g_\lambda(\emptyset) + \lambda g_\lambda(\emptyset), \end{aligned}$$

ou seja,

$$1 = 1 + g_\lambda(\emptyset) + \lambda g_\lambda(\emptyset) \iff (1 + \lambda)g_\lambda(\emptyset) = 0.$$

Daí, de (2) vem que $g_\lambda(\emptyset) = 0$ pois $\lambda > -1$ já que $\Omega \cap \emptyset = \emptyset$.

- Se $A \subseteq B$ então $B = A \cup (B - A)$ e $A \cap (B - A) = \emptyset$

$$\begin{aligned}
 g_\lambda(B) &= g_\lambda(A \cup (B - A)) \\
 &= g_\lambda(A) + g_\lambda(B - A) + \lambda g_\lambda(A)g_\lambda(B - A) \\
 &= g_\lambda(A) + [1 + \lambda g_\lambda(A)]g_\lambda(B - A).
 \end{aligned}$$

Porém, $[1 + \lambda g_\lambda(A)]g_\lambda(B - A) \geq 0$. Portanto, $g_\lambda(B) \geq g_\lambda(A)$.

Exercício 7.1. Prove que para $\lambda = 0$, g_λ é uma medida de Sugeno se, e somente se, é uma medida de probabilidade. (Sugestão: ver Proposição 1.4 em [68])

Exemplo 7.3. Consideremos uma alcateia com n lobos, matematicamente, $\Omega = \{x_1, x_2, \dots, x_n\}$. A cada elemento do espaço finito Ω atribuímos um número $p_i \in [0, 1]$ para seu grau de predação. Tal valor pode estar associado à idade do lobo em questão, distinguindo filhote, jovem, adulto ou velho. Vamos definir no conjunto $\mathcal{P}(\Omega)$ das partes de Ω , uma função de conjuntos g que “mede” a potencialidade de predação numa caçada:

Apenas para a alcateia inteira, o potencial de caçada é máximo:

$$g(\Omega) = g(\{x_1, x_2, \dots, x_n\}) = 1.$$

Para caçadas de dois grupos A e B , com $A \cap B = \emptyset$, tomamos

$$g(A \cup B) = g(A) + g(B) + \lambda g(A)g(B) \text{ para algum } \lambda > -1.$$

De acordo com o Exemplo 7.2, o potencial de predação, dado por g , é uma medida fuzzy.

Vamos explorar um pouco mais o Exemplo 7.3, investigando seu poder de modelar o fenômeno aqui considerado, avaliando o desempenho da participação dos lobos mais jovens numa caçada:

- Se cooperam pouco (capturam e também espantam as presas), então escolhemos λ no intervalo aberto $(-1, 0)$;
- Se cooperam moderadamente (não espantando as presas) temos $\lambda = 0$;
- Se cooperam fortemente (captam e fazem as presas correrem em direção aos lobos mais fortes), então devemos considerar $\lambda > 0$.

Na teoria dos conjuntos fuzzy um conceito bastante estudado é o de *possibilidade*. Tal assunto foi introduzido por Zadeh e tem ganhado muito destaque, tanto na teoria como na sua aplicabilidade. Devido à noção de distribuição de possibilidade, a comparação com a medida de probabilidade é frequentemente discutida.

7.1.3 Medida de possibilidade

Em 1978 Zadeh publicou o primeiro artigo que trata da medida de possibilidade [131]. Tal artigo traz importantes discussões no sentido de entender e distinguir o conceito de possibilidade do de probabilidade. Uma dessas discussões é a respeito da afirmação, aparentemente ingênua, mas bastante frequente no dia-a-dia: “tal fato é possível mas improvável”. Isto sugere que, seja qual for a noção de possibilidade (π) adotada, deve-se ter $\pi(A) \geq P(A)$. Atualmente, tal desigualdade tem sido bastante debatida e costuma ser chamada de *princípio da consistência*.

Para introduzir o conceito de medida de possibilidade é interessante algumas reflexões preliminares.

Suponha que em um determinado problema deseja-se obter o valor de um parâmetro ω_0 . Porém, a única informação disponível é que tal valor pertence a um determinado espaço Ω . Esse conhecimento parcial a respeito de ω_0 indica que algum modelo de incerteza deve ser usado para estimar ω_0 . Se por algum motivo sabe-se que todos os elementos de Ω são igualmente possíveis, então, pela metodologia Bayesiana, poder-se-

ia supor uma distribuição uniforme em Ω para se estimar ω_0 . Do ponto de vista de possibilidade essa informação pode ser descrita por meio de uma função de pertinência onde os elementos de Ω têm o mesmo grau de pertinência.

Agora, se houver informações de gradualidades (dadas por um especialista, por exemplo), isto é, que há elementos mais plausíveis que outros em Ω , como tratar tal informação? Novamente, o tratamento Bayesiano sugere a adoção de uma distribuição de probabilidade (qual deve ser a adotada é uma questão a ser debatida) para, a partir daí, usá-la no sentido de se obter ω_0 .

Na Teoria dos Conjuntos Fuzzy, a informação do especialista é tratada por meio de funções de pertinência onde ele (o especialista) indica qual dos elementos de Ω deve ter maior ou menor “peso”, de acordo com seu conhecimento.

A adoção de um modelo matemático, concebido a priori, ou de um “construído” juntamente com um especialista, é uma diferença crucial entre a teoria de probabilidade e a de possibilidade no tratamento matemático de incertezas.

Em resumo, na teoria estocástica, as informações disponíveis são tratadas por meio de funções de densidade de probabilidade. Na teoria dos conjuntos fuzzy, tais informações são modeladas por funções de pertinência $\varphi : \Omega \rightarrow [0, 1]$, que podem ser construídas segundo um especialista e $\varphi(\omega)$ indica a possibilidade de ω ser ω_0 . Como veremos, a função φ é vista como uma *distribuição de possibilidades* sobre Ω . Note que, formalmente, φ é simplesmente uma função de pertinência de algum subconjunto fuzzy de Ω .

O exemplo a seguir ilustra o tratamento de informações típicas de especialista que podem ser modeladas por meio de uma distribuição de possibilidade.

Exemplo 7.4. Na proposição “ X é um número pequeno”, considere que *número pequeno* é dado por um subconjunto fuzzy de números inteiros

não-negativos. Neste caso, tem-se mais uma distribuição de possibilidade (não formalmente definida ainda) que uma distribuição de probabilidade de X . Ou seja, é possível dizer com que grau um número inteiro n se ajusta à noção subjetiva de *número pequeno*. Este grau pode ser dado por um valor, $\varphi_X(n)$, o qual indica “tendência” de n ser pequeno e $\varphi_X : \mathbb{N} \rightarrow [0, 1]$ é interpretada como uma distribuição de possibilidade para X sobre o conjunto dos números naturais. Por outro lado, como sugerir um número $P(n)$ para a probabilidade de n ?

A seguir faremos um resumo sobre a teoria de possibilidades.

Definição 7.5. Uma *distribuição de possibilidade* sobre o conjunto $\Omega \neq \emptyset$ é uma função $\varphi : \Omega \rightarrow [0, 1]$ satisfazendo $\sup_{\omega \in \Omega} \varphi(\omega) = 1$.

Note que qualquer subconjunto fuzzy normal de Ω define uma distribuição de possibilidade sobre Ω .

Definição 7.6. Uma *medida de possibilidade* sobre Ω é uma função de conjuntos $\pi : \mathcal{A} \rightarrow [0, 1]$, satisfazendo:

- (a) $\pi(\emptyset) = 0$ e $\pi(\Omega) = 1$;
- (b) Para qualquer família $\{A_{i \in \mathbb{J}}\}$ de subconjuntos de Ω tem-se

$$\pi\left(\bigcup_{i \in \mathbb{J}} A_i\right) = \sup\{\pi(A_i) : i \in \mathbb{J}\},$$

onde $\mathbb{J}$ um conjunto de índices.

No sentido estrito, uma medida de possibilidade nada mais é que um subconjunto fuzzy do conjunto das partes de Ω , uma vez que seu contradomínio é o intervalo $[0, 1]$. Note que, dada a medida de possibilidade π , esta induz uma função de distribuição de possibilidades, φ_π , sobre Ω através de sua restrição aos elementos de Ω , ou seja, $\varphi_\pi(\omega) = \pi(\{\omega\})$.

Por outro lado, dada uma função $\varphi : \Omega \rightarrow [0, 1]$, de distribuição de possibilidade, esta induz uma medida de possibilidade sobre Ω dada por

$$\pi(A) = \begin{cases} \sup_{\omega \in A} \varphi(\omega) & \text{se } A \neq \emptyset \\ 0 & \text{se } A = \emptyset \end{cases},$$

para todo $A \subset \mathcal{A}$.

Segue da definição de medida de possibilidade que, para quaisquer subconjuntos (clássicos) $A, B \in \mathcal{A}$

$$\pi(A \cup B) = \max \{ \pi(A), \pi(B) \}.$$

No sentido de enfatizar as diferenças entre distribuição de probabilidade e de possibilidade damos o exemplo a seguir.

Exemplo 7.5. Depois de alguns dias perdido num deserto, um sujeito encontra um oásis com duas fontes de água. Na primeira fonte há uma tabuleta com os dizeres “a probabilidade da água estar contaminada é 0,02”. Isto é, $P(A) = 0,02$. Na outra fonte, a inscrição na tabuleta é “o grau de contaminação desta fonte é de 0,02”, ou seja, $\pi(A) = 0,02$.

A questão que se impõe é escolher de qual fonte o indivíduo poderá saciar sua sede.

Observamos que a dúvida, neste caso, não é apenas uma questão de semântica mas de saúde, pois se o indivíduo beber da primeira fonte, terá grande chance de beber água potável, mas corre o risco de ser envenenado em 2%. Se escolher a segunda fonte, o sujeito tem certeza que não estará bebendo água totalmente potável e seu único risco será algo como uma diarreia ou dor de cabeça.

Observe que somente se terá certeza do conteúdo de cada fonte a *posteriori* – o processo de inferência é um esforço racional para prever o desconhecido. O que se deve arguir é que tipo de conhecimento instrui melhor a tomada de decisão. Pode-se notar neste exemplo que as duas

estruturas lógicas resultam em dois processos distintos de aquisição de conhecimento, duas alternativas epistemológicas. O que informa melhor o conhecimento: chance ou tendência? Admitir que seja chance é admitir que as coisas são ou não são – no caso da primeira fonte, onde a informação é dada pela probabilidade de contaminação – a água é ou não totalmente potável. Optar pela segunda fonte é decidir pelo grau de contaminação que indica a tendência de contaminação.²

Probabilidade e graus de pertinência têm naturezas distintas nas suas interpretações. Embora ambas se expressem por valores de **zero** a **um** e ambas indiquem incertezas, a probabilidade afere e informa a **chance** de um determinado evento ocorrer, enquanto que pertinência (ou possibilidade) mede a **tendência** do evento ser verdadeiro.

O exemplo a seguir tem por objetivo continuar enfatizando a diferença entre probabilidade e possibilidade, porém destacando que nem toda função de pertinência pode ser interpretada como distribuição de possibilidade.

Exemplo 7.6 (Epidemiologia). No estudo de epidemias é muito comum o interesse do quão intensa a infecciosidade de determinada doença, isto é, quantas pessoas são infectadas por um indivíduo infeccioso. Tal infecciosidade está estreitamente relacionada com a taxa, $\beta \in [0, 1]$, com que indivíduos suscetíveis se tornam infectados. Biologicamente o parâmetro β , denominado *coeficiente de transmissão*, está diretamente ligado à chance ou tendência de ocorrer a transmissão da doença quando há contato potencialmente infectante entre um indivíduo suscetível e um infectado.

Nos modelos clássicos (determinísticos) tal parâmetro é avaliado por uma espécie de média, obtida na população e, com isso, os indivíduos infectantes têm o mesmo “poder” de infectar os suscetíveis. É como se admitíssemos homogeneidade na classe dos infectados. Entretanto,

²Adaptado de Bezdek [27]

essa é uma hipótese bastante simplificadora já que é bastante razoável se esperar o contrário, ou seja, que haja indivíduos com maior poder de transmitir a doença que outros, e os motivos para isto são bem diversos (ver Sadegh-Zadeh [111]). Um desses, e que será o único considerado aqui, é a carga viral que o indivíduo infectante possui. Desse modo, podemos considerar $\beta = \beta(v)$ onde v representa a carga viral de um indivíduo infectante.

Das considerações feitas até aqui, o parâmetro β pode ser visto como uma função de pertinência de algum subconjunto fuzzy do domínio em que a carga viral toma seus valores. Como v pode ser traduzido por um número, tal domínio é o conjunto dos números reais. Assim,

$$\beta : \mathbb{R}^+ \rightarrow [0, 1].$$

O número $\beta(v)$ apenas reflete o grau (correlação) com que β está relacionado com v , isto é, o efeito de v no parâmetro β . Sabendo-se o valor efetivo (v_0) da carga viral, tem-se, como consequência, o valor de β .

Efetivamente, até aqui não foi abordado qualquer tipo de incerteza. Nenhuma informação a respeito da carga viral foi dada no sentido de se obter v_0 e assim, nada indica que a função de pertinência β corresponda a uma distribuição de possibilidade. Porém, junto a um especialista da doença em questão, pode-se obter informações como, por exemplo, que v_0 está restrito a um intervalo $v_{\min}, v_{\max}$. Nesse caso, podemos pensar em um modelo matemático na tentativa de avaliar v_0 , já que um espaço para o parâmetro em questão foi selecionado. Se, além do espaço escolhido, soubermos que há valores de $v \in [v_{\min}, v_{\max}]$ mais plausíveis que outros, e com “pesos” $\rho(v) \in [0, 1]$, é possível então estabelecer uma *distribuição de possibilidade*

$$\rho : [v_{\min}, v_{\max}] \rightarrow [0, 1]$$

para v na expectativa de se avaliar v_0 .

Essa função ρ pode ser “construída” diretamente pelo especialista, de acordo com seus conhecimentos empíricos. Tal função não precisa ser nenhuma distribuição de densidade de probabilidade conhecida a priori. Mais ainda, ρ não precisa ser uma densidade de distribuição de probabilidade – sua integral não precisa ser necessariamente igual a 1. Com isso, estamos reforçando a diferença entre o método fuzzy e o estocástico, no esforço de obter uma estimação, no caso do parâmetro v_0 .

À luz do exemplo acima podemos dizer que a densidade de distribuição de probabilidade está para a medida de probabilidades assim como a distribuição de possibilidade está para a medida de possibilidade. Por exemplo, considere $A \subset \Omega = \mathbb{R}$.

Se para algum $v \in [v_{\min}, v_{\max}]$ temos $\rho(v) = 1$, então a distribuição de possibilidade ρ induz uma medida de possibilidade sobre Ω dada por

$$\pi(A) = \begin{cases} \sup_{v \in A} \rho(v) & \text{se } A \neq \emptyset \\ 0 & \text{se } A = \emptyset \end{cases}.$$

Não é difícil verificar que π é também uma medida fuzzy.

Se $\int_{\Omega} \rho(v) dv = 1$, então ρ é uma densidade de distribuição de probabilidade que induz uma medida de probabilidade em Ω , dada por

$$P(A) = \int_A \rho(v) dv.$$

Não é difícil verificar que P é uma medida de Sugeno. Porém π pode não ser uma medida de Sugeno. Por outro lado, em qualquer espaço finito os conceitos de medida de possibilidade e de Sugeno são equivalentes (ver [11]).

Para resumir, a Figura 7.1 ilustra uma certa hierarquia existente nas medidas discutidas acima.




Figura 7.1: Hierarquia das medidas fuzzy.

A subseção seguinte encerra nossa discussão a respeito de medidas.

7.1.4 Transformação Probabilidade/Possibilidade

Em muitos problemas práticos é essencial uma maneira de transformar probabilidade em possibilidade ou vice-versa. Por exemplo, construir uma função de pertinência (distribuição de possibilidade) de um conjunto fuzzy a partir de um conjunto de dados estatísticos ou o inverso, isto é, construir uma função de densidade de probabilidade a partir de uma distribuição de possibilidade. Também, em muitos casos, pode ser interessante comparar as informações obtidas a partir dos dois métodos aplicados ao um mesmo fenômeno.

Na literatura, todos os métodos adotados para transformar probabilidade em possibilidade, ou vice-versa, têm algo em comum: todos obedecem ao princípio da consistência, comentado no início da Seção 7.1.3:

$$P(A) \leq \pi(A) \text{ para todo } A \subseteq \Omega.$$

Aqui vamos nos concentrar apenas no método de transformação entre probabilidade e possibilidade para o caso em que o espaço Ω é finito.

Suponhamos que $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$. Além disso,

$$1 = \pi(\omega_1) \geq \pi(\omega_2) \geq \dots \geq \pi(\omega_n) \quad \text{e} \quad P(\omega_1) \geq P(\omega_2) \geq \dots \geq P(\omega_n).$$

As transformações mais simples, e as únicas que trataremos aqui, são

$$\text{a) } \pi(\omega_i) = \frac{P(\omega_i)}{P(\omega_1)} \quad \text{ou} \quad \text{b) } P(\omega_i) = \frac{\pi(\omega_i)}{\sum_{i=1}^n \pi(\omega_i)}.$$

O exemplo a seguir é um resumo de um estudo realizado por Castanho [34] em sua tese de doutorado.

Exemplo 7.7 (Diagnóstico do câncer de próstata). Ao diagnosticar um câncer de próstata, o médico avalia o estágio em que esse se encontra, para indicar o tratamento apropriado. Sabe-se que tratamentos, como cirurgia ou radioterapia, têm grande chance de cura quando o câncer está confinado no órgão.

Para fazer essa avaliação o médico dispõe de informações dadas pelo exame clínico (toque retal e/ou modalidades de imagem), exame de sangue que mede o nível de antígeno prostático específico (PSA) – que é uma substância que aumenta com o aumento do tumor – e pela biópsia. Na biópsia o tumor é classificado pelo escore de Gleason de acordo com o grau de diferenciação das células (agressividade do tumor).

Combinando essas três variáveis e utilizando dados estatísticos, existem, na literatura urológica, várias tabelas que indicam a probabilidade do paciente estar em determinado estágio de desenvolvimento da doença, com envolvimento da cápsula prostática, envolvimento de vesículas seminais, e com envolvimento de linfonodos pélvicos. Essas classificações são claramente imprecisas. As fronteiras entre cada um desses estágios não são precisas nem bem definidas, o que sugere tratá-las como variáveis linguísticas, como vimos no Capítulo 4.

Com as variáveis utilizadas para prognosticar o estágio do câncer de próstata foi desenvolvido um sistema baseado em regras fuzzy com a finalidade de se obter o estágio da doença. Neste sistema a variável de saída (estágio da doença) é modelada por meio de conjuntos fuzzy. Então,

para cada valor real que representa a saída do sistema, corresponde um grau de pertinência ao conjunto fuzzy que descreve determinado estágio da doença. A proposição “estágio da doença é confinado”, por exemplo, permite ver esse grau como a possibilidade que a doença esteja confinada no órgão. Dessa forma, essa proposição define uma distribuição de possibilidade no conjunto dos indivíduos.

Assim sendo, temos informações de um mesmo fenômeno dadas em termos probabilísticos (tabelas de probabilidade) e possibilísticos (sistema baseado em regras fuzzy). Para verificar se essas informações são consistentes, uma transformação probabilidade/possibilidade deve ser utilizada.

Seja, por exemplo, um paciente com os seguintes dados pré-cirúrgicos: estado clínico classificado como *palpável*; circunscrito *a menos da metade de um lobo* (*lobo* é cada uma das duas partes em que a próstata é subdividida); nível de PSA igual a 5,3 ng/ml (ng significa nanograma) e grau de Gleason na biópsia igual a 7,0. Segundo o sistema baseado em regras, a possibilidade desse paciente ter câncer confinado no órgão é 0,60; de que tenha envolvimento capsular é 0,93 e de ter envolvimento de vesículas e/ou linfonodos é 0,11. Utilizando a transformação

$$P(\omega_i) = \frac{\pi(\omega_i)}{\sum_{i=1}^n \pi(\omega_i)},$$

obtemos as seguintes possibilidades: 0,36; 0,57 e 0,07, respectivamente. Nas tabelas de probabilidade de Partin (ver [34]) encontramos 0,33; 0,52 e 0,14 respectivamente. Pelo menos para este caso, podemos afirmar que os resultados fornecidos em termos de probabilidade e possibilidade indicam o mesmo estágio de desenvolvimento da doença.

O leitor pode encontrar outras transformações em diversos textos de lógica fuzzy [34, 40, 48, 49, 72, 121].

Vamos encerrar essa seção comentando que, no esforço de se obter um valor esperado que estime um certo parâmetro, como discutimos no Exemplo 7.6, além do conceito de medida, precisamos da noção de integral, a exemplo do que é feito no caso clássico.

Resumidamente, podemos traçar um paralelo entre as metodologias estocástica e fuzzy a fim de se obter valores que estimem, por exemplo, parâmetros.

No caso estocástico, a partir de um experimento aleatório tem-se uma função de distribuição de densidade que, por sua vez, induz uma medida de probabilidade. A partir dessa medida, constrói-se uma integral para, finalmente, se obter o valor esperado.

No caso fuzzy, a partir de um subconjunto fuzzy, mais precisamente, de sua função de pertinência (que pode ser fornecida por um especialista, ou construída a partir de um conjunto de dados estatísticos) tem-se uma função de distribuição de possibilidade, que induz uma medida de possibilidade (que é uma medida fuzzy).

A ideia agora é partir dessa medida fuzzy, construir uma integral fuzzy e finalmente obter um valor esperado. Assim, na seção seguinte nos deteremos ao estudo de diversos tipos de integral.

7.2 Integrais Fuzzy

Acima apresentamos uma pequena justificativa da necessidade de se estudar o conceito de integral, muito embora tanto na matemática ou mais geralmente nas ciências exatas, tal conceito dispensa qualquer motivação. Sua importância nas disciplinas teóricas ligadas à Análise Matemática não é menor que aquela devida às aplicações em variados tipos de problemas, como cálculo de volumes, áreas, energia, trabalho entre tantos outros.

Nesta seção, subdividida em subseções, serão relatados alguns conceitos e propriedades de integrais com respeito às medidas clássicas e

fuzzy.

7.2.1 Integral de Lebesgue

Aqui será dada apenas a noção da construção da integral de Lebesgue com respeito a uma medida abstrata, sem qualquer interesse em questões técnicas como, por exemplo, a existência de tal integral.

A ideia é a seguinte: apoiados no fato que *toda função positiva f é limite de uma sequência de funções simples*, definimos inicialmente a integral de Lebesgue para funções simples e a integral da função f será definida como o limite das integrais destas funções simples que convergem para f .

Suponha que $g : \Omega \rightarrow [0, \infty)$ seja uma função simples, ou seja,

$$g(\omega) = \sum_{i=1}^k \alpha_i \chi_{A_i}(\omega),$$

onde A_i , $1 \leq i \leq k$, é uma partição de Ω e χ_{A_i} é a função característica de A_i .

Definição 7.7. Seja μ uma medida (σ -aditiva) em Ω . A *integral de Lebesgue* da função simples g sobre Ω , com respeito a medida (clássica) μ , é dada por

$$\int_{\Omega} g \, d\mu = \sum_{i=1}^k \alpha_i \mu(A_i). \quad (7.3)$$

Exemplo 7.8. Considere g dada apenas por três valores distintos: α_1, α_2 , e α_3 , ou seja,

$$g(\omega) = \alpha_1 \chi_{A_1}(\omega) + \alpha_2 \chi_{A_2}(\omega) + \alpha_3 \chi_{A_3}(\omega), \quad \forall \omega \in \Omega.$$

Então

$$\int_{\Omega} g \, d\mu = \alpha_1 \mu(A_1) + \alpha_2 \mu(A_2) + \alpha_3 \mu(A_3).$$

Note que cada parcela $\alpha_i \mu(A_i)$ pode ser vista como uma “área” e a integral de g é a área total da figura limitada pelo seu gráfico, pelas retas verticais limítrofes da figura e pelo eixo Ω . A Figura 7.2 ilustra a integral de Lebesgue de g .




Figura 7.2: Integral de Lebesgue de uma função simples.

Por outro lado, a “área” citada acima, que dá a integral de Lebesgue de g , pode ser obtida fazendo-se a partição no eixo vertical dos α . Sob este ponto de vista, tal área é dada por

$$\begin{aligned} & \mu\{\omega \in \Omega : g(\omega) > 0\}(\alpha_1 - 0) + \mu\{\omega \in \Omega : g(\omega) > \alpha_1\}(\alpha_2 - \alpha_1) \\ & + \mu\{\omega \in \Omega : g(\omega) > \alpha_2\}(\alpha_3 - \alpha_2) = \\ & = \int_0^{\alpha_3} \mu\{\omega \in \Omega : g(\omega) > \alpha\} d\alpha, \end{aligned}$$

sendo que esta última corresponde à integral de Riemann da função $h(\alpha) = \mu\{\omega \in \Omega : g(\omega) > \alpha\}$ em relação a α .

Desta forma, tem-se

$$\int_{\Omega} g d\mu = \int_0^{\alpha_3} \mu\{\omega \in \Omega : g(\omega) > \alpha\} d\alpha.$$

Este exemplo pode ser facilmente generalizado para qualquer função

simples, ou seja,

$$\begin{aligned} \int_{\Omega} g \, d\mu &= \sum_{i=0}^{\infty} \mu\{\omega \in \Omega : g(\omega) > \alpha_i\}(\alpha_{(i+1)} - \alpha_i) \\ &= \int_0^{\infty} \mu\{\omega \in \Omega : g(\omega) > \alpha\} \, d\alpha. \end{aligned} \quad (7.4)$$

De acordo com o que foi dito, uma função positiva $f : \Omega \rightarrow [0, \infty)$ é limite de uma sequência de funções simples, sua integral de Lebesgue, com respeito à medida (clássica) μ , é o limite das integrais destas funções simples. Daí e de (7.4) vem que

$$\begin{aligned} \int_{\Omega} f \, d\mu &= (\text{“área” da figura entre o gráfico de } f \text{ e } \Omega) \\ &= \int_0^{\infty} h(\alpha) \, d\alpha \end{aligned} \quad (7.5)$$

onde $h(\alpha) = \mu\{\omega \in \Omega : f(\omega) > \alpha\}$.

A Fórmula (7.5) indica que a integral abstrata de Lebesgue de f pode ser obtida pela integral de Riemann da função que fornece a medida dos “níveis” de f (veja Figura 7.3).




Figura 7.3: Integral de Riemann da função h e a de Lebesgue da função f .

Uma consequência imediata da Fórmula (7.5) é a seguinte:

Se $X : \Omega \rightarrow [0, \infty)$ é uma variável aleatória em Ω com medida de probabilidade P , então

$$E(X) = \int_{\Omega} X \, dP = \int_0^{\infty} P[X > x] \, dx,$$

onde $E(X)$ é a esperança matemática de X e $[X > x] = \{\omega \in \Omega : X(\omega) > x\}$.

Este é um resultado bastante utilizado no cálculo da esperança estocástica de variáveis aleatórias e serve como motivação para integral de Choquet, a qual tem sido utilizada também em teoria de integral fuzzy, e não requer a aditividade na medida em questão.

Observe que se X for uma variável aleatória com

$$X(\omega) \geq 0 \quad \forall \omega \in \Omega,$$

então

$$E(X) = \int_0^{\infty} (1 - F(x)) \, dx$$

onde $F(x) = P(X \leq x)$ é a distribuição acumulada de X .

Para o caso discreto, tem-se

$$E(X) = \sum_{n=0}^{\infty} P(X > n) = \sum_{n=1}^{\infty} P(x \geq n).$$

7.2.2 Integral de Choquet

Definição 7.8. A *integral de Choquet* da função $f : \Omega \rightarrow [0, \infty)$ em relação à medida (não necessariamente aditiva) μ é dada por:

$$(C) \int_{\Omega} f \, d\mu = \int_0^{\infty} \mu\{\omega \in \Omega : f(\omega) > \alpha\} \, d\alpha.$$

Note que se μ não for aditiva, algumas propriedades próprias da integral de Lebesgue deixam de valer. A principal delas é a linearidade,

isto é, se μ não for aditiva então pode ocorrer que:

$$(C) \int_{\Omega} (af + g) d\mu \neq a \left[(C) \int_{\Omega} f d\mu \right] + (C) \int_{\Omega} g d\mu.$$

Intuitivamente, para se obter a integral de Choquet de uma função

$$f : \Omega \rightarrow [0, \infty),$$

usa-se apenas o conceito de integral de Riemann nos níveis estritos de f , os quais estão definidos no contra-domínio (números reais) dessa função.

Choquet usou este conceito de integral com respeito à medida de capacidade (que não é aditiva) em estudos de mecânica [39].

7.2.3 Integral de Sugeno

A integral de Sugeno foi introduzida ainda na década de 70 e foi a primeira que recebeu o nome de integral fuzzy [122]. Tal integral foi definida de modo que se pudesse defuzzificar um número fuzzy a partir de uma medida que não fosse necessariamente σ -aditiva.

A definição dada aqui é para funções cujo contra-domínio é o intervalo $[0, 1]$, isto é, para funções de pertinência de subconjuntos fuzzy. Há casos em que essa exigência é deixada de lado [95].

Definição 7.9. Sejam $f : \Omega \rightarrow [0, 1]$ uma função e μ uma medida fuzzy sobre Ω . A *integral de Sugeno* de f sobre Ω , com respeito à medida μ , é o número

$$\begin{aligned} (S) \int_{\Omega} f d\mu &= \sup_{0 \leq \alpha \leq 1} [\alpha \wedge \mu\{\omega \in \Omega : f(\omega) \geq \alpha\}] \\ &= \sup_{0 \leq \alpha \leq 1} [\alpha \wedge \mu\{\omega \in \Omega : f(\omega) > \alpha\}]. \end{aligned} \quad (7.6)$$

Uma primeira observação a ser feita é que a integral de Sugeno pode ser obtida formalmente, substituindo a soma pelo **supremo** (sup) e o

produto pelo **mínimo** ($\wedge$) na integral de Lebesgue (ou na de Choquet).

Se A for um subconjunto clássico de Ω , então

$$(S) \int_A f \, d\mu = \sup_{0 \leq \alpha \leq 1} [\alpha \wedge \mu(A \cap H(\alpha))],$$

onde $H(\alpha) = \mu\{\omega \in \Omega : f(\omega) \geq \alpha\}$ é denominada *função nível de f* .

É interessante notar que $H : [0, 1] \rightarrow [0, 1]$ é uma função decrescente e contínua em quase todo ponto [11]. Essa observação terá utilidade no entendimento dos próximos resultados.

Teorema 7.1. *Sejam $f : \Omega \rightarrow [0, 1]$ uma função (típica de pertinência) e μ uma medida fuzzy sobre Ω . Se a função $H(\alpha) = \mu\{\omega \in \Omega : f(\omega) \geq \alpha\}$ tem um ponto fixo $\bar{\alpha}$, então*

$$(S) \int_{\Omega} f \, d\mu = \bar{\alpha} = H(\bar{\alpha}). \quad (7.7)$$

Em outras palavras, a integral de Sugeno de f coincide com o ponto fixo de H , se este existir.

Demonstração. A demonstração deste teorema pode ser vista em [122]. ■

A Figura 7.4 é uma ilustração deste teorema.




Figura 7.4: Ilustração do Teorema 7.1.

A parte da curva destacada na Figura 7.4 (b) indica o valor de $[\alpha \wedge H(\alpha)]$, para $\alpha \in [0, 1]$, e tem como sup o valor $\bar{\alpha}$, que é a intersecção da bissetriz com o gráfico de $H(\alpha)$ e portanto, coincide com o ponto fixo de $H(\alpha)$.

Exemplo 7.9. Seja F um subconjunto fuzzy de $\mathbb{R}$, cuja função de pertinência $f : \mathbb{R} \rightarrow [0, 1]$ é definida por $f(x) = -4x^2 + 4x$. Então,

$$[F]^\alpha = \{x \in \mathbb{R} : -4x^2 + 4x \geq \alpha\} = \left[\frac{1 - \sqrt{1 - \alpha}}{2}, \frac{1 + \sqrt{1 - \alpha}}{2} \right].$$

Se considerarmos a medida usual m de Lebesgue da reta que, obviamente é uma medida fuzzy, então $m([F]^\alpha) = \frac{1 + \sqrt{1 - \alpha}}{2} - \frac{1 - \sqrt{1 - \alpha}}{2} = \sqrt{1 - \alpha} = H(\alpha)$.

Logo,

$$(S) \int_{\mathbb{R}} f \, dm = \sup_{0 \leq \alpha \leq 1} [\alpha \wedge \sqrt{1 - \alpha}].$$

A função $H(\alpha) = m([F]^\alpha) = \sqrt{1 - \alpha}$, que associa a cada α -nível a sua medida, é monótona decrescente e, neste caso, é contínua. Pelo Teorema 7.1, temos

$$(S) \int_{\mathbb{R}} f \, dm = H(\bar{\alpha}) = \bar{\alpha} = \frac{-1 + \sqrt{5}}{2}$$

$$\text{pois, } H(\bar{\alpha}) = \bar{\alpha} \iff \sqrt{1 - \bar{\alpha}} = \bar{\alpha} \implies \bar{\alpha} = \frac{-1 + \sqrt{5}}{2}.$$

$$\begin{aligned} \text{Seja agora } A = \left[\frac{1}{3}, \frac{1}{2}\right], \text{ então } m(A \cap [F]^\alpha) &= \begin{cases} \frac{1}{6} & \text{se } \alpha \leq \frac{8}{9} \\ \frac{\sqrt{1 - \alpha}}{2} & \text{se } \frac{8}{9} \leq \alpha \leq 1 \end{cases} \\ \implies [\alpha \wedge m(A \cap [F]^\alpha)] &= \begin{cases} \alpha & \text{se } \alpha \leq \frac{1}{6} \\ \frac{1}{6} & \text{se } \frac{1}{6} < \alpha \leq \frac{8}{9} \\ \frac{\sqrt{1 - \alpha}}{2} & \text{se } \frac{8}{9} < \alpha \leq 1 \end{cases} \implies \int_{\left[\frac{1}{3}, \frac{1}{2}\right]} f \, dm = \frac{1}{6}. \end{aligned}$$




Figura 7.5: Esquema geométrico da integral de Sugeno de f sobre A .

Deixamos como tarefa para o leitor obter

$$(C) \int f \, d\mu \text{ e } \left| (C) \int f \, d\mu - (S) \int f \, d\mu \right|$$

para f do Exemplo 7.9.

Teorema 7.2. *Sejam $f : \Omega \rightarrow [0, 1]$ uma função (típica de pertinência) e μ uma medida (clássica) sobre Ω . Então*

$$\left| (S) \int_{\Omega} f \, d\mu - \int_0^1 H(\alpha) \, d\alpha \right| \leq \frac{1}{4}. \quad (7.8)$$

Note que $\int_0^1 H(\alpha) \, d\alpha = \int_0^1 \mu\{\omega \in \Omega : f(\omega) \geq \alpha\} \, d\alpha$ é a integral de Choquet da função f .

Demonstração. Faremos apenas um esboço da demonstração.

Seja $\bar{\alpha} = H(\bar{\alpha})$ o ponto fixo de $H(\alpha)$. Então,

$$\begin{aligned} \left| (S) \int_{\Omega} f \, d\mu - \int_0^1 H(\alpha) \, d\alpha \right| &= \left| \bar{\alpha} - \int_0^1 H(\alpha) \, d\alpha \right| = \\ &= \left| \int_0^{\bar{\alpha}} 1 \, d\alpha - \left[\int_0^{\bar{\alpha}} H(\alpha) \, d\alpha + \int_{\bar{\alpha}}^1 H(\alpha) \, d\alpha \right] \right|. \end{aligned}$$

Logo, segue que

$$\left| \int_0^{\bar{\alpha}} (1 - H(\alpha)) \, d\alpha - \int_{\bar{\alpha}}^1 H(\alpha) \, d\alpha \right| \leq \int_0^{\bar{\alpha}} (1 - H(\alpha)) \, d\alpha \leq$$

$$\int_0^{\bar{\alpha}} (1 - H(\bar{\alpha})) d\alpha = \int_0^{\bar{\alpha}} (1 - \bar{\alpha}) d\alpha = (1 - \bar{\alpha})\bar{\alpha} \leq \frac{1}{4},$$

já que $\bar{\alpha} \in [0, 1]$.

A penúltima desigualdade acima é válida porque H é decrescente. É importante frisar que não é possível diminuir a diferença máxima de $\frac{1}{4}$ que aparece no teorema acima. Ou seja, existem funções f para as quais esta diferença é atingida [11, 107]. No entanto, escolhendo certas categorias de funções, tal diferença cai bastante (veja Exemplos 7.10 e 7.11). ■

Este teorema foi originalmente proposto por Sugeno em 1974 para variável inexata. No fim desta seção ele será enunciado em tal contexto.

Propriedades da integral de Sugeno

Assim como a integral de Choquet, a integral de Sugeno também não é linear. No entanto, ambas são monótonas, isto é,

$$(S) \int_{\Omega} f d\mu \leq (S) \int_{\Omega} g d\mu \quad \text{se } f \leq g.$$

A seguir estão listadas mais propriedades da integral de Sugeno, cujas provas podem ser encontradas em [11].

Sejam $f : \Omega \longrightarrow [0, 1]$ e $g : \Omega \longrightarrow [0, 1]$ funções, μ uma medida fuzzy em Ω e, A e B subconjuntos de Ω . Então valem as propriedades:

- (i) Se $f(x) = k$, então $(S) \int_A f d\mu = k \wedge \mu(A)$;
- (ii) Se $f \leq g$, então $(S) \int_A f d\mu \leq (S) \int_A g d\mu$;
- (iii) $(S) \int_A (f \vee g) d\mu \geq (S) \int_A f d\mu \vee (S) \int_A g d\mu$;
- (iv) $(S) \int_A (f \wedge g) d\mu \leq (S) \int_A f d\mu \wedge (S) \int_A g d\mu$;

- (v) Se $A \subset B$, então $(S) \int_A f \, d\mu \leq (S) \int_B f \, d\mu$;
- (vi) $(S) \int_{A \cup B} f \, d\mu \geq (S) \int_A f \, d\mu \vee (S) \int_B f \, d\mu$;
- (vii) $(S) \int_{A \cap B} f \, d\mu \leq (S) \int_A f \, d\mu \wedge (S) \int_B f \, d\mu$;

onde $f \vee g$ e $f \wedge g$ são, respectivamente, as funções máximo e mínimo entre f e g .

A exemplo da integral de Lebesgue, que é usada para obter o valor esperado de uma variável aleatória com respeito a uma medida de probabilidade, a integral de Sugeno tem sido usada para se obter o valor esperado fuzzy EF de uma variável incerta, com respeito a uma medida fuzzy.

Definição 7.10. Sejam $X : \Omega \rightarrow [0, 1]$ uma variável incerta (tipicamente uma função de pertinência) e μ uma medida fuzzy em Ω . A *esperança fuzzy* (ou valor esperado fuzzy) de X é o número real

$$EF(X) = (S) \int_{\Omega} X \, d\mu = \sup_{0 \leq \alpha \leq 1} [\alpha \wedge \mu\{\omega \in \Omega : X(\omega) \geq \alpha\}]. \quad (7.9)$$

O resultado a seguir foi enunciado por Sugeno em 1974 [122] e é uma consequência do Teorema 7.2.

Corolário 7.3. *Seja $X : \Omega \rightarrow [0, 1]$ uma variável aleatória normalizada (que é tipicamente uma função de pertinência) e P uma medida de probabilidade em Ω . Então valem*

a) (Sugeno)

$$| EF(X) - E(X) | \leq \frac{1}{4}.$$

b)

$$EF(X) \leq \sqrt{E(X)}.$$

Demonstração. a) Basta lembrar que a medida fuzzy aqui é a probabilidade e que

$$EF(X) = (S) \int_{\Omega} X \, dP$$

e

$$E(X) = \int_{\Omega} X \, dP = \int_0^1 P\{\omega \in \Omega : X(\omega) \geq \alpha\} \, d\alpha = \int_0^1 H(\alpha) \, d\alpha.$$

O resultado segue do Teorema 7.2.

b) Note que $0 \leq E(X) \leq 1$.

Da desigualdade de Chebyshev [68]

$$H(\alpha) = P\{\omega : X(\omega) \geq \alpha\} \leq \frac{1}{\alpha} E(X),$$

logo

$$EF(X) = \sup_{0 \leq \alpha \leq 1} [\alpha \wedge H(\alpha)] \leq \sup_{0 \leq \alpha \leq 1} [\alpha \wedge \frac{1}{\alpha} E(X)] = \bar{\alpha},$$

onde $\bar{\alpha}$ é a solução de $\alpha = \frac{1}{\alpha} E(X)$.

Daí, $\bar{\alpha} = \sqrt{E(X)}$, donde segue o resultado. ■

Esse corolário legitima o uso da esperança fuzzy em substituição à esperança clássica quando a incerteza do fenômeno estudado não for proveniente apenas de aleatoriedade, mas de diferentes possibilidades para a variável de interesse em questão.

Pelo fato de $EF(X)$ ser ponto fixo da função $H : [0, 1] \rightarrow [0, 1]$, teoremas de pontos fixos, como o da contração de Banach ou o Brouwer [61] podem ajudar o leitor a estimar $EF(X)$.

A seguir serão apresentados alguns exemplos de variáveis aleatórias com função de densidade de distribuição f para as quais a diferença entre $EF(X)$ e $E(X)$ será menor que $\frac{1}{4}$. Antes, vamos lembrar que valem as seguintes identidades [68].

a) Se $g : \mathbb{R} \rightarrow \mathbb{R}$, então para a variável aleatória $g(X)$ tem-se

$$E(g(X)) = \int_{\Omega} g(X) dP = \int_{\mathbb{R}} g(x) f(x) dx, \quad (7.10)$$

em que X é variável aleatória contínua com densidade f .

Em particular

$$E(X) = \int_{\Omega} X dP = \int_{\mathbb{R}} x f(x) dx.$$

No caso em que X é discreta, tem-se

$$E(g(X)) = \sum_i g(x_i) P[X = x_i], \quad (7.11)$$

onde $P[X = x_i] = P\{\omega \in \Omega : X = x_i\}$.

Em particular

$$E(X) = \sum_i x_i P[X = x_i].$$

b) Para o caso em que X é contínua

$$P\{\omega \in \Omega : X(\omega) \geq t\} = \int_t^{\infty} f(x) dx. \quad (7.12)$$

Em particular, se $\alpha \in [0, 1]$,

$$H(\alpha) = P\{\omega \in \Omega : X(\omega) \geq \alpha\} = \int_{\alpha}^1 f(x) dx.$$

Exemplo 7.10 (Distribuição uniforme). Suponhamos que a variável aleatória $X : \Omega \rightarrow [0, 1]$ tenha distribuição uniforme, isto é, sua função de

densidade de probabilidade seja dada por

$$f(x) = \begin{cases} 1 & \text{se } 0 \leq x \leq 1 \\ 0 & \text{caso contrário} \end{cases}.$$

É fácil ver que $E(X) = \int_0^1 xf(x) dx = \frac{1}{2}$.

Por outro lado,

$$H(\alpha) = P\{\omega \in \Omega : X(\omega) \geq \alpha\} = \int_{\alpha}^1 f(x) dx = 1 - \alpha.$$

Agora, como $EF(X)$ é a solução de $H(\alpha) = \alpha \rightarrow 1 - \alpha = \alpha$, temos $\bar{\alpha} = \frac{1}{2}$. Nesse exemplo tem-se que $EF(X) = E(X) = \frac{1}{2}$. Portanto, $|EF(X) - E(X)| = 0$.

Exemplo 7.11 (Distribuição β). A variável aleatória $X : \Omega \rightarrow [0, 1]$ tem distribuição beta se sua função de densidade de probabilidades for dada por

$$f(x) = \frac{1}{\beta(a, b)} x^{a-1} (1-x)^{b-1}, \quad x \in [0, 1].$$

Sabe-se [68] que a esperança estocástica de X é dada por

$$E(X) = \frac{a}{a+b}.$$

Por meio de métodos numéricos foram obtidos valores da esperança fuzzy $EF(X)$, para diversos valores dos parâmetros a e b da distribuição β , os quais estão dispostos na Tabela 7.1.

Note que para quaisquer valores dos parâmetros a e b a diferença foi bem inferior a 0,25 (Teorema de Sugeno) e que $EF(X) \leq \sqrt{E(X)}$. Além disso, se $a = b$ na distribuição β , então as esperanças estocástica e fuzzy coincidem. Na verdade este resultado foi provado para um caso mais geral [98].

a	b	a - b	E(X)	EF(X)	E(X) - EF(X)
1	1	0	0,5000	0,5000	0,0000
1	2	1	0,3333	0,3820	0,0486
1	3	2	0,2500	0,3177	0,0677
1	4	3	0,2000	0,2755	0,0755
2	1	1	0,6667	0,6180	0,0486
2	2	0	0,5000	0,5000	0,0000
2	3	1	0,4000	0,4278	0,0278
2	4	2	0,3333	0,3773	0,0440
3	1	2	0,7500	0,6823	0,0677
3	2	1	0,6000	0,5722	0,0278
3	3	0	0,5000	0,5000	0,0000
3	4	1	0,4286	0,4472	0,0186
4	1	3	0,8000	0,7245	0,0755
4	2	2	0,6667	0,6227	0,0440
4	3	1	0,5714	0,5528	0,0186
4	4	0	0,5000	0,5000	0,0000

Tabela 7.1: Alguns valores de E(X) e EF(X) para distribuição beta (β).

Teorema 7.4. *Seja $X : \Omega \rightarrow [0, 1]$ uma variável aleatória com função de densidade $f : [0, 1] \rightarrow [0, 1]$ simétrica em relação a $x = \frac{1}{2}$, isto é, $f(x) = f(1 - x)$ para todo $x \in [0, 1]$. Então, $EF(X) = E(X)$.*

Demonstração. Como $f(x) = f(1 - x)$ tem-se

$$\int_0^{\frac{1}{2}} f(x) \, dx = \int_0^{\frac{1}{2}} f(1 - x) \, dx = \int_1^{\frac{1}{2}} -f(x) \, dx = \int_{\frac{1}{2}}^1 f(x) \, dx.$$

Por outro lado,

$$\int_0^1 f(x) \, dx = 1 = \int_0^{\frac{1}{2}} f(x) \, dx + \int_{\frac{1}{2}}^1 f(x) \, dx \implies$$

$$\int_0^{\frac{1}{2}} f(x) \, dx = \int_{\frac{1}{2}}^1 f(x) \, dx = \frac{1}{2}$$

$$e \ H(\alpha) = P\{\omega \in \Omega : X(\omega) \geq \alpha\} = \int_{\alpha}^1 f(x) \, dx.$$

Daí,

$$H\left(\frac{1}{2}\right) = \int_{\frac{1}{2}}^1 f(x) \, dx = \frac{1}{2}$$

e, conseqüentemente, $EF(X) = \frac{1}{2}$.

Agora, é sabido que a esperança estocástica $E(X)$ de qualquer variável aleatória simétrica coincide com a mediana e esta, por sua vez vale $\frac{1}{2}$, o que prova o teorema. ■

Para encerrar esta seção será enunciado um método para se obter $EF(X)$ para o caso em que X é uma variável incerta, que assume apenas um número finito de valores.

Teorema 7.5. *Suponha que a variável $X : \Omega \rightarrow [0, 1]$, assume apenas $n + 1$ valores $\{x_i\}_{1 \leq i \leq n+1}$ e sejam $\{\mu_i\}_{i=1}^n$ os valores distintos de $\mu\{\omega \in \Omega : X(\omega) \geq x_i\}$, excluindo-se os valores $\mu = 1$ e $\mu = 0$.*

Supondo, sem perda de generalidade, que $0 \leq x_i \leq x_j \leq 1$ se $i \leq j$, então

$$EF(X) = \int_{\Omega} X \, d\mu = \text{mediana de } A,$$

onde $A = \{x_1, x_2, \dots, x_{n+1}, \mu_1, \dots, \mu_n\}$ e está ordenado em ordem crescente.

Demonstração. Ver [70, Teorema 4.2.3, pág. 80]. ■

Lembramos que a mediana de uma sequência ordenada $\{a_n\}_{n \in \mathbb{N}}$ é definida por

$$\text{med}(\{a_n\}) = \begin{cases} a_{(n+1)/2} & \text{se } n \text{ é ímpar} \\ \frac{[a_{n/2} + a_{(n/2)+1}]}{2} & \text{se } n \text{ é par} \end{cases}.$$

Exemplo 7.12. Suponha que o conjunto fuzzy das pessoas que “*ganham bem*” em uma determinada empresa, seja dado por:

- 1 pessoa ganha por hora R\$ 3,00 $\longrightarrow \alpha_1 = 1,00$
- 2 pessoas ganham por hora R\$ 4,00 $\longrightarrow \alpha_2 = 0,60$
- 4 pessoas ganham por hora R\$ 4,20 $\longrightarrow \alpha_3 = 0,55$
- 2 pessoas ganham por hora R\$ 4,50 $\longrightarrow \alpha_4 = 0,50$
- 3 pessoas ganham por hora R\$ 10,00 $\longrightarrow \alpha_5 = 0,40$

onde α_i indica o grau com que cada indivíduo “ganha bem”.

Suponha que $\mu(S) = \frac{\#S}{\#\Omega} = \frac{\#S}{12}$, onde $\#S$ é o número de elementos de S .

$$\mu\{\omega \in \Omega : X \geq \alpha\} = \begin{cases} 1 = \mu_0 & \text{se } 0 \leq \alpha \leq \alpha_5 \\ \frac{11}{12} = \mu_1 & \text{se } \alpha_5 < \alpha \leq \alpha_4 \\ \frac{9}{12} = \mu_2 & \text{se } \alpha_4 < \alpha \leq \alpha_3 \\ \frac{5}{12} = \mu_3 & \text{se } \alpha_3 < \alpha \leq \alpha_2 \\ \frac{3}{12} = \mu_4 & \text{se } \alpha_2 < \alpha \leq \alpha_1 \\ 0 = \mu_5 & \text{se } \alpha_1 < \alpha \leq 1 \end{cases}.$$

Portanto,

$$\begin{aligned} EF(X) &= \int_{\Omega} X \, d\mu \\ &= \text{med} \left\{ \frac{3}{12}; 0,40; \frac{5}{12}; 0,50; 0,55; 0,60; \frac{9}{12}; \frac{11}{12} \right\} \\ &= 0,55, \end{aligned}$$

onde “med” é a mediana. Observe ainda que a média aritmética nesse caso é 0,65.

Note que no Exemplo 7.12, a integral de Sugeno nos dá uma boa indicação dos dados, uma vez que o valor extremo de R\$ 10,00 não afeta o resultado. Já a média aritmética clássica é consideravelmente afetada pelos valores extremos.

7.3 Eventos Fuzzy

Historicamente, alguns pesquisadores defendem que as teorias de probabilidades e a fuzzy são, de certa forma “concorrentes”. A noção de eventos fuzzy, introduzida por Zadeh [130], indica justamente o contrário. Esse conceito ilustra o potencial da combinação das duas teorias: a fuzzy, tratando da indentificação do evento; e a probabilística, lidando com a ocorrência do mesmo. Desde então, vários autores vêm se dedicando a esse tema tanto do ponto de vista teórico como das aplicações. Massad et al [84] aplicam o conceito de evento fuzzy para avaliar o risco de contaminação por HIV de um indivíduo sexualmente muito/ou pouco ativo. Diferentemente de Zadeh, Buckley [30] considera a probabilidade $P(A)$, de um evento A como um número fuzzy, isto é, $P(A) \in \mathcal{F}(\mathbb{R})$.

Neste texto seguiremos a linha do Zadeh em que A é fuzzy e $P(A)$ é um número real.

Seja $(\Omega, P, \mathcal{A})$ um espaço de probabilidades, isto é, Ω é um conjunto não vazio, $\mathcal{A}$ é uma σ -álgebra e P uma medida de probabilidades.

Definição 7.11. Um *evento fuzzy* em Ω é simplesmente um subconjunto fuzzy de Ω cujos α -níveis estão na σ -álgebra $\mathcal{A}$.

Claro que um evento clássico A se enquadra na definição acima e, portanto, pode ser considerado como um evento fuzzy. Neste caso, a função indicadora (característica) de A é uma variável aleatória discreta já que $\chi_A : \Omega \rightarrow \{0, 1\}$. Por outro lado, se A for fuzzy, sua função de

pertinência $\varphi_A : \Omega \rightarrow [0, 1]$ é uma variável aleatória que pode não ser discreta.

A questão que surge é como calcular a probabilidade de A ?

7.3.1 Probabilidade de Eventos Fuzzy

Como dito acima, é exatamente nesse ponto que há sobreposição de incertezas: a fuzzy, ligada à identificação de A (uma vez que sua fronteira não é “nítida”); e a probabilística, proveniente da “ocorrência” do evento.

Por motivos didáticos, vamos iniciar com o clássico caso em que o espaço amostral é finito, $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$, e todos os pontos com mesma probabilidade $\frac{1}{n}$. É sabido que se A for um evento com m elementos, então

$$P(A) = \frac{m}{n} \quad (7.13)$$

define uma probabilidade em Ω .

Dado o evento A , sua função indicadora $\chi_A : \Omega \rightarrow \{0, 1\}$ é conhecida e o número de casos favoráveis é

$$m = \sum_i \chi_A(\omega_i).$$

Portanto

$$P(A) = \frac{\sum_i \chi_A(\omega_i)}{n}.$$

Por extensão, se A for fuzzy, e conhecendo-se $\varphi_A : \Omega \rightarrow [0, 1]$, o “número de casos favoráveis” é

$$m = \sum_i \varphi_A(\omega_i),$$

de modo que

$$P(A) = \frac{\sum_i \varphi_A(\omega_i)}{n}. \quad (7.14)$$

Claro que nesse caso m pode não ser inteiro.

Exemplo 7.13. Considere $\Omega = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$ o espaço amostral e o evento

$$A = \frac{0,1}{1} + \frac{0,25}{2} + \frac{0,25}{3} + \frac{0,8}{5} + \frac{0,8}{0,8} + \frac{1,0}{10}.$$

Vamos calcular $P(A)$ e $P(A')$ a partir de (7.14)

$$P(A) = \frac{\sum_i \varphi_A(\omega_i)}{10} = \frac{0,1 + 0,25 + 0,25 + 0,8 + 0,8 + 1,0}{10} = 0,32$$

e, lembrando que $\varphi_{A'}(\omega_i) = (1 - \varphi_A(\omega_i))$ tem-se

$$A' = \frac{0,9}{1} + \frac{0,75}{2} + \frac{0,75}{3} + \frac{1,0}{4} + \frac{0,2}{5} + \frac{1,0}{6} + \frac{1,0}{7} + \frac{0,2}{8} + \frac{1,0}{9}$$

de modo que

$$\begin{aligned} P(A') &= \frac{\sum_i \varphi_{A'}(\omega_i)}{10} \\ &= \frac{0,9 + 0,75 + 0,75 + 1,0 + 0,2 + 1,0 + 1,0 + 0,2 + 1,0}{10} \\ &= 0,68. \end{aligned}$$

Note que esse resultado era esperado, já que $P(A') = 1 - P(A) = 1 - 0,32 = 0,68$.

Agora, qualquer outro evento B , com o mesmo número de caso favoráveis m que A , tem mesma probabilidade que A . Isso porque, se-

gundo a fórmula (7.13) o que interessa é o quociente entre m e o número de casos possíveis n , não interessando quem são os elementos que fazem parte de A ou de B .

Para o caso clássico, o número de casos favoráveis m , pode ser obtido via métodos de contagem da análise combinatória: permutação, arranjo e/ou combinação. Como o leitor já deve estar familiarizado, claramente tais princípios não levam em conta “qualidades” dos elementos que fazem parte do evento. Porém, para o caso fuzzy, se A não for conhecido, o número de casos favoráveis não é tão fácil de se obter.

Pensando na adaptação de métodos de contagem para o caso fuzzy, deve-se levar em conta a “qualidade de cada elemento” do evento fuzzy. Para obter o número de casos favoráveis, o que se pode fazer é “relativizar” a “contribuição” de cada elemento no sentido de se apurar o número total de casos favoráveis m .

Seja A um evento fuzzy com α -níveis

$$\alpha_1 > \alpha_2 > \dots > \alpha_k > \alpha_{k+1} = 0.$$

Temos $[A]^{\alpha_1} \subset [A]^{\alpha_2} \subset \dots \subset [A]^{\alpha_k} \subset [A]^0$. Assim, o número de casos favoráveis é

$$m = \alpha_1 m_1 + \alpha_2 (m_2 - m_1) + \dots + \alpha_k (m_k - m_{k-1})$$

ou

$$m = (\alpha_1 - \alpha_2)m_1 + (\alpha_2 - \alpha_3)m_2 + \dots + \alpha_k m_k,$$

em que cada m_i é o número de casos favoráveis associado ao conjunto clássico $[A]^{\alpha_i}$, o qual pode ser obtido por métodos clássicos contagens.

Assim, (7.13) passa a ser

$$P(A) = \frac{\sum_{i=1}^k (\alpha_i - \alpha_{i+1}) m_i}{n}. \quad (7.15)$$

Com essa fórmula é possível obter $P(A)$. Por exemplo, para o evento fuzzy A acima, embora não seja esse o objetivo das fórmulas acima, pois no caso A é dado, tem-se

$$m = (1, 0 - 0, 8)1 + (0, 8 - 0, 25)3 + (0, 25 - 0, 1)5 + (0, 1 - 0)6 = 3,2$$

e

$$P(A) = \frac{3,2}{10} = 0,32.$$

Embora nosso interesse maior seja no caso em que o evento A é dado, consequentemente sua função de pertinência φ_A é conhecida, vamos explorar um pouco mais a expressão 7.15.

A fórmula 7.15 pode ser reescrita como

$$\begin{aligned} P(A) &= \sum_{i=1}^k (\alpha_i - \alpha_{i+1}) \frac{m_i}{m} = \sum_{i=1}^k (\alpha_i - \alpha_{i+1}) P([A]^{\alpha_i}) \\ &= \sum_{i=1}^k (\alpha_i - \alpha_{i+1}) P[\varphi_A \geq \alpha_i] = \int_{\Omega} \varphi_A dP \end{aligned} \quad (7.16)$$

As fórmulas (7.15) e (7.16) indicam que, para o caso finito, $P(A)$ é exatamente a esperança da variável aleatória φ_A . De modo mais geral, se A for um evento clássico qualquer (finito ou não), sua função indicadora (característica) é uma variável aleatória discreta, já que $\chi_A : \Omega \rightarrow \{0, 1\}$, e nesse caso

$$E(\chi_A) = 1.P(\chi_A = 1) + 0.P(\chi_A = 0) = P(A).$$

Tendo em vista os comentários anteriores e essa última identidade, propomos a

Definição 7.12. Seja $(\Omega, P, \mathcal{A})$ um espaço de probabilidades e A um evento fuzzy. Então, sua função de pertinência $\varphi_A : \Omega \rightarrow [0, 1]$ é uma

variável aleatória e, por definição,

$$P(A) = E(\varphi_A).$$

É oportuno observar que a esperança fuzzy de φ_A , $EF(\varphi_A)$, também está bem definida uma vez que $\varphi_A : \Omega \rightarrow [0, 1]$. Mais ainda, fica como exercício para o leitor provar que se A for clássico, então

$$EF(\chi_A) = P(A) = E(\chi_A).$$

Para explorar os conceitos até aqui apresentados, vamos considerar eventos reais, isto é, aqueles que são subconjuntos (clássicos ou fuzzy) da reta real $\mathbb{R}$. Assim, para calcular $P(A)$, vamos nos valer dos comentários feitos imediatamente antes do Exemplo 7.10, especificamente (7.10) e (7.11) os quais sugerem que $\mathbb{R}$ é um espaço amostral cuja medida P é induzida pela distribuição de probabilidades de uma variável aleatória X .

Suponha que X seja uma variável aleatória e A um evento fuzzy real com função de pertinência $\varphi_A : \mathbb{R} \rightarrow [0, 1]$. Então, a probabilidade de A é dada por

$$P(A) = E(\varphi_A) = E(\varphi_A(X)) = \sum_i \varphi_A(x_i) P(X = x_i) \quad (7.17)$$

se X for discreta, e

$$P(A) = E(\varphi_A) = E(\varphi_A(X)) = \int_{\mathbb{R}} \varphi_A(x) f(x) dx = \int_{\text{supp} A} \varphi_A(x) f(x) dx \quad (7.18)$$

onde f é a função densidade de probabilidades de X .

A figura abaixo ilustra a probabilidade $P(A)$, do evento A para os dois casos: clássico e fuzzy.

No primeiro, $P(A)$ pode ser interpretada como a “área” limitada pelo




Figura 7.6: Em (a): evento clássico, f densidade e $P(A) = \text{probabilidade de } A$. Em (b): evento fuzzy, f densidade e $P(A) = \text{probabilidade de } A$.

gráfico de f , pelo eixo das abscissas e pelas fronteiras de A . Já no caso fuzzy, $P(A)$ é a “área” compreendida pelo gráfico de $\varphi_A \cdot f$, pelo eixo das abscissas e o suporte de A .

Não é difícil verificar que $P(A)$, como definida em (7.18) acima, satisfaz os axiomas de probabilidade. Por exemplo,

$$P(\phi) = E(\varphi_\phi) = \int_{\mathbb{R}} 0 \cdot f(x) dx = 0$$

e

$$P(\Omega) = E(\varphi_{\mathbb{R}}) = \int_{\mathbb{R}} 1 \cdot f(x) dx = 1.$$

As demais propriedades ficam como exercício, a cargo do leitor. Lembre-se que

$$\varphi_{A \cup B}(x) = \frac{\varphi_A(x) + \varphi_B(x) + |\varphi_A(x) - \varphi_B(x)|}{2}$$

e

$$\varphi_{A \cap B}(x) = \frac{\varphi_A(x) + \varphi_B(x) - |\varphi_A(x) - \varphi_B(x)|}{2}.$$

7.3.2 Independência de Eventos Fuzzy

O conceito de independência entre eventos fuzzy passa necessariamente pelo de probabilidade condicional. Para estender a noção de probabilidade condicional clássica ao caso fuzzy, devemos repensar a modelagem matemática de ocorrência simultânea de dois eventos A e B . Para o caso clássico, a ocorrência simultânea é dada pela interseção $A \cap B$. No entanto, para estender ao caso fuzzy, devemos passar pela função indicadora $\chi_{A \cap B}$. Como sabemos, qualquer t -norma pode modelar a conjunção “e”, em particular as t -normas do *produto* e do *mínimo*. Mais ainda, para o caso clássico, valem

$$\chi_{A \cap B}(x) = \chi_A(x) \cdot \chi_B(x) \quad e \quad \chi_{A \cap B}(x) = \chi_A(x) \wedge \chi_B(x),$$

de modo que, a princípio, poderíamos adotar tanto “.” como “ $\wedge$ ” para representar a conjunção. Como o mais comum no caso clássico é “.” e estamos interessados na sua extensão para o caso fuzzy, adotaremos o *produto* para representar ocorrência simultânea. O *mínimo* está intimamente ligado à pertinência enquanto o *produto* à ocorrência, o que corrobora com nossa opção.

Para o caso clássico, sabemos que se A e B forem eventos de Ω com $P(B) > 0$, então

$$P(A|B) = \frac{P(AB)}{P(B)} = \frac{E(\chi_A \cdot \chi_B)}{E(\chi_B)}. \quad (7.19)$$

A é dito independente de B se a ocorrência de B não interferir na probabilidade de A , isto é, se $P(A|B) = P(A)$. A notação AB no lugar de $A \cap B$ não é por acaso. Ela vem do fato de optarmos por $\chi_A \cdot \chi_B$ para representar $\chi_{A \cap B}$.

Portanto, A independente de B se, e somente se,

$$\frac{E(\chi_A \cdot \chi_B)}{E(\chi_B)} = E(\chi_A) \Leftrightarrow E(\chi_A \cdot \chi_B) = E(\chi_A) \cdot E(\chi_B) \quad (7.20)$$

ou

$$P(AB) = P(A)P(B).$$

Da fórmula (7.20) acima, é possível ver que A independe de B se, e somente se, B independe de A . Mais ainda, A e B são independentes se, e somente se, as variáveis aleatórias χ_A e χ_B são não correlacionadas ($\rho = 0$ - ver definição em [31]).

Na verdade, χ_A e χ_B são variáveis aleatórias independentes se A e B forem eventos independentes. Esse fato é consequência de χ_A e χ_B serem discretas e assumirem apenas dois valores (ver Exercício 7.8). De modo geral, variáveis aleatórias não correlacionadas não necessariamente são independentes (ver Exercício 7.9).

Definição 7.13. Considere A e B dois eventos fuzzy de $\mathbb{R}$, com $P(B) > 0$ ($\Leftrightarrow E(\varphi_B) > 0$). Em vista de (7.19), a probabilidade condicional de A dado B é definida por

$$P(A|B) = \frac{P(AB)}{P(B)} = \frac{E(\varphi_A \cdot \varphi_B)}{E(\varphi_B)}. \quad (7.21)$$

Assim como no caso clássico, A é dito independente de B se a ocorrência de B não interferir na probabilidade de A , isto é, se $P(A|B) = P(A)$. De (7.21), A independe de B se, e somente se,

$$\frac{\varphi_A \cdot \varphi_B}{\varphi_B} = E(\varphi_A) \Leftrightarrow E(\varphi_A \cdot \varphi_B) = E(\varphi_A) \cdot E(\varphi_B). \quad (7.22)$$

Portanto, desde que as probabilidades não se anulem, A e B são independentes se, e somente se, as variáveis aleatórias φ_A e φ_B são não correlacionadas. Aqui, diferentemente do caso clássico, a independência entre A e B não é equivalente à independência entre φ_A e φ_B . Claro que se φ_A e φ_B forem independentes, então A e B serão. Porém a recíproca não é necessariamente verdadeira (ver Exercício 7.9).

A próxima subseção trata de um tema em franco desenvolvimento e é conhecido na literatura por variável aleatória fuzzy. A partir de um

experimento aleatório, há pelo menos duas maneiras de se introduzir o estudo das variáveis aleatórias fuzzy: o primeiro está ligado apenas à incerteza no reconhecimento do resultado do experimento. No segundo, o que há de incerto é o próprio mecanismo do experimento: a forma de sorteio, por exemplo. De certo modo, aqui no texto estamos tratando apenas do primeiro caso. Para este, diferentemente do segundo caso, tem-se que a probabilidade de um evento fuzzy é necessariamente um número real.

7.3.3 Variável Aleatória Linguística

A ideia aqui é explorar o conceito de variável linguística supondo que a mesma seja aleatória. Variáveis com essas duas características serão chamadas de *variável aleatória linguística*.

Como dissemos na subseção anterior, uma variável aleatória X induz uma medida de probabilidades em $\mathbb{R}$. Daí, a questão que se coloca ([130]) é como calcular a probabilidade

$$P(X \text{ ser } A)$$

onde A é um termo linguístico (*alto*, *baixo*, *muito alto* ...) modelado por um evento fuzzy real A .

De maneira informal, essa questão já foi tratada nas subseções anteriores.

Do ponto de vista da teoria clássica, $P(X \text{ ser } A) = P(X \in A)$ e questão acima é traduzida por

$$P(X \in A) = \begin{cases} \sum_{x_i \in A} P[X = x_i] & = \sum_i \chi_A(x_i) P[X = x_i] \\ \int_A f(x) dx & = \int_{\mathbb{R}} \chi_A(x) f(x) dx \end{cases}$$

dependendo se X é variável discreta ou contínua. De qualquer forma $P(X \in A) = E(\chi_A)$.

Desta forma, nada mais natural que definir $P(X \text{ ser } A)$ com

$$P(X \text{ ser } A) = E(\varphi_A) = P(A)$$

onde A é um conjunto fuzzy real modelando o termo linguístico de interesse.

Para tornar a questão mais formal, uma variável aleatória linguística é simplesmente uma função

$$X : \Omega \rightarrow \mathcal{F}(\mathbb{R}).$$

Claramente vemos que esse conceito estende o de variável aleatória uma vez que $\mathbb{R} \subset \mathcal{F}(\mathbb{R})$.

A essa altura cabe um parêntese a respeito do tema em questão. Na literatura, em vez de variável aleatória linguística, o termo usado é *variável aleatória fuzzy*. Há pelo menos duas abordagens para tal conceito. O primeiro está ligado à proposta adotada nesse texto. Especificamente, $X : \Omega \rightarrow \mathcal{F}(\mathbb{R})$, porém a função de densidade de probabilidades envolvida é a mesma da variável aleatória X , ou seja, a probabilidade é induzida em $\mathbb{R}$ pela densidade, $f : \mathbb{R} \rightarrow \mathbb{R}$, da própria variável aleatória (clássica) X .

Por outro lado, originalmente tínhamos $X : \Omega \rightarrow \mathbb{R}$ e ao considerar $X : \Omega \rightarrow \mathcal{F}(\mathbb{R})$, estamos cometendo um abuso de notação já que o contra-domínio da variável original foi alterado. Sendo assim, estamos tratando de fato de outra variável $\hat{X} : \Omega \rightarrow \mathcal{F}(\mathbb{R})$ cuja densidade de probabilidades é uma $F : \mathcal{F}(\mathbb{R}) \rightarrow \mathcal{F}(\mathbb{R})$, já que por definição de densidade, esta deve ter como domínio um subconjunto do contra-domínio da variável aleatória. Dessa maneira, F induz uma medida de probabilidades em $\mathcal{F}(\mathbb{R})$. Nessa abordagem, a probabilidade de um evento fuzzy passa a ser um número fuzzy. Para um estudo a respeito das diversas abordagens sobre variável aleatória fuzzy o leitor pode consultar [53].

Para distinguir um caso do outro é que achamos por bem chamar o

primeiro de variável aleatória linguística.

Dando prosseguimento ao nosso estudo sobre as variáveis aleatórias linguísticas, um caso de interesse é o cálculo de $P(X \text{ ser } A^*)$, onde A^* é um evento obtido por meio de algum modificador fuzzy do evento A (ver seção 4.5).

Assim como no Capítulo 4, também aqui trataremos apenas dos modificadores potências, com único objetivo de expor as principais ideias desse tema e explorar seu potencial de aplicação em, por exemplo, obter funções de pertinências de conjuntos fuzzy. Claro que para uma aplicação particular, outros modificadores devem ser levados em conta.

Supondo então que $A^* = A^s$, isto é, que $\varphi_{A^*} = (\varphi_A)^s$,

$$P(X \text{ ser } A^*) = E(\varphi_{A^*}) = E(\varphi_A^s).$$

Um caso de particular interesse é quando $s = 2$:

$$P(A^2) = E(\varphi_A^2),$$

que é o segundo momento de φ_A , e

$$P(A^2) - [P(A)]^2 = E(\varphi_A^2) - [E(\varphi_A)]^2 = \text{Var}(\varphi_A),$$

em que $\text{Var}(Y)$ é a variância da variável aleatória Y . Por abuso, às vezes escreveremos $\text{Var}(A)$ em vez de $\text{Var}(\varphi_A)$.

Da desigualdade de Jensen [68], temos que se o modificador for restritivo ($s > 1$),

$$E(X^s) - [E(X)]^s \geq 0,$$

já que nesse caso o modificador é dado pela função côncava $m(x) = x^s$.

Em particular,

$$E(\varphi_A^2) - [E(\varphi_A)]^2 = P(A^2) - [P(A)]^2 \geq 0.$$

Uma possibilidade de aplicação do estudo acima é na “construção” de A e de A^* , isto é, nos ajustes de φ_A e φ_{A^*} . O problema passa a ser obter parâmetros (s é um deles) de distribuições de possibilidades para A e A^* . Para isso, a partir de princípios como o de *máximo verossimilhança* (ver [31]), os parâmetros que devemos achar podem ser baseados em um ou nos dois princípios abaixo:

- a) $P(A^*)$ seja máxima (*máxima verossimilhança*);
- b) $Var(\varphi_{A^*})$ seja mínima (*menor variância*).

Claro que outros métodos, como mínimos quadrados, interpolação polinomial ou mesmo métodos de inferência estatística podem ser usados para obter as distribuições de possibilidade de A e A^* .

Outra área de clara aplicação é a estimação de parâmetros de uma determinada distribuição de densidade, supondo que seja dado um conjunto fuzzy A (isto é, φ_A). Tal conjunto pode ser fornecido por um especialista ou mesmo por um conjunto de dados. O parâmetro em questão pode ser estimado a partir de técnicas clássicas de estatística paramétrica. Claro que pode-se usar também técnicas não paramétricas para se estimar funções densidades. O leitor interessado em tais estudos pode consultar [74].

Antes de passar aos exercícios, chamamos a atenção do leitor sobre a diferença entre os conceitos de independência para conjuntos fuzzy vistos aqui e na Seção 4.6. No Capítulo 4 a independência é dada pela medida de possibilidade, que tecnicamente relaciona a função de pertinência condicional com cada uma das funções de pertinências dos conjuntos fuzzy envolvidos (ver seção 4.6.2). Por outro lado, a independência entre eventos fuzzy, vista nessa seção, é dada pela medida de probabilidades e, tecnicamente, envolve as esperanças das funções de pertinências dos conjuntos fuzzy em questão, como pode ser visto na fórmula (7.22).

O exemplo a seguir ilustra os conceitos apresentados nesse seção.

Exemplo 7.14. Um fabricante produz peças em que 5% são defeituosas. Para uma amostra de 10 peças, considere X o número de defeituosas. Pede-se

- a) $P(X \leq 1)$;
- b) $P(X \text{ ser pequeno})$, em que “pequeno” é o número fuzzy triangular $(0; 0; 2)$;
- c) $P(A \cap B)$, onde A e B são os eventos dos itens a) e b), respectivamente;
- d) $P(A \cup B)$;
- e) $P(A/B)$;
- f) A e B são independentes?

Soluções

X tem distribuição binomial com $n = 10$ e $p = 0,05$ (ver [31]).

- a) Temos

$$\varphi_A(x) = \begin{cases} 1 & \text{se } 0 \leq x \leq 1 \\ 0 & \text{caso contrário} \end{cases}$$

Assim, pela fórmula (7.17)

$$\begin{aligned} P(A) &= \sum_i \varphi_A(x_i) P(X = x_i) = \varphi_A(0) P(X = 0) + \varphi_A(1) P(X = 1) \\ &= 1 \cdot P(X = 0) + 1 \cdot P(X = 1) = \binom{10}{0} 0,95^{10} + \binom{10}{1} 0,95^9 0,05^1 \\ &= 0,91 \end{aligned}$$

- b)

$$\varphi_B(x) = \begin{cases} 1 - \frac{x}{2} & \text{se } 0 \leq x \leq 2 \\ 0 & \text{caso contrário} \end{cases}$$

Portanto,

$$\begin{aligned}
 P(B) &= \sum_i \varphi_B(x_i)P(X = x_i) = \varphi_B(0)P(X = 0) + \varphi_B(1)P(X = 1) \\
 &\quad + \varphi_B(2)P(X = 2) = 1.P(X = 0) + \frac{1}{2}P(X = 1) + 0.P(X = 2) \\
 &= \binom{10}{0} 0,95^{10} + \frac{1}{2} \binom{10}{1} 0,95^9 0,05^1 = 0,7563
 \end{aligned}$$

c) $\varphi_{A \cap B}(x) = \min[\varphi_A(x), \varphi_B(x)]$. Portanto,

$$\begin{aligned}
 P(A \cap B) &= \sum_i \varphi_{A \cap B}(x_i)P(X = x_i) = \varphi_{A \cap B}(0)P(X = 0) \\
 &\quad + \varphi_{A \cap B}(1)P(X = 1) + \varphi_{A \cap B}(2)P(X = 2) \\
 &= 1.P(X = 0) + \frac{1}{2}.P(X = 1) + 0.P(X = 2) = 0,7563
 \end{aligned}$$

$$\begin{aligned}
 \text{d) } P(A \cup B) &= P(A) + P(B) - P(A \cap B) = 0,7563 + 0,91 - 0,7563 \\
 &= 0,91
 \end{aligned}$$

$$\text{e) } P(B/A) = \frac{P(AB)}{P(A)} = \frac{E(\varphi_A \varphi_B)}{E(\varphi_A)} =$$

$$\frac{\varphi_A(0)\varphi_B(0)P(X = 0) + \varphi_A(1)\varphi_B(1)P(X = 1) + \varphi_A(2)\varphi_B(2)P(X = 2)}{0,91}$$

$$= \frac{1.P(X = 0) + 0,5P(X = 1)}{0,91} = \frac{0,7563}{0,91} \neq 0,7563 = P(B)$$

f) De acordo com o item e), A e B não são eventos independentes.

Exercício 7.2. Refaça o exemplo anterior supondo que X tem distribuição binomial com $n = 8$ e $p = 0.02$.

Exercício 7.3. Calcule a probabilidade do evento fuzzy dado no Exemplo 7.12.

Exercício 7.4. Numa central telefônica, o número N de chamadas chega segundo uma distribuição de Poisson, com a média $\lambda = 8$ chamadas por minutos. Sabendo que a lei de probabilidade de uma distribuição de Poisson é dada por

$$P(N = k) = \frac{e^{-\lambda} \lambda^k}{k!},$$

determine qual a probabilidade de que num minuto se tenha:

- a) dez ou mais chamadas;
- b) menos que nove chamada;
- c) um número *baixo* de chamada, onde *baixo* é o conjunto fuzzy dado pelo número fuzzy triangular $(0; 0; 9)$;
- d) um número *médio baixo* de chamada, onde *médio baixo* é o evento fuzzy dado pelo número fuzzy trapezoidal $(0; 1; 4; 9)$;
- e) $P(C|B)$ e $P(D|B)$, onde A, B, C e D são os eventos dos respectivos itens acima.

Exercício 7.5. Suponha que o tempo T de duração de certa enfermidade seja uma variável aleatória exponencial com parâmetro

$$\lambda = \frac{1}{5} (X \sim \exp(\lambda)),$$

ou seja, sua densidade é dada por

$$f(t) = \begin{cases} \frac{1}{5} e^{-\frac{t}{5}} & \text{se } t \geq 0 \\ 0 & \text{se } t < 0 \end{cases}.$$

Pede-se:

- a) a esperança T ;

- b) $P(M)$ onde M é o evento “médio” dado pelo conjunto fuzzy triangular $(0; 5; 8)$;
- c) $P(M/B)$ onde B é o evento “baixo” dado pelo conjunto fuzzy triangular $(0; 0; 8)$;
- d) M e B são independentes?

Exercício 7.6. Suponha que $X \sim \exp(1)$, isto é, X é uma variável aleatória com distribuição exponencial com parâmetro $\lambda = 1$.

- a) Calcule $P(A)$, onde A é o número fuzzy triangular $(0; 1; 1)$.
- b) Calcule $P(C)$ em que

$$\varphi_C(x) = \begin{cases} x - x^2 & \text{se } 0 \leq x \leq 1 \\ 0 & \text{caso contrário} \end{cases}.$$

- c) Refaça o item a) supondo $X \sim N(0, 1)$.

Exercício 7.7. Suponha que X tem distribuição uniforme no intervalo $[0, 1]$, que A seja o evento fuzzy com função de pertinência

$$\varphi_A(x) = a \in [0, 1],$$

e B o número fuzzy triangular $(0; 0; 1)$. Pede-se:

- a) $P(A)$ e $P(B)$;
- b) $P(A \cap B)$ e $P(AB)$;
- c) A e B são independentes?
- d) Sendo C o evento do Exercício 7.6 b), verifique se A e C são independentes. E B e C ?

Exercício 7.8. Mostre que se X e Y assumem apenas os valores 0 ou 1, então X e Y são não correlacionadas se, e somente se, forem independentes.

Exercício 7.9. Suponha que tanto X como Y assumem os valores $-1, 0$ e 1 , com probabilidades

$$P_X(-1) = P_Y(-1) = P_X(1) = P_Y(1) = \frac{2}{5} \quad e \quad P_X(0) = P_Y(0) = \frac{1}{5}.$$

Mostre que X e Y são não correlacionadas ($\rho = 0$). Porém, não são independentes.

Exercício 7.10. Verifique que se X e Y têm distribuições normais, então X e Y são não correlacionadas se, e somente se, forem independentes.

Exercício 7.11. Prove que

- a) $P(A \cap B) \geq P(AB)$;
- b) $P(A|B) = 0$, se A e B forem mutuamente exclusivos, isto é, $A \cap B = \emptyset$.

Exercício 7.12. Considere $X \sim U[0, 2]$ e o número fuzzy triangular $(0; 0; \delta)$, com $0 < \delta \leq 2$. Pede-se:

- a) δ de modo que $P(A)$ seja máxima;
- b) $s > 0$ de forma que $P(A^*)$ seja máxima onde $A^* = A^s$ e A é o conjunto fuzzy encontrado no item a);
- c) $Var(\varphi_A)$ e $Var(\varphi_{A^*})$.

Exercício 7.13. Considere o número fuzzy triangular $A = (0; 0; 2)$ e X uma variável aleatória triangular cuja densidade é dada por

$$f(x; \theta) = \begin{cases} \frac{1}{\theta^2}(\theta - |x - 1|) & \text{se } x \in [1 - \theta, 1 + \theta] \\ 0 & \text{se } x \notin [1 - \theta, 1 + \theta] \end{cases}.$$

Pede-se:

- a) $\theta > 0$ de modo que $P(A)$ seja máxima;
- b) represente graficamente a densidade encontrada no item anterior.

Finalizamos essa seção comentando que temos lidado com fenômenos que apresentam os dois tipos de incertezas aqui discutidas. Via de regra, temos interesse na dinâmica desses fenômenos. A metodologia que temos utilizado envolve o acoplamento de métodos de simulação estatística e controladores fuzzy, especificamente do tipo Mamdani. Os conjuntos fuzzy que compõem a base de regras servem para simular a dinâmica de interesse. No entanto, as entradas para esses sistemas são extraídas utilizando algum método de simulação estatística (Monte Carlo, por exemplo), levando em conta alguma distribuição priori. Sendo assim, podemos olhar os conjuntos fuzzy antecedentes como eventos fuzzy.

Maristela [86] usou essa metodologia para estudar a evolução da Febre Aftosa no Mato Grosso do Sul. Gomes [56] utilizou mesma metodologia para estudar a evolução da Dengue na cidade de Campinas.

Capítulo 8

Sistemas Dinâmicos Fuzzy

*“Deus calcula vários mundos, mas faz
existir o melhor desses mundos.”*

(Leibniz – Séc. XVI d.C.)

Certamente Leibniz deve ter observado vários fatos que o levaram a concluir seu pensamento. Resta saber se a solução dada por Deus é nítida (determinística) ou nebulosa (fuzzy). Como veremos a seguir, soluções nítidas, num certo sentido, fazem parte da nebulosa.

Aqui será apresentada uma breve introdução aos sistemas dinâmicos fuzzy com o intuito de ilustrar o potencial da lógica fuzzy no estudo de sistemas evolutivos.

Como geralmente é feito nos sistemas determinísticos e estocásticos, vamos aqui distinguir dois casos: contínuos e discretos. No caso contínuo, de alguma forma aparecerá algum tipo de derivada para representar as taxas de variações contínuas. No caso discreto, a evolução do sistema é baseada em um processo iterativo.

8.1 Sistemas Dinâmicos Fuzzy Contínuos

Nesta seção apresentaremos algumas abordagens, conceitualmente distintas, para o estudo dos sistemas dinâmicos fuzzy contínuos. Fundamentalmente, o que distingue cada caso é o tratamento dado à taxa

de variação (ou derivada) e/ou como esta se relaciona com as variáveis de estado. Destas abordagens, a primeira envolve a derivada de Hukuhara, originalmente desenvolvida para funções com valores em conjuntos clássicos [63] e posteriormente adaptada para funções com valores em conjuntos fuzzy [105]. Essa adaptação para funções fuzzy (funções com valores em conjuntos fuzzy) é feita a partir do Teorema 1.4 de representação de conjuntos fuzzy, visto no Capítulo 1. A segunda abordagem é tratada por meio das inclusões diferenciais fuzzy [9, 64], enquanto que a terceira é simplesmente dada pela fuzzificação da solução determinística, supondo que a condição inicial e/ou algum parâmetro da equação diferencial seja dada por um conjunto fuzzy. Finalmente, a quarta abordagem se diferencia das demais porque a variação está relacionada com as variáveis de estado por meio de regras fuzzy em vez de uma equação. Queremos ressaltar que nos três últimos casos não utilizamos qualquer noção de derivada para funções fuzzy, mas apenas o conceito de derivada para funções determinísticas.

Antes de expor cada um dos conceitos comentados acima, queremos registrar que recentemente Barros et al [19] têm investigado um “novo” tipo de equações diferenciais fuzzy em que o princípio de extensão é utilizado para fuzzificar o operador derivação, e não a solução determinística como comentado na terceira abordagem acima. A partir do Teorema 1.4 e sob certas condições, é possível concluir que essa metodologia produz equações diferenciais fuzzy cujas soluções coincidem com as de Hüllermeier. Ressaltamos que nessa abordagem tem-se, de fato, derivada para funções fuzzy, o que não acontece para a metodologia de Hüllermeier.

Para motivar as abordagens citadas acima vamos estudar o “modelo de crescimento malthusiano”. Salientamos que Malthus não prescrevia originalmente nenhuma equação matemática de crescimento populacional, simplesmente enunciava que a população cresceria geometricamente enquanto o alimento cresceria numa taxa aritmética, desde que não houvesse mecanismo de controle (doenças, misérias, etc). A pri-

meira interpretação matemática da conjectura de Malthus foi através de um modelo determinístico pressupondo que “o crescimento de uma população é proporcional à própria população”. Desta forma, o modelo matemático contínuo, conhecido como modelo de Malthus, é dado pela equação diferencial

$$\begin{cases} \frac{dx}{dt} = \lambda x \\ x(0) = x_0 \end{cases}, \quad (8.1)$$

onde $x(t)$ é o número de indivíduos em cada instante t e x_0 indica o número inicial de indivíduos da população.

Neste modelo admite-se que todas as grandezas envolvidas sejam dadas por números reais. Tanto λ como x_0 são supostamente bem determinados, e portanto, não há dados incertos. Porém, se considerarmos que existam incertezas, na taxa de crescimento λ ou na condição inicial x_0 , devemos repensar o significado de $\frac{dx}{dt}$, ou como esta variação se relaciona com a variável de estado x .

Supondo que as incertezas tenham natureza aleatória, o modelo acima pode ser tratado por meio das *equações diferenciais estocásticas* [6, 81, 113]. No entanto, se as incertezas forem modeladas por meio de subconjuntos fuzzy, a equação diferencial pode ser tratada de várias formas tais como:

- ▷ *Equações diferenciais fuzzy* (a partir da *derivada de Hukuhara*) – neste caso a noção de derivada fuzzy faz-se necessária [12, 69, 105, 115];
- ▷ *Inclusões diferenciais fuzzy* [9, 13, 64, 87];
- ▷ *Extensão da solução determinística* [87];
- ▷ *Base de regras fuzzy* (Seção 6.4 do Capítulo 6 e Capítulo 9).

A seguir apresentaremos uma introdução ao Cálculo Diferencial e Integral para funções fuzzy, isto é, funções com domínio no conjunto dos números reais e com valores fuzzy.

8.1.1 Derivada e Integral de Função Fuzzy

Vamos aqui estudar apenas o caso unidimensional, ou seja, o caso em que a função está definida em um intervalo da reta com valores no conjunto dos números fuzzy:

$$u : [a, b] \rightarrow \mathcal{F}(\mathbb{R}), \quad a \geq 0,$$

onde $\mathcal{F}(\mathbb{R})$ representa o conjunto dos números fuzzy.

Para o caso mais geral e mais informações sobre derivadas de funções fuzzy o leitor pode consultar [12, 45, 69, 115], além de muitos artigos presentes na literatura de “Matemática Fuzzy”.

Para o caso unidimensional definimos a derivada de $u(t)$ a partir de seus α -níveis. Lembramos [69] que a função $u : [a, b] \rightarrow \mathcal{F}(\mathbb{R})$ que associa um número real t a um número fuzzy $u(t)$ está bem definida se, e somente se, para cada $\alpha \in [0, 1]$, existem funções reais

$$u_1^\alpha, u_2^\alpha : [a, b] \rightarrow \mathbb{R}$$

tais que os α -níveis de $u(t)$ são $[u_1^\alpha(t), u_2^\alpha(t)]$, ou seja,

$$[u(t)]^\alpha = [u_1^\alpha(t), u_2^\alpha(t)]. \quad (8.2)$$

Antes de enunciarmos os conceitos de derivada e integral queremos ressaltar que, para não sobrecarregar a notação, nesta seção usaremos u' para indicar a derivada e $\int_a^b u(t) dt$ para a integral de funções fuzzy $u : [a, b] \rightarrow \mathcal{F}(\mathbb{R})$.

Definição 8.1 (Derivada de Hukuhara). A função $u' : [a, b] \rightarrow \mathcal{F}(\mathbb{R})$ cujos α -níveis são dados por

$$[u'(t)]^\alpha = [(u_1^\alpha)'(t), (u_2^\alpha)'(t)], \quad (8.3)$$

para todo $\alpha \in [0, 1]$, é a derivada da função fuzzy $u(t)$, conhecida como *derivada de Hukuhara*. Claro que estamos supondo a existência das derivadas clássicas $(u_1^\alpha)'(t)$ e $(u_2^\alpha)'(t)$.

Assim α -níveis da derivada (fuzzy) são as derivadas (clássicas) dos extremos dos α -níveis de u .

Observamos que a existência de $u'(t)$ implica necessariamente que os intervalos $[(u_1^\alpha)'(t), (u_2^\alpha)'(t)]$ satisfazem o Teorema 1.4 de representação.

A integral de $u : [a, b] \rightarrow \mathcal{F}(\mathbb{R})$ também é definida por meio de seus α -níveis, a partir da integral de Aumann¹, originalmente definida para funções com valores em conjuntos clássicos (veja em [12]).

Definição 8.2. A integral de u no intervalo $[a, b]$, indicada por $\int_a^b u(t) dt$, é o número fuzzy com α -níveis:

$$\left[\int_a^b u(t) dt \right]^\alpha = \left[\int_a^b u_1^\alpha(t) dt, \int_a^b u_2^\alpha(t) dt \right], \quad (8.4)$$

onde $\int_a^b u_1^\alpha(t) dt$ e $\int_a^b u_2^\alpha(t) dt$ são as integrais de Riemann das funções reais u_1^α e u_2^α .

A existência de $\int_a^b u(t) dt$ implica necessariamente que os intervalos

$$\left[\int_a^b u_1^\alpha(t) dt, \int_a^b u_2^\alpha(t) dt \right]$$

satisfazem o Teorema 1.4 de representação. Como observado para as derivadas, aqui também estamos supondo que as funções u_1^α e u_2^α são Riemann integráveis no intervalo $[a, b]$.

Note que se u for uma função real (isto é, $u : [a, b] \rightarrow \mathbb{R} \subset \mathcal{F}(\mathbb{R})$), então os conceitos dados acima de derivada e integral coincidem com os clássicos.

¹Aumann ganhou prêmio Nobel de Economia em 2005.

Exemplo 8.1. Seja a função $u(t) = At$, $t \geq 0$, onde A é um número fuzzy, cujos α -níveis são dados pelos intervalos $[A]^\alpha = [a_1^\alpha, a_2^\alpha]$.




Figura 8.1: Função $u(t)$ e seus α -níveis.

Temos que $[u(t)]^\alpha = [u_1^\alpha(t), u_2^\alpha(t)] = [a_1^\alpha t, a_2^\alpha t]$ e, portanto,

$$[u'(t)]^\alpha = [(u_1^\alpha)'(t), (u_2^\alpha)'(t)] = [(a_1^\alpha t)', (a_2^\alpha t)'] = [a_1^\alpha a_2^\alpha] = [A]^\alpha.$$

Logo,

$$u'(t) = A.$$

Por outro lado,

$$\begin{aligned} \left[\int_a^b u(t) dt \right]^\alpha &= \left[\int_a^b u_1^\alpha(t) dt, \int_a^b u_2^\alpha(t) dt \right] = \left[\int_a^b a_1^\alpha t dt, \int_a^b a_2^\alpha t dt \right] \\ &= \left[a_1^\alpha \left(\frac{b^2}{2} - \frac{a^2}{2} \right), a_2^\alpha \left(\frac{b^2}{2} - \frac{a^2}{2} \right) \right] = \left(\frac{b^2}{2} - \frac{a^2}{2} \right) [a_1^\alpha, a_2^\alpha] \\ &= \left(\int_a^b t dt \right) [A]^\alpha. \end{aligned}$$

Portanto,

$$\int_a^b u(t) dt = \int_a^b At dt = A \int_a^b t dt = \left(\frac{b^2 - a^2}{2} \right) A.$$

Observamos que $\int_a^b t dt$ é a integral de Riemann que, multiplicada pelo número fuzzy A , dá a integral de Aumann de $u(t) = At$.

Neste texto não pretendemos aprofundar nossa investigação sobre diferenciabilidade e integrabilidade de funções fuzzy. Porém, para o estudo de estabilidade de sistemas dinâmicos, faz-se necessário o conceito de métrica em $\mathcal{F}(\mathbb{R})$.

Definição 8.3. A *métrica para conjuntos fuzzy*, proveniente da métrica de Hausdorff, é dada por:

$$\mathcal{D}(A, B) = \sup_{0 \leq \alpha \leq 1} d_H([A]^\alpha, [B]^\alpha), \quad (8.5)$$

onde d_H é a métrica de Hausdorff para intervalos compactos de $\mathbb{R}$, cuja definição é

$$d_H(I, J) = \max(\sup_{x \in I} d(x, J), \sup_{y \in J} d(y, I)), \quad (8.6)$$

onde $d(x, J) = \inf_{j \in J} d(x, j)$ e $d(r, s) = |r - s|$.

Com essa métrica Ralescu [106] provou que o espaço métrico $\mathcal{F}(\mathbb{R})$ é completo, garantindo que toda sequência convergente de números fuzzy converge para um número fuzzy.

O teorema a seguir tem importância no estudo das equações diferenciais fuzzy.

Teorema 8.1. Se $F, G : [a, b] \longrightarrow \mathcal{F}(\mathbb{R})$ são funções diferenciáveis e $\lambda \in \mathbb{R}$, então

(a) F e G são contínuas na métrica $\mathcal{D}$;

$$(b) (F + G)'(t) = F'(t) + G'(t);$$

$$(c) (\lambda F)'(t) = \lambda F'(t).$$

Demonstração. Ver [12, 69]. ■

O teorema a seguir é uma versão do teorema fundamental do cálculo para o caso fuzzy com os conceitos de derivada e integral acima.

Teorema 8.2. *Seja $F : [a, b] \longrightarrow \mathcal{F}(\mathbb{R})$ contínua. Então a função $G(t) = \int_a^t F(s) ds$ é derivável e $G'(t) = F(t)$ para todo $t \in [a, b]$.*

Demonstração. Ver [12, 69]. ■

Vale também o seguinte resultado.

Teorema 8.3. *Seja $F : [a, b] \longrightarrow \mathcal{F}(\mathbb{R})$ integrável. Então, para todo $c \in [a, b]$ vale*

$$\int_a^c F(t) dt + \int_c^b F(t) dt = \int_a^b F(t) dt. \quad (8.7)$$

Estes teoremas fornecem o suporte para estudar equações diferenciais fuzzy. A partir dos conceitos de derivadas e integrais apresentados acima, podemos começar nosso estudo de *equações diferenciais fuzzy*.

8.1.2 Problema de Valor Inicial Fuzzy (PVIF)

Vamos considerar neste texto o problema de valor inicial fuzzy sempre da forma

$$\begin{cases} u'(t) &= F(t, u(t)) \\ u(a) &= u_0 \end{cases}, \quad (8.8)$$

onde $F : [a, b] \times \mathcal{F}(\mathbb{R}) \rightarrow \mathcal{F}(\mathbb{R})$ e $a > 0$.

Lema 8.4. *Seja $F : [a, b] \times \mathcal{F}(\mathbb{R}) \rightarrow \mathcal{F}(\mathbb{R})$ contínua. Então a função*

$$u : [a, b] \longrightarrow \mathcal{F}(\mathbb{R})$$

é solução de (8.8) se, e somente se, é contínua e satisfaz à equação integral

$$u(t) = u(a) + \int_a^t F(s, u(s)) \, ds. \quad (8.9)$$

Demonstração. Ver [12, 69].

Como ilustração, considere $u(t) = At$. Vimos no Exemplo 8.1 que $u'(t) = A$. Logo,

$$u(t) = Aa + \int_a^t A \, ds = u(a) + \int_a^t u'(s) \, ds.$$

■

Corolário 8.5. Se $u(t)$ é solução do (8.8) então, para cada $\alpha \in [0, 1]$, a função $d(t) = \text{diam}[u(t)]^\alpha$ é não decrescente.

Demonstração. $\text{diam}([u(t)]^\alpha) = u_2^\alpha(t) - u_1^\alpha(t)$, o qual é o diâmetro de $[u(t)]^\alpha$. Assim, de acordo com o Lema 8.4, temos

$$\begin{aligned} [u(t)]^\alpha &= [u_1^\alpha(a), u_2^\alpha(a)] + \left[\int_a^t F_1^\alpha(s, u(s)) \, ds, \int_a^t F_2^\alpha(s, u(s)) \, ds \right] \\ &= \left[u_1^\alpha(a) + \int_a^t F_1^\alpha(s, u(s)) \, ds, u_2^\alpha(a) + \int_a^t F_2^\alpha(s, u(s)) \, ds \right]. \end{aligned}$$

Portanto,

$$\begin{aligned} \text{diam}([u(t)]^\alpha) &= u_2^\alpha(t) - u_1^\alpha(t) \\ &= (u_2^\alpha(a) - u_1^\alpha(a)) + \int_a^t [F_2^\alpha(s, u(s)) - F_1^\alpha(s, u(s))] \, ds \end{aligned}$$

é não decrescente, uma vez que $(F_2^\alpha(s, u(s)) - F_1^\alpha(s, u(s))) \geq 0$ para todo $s \in [a, b]$. ■

Exemplo 8.2. Para ilustrar as aplicações das equações diferenciais fuzzy vamos supor então que, no modelo de Malthus, apenas a condição inicial

seja fuzzy e considerar taxas de variações positivas (**populações em expansão**) e negativas (**populações em retração**).

- Consideremos o modelo malthusiano fuzzy com taxa de crescimento positiva $\lambda > 0$.

$$\begin{cases} u'(t) = \lambda u(t) \\ u_0 \in \mathcal{F}(\mathbb{R}) \end{cases} \quad (8.10)$$

Suponhamos que $[u(t)]^\alpha = [u_1^\alpha(t), u_2^\alpha(t)]$ e que a condição inicial seja fuzzy e dada pelos α -níveis $[u_0]^\alpha = [u_{01}^\alpha, u_{02}^\alpha]$.

De acordo com a Definição 8.1, para cada $\alpha \in [0, 1]$, devemos resolver a equação

$$\begin{cases} [u'(t)]^\alpha = \lambda[u_1^\alpha(t), u_2^\alpha(t)] \\ u_0 \in \mathcal{F}(\mathbb{R}) \text{ e } \lambda > 0 \end{cases} \quad (8.11)$$

A partir da multiplicação de número real por números fuzzy, temos que a solução dessa equação é obtida a partir da solução do sistema de equações determinísticas para seus α -níveis:

$$\begin{cases} (u_1^\alpha)'(t) = \lambda u_1^\alpha(t), \text{ com } u_1^\alpha(a) = u_{01}^\alpha \\ (u_2^\alpha)'(t) = \lambda u_2^\alpha(t), \text{ com } u_2^\alpha(a) = u_{02}^\alpha \end{cases}.$$

Para cada α a solução do sistema (8.11) existe e é dada por:

$$\begin{cases} u_1^\alpha(t) = u_{01}^\alpha e^{\lambda t} \\ u_2^\alpha(t) = u_{02}^\alpha e^{\lambda t} \end{cases} \quad (8.12)$$

Observamos que se $[u_0]^1$ tiver apenas um ponto, isto é, se $u_{01} = u_{02} = x_0$ então $[u(t)]^1$ se comporta como a solução do modelo malthusiano determinístico, isto é, $[u(t)]^1 = x_0 e^{\lambda t}$.




Figura 8.2: Solução do modelo malthusiano fuzzy de expansão populacional ($\lambda > 0$).

- Consideremos agora o Problema de Valor Inicial Fuzzy que representa uma **população em retração**:

$$\begin{cases} u'(t) = -\lambda u(t) \\ u_0 \in \mathcal{F}(\mathbb{R}) \text{ e } \lambda > 0 \end{cases} \quad (8.13)$$

De acordo com a Definição 8.1, para cada $\alpha \in [0, 1]$ devemos resolver a equação

$$[u'(t)]^\alpha = -\lambda[u_1^\alpha(t), u_2^\alpha(t)],$$

que pela definição de multiplicação de número real (negativo) por número fuzzy, é equivalente a resolver o sistema determinístico:

$$\begin{cases} (u_1^\alpha)'(t) = -\lambda u_2^\alpha(t), \text{ com } u_1^\alpha(0) = u_{01}^\alpha \\ (u_2^\alpha)'(t) = -\lambda u_1^\alpha(t), \text{ com } u_2^\alpha(0) = u_{02}^\alpha \end{cases}, \quad (8.14)$$

cujas soluções são

$$\begin{aligned} u_1^\alpha(t) &= \frac{u_{01}^\alpha - u_{02}^\alpha}{2} e^{\lambda t} + \frac{u_{01}^\alpha + u_{02}^\alpha}{2} e^{-\lambda t} \\ u_2^\alpha(t) &= \frac{u_{02}^\alpha - u_{01}^\alpha}{2} e^{\lambda t} + \frac{u_{01}^\alpha + u_{02}^\alpha}{2} e^{-\lambda t}. \end{aligned} \quad (8.15)$$

Assim, a solução do problema (8.14) é a função $u(t)$ com α -níveis dados pelas equações (8.15) acima. A Figura 8.3 representa a solução de decaimento do modelo fuzzy malthusiano.




Figura 8.3: Decaimento no modelo fuzzy malthusiano ($\lambda < 0$).

Observações

1. O diâmetro de $[u(t)]^\alpha$, dado por:

$$\text{diam}([u(t)]^\alpha) = u_2^\alpha(t) - u_1^\alpha(t) = (u_{02}^\alpha - u_{01}^\alpha)e^{\lambda t}$$

é sempre crescente com t , exceto se $u_{02}^\alpha = u_{01}^\alpha$, ou seja, se $u_0 \in \mathbb{R}$. Esta é a maior crítica à derivada fuzzy (e à derivada de Hukuhara de um modo particular, a qual deu origem à derivada fuzzy utilizada acima). Há uma clara dificuldade para se definir o conceito de estabilidade, bem como de atrator neste tipo de equação diferencial fuzzy.

2. Resolver $u' = -\lambda u$ é diferente de resolver $u' + \lambda u = 0$ [28].
3. Quando temos um problema de valor inicial fuzzy onde o campo de direções é extensão fuzzy de um campo determinístico, então toda solução determinística é uma *solução preferida*, no sentido de ter

grau de pertinência 1 (um) no conjunto das soluções fuzzy. Esse resultado está formalizado e demonstrado em [12]. Para ilustrar melhor este fato, vamos nos restringir ao Problema de Valor Inicial Fuzzy da equação malthusiana estudada anteriormente. Associado a este problema temos o Problema de Valor Inicial determinístico

$$\begin{cases} x'(t) = -\lambda x(t) \\ x_0 \in \mathbb{R} \end{cases}, \quad (8.16)$$

cujas soluções são

$$x(t) = x_0 e^{-\lambda t}.$$

Assim, se $x_0 \in [u_0]^1$, então é fácil ver que

$$u_1^\alpha(t) \leq x(t) \leq u_2^\alpha(t), \quad \forall \alpha \in [0, 1].$$

Isto significa que $x(t) \in [u(t)]^1$ para todo t , ou seja, a solução determinística $x(t)$ tem pertinência 1 (um) na solução fuzzy. Portanto é uma solução *preferida* (veja Figuras 8.2 e 8.3).

De acordo com a observação 1, há uma dificuldade em definir estabilidade para esse tipo de equação diferencial, já que o diâmetro das soluções é crescente com o tempo para todo α do intervalo $[0, 1]$. Tem-se procurado contornar este inconveniente utilizando outros métodos para o estudo de sistemas dinâmicos fuzzy contínuos, isto é, com **taxa de variação contínua** em algum sentido. As inclusões diferenciais fuzzy e o método de extensão de Zadeh que, sob certas condições produzem as mesmas soluções [87], resolvem este problema. Outro enfoque tem sido apresentado recentemente por Bede [26] estendendo a derivada de Hukuhara (este método não será discutido aqui).

O método das inclusões diferenciais fuzzy requer conhecimentos de análise de multifunções e de inclusões diferenciais clássicas. Por esse

motivo, apresentaremos aqui apenas as ideias principais para introduzir e ilustrar o seu potencial de aplicações (o leitor interessado pode consultar [7, 13, 37, 38, 77, 87], entre tantos outros textos de Análise Multivaluada).

O método da extensão de Zadeh pode ser considerado mais simples, pois exige apenas a aplicação do princípio de extensão nas soluções determinísticas. Mais especificamente, a partir da solução determinística, que para cada t fixo pode ser vista como uma função da condição inicial x_0 , aplica-se o Princípio de Extensão de Zadeh. Portanto, este último método é aplicável apenas em sistemas fuzzy originados de determinísticos, para os quais é conveniente considerar a condição inicial e/ou algum parâmetro fuzzy.

8.1.3 Problema de Valor Inicial Fuzzy Generalizado (PVIFG)

Para dar continuidade ao nosso estudo sobre os sistemas fuzzy contínuos, vamos analisar o problema de valor inicial fuzzy generalizado considerando dois enfoques distintos: via inclusões diferenciais fuzzy e com o princípio de extensão de Zadeh.

Considere o problema

$$\begin{cases} \frac{du}{dt} &= F(t, u(t)) \\ u(a) &= u_0 \end{cases}, \quad (8.17)$$

onde $F : [a, b] \times \mathcal{F}(\mathbb{R}) \longrightarrow \mathcal{F}(\mathbb{R})$, $u_0 \in \mathcal{F}(\mathbb{R})$ e $\frac{du}{dt}$ representa a taxa de variação contínua da função u , em algum sentido. Se $\frac{du}{dt}$ é a derivada de Hukuhara da função incógnita $u(t)$, o estudo do *PVIFG* se reduz ao tratado na Seção 8.1.2.

Uma função $u : [a, b] \rightarrow \mathcal{F}(\mathbb{R})$ é uma solução, nos diversos sentidos que daremos, de (8.17) se, e somente se, satisfizer a Equação (8.17) e $u(a) = u_0$. Para este problema generalizado definimos, para cada $t \geq 0$,

a família de funções dadas por

$$\begin{aligned}\psi_t : \mathcal{F}(\mathbb{R}) &\rightarrow \mathcal{F}(\mathbb{R}) \\ u_0 &\mapsto \psi_t(u_0) := u(t, u_0),\end{aligned}$$

onde $u(t, u_0)$ é solução de (8.17) no instante t , com condição inicial $u(a) = u_0$.

As subseções seguintes têm por objetivo propor duas maneiras de se obter a família ψ_t .

Problema de Valor Inicial Fuzzy via Inclusão Diferencial Fuzzy

Como já dissemos antes, uma abordagem alternativa à derivada de Hukuhara para se estudar um problema de valor inicial fuzzy é por meio das inclusões diferenciais fuzzy. Nesse caso, não é usado qualquer conceito para derivada de função fuzzy. A derivada utilizada é a de funções determinísticas e a solução fuzzy é “constituída” de funções determinísticas. Há várias formas de se utilizar as inclusões diferenciais no sentido de adaptá-las ao contexto fuzzy (ver [9, 37, 64, 87]).

Aqui daremos ênfase à sugestão de Hullermeier [64]. Sua ideia é a seguinte: como o campo $F : [a, b] \times \mathcal{F}(\mathbb{R}) \rightarrow \mathcal{F}(\mathbb{R})$ é tal que, para cada par (t, u) tem-se $F(t, u) \in \mathcal{F}(\mathbb{R})$, então a solução fuzzy de (8.17) será constituída de todas as trajetórias determinísticas que satisfazem as inclusões diferenciais clássicas:

$$\begin{cases} x'(t) \in [F(t, x(t))]^\alpha \\ x(a) \in [u_0]^\alpha \end{cases}. \quad (8.18)$$

Uma função determinística $x_\alpha : [a, b] \rightarrow \mathbb{R}$ é uma solução de (8.17), com pertinência α , se for absolutamente contínua e satisfizer (8.18) para quase todo $t \geq a$.

A solução fuzzy de (8.17) é a função fuzzy $u : [a, b] \rightarrow \mathcal{F}(\mathbb{R})$ cujos

α -níveis são

$$[u]^\alpha = \{x_\alpha : [a, b] \rightarrow \mathbb{R}, \text{ que são soluções de (8.18)}\}.$$

Observação

Sob certas condições de regularidade de F , Diamond [44] provou que os conjuntos $\{x_\alpha : [a, b] \rightarrow \mathbb{R}, \text{ que são soluções de (8.18)}\}$ satisfazem o Teorema 1.4 de representação (no espaço das funções), e neste caso, a função u está bem definida.

Assim, para cada t , as funções $\psi_t : \mathcal{F}(\mathbb{R}) \rightarrow \mathcal{F}(\mathbb{R})$ associadas ao *PVIFG* (8.17) são dadas por:

$$\psi_t(u_0) = u(t, u_0),$$

onde u é solução de (8.17) no sentido de Hullermeier. Neste caso, os α -níveis de $\psi_t(u_0)$ são os intervalos $[\psi_t(u_0)]^\alpha$.

Vamos ilustrar os conceitos apresentados aqui com o modelo malthusiano e verificar que os diâmetros dos α -níveis das soluções $[\psi_t(u_0)]^\alpha$ são crescentes para população em expansão e são decrescentes para população em retração.

Exemplo 8.3 (Taxa de crescimento bem determinada). Se $\lambda \in \mathbb{R}$ e $u_0 \in \mathcal{F}(\mathbb{R})$, então o modelo de Malthus toma a forma

$$\begin{cases} x'(t) = \lambda x(t) \\ x_\alpha(a) \in [u_0]^\alpha = [u_{01}^\alpha, u_{02}^\alpha] \end{cases} \quad (8.19)$$

cuja solução (fuzzy) é formada pelas funções determinísticas

$$x_\alpha(t) = x_\alpha(a)e^{\lambda t}, \text{ com } x_\alpha(a) \in [u_{01}^\alpha, u_{02}^\alpha].$$

Portanto,

$$[\psi_t(u_0)]^\alpha = [u_{01}^\alpha e^{\lambda t}, u_{02}^\alpha e^{\lambda t}] = [u_{01}^\alpha, u_{02}^\alpha] e^{\lambda t},$$

de modo que

$$\psi_t(u_0) = u_0 e^{\lambda t}.$$

Os diâmetros dos α -níveis da solução são

$$\text{diam}([\psi_t(u_0)]^\alpha) = (u_{02}^\alpha - u_{01}^\alpha) e^{\lambda t}.$$

Logo, para população em expansão ($\lambda > 0$), temos diâmetro crescente com o tempo t , e decrescente para população em retração ($\lambda < 0$).

Exemplo 8.4 (Taxa de crescimento e condição inicial incertas). Se a taxa de crescimento e a condição inicial são incertas, isto é, $\Lambda \in \mathcal{F}(\mathbb{R})$, com $[\Lambda]^\alpha = [\lambda_1^\alpha, \lambda_2^\alpha]$, e $u_0 \in \mathcal{F}(\mathbb{R})$, então o modelo malthusiano toma a forma

$$\begin{cases} x'(t) \in [\Lambda x(t)]^\alpha = x(t)[\lambda_1^\alpha, \lambda_2^\alpha] \\ x_\alpha(a) \in [u_0]^\alpha = [u_{01}^\alpha, u_{02}^\alpha] \end{cases} \quad (8.20)$$

cuja solução (fuzzy) é formada pelas funções determinísticas:

$$x_\alpha(t) = x_\alpha(a) e^{\lambda t}, \text{ com } \lambda \in [\lambda_1^\alpha, \lambda_2^\alpha] \text{ e } x_\alpha(a) \in [u_{01}^\alpha, u_{02}^\alpha].$$

Portanto, supondo que $\lambda_1^\alpha \geq 0$ (**expansão forte**), temos

$$[\psi_t(u_0)]^\alpha = [u_{01}^\alpha e^{\lambda_1 t}, u_{02}^\alpha e^{\lambda_2 t}],$$

e neste caso, $\text{diam}[\psi_t(u_0)]^\alpha$ cresce com t , já que $\lambda_2^\alpha > \lambda_1^\alpha > 0$.

Por outro lado, supondo que $\lambda_2^\alpha < 0$ (**retração forte**),

$$[\psi_t(u_0)]^\alpha = [u_{01}^\alpha e^{-\lambda_2^\alpha t}, u_{02}^\alpha e^{-\lambda_1^\alpha t}],$$

e neste caso, $\text{diam}[\psi_t(u_0)]^\alpha$ decresce com t , já que $\lambda_2^\alpha > \lambda_1^\alpha$.

Os casos em que λ_1^α e λ_2^α têm sinais contrários, ficam como exercício para o leitor.

Aplicações das inclusões diferenciais fuzzy a fenômenos biológicos podem ser encontradas em um número ainda reduzido na literatura. O leitor interessado pode consultar [13], para modelos em epidemiologia, e [77, 87] em dinâmica de populações. Comparações entre as soluções de Hullermeier e a de Hukuhara podem ser encontradas em [18].

Outra abordagem para obter uma solução fuzzy para o *PVIFG* (8.17) é por meio do princípio de extensão visto no Capítulo 2. Nesse caso, se apenas a condição inicial e/ou algum parâmetro do campo F for fuzzy, então as soluções do *PVIFG* são obtidas através da fuzzificação das soluções determinísticas por meio do princípio de extensão.

Problema de Valor Inicial Fuzzy via Extensão de Zadeh

Como fizemos no caso das inclusões diferenciais fuzzy, vamos estudar dois casos distintos aqui. O primeiro é quando apenas a condição inicial é dada por um número fuzzy. No segundo caso vamos admitir que a condição inicial e/ou algum parâmetro do problema de valor inicial em questão seja fuzzy.

Caso (a) – Condição inicial fuzzy

- Consideramos apenas a condição inicial fuzzy. Neste caso, o problema de valor inicial é dado por

$$\begin{cases} \frac{dx}{dt} = f(t, x(t)) \\ x(a) = u_0 \in \mathcal{F}(\mathbb{R}) \end{cases}, \quad (8.21)$$

com $f : [a, b] \rightarrow \mathbb{R}$ contínua.

Supondo que para cada condição inicial $x_0 \in \mathbb{R}$ o problema determinístico

$$\begin{cases} \frac{dx}{dt} &= f(t, x(t)) \\ x(a) &= x_0 \end{cases}, \quad (8.22)$$

admita solução única ϕ_t então, para cada t , a solução fuzzy ψ_t de (8.21) é definida como a extensão de Zadeh da solução determinística ϕ_t . Isto é,

$$\text{se } u_0 \in \mathcal{F}(\mathbb{R}) \text{ então } \psi_t(u_0) = \widehat{\phi}_t(u_0).$$

Neste caso, como ϕ_t é contínua em relação à condição inicial, pelo Teorema 2.1 do Capítulo 2, temos que

$$[\psi_t(u_0)]^\alpha = [\widehat{\phi}_t(u_0)]^\alpha = \phi_t([u_0]^\alpha) = \phi_t([u_{01}^\alpha, u_{02}^\alpha]).$$

Observamos que a fórmula acima indica que o grau de pertinência de x_0 a u_0 é o mesmo grau de pertinência de $\phi_t(x_0)$ a $\widehat{\phi}_t(u_0)$, para todo t .

Com esse procedimento vamos encontrar a solução do modelo malthusiano.

- Se $\lambda \in \mathbb{R}$ e $u_0 \in \mathcal{F}(\mathbb{R})$, temos

$$\begin{cases} \frac{dx}{dt} &= \lambda x(t) \\ x(a) &= u_0 \end{cases}. \quad (8.23)$$

O fluxo determinístico do modelo malthusiano (8.1) é dado por $\phi_t(x_0) = x_0 e^{\lambda t}$. Então, usando a Definição 2.1, o fluxo fuzzy é $\widehat{\phi}_t(u_0) = u_0 e^{\lambda t}$, cujos α -níveis são dados por

$$[\widehat{\phi}_t(u_0)]^\alpha = \phi_t([u_0]^\alpha) = [u_0]^\alpha e^{\lambda t} = [u_{01}^\alpha, u_{02}^\alpha] e^{\lambda t}.$$

Portanto, para cada t , os diâmetros dos α -níveis da solução fuzzy são dados por

$$\text{diam}([\hat{\phi}_t(u_0)]^\alpha) = (u_{02}^\alpha - u_{01}^\alpha)e^{\lambda t}$$

que, como se vê, coincidem com aqueles obtidos no caso anterior de inclusões diferenciais (8.19). Isto nos permite concluir que tais diâmetros crescem para populações em expansão e decrescem para populações em retração.

Caso (b) – Condição inicial e parâmetro fuzzy

- Vamos supor agora que o *PVIFG* (8.17) seja fuzzy porque algum parâmetro (Λ) e também a condição inicial são fuzzy.

Assim, o problema de valor inicial toma a forma

$$\begin{cases} \frac{dx}{dt} &= \hat{f}(t, \Lambda, x(t)) \\ x_\alpha(a) &= u_0 \in \mathcal{F}(\mathbb{R}) \end{cases} \quad (8.24)$$

Nesse caso, recaímos no caso anterior, acrescentando uma nova equação ($y = \lambda$, com $y' = 0$), isto é, olhando o parâmetro como uma variável e adotando, no modelo determinístico original (8.22), o par (λ, x_0) como condição inicial. Para um formalismo matemático dessa metodologia o leitor pode consultar [87].

Vamos exemplificar este caso considerando ainda o modelo malthusiano.

- Suponhamos que a taxa de crescimento $\Lambda \in \mathcal{F}(\mathbb{R})$ e a condição inicial $u_0 \in \mathcal{F}(\mathbb{R})$. Sabemos que as soluções determinísticas do

modelo maltusiano (8.1) ampliado

$$\begin{cases} \frac{dx}{dt} = \lambda x \\ \frac{dy}{dt} = 0 \\ x(a) = x_0 \text{ e } y = \lambda \end{cases}$$

são dadas por $\phi_t(\lambda, x_0) = x_0 e^{\lambda t}$, onde x_0 e λ são reais.

Agora, se

$$[\Lambda]^\alpha = [\lambda_1^\alpha, \lambda_2^\alpha] e [u_0]^\alpha = [u_{01}^\alpha, u_{02}^\alpha]$$

então a solução de (8.24) com $\hat{f}(t, \Lambda, x(t)) = \Lambda x$ é dada por

$$[\psi_t(\Lambda, u_0)]^\alpha = [\hat{\phi}_t(\Lambda, u_0)]^\alpha = \phi_t([\lambda_1^\alpha, \lambda_2^\alpha], [u_{01}^\alpha, u_{02}^\alpha]). \quad (8.25)$$

Portanto, supondo que $\lambda_1^\alpha \geq 0$ (**expansão forte**),

$$[\psi_t(\Lambda, u_0)]^\alpha = [u_{01}^\alpha e^{\lambda_1^\alpha t}, u_{02}^\alpha e^{\lambda_2^\alpha t}],$$

e neste caso, $\text{diam}[\psi_t(\Lambda, u_0)]^\alpha$ cresce com t , uma vez que $\lambda_2^\alpha > \lambda_1^\alpha$.

Por outro lado, supondo $\lambda_2^\alpha \leq 0$ (**retração forte**),

$$[\psi_t(\Lambda, u_0)]^\alpha = [u_{01}^\alpha e^{-\lambda_2^\alpha t}, u_{02}^\alpha e^{-\lambda_1^\alpha t}],$$

e neste caso, $\text{diam}[\psi_t(\Lambda, u_0)]^\alpha$ decresce com t , já que $\lambda_2^\alpha > \lambda_1^\alpha$.

Os casos em que λ_1^α e λ_2^α têm sinais contrários ficam para o leitor analisar.

Como o leitor pode perceber, as soluções para o modelo de Malthus obtidas via inclusão diferencial e via princípio de extensão são as mesmas. Isto não foi uma coincidência apenas para o modelo escolhido. Sob certas condições tais métodos produzem as mesmas soluções (veja [87] para maiores informações).

Jafelice *et al* [66] têm utilizado essa metodologia no estudo da dinâmica do HIV com tratamento, considerando a ação do retardo fuzzy na ação do fármaco.

O estudo de estabilidade dos estados estacionários (equilíbrios) desempenham papel fundamental em sistemas dinâmicos. Por isso, apresentaremos a seguir uma introdução sobre estabilidade dos sistemas dinâmicos fuzzy formulados via inclusões diferenciais fuzzy e/ou via princípio de extensão. Queremos salientar que ainda não há uma teoria consolidada sobre estabilidade de sistemas dinâmicos fuzzy.

Estabilidade de Sistemas Dinâmicos Fuzzy Contínuos

Vamos iniciar esta seção definindo estados estacionários (ou de equilíbrio) para o *PVIFG* (8.17).

Definição 8.4 (Equilíbrio). Um número fuzzy $\bar{u} \in \mathcal{F}(\mathbb{R})$ é um *ponto de equilíbrio* ou *estado estacionário* de (8.17) se

$$\psi_t(\bar{u}) = \bar{u}, \text{ para todo } t \geq a,$$

ou seja, se $\bar{u}$ é ponto fixo para todas as ψ_t , com $t > 0$.

Lembramos que para um problema de valor inicial determinístico, os pontos de equilíbrio são aqueles cuja derivada é *zero*, e estes são exatamente os pontos fixos de suas soluções, vistas como funções das condições iniciais. Como aqui não temos a noção de derivadas para funções fuzzy, definimos equilíbrios como sendo os pontos fixos dos fluxos gerados pelos *PVIFG'S*.

A partir daqui estamos interessados apenas nos problemas de valor inicial que sejam **autônomos**, isto é, o campo F não depende explicitamente de t . Vamos considerar apenas os sistemas autônomos que, em que os **pvi's** tenham solução única. A grande vantagem dos sistemas autônomos, e que será explorada aqui, vem do fato de suas soluções

terem a propriedade de fluxo, que esclareceremos abaixo.

Iremos apresentar resultados de estabilidade apenas para *problema de valor inicial fuzzy generalizado autônomo PVIFGA* da forma

$$\begin{cases} \frac{du}{dt} &= F(u(t)) \\ u(a) &= u_0 \in \mathcal{F}(\mathbb{R}) \end{cases}. \quad (8.26)$$

Para este problema é sabido que a família de soluções ψ_t tem a característica de fluxo, ou seja,

- (1) $\psi_0(u_0) = u_0$ para todo $u_0 \in \mathcal{F}(\mathbb{R})$, isto é, ψ_0 é a função identidade de $\mathcal{F}(\mathbb{R})$;
- (2) $\psi_{t+s}(u_0) = \psi_t(\psi_s(u_0)) = (\psi_t \circ \psi_s)(u_0)$ para todo $u_0 \in \mathcal{F}(\mathbb{R})$.

A propriedade (2) acima é a que de fato caracteriza um fluxo. Ela significa que, partindo-se de um estado u_0 , o estado atingido, $\psi_{t+s}(u_0)$, após $t + s$ instantes, é o mesmo que aquele atingido após t instantes, $\psi_t(\psi_s(u_0))$, partindo-se de $\psi_s(u_0)$.

Exemplos desses fluxos são as soluções de problemas de valores iniciais autônomos determinísticos e também aqueles fluxos gerados por inclusões diferenciais (veja [64]).

Proposição 8.6. *Dado o problema de valor inicial determinístico autônomo*

$$\begin{cases} \frac{dx}{dt} &= f(x(t)) \\ x(a) &= x_0 \end{cases}, \quad (8.27)$$

considere o PVIFGA (8.26) associado ao PVI (8.27)

$$\begin{cases} \frac{dx}{dt} &= f(x(t)) \\ x(a) &= u_0 \in \mathcal{F}(\mathbb{R}) \end{cases}. \quad (8.28)$$

Nestas condições todo ponto de equilíbrio de (8.27) é equilíbrio de (8.28). E ainda os números reais que são equilíbrios de (8.28) são também

equilíbrios de (8.27), se a solução for dada pelo método da extensão ou da inclusão diferencial fuzzy.

Demonstração. Do Teorema 2.1 temos

$$[\hat{\phi}_t(\chi_{\{\bar{x}\}})]^\alpha = \phi_t([\chi_{\{\bar{x}\}}]^\alpha) = \phi_t(\bar{x}),$$

sendo $\chi_{\{\bar{x}\}}$ a função característica de $\bar{x}$, ϕ_t o fluxo determinístico e $\hat{\phi}_t$ o fluxo fuzzy.

Desse modo,

$$\phi_t(\bar{x}) = \bar{x} \iff [\hat{\phi}_t(\chi_{\{\bar{x}\}})]^\alpha = [\chi_{\{\bar{x}\}}]^\alpha,$$

ou seja, $\bar{x}$ é equilíbrio de (8.27) se, e somente se, $\chi_{\{\bar{x}\}}$ é equilíbrio de (8.28). ■

A estabilidade dos sistemas dinâmicos contínuos será estudada por meio dos fluxos de suas soluções.

A partir da métrica $\mathcal{D}$ (Definição 8.3), vamos definir estabilidade dos pontos de equilíbrio.

Definição 8.5 (Estabilidade). Seja $\bar{u}$ o ponto de equilíbrio de (8.28). Então ele é

(a) *Estável* se para todo $\varepsilon > 0$ existir $\delta > 0$ tal que

$$\text{se } \mathcal{D}(\bar{u}, u) \leq \delta, \text{ então } \mathcal{D}(\bar{u}, \psi_t(u)) \leq \varepsilon, \text{ para todo } t \geq a.$$

Os equilíbrios que não são estáveis são chamados de *instáveis*.

(b) *Assintoticamente estável* se for estável e existir $r > 0$ de modo que

$$\lim_{t \rightarrow +\infty} \mathcal{D}(\psi_t(u), \bar{u}) = 0 \text{ sempre que } \mathcal{D}(\bar{u}, u) \leq r.$$

Com esta noção de estabilidade é fácil ver que não é possível ter equilíbrio assintoticamente estável para sistemas fuzzy contínuos, para os quais a derivada utilizada é a de Hukuhara. Lembremos que para tais sistemas os diâmetros dos α -níveis das soluções são sempre crescentes.

O principal resultado que enunciaremos aqui sobre estabilidade é para os sistemas fuzzy contínuos cujas soluções são obtidas por meio do princípio de extensão de Zadeh.

Observamos que, com a Definição 8.5 de estabilidade é fácil verificar que as populações em **retração** no modelo malthusiano, cujas soluções são obtidas via inclusões diferenciais fuzzy ou extensão de Zadeh, são assintoticamente estáveis. O resultado seguinte generaliza essa observação feita para o modelo de Malthus.

Teorema 8.7. *Seja $\bar{x}$ um equilíbrio do problema de valor inicial determinístico (8.27). Então:*

- (a) $\bar{x}$ é estável para o PVI (8.27) se, e somente se, $\chi_{\{\bar{x}\}}$ é estável para o PVIFGA (8.28);
- (b) $\bar{x}$ é assintoticamente estável para o PVI (8.27) se, e somente se, $\chi_{\{\bar{x}\}}$ é assintoticamente estável para o PVIFGA (8.28).

Demonstração. Ver [87]. ■

Corolário 8.8. *Seja $\bar{x}$ um equilíbrio de (8.27). Então, o equilíbrio $\chi_{\{\bar{x}\}}$ de (8.28) será estável se $f'(\bar{x}) < 0$, e instável se $f'(\bar{x}) > 0$.*

Demonstração. Basta lembrar que essa hipótese é suficiente para estabilidade assintótica no caso clássico. A conclusão é feita a partir do Teorema 8.7. ■

Para encerrar esta seção queremos observar que, embora o Teorema 8.7 seja bastante intuitivo, ele revela algo que consideramos forte: $\bar{x}$ ser assintoticamente estável para (8.27), significa que $\bar{x}$ atrai pontos de $\mathbb{R}$.

Agora, ser assintoticamente estável no espaço fuzzy $(\mathcal{F}(\mathbb{R}), \mathcal{D})$, quer dizer que tal ponto atrai conjuntos fuzzy, e portanto atrai seus níveis, que são subconjuntos compactos de $\mathbb{R}$. Do ponto de vista de modelagem isto significa que a estabilidade de $\bar{x}$ independe das incertezas das condições iniciais.

Um estudo mais abrangente de estabilidade de sistemas fuzzy via princípio de extensão o leitor pode encontrar em [87].

Lembrando que no início da Seção 8.1 havíamos prometido quatro abordagens para os sistemas dinâmicos fuzzy contínuos, vamos comentar rapidamente a última delas, ou seja, os sistemas fuzzy onde o campo de direções é dado por meio de uma base de regras.

Problema de Valor Inicial p-fuzzy

A nomenclatura p-fuzzy significa parcialmente fuzzy. Esses sistemas são parcialmente fuzzy no sentido que o campo de direções F do PVI em questão é apenas conhecido parcialmente. No entanto, sua solução (trajetória) é crisp, já que, em cada instante t , é um valor obtido após um processo de defuzzificação. Formalmente teremos

Definição 8.6. Um PVI *p-fuzzy* pode ser dado por

$$\begin{cases} \frac{du}{dt} = F(t, u(t)) \\ u(a) = u_0 \end{cases}, \quad (8.29)$$

em que F é parcialmente conhecida e decrita por uma base de regras fuzzy (ver Capítulo 5).

Até aqui, nenhum processo de defuzzificação está sendo exigido para modelar F . Isto desobriga que a solução $u(t)$ de (8.29), em algum sentido, seja um número real.

Entretanto, se algum método de defuzzificação for adotado, então espera-se que $u(t) \in \mathbb{R}$. Neste caso, estaremos diante da metodolo-

gia estudada na Seção 6.4 em que F é a função dada por controladores fuzzy.

Mantendo a linha de investigação adotada neste capítulo vamos estudar o *PVI*

$$\begin{cases} \frac{dx}{dt} = f(x) \\ x(a) = x_0 \end{cases}, \quad (8.30)$$

em que f é substituída por uma base de regras fuzzy coerente com o modelo malthusiano, cuja principal suposição é que, em cada instante t , a taxa de crescimento de uma população é diretamente proporcional à população.

A base de regras construída aqui é para a taxa de variação por unidade de tempo, denotada por $\frac{dX}{dt}$, em função da população X . Assim, x é o valor da variável de entrada, enquanto $\frac{dx}{dt}$ é o valor da variável de saída.

Adotaremos apenas quatro qualificações para cada uma dessas variáveis linguísticas, resumidas no Quadro 8.1.

R_1 :	Se a população (X) é “muito baixa” (MB) então a variação é “muito baixa” (MB)
R_2 :	Se a população (X) é “baixa” (B) então a variação é “baixa” (B)
R_3 :	Se a população (X) é “média” (M) então a variação é “média” (M)
R_4 :	Se a população (X) é “alta” (A) então a variação é “alta” (A).

Quadro 8.1: Base de regras para modelar a variação da população com base na densidade da mesma.

As funções de pertinência que correspondem às variáveis linguísticas da base de regras são dadas na Figura 8.4.

A Figura 8.5 ilustra as regras do Quadro 8.1 na forma granular, supondo que cada uma das qualificações acima seja dada por um número fuzzy triangular e uma possível f .

Adotando um controlador fuzzy, com o método de Mamdani e o centro de área como defuzzificador, combinado com o método de Euler, como




Figura 8.4: Funções de pertinência da base de regras.

comentado na Seção 6.4 (ver detalhes no Capítulo 9), chegamos à solução do p-fuzzy malthusiano, cujo gráfico está na Figura 8.6.




Figura 8.5: Grânulos para o modelo malthusiano e uma possível função de crescimento f .

Os sistemas **p-fuzzy** terão destaque no Capítulo 9.

8.2 Sistemas Dinâmicos Fuzzy Discretos

Um sistema dinâmico discreto é modelado através de uma forma de recorrência (processo iterativo). Nesta seção vamos introduzir os *sistemas dinâmicos fuzzy discretos* como uma generalização dos modelos clássicos.




Figura 8.6: Solução $x(t)$ do p-fuzzy malthusiano e do determinístico com $a = 9.5\%$ e $x_0 = 2$.

Para ilustrar o processo, usamos mais uma vez os modelos populacionais – o modelo exponencial (de Malthus) e o logístico (de Verhulst).

Definição 8.7. Um *sistema dinâmico fuzzy discreto* é um processo iterativo de subconjuntos fuzzy

$$\begin{cases} u_{t+1} = F(u_t) \\ u_0 \in \mathcal{F}(\mathbb{R}) \end{cases}, \quad (8.31)$$

onde $F : \mathcal{F}(\mathbb{R}) \rightarrow \mathcal{F}(\mathbb{R})$ é uma aplicação entre espaços dos subconjuntos fuzzy.

Definição 8.8. Dado $u_0 \in \mathcal{F}(\mathbb{R})$ e F conforme a Definição 8.7, a sequência de iteradas $u_0, F(u_0), F(F(u_0)), \dots$, é chamada de *solução* ou *órbita positiva* de u_0 .

De acordo com estas definições, o fluxo ψ_t , para sistemas discretos, é dado pelas sucessivas composições do campo F :

$$\begin{aligned} \psi_0(u_0) &= F^0(u_0) = u_0 \\ \psi_1(u_0) &= F^1(u_0) = F(u_0) \\ \psi_2(u_0) &= F^2(u_0) = F(F(u_0)) \\ \vdots &= \vdots = \vdots \\ \psi_t(u_0) &= F^t(u_0) = F(F^{t-1}(u_0)), \end{aligned}$$

para $t \in \mathbb{N}$.

Deste modo, se $u_0 \in \mathcal{F}(\mathbb{R})$, então as iteradas definidas acima, bem como seu limite, quando existir (na métrica $\mathcal{D}$), estão em $\mathcal{F}(\mathbb{R})$, já que o espaço métrico $(\mathcal{F}(\mathbb{R}), \mathcal{D})$ é completo (veja [106]).

Observamos que, em um sistema discreto, o tempo é determinado proporcionalmente ao número de iterações executadas.

Com base na Definição 8.4 podemos também fazer a seguinte definição.

Definição 8.9 (Equilíbrio). Um número fuzzy $\bar{u} \in \mathcal{F}(\mathbb{R})$ é um *ponto de equilíbrio* do sistema fuzzy discreto (8.31) se $\psi_t(\bar{u}) = \bar{u}$, para todo $t \geq 0$, o que acarreta $F(\bar{u}) = \bar{u}$, ou seja, $\bar{u}$ é um ponto fixo de F .

A seguir vamos analisar brevemente a dinâmica do modelo malthusiano, supondo a incerteza na condição inicial, o que é bastante razoável em problemas de dinâmica de populações, principalmente quando se inicia com uma população muito grande ou estimada. Um exemplo típico é o número inicial de uma cultura de bactérias.

8.2.1 Modelo Malthusiano Fuzzy Discreto

Como no caso contínuo, vamos supor que em cada geração t , o número de indivíduos seja proporcional à população na geração anterior. Além disso, que a condição inicial seja incerta, dada por $u_0 \in \mathcal{F}(\mathbb{R})$ de modo que seus α -níveis sejam os intervalos fechados $[u_0]^\alpha = [u_{01}^\alpha, u_{02}^\alpha] \subset \mathbb{R}^+$, para todo $\alpha \in [0, 1]$.

Como fizemos no caso contínuo, aqui vamos também distinguir duas situações:

Caso (a) Taxa de crescimento crisp e condição inicial incerta

- Se $\lambda > 0$, o modelo malthusiano fuzzy discreto é dado por:

$$\begin{cases} u_{t+1} = \lambda u_t \\ u_0 \in \mathcal{F}(\mathbb{R}) \end{cases} \quad (8.32)$$

Levando-se em conta a multiplicação de número real por número fuzzy (Capítulo 2), a solução de (8.32) é dada por:

$$u_t = \lambda^t u_0, \quad (8.33)$$

cujos α -níveis são $[u_t]^\alpha = \lambda^t [u_0]^\alpha = [\lambda^t u_{01}^\alpha, \lambda^t u_{02}^\alpha]$.

Caso (b) Taxa de crescimento e condição inicial incertas

- Neste caso, além da condição inicial, também é considerado que a taxa de crescimento (Λ) é fuzzy.

Se $\Lambda \in \mathcal{F}(\mathbb{R})$ com $[\Lambda]^\alpha = [\lambda_1^\alpha, \lambda_2^\alpha]$ e $u_0 \in \mathcal{F}(\mathbb{R})$, o modelo malthusiano fuzzy discreto é dado por:

$$\begin{cases} u_{t+1} = \Lambda u_t \\ u_0 \in \mathcal{F}(\mathbb{R}) \end{cases}, \quad (8.34)$$

com solução fuzzy

$$u_t = \Lambda^t u_0, \quad (8.35)$$

cujos α -níveis são $[u_t]^\alpha = [(\lambda_1^\alpha)^t u_{01}^\alpha, (\lambda_2^\alpha)^t u_{02}^\alpha]$.

Pontos de Equilíbrio

De acordo com as soluções acima (8.33) e (8.35) podemos concluir que se $\lambda \neq 1$ ($\Lambda \neq \hat{1}$) o único equilíbrio do sistema malthusiano fuzzy discreto é o ponto fuzzy $\chi_{\{0\}}$ e, se $\lambda = 1$ ($\Lambda = 1$) então qualquer condição inicial $u_0 \in \mathcal{F}(\mathbb{R})$ é ponto de equilíbrio.

Diferentemente do caso contínuo, isto é, das equações diferenciais fuzzy, como vimos na Seção 8.1.2, aqui o diâmetro da solução pode diminuir à medida que o tempo cresce. Para o nosso exemplo acima temos que, se $\lambda \in \mathbb{R}$,

$$\text{diam}[u_t]^\alpha = \text{diam}[\lambda^t u_0]^\alpha = \lambda^t \text{diam}[u_0]^\alpha$$

e assim,

$$\lim_{t \rightarrow +\infty} \text{diam}[u_t]^\alpha = \begin{cases} 0 & \text{se } 0 < \lambda < 1 \\ +\infty & \text{se } \lambda > 1 \\ \text{diam}[u_0]^\alpha & \text{se } \lambda = 1 \end{cases}.$$

Estabilidade do Ponto de Equilíbrio $\chi_{\{0\}}$

Da definição da métrica $\mathcal{D}$ temos

$$\mathcal{D}(\chi_{\{0\}}, u_0) = \sup_{0 \leq \alpha \leq 1} d_H([\chi_{\{0\}}]^\alpha, [u_0]^\alpha) = u_{02}^0$$

e

$$\mathcal{D}(\chi_{\{0\}}, u_t) = D(\chi_{\{0\}}, \lambda^t u_0) = \lambda^t u_{02}^0.$$

Portanto, para o modelo (8.32), $\chi_{\{0\}}$ é estável se $0 < \lambda \leq 1$, e assintoticamente estável se $0 < \lambda < 1$ pois, neste caso, $\lim_{n \rightarrow +\infty} \mathcal{D}(\chi_{\{0\}}, u_t) = 0$.

Para $\lambda > 1$, o ponto de equilíbrio $\chi_{\{0\}}$ é instável.

Deixamos para o leitor estudar o caso em que a taxa de crescimento Λ é fuzzy.

As conclusões obtidas no modelo de Malthus discreto fuzzy, quanto à estabilidade, são de fato mais gerais como veremos abaixo.

Seja o sistema discreto determinístico

$$x_{t+1} = f(x_t). \quad (8.36)$$

Associado a este sistema, temos um sistema fuzzy (8.31) (basta considerar em (8.31) a extensão $\hat{f}$ da função f). Agora, se $\bar{x}$ é um ponto de equilíbrio do sistema (8.36), então $\chi_{\{\bar{x}\}}$ é um equilíbrio do sistema (8.31) obtido pela fuzzificação do campo determinístico f , e estes equilíbrios têm as mesmas características quanto à estabilidade.

O teorema seguinte nos permite caracterizar os tipos de estabilidade dos equilíbrios de sistemas dinâmicos fuzzy discretos que são oriundos

dos sistemas determinísticos. Ou seja, é a versão do Teorema 8.7 para o caso discreto.

Teorema 8.9. *Seja $f : \mathbb{R} \rightarrow \mathbb{R}$ uma função contínua e $\hat{f}$ sua extensão de Zadeh. Então,*

- (a) $\chi_{\{\bar{x}\}}$ é equilíbrio para o sistema fuzzy $u_{t+1} = \hat{f}(u_t)$ se, e somente se, $\bar{x}$ for equilíbrio para o sistema determinístico $x_{t+1} = f(x_t)$;
- (b) $\chi_{\{\bar{x}\}}$ é estável para o sistema fuzzy $u_{t+1} = \hat{f}(u_t)$ se, e somente se, $\bar{x}$ é estável para o sistema determinístico $x_{t+1} = f(x_t)$;
- (c) $\chi_{\{\bar{x}\}}$ é assintoticamente estável para o sistema $u_{t+1} = \hat{f}(u_t)$ se, e somente se, $\bar{x}$ é assintoticamente estável para o sistema determinístico $x_{t+1} = f(x_t)$.

Demonstração. Ver [12]. ■

Corolário 8.10. *Suponha que f é diferenciavelmente contínua. Então, o equilíbrio $\chi_{\{\bar{x}\}}$ do sistema fuzzy discreto, $u_{t+1} = \hat{f}(u_t)$, será assintoticamente estável se $|f'(\bar{x})| < 1$, e instável se $|f'(\bar{x})| > 1$.*

Demonstração. Basta lembrar que as hipóteses do corolário acima são suficientes para estabilidade no caso determinístico (veja [50]). A conclusão é consequência do Teorema 8.9. ■

Estes dois últimos resultados valem num contexto mais geral [12].

Voltando ao modelo de Malthus, como $\bar{x} = 0$ é assintoticamente estável para o caso determinístico, o Corolário 8.10 nos permite concluir imediatamente que $\chi_{\{0\}}$ é assintoticamente estável para o modelo fuzzy de Malthus discreto, se $0 < \lambda < 1$.

Para casos de sistemas não lineares, como o *logístico*, a dinâmica muda radicalmente quando estudada através dos sistemas fuzzy discretos. Como o espaço fuzzy $\mathcal{F}(\mathbb{R})$ contém $\mathbb{R}$, é razoável que o número

de pontos críticos dos sistemas fuzzy seja maior que o do caso determinístico. Além disso, surgem novas órbitas periódicas. Também, o diagrama de bifurcação é diferente daquele que aparece no caso clássico. Vamos verificar este fato no modelo logístico (ou de Verhulst).

8.2.2 O Modelo Logístico Fuzzy Discreto

O modelo logístico (ou de Verhulst) determinístico supõe uma inibição no crescimento quando a população é muito alta, isto é, $x_{t+1} \rightarrow x_t$ para $t \rightarrow +\infty$. Sua formulação matemática é a equação discreta

$$\begin{cases} x_{t+1} = ax_t(1 - x_t) \\ x_0 \in \mathbb{R}^+ \end{cases}, \quad (8.37)$$

onde x_t denota a densidade populacional na geração t e a é a taxa de crescimento intrínseco, $1 \leq a \leq 4$.

Os equilíbrios desta equação são $\bar{x} = 0$ e $x_a = 1 - \frac{1}{a}$. Sabemos também que $\bar{x} = 0$ é instável, e $x_a = 1 - \frac{1}{a}$ é assintoticamente estável se $1 < a < 3$. Mais ainda, quando $a = a_1 = 3$ (primeiro valor de bifurcação), o ponto fixo $x_a = 1 - \frac{1}{a}$ perde a estabilidade e, a partir daí, a população oscila entre dois valores $[x_1, x_2]$ até o próximo valor de bifurcação que é $a = a_2 = 1 + \sqrt{6}$. Em a_2 esta órbita de período 2 perde a estabilidade e origina-se uma órbita de período 4, que é estável até o próximo valor de bifurcação $a = a_3$. Este comportamento de duplicação do período das órbitas (Figura 8.7) continua ocorrendo até que o sistema alcance o caos em $a^* = 3,569 \dots$ (veja [50]).

Lembramos que, no modelo logístico discreto, estamos assumindo que a população é homogênea e que a taxa de crescimento a é constante para toda população. Entretanto, em qualquer comunidade existe sempre uma diferenciação comportamental e física entre seus elementos. Essa heterogeneidade é mais acentuada quando os indivíduos são considerados isoladamente e menos quando se considera o grupo. Porém, aqui nesse




Figura 8.7: Diagrama de bifurcação determinístico.

exemplo, consideramos a mesma taxa a para toda a população.

Diferentemente da análise que fizemos do modelo malthusiano, aqui vamos estudar apenas o caso em que a condição inicial é fuzzy e o parâmetro a é determinístico. Fica como desafio para o leitor o caso em que a taxa de crescimento é também fuzzy (o leitor pode consultar [79]).

Consideremos então o caso fuzzy em que a é real, com $1 \leq a \leq 4$, e a condição inicial como sendo um número fuzzy, ou seja,

$$\begin{cases} u_{t+1} = \hat{f}(u_t) \\ u_0 \in \mathcal{F}(\mathbb{R}) \end{cases}, \quad (8.38)$$

em que f é a função logística normalizada $f(x) = ax(1-x)$ e $\hat{f}$ é sua extensão de Zadeh.

Pontos de Equilíbrio

Os pontos de equilíbrio do sistema fuzzy (8.38) são os pontos fixos de $\hat{f}$, isto é, os números fuzzy u que são soluções da equação

$$\hat{f}(u) = u$$

ou, equivalentemente em níveis, já que f é contínua (pelo Teorema 2.1),

$$[\hat{f}(u)]^\alpha = f([u]^\alpha) = [u]^\alpha = [u_1^\alpha, u_2^\alpha]$$

para todo $\alpha \in [0, 1]$, isto é,

$$\begin{cases} u_1^\alpha = \min_{u_1^\alpha \leq x \leq u_2^\alpha} f(x) \\ u_2^\alpha = \max_{u_1^\alpha \leq x \leq u_2^\alpha} f(x) \end{cases} . \quad (8.39)$$

Indicando por $\hat{0}$ e $\hat{x}_a$ as funções características dos pontos fixos 0 e $x_a = 1 - \frac{1}{a}$ da função f e usando um cálculo direto, porém trabalhoso, obtemos os pontos fixos de $\hat{f}$ em $\mathcal{F}(\mathbb{R})$ (veja [12, 14]).

- Se $1 \leq a \leq 2$, os únicos pontos fixos da equação fuzzy logística são: $\hat{0}, \hat{x}_a$ e $\bar{u}_1$, onde $\bar{u}_1$ é definido por $[\bar{u}_1]^\alpha = [0, x_a], \forall \alpha \in [0, 1]$.
- Se $2 < a \leq 3$, além dos pontos fixos $\hat{0}$ e $\hat{x}_a$, temos também $\bar{u}_2$, definido por $[\bar{u}_2]^\alpha = [0, \frac{a}{4}], \forall \alpha \in [0, 1]$.
- Se $3 < a \leq 1 + \sqrt{5}$, além de $\hat{0}, \hat{x}_a$ e $\bar{u}_2$, temos o ponto fixo $\bar{u}_3$ com $[\bar{u}_3]^\alpha = [x_1, x_2], \forall \alpha \in [0, 1]$, onde x_1 e x_2 são pontos fixos de $\hat{f}$, isto é, $f(x_1) = x_2$ e $f(x_2) = x_1$.
- Se $1 + \sqrt{5} < a < 4$, os pontos fixos são $\hat{0}, \hat{x}_a, \bar{u}_2, \bar{u}_3, \bar{u}_4$, onde $[\bar{u}_4]^\alpha = [f(\frac{a}{4}), \frac{a}{4}]$ e $\bar{u}_5$ que é definido por:

$$[\bar{u}_5]^\alpha = \begin{cases} [0, f(\frac{a}{4})] & \text{se } \alpha \leq \bar{\alpha} \\ [f(\frac{a}{4}), \frac{a}{4}] & \text{se } \alpha > \bar{\alpha} \end{cases}$$

para todo $\alpha \in [0, 1]$ e algum $\bar{\alpha}$.

- Se $a = 4$, os únicos pontos fixos são: $\hat{0}, \hat{x}_a$ e $\bar{u}_6$ com $[\bar{u}_6]^\alpha = [0, 1]$ para todo $\alpha \in [0, 1]$.

Na Figura 8.8 estão resumidos os pontos fixos desse exemplo.




Figura 8.8: Equilíbrios do sistema fuzzy logístico.

Estabilidade dos pontos de equilíbrio

A estabilidade dos equilíbrios $\hat{0}$, $\hat{x}_a$ e dos ciclos de $\hat{f}$, que são funções características dos ciclos de f , são as mesmas quando se estuda f ou $\hat{f}$, de acordo com o Teorema 8.9.

Os únicos pontos fixos novos (fuzzy) de $\hat{f}$ que são assintoticamente estáveis são $\bar{u}_3$ e $\bar{u}_4$. Os demais são instáveis. Este estudo pode ser encontrado com detalhe em [12, 79].

A Figura 8.9 representa as bifurcações dos pontos de equilíbrio e mostra a mudança em sua magnitude quando variamos o parâmetro a . Para o modelo fuzzy, a ramificação determinística é igual ao diagrama de bifurcação clássico (Figura 8.7) e a ramificação fuzzy ilustra os novos pontos fixos de acordo com nossos resultados.

Como já salientamos, no caso determinístico, $a = 3$ é um valor de bifurcação, isto é, se a é pouco superior a 3, o ponto fixo x_a deixa de ser estável e surge uma órbita de período 2. Para valores de a ligeiramente




Figura 8.9: Diagrama de bifurcação para o caso fuzzy.

superiores a $1 + \sqrt{6}$ aparece uma órbita de período 4. Para valores próximos de 3.89, surge um comportamento caótico na dinâmica desta equação (ver [43, 50]).

No caso da equação fuzzy, $a = 1$, $a = 2$, $a = 3$ e $a = 1 + \sqrt{5}$ são também valores de bifurcação. O diagrama de bifurcação abaixo ilustra a dinâmica do modelo logístico acima supondo uma condição inicial fuzzy.

Devemos salientar que o estudo feito acima trata apenas dos pontos de equilíbrio fuzzy. As órbitas periódicas (ciclos) estudadas são as determinísticas que, como pode ser mostrado (veja [12]), não muda o tipo de estabilidade quando estas são consideradas no espaço euclidiano ou no espaço fuzzy. Estudos de órbitas periódicas fuzzy foram desenvolvidos recentemente e já sabemos que cada órbita periódica determinística de período 2^p dá origem a uma órbita fuzzy de período 2^{p-1} , $p \geq 2$ (veja [79]). Exemplo disto é a órbita determinística de período 2 que passou a ser o ponto de equilíbrio fuzzy $\bar{u}_3$, com α -níveis $[\bar{u}_3]^\alpha = [x_1, x_2]$ para todo $\alpha \in [0, 1]$. Nenhum tipo de estudo sobre caos fuzzy foi feito aqui em nosso texto. O leitor interessado nesse assunto pode consultar, por exemplo, [73, 109].

Queremos encerrar esse capítulo comentando que, como vimos acima,

há diversas abordagens sobre sistemas dinâmicos fuzzy. Além das apresentadas aqui o leitor pode encontrar outras, consultando por exemplo [80]. Os sistemas p-fuzzy, formalmente descritos com a metodologia vista na Subseção 8.1.5, tanto para o caso discreto como contínuo, serão destacados no Capítulo 9, devido a sua riqueza de detalhes.

Capítulo 9

Modelagem em Biomatemática: Fuzziness Demográfica

“Conforme a complexidade de um sistema aumenta, nossa habilidade de fazer afirmações precisas e significativas sobre seu comportamento diminui, até um limiar em que a precisão e relevância tornam-se praticamente características mutuamente exclusivas.”

(Princípio da Incompatibilidade - Zadeh)

A característica essencial da modelagem matemática de processos variacionais, utilizando equações determinísticas, é a “exatidão” obtida nas previsões do fenômeno estudado. Evidentemente, tais previsões são dependentes de hipóteses sobre a precisão tanto das variáveis de estado como dos parâmetros, inseridos nos modelos por meio de valores “médios” de um conjunto de dados.

Os modelos clássicos de biomatemática, particularmente os modelos de dinâmica populacional e epidemiologia, são fundamentados em hipóteses quase sempre provenientes da físico-química, onde a reação entre duas substâncias (variáveis de estado) é modelada pelo produto de suas concentrações – *lei da ação das massas*. Esta mesma lei é usada

nos modelos de Lotka-Volterra de interação entre duas espécies e nos modelos de Kermack-MacKendrick de epidemiologia. O parâmetro que representa a taxa de predação do modelo presa-predador ou a força de infecção dos modelos epidemiológicos são valores “médios” simulados ou obtidos empiricamente.

Nos modelos que lidam com incerteza, os estocásticos, por exemplo, as soluções são processos estocásticos cujas médias podem ser obtidas a posteriori, quando se tem as densidades de distribuição das variáveis e/ou dos parâmetros envolvidos no modelo referente ao fenômeno analisado. Porém, se numa população, além de quantificar seus elementos, pretendemos levar em conta certas qualidades dos indivíduos, as variáveis devem “captar” tais incertezas. Por exemplo, numa população de *presas* de uma determinada espécie, a cada presa podemos levar em conta a *facilidade como é predada*, o que pode estar relacionado com a sua idade, seu estado de saúde, habitat etc. Considerações deste tipo (variáveis com adjuntos qualitativos) são muito frequentes em fenômenos biológicos e muitas vezes essenciais na modelagem e entendimento do fenômeno. Num sistema evolutivo, o que parece ser insignificante inicialmente pode ter importância extrema no futuro.

Os vários tipos de incertezas que aparecem nos fenômenos de biomatemática podem ter modelagem bem variadas. Quando optamos pelos modelos estocásticos, implicitamente estamos supondo conhecer, a priori, as distribuições de probabilidades dos parâmetros e condições iniciais do fenômeno estudado. Este é o caso do modelo estocástico malthusiano estudado por Pielou (veja [22]). Entretanto, se no fenômeno em questão pretendemos levar em conta heterogeneidade, como gradualidades, que não são provenientes de aleatoriedades, como modelar matematicamente estas características?

Por exemplo, se temos uma população de “*fumantes*” num instante t_0 , sujeita a alguma taxa de mortalidade, podemos querer saber como estará composta esta população no futuro. Se considerarmos que cada

indivíduo desta população é simplesmente fumante ou não-fumante o problema pode ser resolvido com um modelo determinístico, tomando separadamente ambas as populações. Por outro lado, se temos inicialmente uma distribuição de probabilidades dos fumantes desta população, podemos usar um modelo estocástico para estudar a evolução desta distribuição inicial. Porém, se a característica de ser *fumante* depender da quantidade de cigarros que se fuma diariamente, qualidade dos cigarros fumados, intermitência do ato de fumar, etc., devemos caracterizar também o *grau* de ser fumante. Neste caso, cada indivíduo pertence à população de *fumantes* com um *grau específico de pertinência*: Se não fumar, seu grau de pertinência é zero; se fumar 3 carteiras diárias podemos dizer que é uma fumante de grau 1; Agora, se o indivíduo fumar 10 cigarros por dia, quanto ele será *fumante*? Esta subjetividade, *ser fumante*, pode ser expressa por uma função φ_A , onde $\varphi_A(x)$ indica o grau com que o indivíduo que fuma x cigarros está em “concordância” com o conceito de *fumante*. Um estudo sobre esperança de vida de um grupo, considerando a quantidade de cigarros fumados por dia, foi realizado por A. Kandel [70].

Os modelos variacionais fuzzy podem comportar vários tipos de incertezas (vagueza ou *fuzziness*), traduzidas por coeficientes, condições iniciais ou pelas próprias variáveis de estado.

Se a subjetividade vem na variável de estado ou nos parâmetros dos modelos temos, respectivamente, *fuzziness demográfica* ou *fuzziness ambiental*. Assim, quando as variáveis de estado são modeladas por meio da teoria dos conjuntos fuzzy, temos *fuzziness demográfica*, e temos *fuzziness ambiental* quando somente os parâmetros são considerados fuzzy. Em geral, ambos os tipos de fuzziness estão presentes nos fenômenos biológicos.

O comentário feito acima sugere que a adoção de fuzziness ambiental permite a utilização dos conceitos clássicos de taxa de variação, uma vez que as variáveis de estado são determinísticas. Essa abordagem será

explorada no Capítulo 10 deste texto.

Para a fuzziness demográfica, devemos adotar algum conceito para variação (ou taxa de variação) que seja compatível com a noção de variáveis incertas.

Há muitas possibilidades de se modelar fuzziness demográfica. Dado que, para esse caso, a variação de estado é incerta, qualquer uma das metodologias vistas nas Seções 8.1.2 e 8.1.3 poderiam ser utilizadas para modelos contínuos. A escolha de qual delas adotar está relacionada com a modelagem adequada do fenômeno. Por outro lado, se o modelo for discreto, então temos a metodologia da Seção 8.2 como opção. No entanto, devido a riqueza dos sistemas **p-fuzzy** (veja abaixo), utilizaremos essa metodologia para estudar a evolução de sistemas dinâmicos em que as variáveis de estado são incertas.

Os sistemas considerados aqui são do tipo autônomo, ou seja, as variações (ou taxas de variações) não dependem explicitamente do tempo. Mais ainda, tanto as variáveis de estado como suas variações são consideradas linguísticas. Dessa forma, as variáveis de estado estão correlacionadas com suas variações, não por meio de equações – que é o caso mais comum na literatura, e sim por uma base de regras fuzzy cuja característica principal é ter **as variáveis de estado como entradas enquanto as variações são as saídas**.

Como denominamos na Seção 8.1.5, os sistemas estudados aqui são chamados **p-fuzzy** porque o campo de direções, conhecido parcialmente a priori, é obtido por meio de metodologias de controladores fuzzy. Assim, p-fuzzy é uma abreviação de parcialmente fuzzy. Como em tais metodologias estão previstos processos de defuzzificação, a solução de um sistema p-fuzzy é crisp, isto é, um valor preciso $x(t)$ que representa a variável de estado em cada instante t .

Os sistemas p-fuzzy podem ser discretos ou contínuos. Para efeito didático, abordaremos primeiro o caso discreto, e em seguida, o contínuo.

9.1 Fuzziness Demográfica: modelagem discreta

Os principais conceitos que estudaremos nesta seção fazem parte do recente trabalho de tese de doutorado de Silva [117]. Portanto, o leitor interessado no aprofundamento desse assunto está convidado a consultar tal trabalho.

Não estamos interessados nesta parte no estudo da convergência dos modelos p-fuzzy para os determinísticos. A modelagem matemática dos fenômenos aqui analisados é fundamentalmente proveniente dos controladores fuzzy. Por isso não adotaremos o índice “ r ”, que indica o número de regras, no campo de direções para distingui-lo do modelo determinístico.

Os sistemas p-fuzzy discretos têm a forma

$$\begin{cases} x_{t+1} = F(x_t) \\ x_0 = x(t_0) \end{cases}, \quad (9.1)$$

onde $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ é a função $F(x) = x + \Delta x$ e Δx é a saída defuzzificada dada por um controlador fuzzy para a entrada x . Um sistema p-fuzzy discreto nada mais é que uma equação de diferenças, $x_{t+1} - x_t = f(x_t)$, em que a função $f(x) = \Delta x$ é a saída do controlador fuzzy. A Figura 9.1 representa esquematicamente um sistema p-fuzzy discreto.




Figura 9.1: Arquitetura de um modelo p-fuzzy discreto.

Recentemente, Ortega *et al* [96] aplicaram essa metodologia aliada ao

princípio de extensão de Zadeh para estudar a evolução da raiva canina no Estado de São Paulo.

Para um melhor entendimento a respeito da estabilidade dos pontos de equilíbrio dos sistemas p-fuzzy faz-se necessário alguns comentários sobre base de regras fuzzy com oposição semântica.

9.1.1 Regras Fuzzy com Oposição Semântica

Se considerarmos o princípio malthusiano para crescimento populacional, isto é,

“a variação de uma população é proporcional à população em cada instante”

então, uma primeira tentativa de modelagem para tal princípio poderia nos levar às regras do Quadro 8.1, cujos antecedentes e consequentes estão representados nas Figuras 8.4(a) e 8.4(b), respectivamente.

Com essa base de regras, o controlador de Mamdani e a defuzzificação dada pelo centro de massa, o sistema p-fuzzy (9.1) nos leva à trajetória ilustrada na Figura 9.2.




Figura 9.2: Número de indivíduos em função do tempo a partir do sistema p-fuzzy discreto e da base de regras do Quadro 8.1.

De acordo com a Figura 9.2, o sistema p-fuzzy discreto produz uma trajetória compatível com o modelo exponencial malthusiano, no qual o

número de mortes é inferior ao de nascimento. No entanto, esse crescimento exponencial ilimitado não é observado na realidade, a não ser por um curto espaço de tempo. Há na natureza fatores como alimentação, competição com outros indivíduos, disputa por espaço, luz, etc, que limitam a população a um certo limiar (capacidade suporte), dando-lhe estabilidade num determinado ambiente.

Fatores como os citados acima desencadeiam um processo de “inibição” da população de modo que, para populações muito grandes, a variação é pequena ou mesmo negativa.


R_1 : Se (X) é “baixa” (A_1) então a variação é “baixa positiva” (B_1)
R_2 : Se (X) é “média baixa” (A_2) então a variação é “média positiva” (B_2)
R_3 : Se (X) é “média” (A_3) então a variação é “alta positiva” (B_3)
R_4 : Se (X) é “média alta” (A_4) então a variação é “média positiva” ($B_4 = B_2$)
R_5 : Se (X) é “alta” (A_5) então a variação é “baixa positiva” ($B_5 = B_1$)
R_6 : Se (X) é “altíssima” (A_6) então a variação é “baixa negativa” (B_6)

Quadro 9.1: Base de regras para modelar a variação da população com base na sua densidade, com oposição semântica.

Com o propósito de aprimorar o modelo malthusiano acima, tais informações devem ser “inseridas” na base de regras. Se esperamos estabilidade ou equilíbrios, a base de regras deve apresentar regras com **oposição semântica** nos consequentes. Oposição semântica é caracterizada aqui pela alternância de sinais nas variações (consequentes). Um estudo teórico sobre esse assunto o leitor pode encontrar em [102]. Por exemplo, poderíamos refinar a base de regras do Quadro 8.1 de modo a obter a base de regras do Quadro 9.1 com oposição semântica nas regras sucessivas R_5 e R_6 , em que os conjuntos fuzzy dos antecedentes e dos consequentes estão ilustrados na Figura 9.3(a) e 9.3(b) respectivamente.

Levando em conta esta base de regras, o controlador de Mamdani e a defuzzificação do centro de gravidade, o sistema p-fuzzy produz a

trajetória mostrada na Figura 9.4.



(a) Conjuntos fuzzy antecedentes para populações (X). (b) Conjuntos fuzzy consequentes para variações (ΔX).

Figura 9.3: Funções de Pertinência para o Quadro 9.1.




Figura 9.4: Solução do sistema p-fuzzy discreto para base de regras Quadro 9.1 e $x_0 = 2$.

A trajetória apresentada na Figura 9.4 tem comportamento qualitativo compatível com os modelos que apresentam inibição como, os modelos logístico, de Gompertz, de Montroll etc.

Para facilitar o estudo de equilíbrios de sistemas p-fuzzy faremos algumas exigências a respeito da base de regras. Uma delas diz respeito à monotonicidade, isto é, as regras devem estar dispostas numa **escala ordinal**. Por exemplo, as regras do Quadro 9.1 apresentam tal ordem: os antecedentes estão monotonicamente dispostos do “menor” para o

“maior”. Isso facilitará a localização de possíveis equilíbrios do modelo. Claro que a não ordenação não elimina os pontos de equilíbrio. A existência ou não deles depende, dentre outros fatores, da existência de oposição semântica nas regras. Regras sem oposição semântica implicam na não existência de **equilíbrios hiperbólicos** ([59]) que são os de nosso interesse. Por outro lado, regras com oposição semântica implicam na possibilidade de existência desses equilíbrios. A existência de tais pontos depende da “continuidade” na base de regras. No caso clássico essa garantia vem do Teorema do Anulamento de Bolzano [5, 57].

Vale ressaltar que não temos interesse no estudo da dinâmica em torno de equilíbrios não hiperbólicos. Intuitivamente, equilíbrio não hiperbólico significa que em torno dele a variação não muda de sinal.

9.1.2 Equilíbrio e Estabilidade dos Sistemas p-fuzzy Discretos Unidimensionais

Como já comentamos, de agora em diante a base de regras fuzzy deve satisfazer algumas propriedades, listadas a seguir. Tal procedimento visa facilitar a localização de possíveis equilíbrios do sistema.

- (i) Os universos devem ser intervalos limitados do conjunto dos números reais;
- (ii) Os conjuntos fuzzy da base de regras devem ser **números fuzzy** (ver Cap. 2);
- (iii) A base de regras deve ser uma cobertura do universo relacionado, no sentido que cada elemento do universo tem pertinência **não nula** a pelo menos um dos números fuzzy da base de regras;
- (iv) No máximo duas regras devem ser ativadas de cada vez, isto é, cada elemento do universo deve ter pertinência não nula a no máximo dois antecedentes;

- (v) Os elementos de pertinência máxima (igual a 1) pertencem somente a um dos números fuzzy da base de regras, isto é, têm grau de pertinência nula aos demais números fuzzy das regras;
- (vi) A base de regras deve ser **ordenada monotonicamente** (crescente ou decrescente), isto é, os qualificadores dos antecedentes devem ser “ordenados”: *pequeno*, *médio* e *grande*, por exemplo. Formalmente, isto significa que o maior elemento do suporte do antecedente da regra “ R_i ” deve ser menor que o da regra seguinte “ R_{i+1} ”.

Com as hipóteses acima vamos enunciar alguns resultados importantes. Mais detalhes o leitor pode encontrar em [117].

Definição 9.1 (Ordenação de regras). Uma base de regras com as seis características acima será denominada **bem ordenada**.

Proposição 9.1. *Suponha que a base de regras do sistema p-fuzzy (9.1) seja bem ordenada e que os números fuzzy A_i e A_{i+1} , de regras consecutivas, tenham funções de pertinências contínuas. Então, para todo $x \in I^* = \text{supp}\{A_i\} \cap \text{supp}\{A_{i+1}\} \neq \emptyset$, a saída Δx é contínua e derivável.*

Demonstração. Ver [117]. ■

Corolário 9.2. *Suponha que a base de regras para (9.1) seja bem ordenada e que seja formada por números fuzzy triangulares, trapezoidais e/ou em forma de sino. Nestas condições, para todo $x \in I^* = \text{supp}\{A_i\} \cap \text{supp}\{A_{i+1}\} \neq \emptyset$, a saída Δx é contínua e derivável.*

Definição 9.2 (Equilíbrio). Um número real $\bar{x}$ é um *ponto de equilíbrio* do sistema p-fuzzy discreto (9.1) se

$$F(\bar{x}) = \bar{x} \iff \bar{x} + \Delta\bar{x} = \bar{x} \iff \Delta\bar{x} = 0.$$

Teorema 9.3 (Existência de equilíbrio). *Suponha que uma base de regras esteja nas condições da Proposição 9.1 e que as regras R_i e R_{i+1} , com antecedentes A_i e A_{i+1} , apresentem oposição semântica nos consequentes B_i e B_{i+1} . Nestas condições o intervalo*

$$I^* = \text{supp} \{A_i\} \cap \text{supp} \{A_{i+1}\} \neq \emptyset$$

possui pelo menos um equilíbrio do sistema (9.1).

Demonstração. A prova é baseada no fato de que a oposição semântica implica na mudança de sinal de Δx no intervalo I^* . Daí, de Δx ser contínua (Proposição 9.1) e do Teorema de Bolzano conclui-se a prova do teorema. Para mais detalhes ver [117]. ■

A Figura 9.5 ilustra o Teorema 9.3.




Figura 9.5: Existência de equilíbrio para base de regras com oposição semântica: “ $B_i > 0$ e $B_{i+1} < 0$ ”.

O estudo de unicidade do equilíbrio de sistemas p-fuzzy é um tanto extenso e o leitor pode consultar [117]. A seguir vamos apenas mencionar alguns resultados.

Com sistemas p-fuzzy em que a base de regras fuzzy satisfaz a Proposição 9.1, a saída Δx tem uma expressão explícita com relação às funções de pertinência dos antecedentes e consequentes das regras que

apresentam oposição semântica. A partir de tal expressão é possível estudar várias proposições a respeito da unicidade do equilíbrio no intervalo I^* .

Um primeiro resultado geral é o seguinte: se Δx se anular em I^* e for monótona, então o sistema p-fuzzy (9.1) tem um único ponto de equilíbrio em I^* . Uma condição suficiente para que Δx seja monótona é que sua derivada não mude de sinal.

A seguir vamos enunciar apenas o resultado para determinação de equilíbrio em que as saídas são simétricas.

Teorema 9.4 (Unicidade de equilíbrio para saídas simétricas). *Suponha que uma base de regras esteja nas condições da Proposição 9.1 e que as regras R_i e R_{i+1} , com antecedentes A_i e A_{i+1} , apresentem oposição semântica nos consequentes B_i e B_{i+1} cujas funções de pertinência sejam simétricas, isto é, $\varphi_{B_i}(s) = \varphi_{B_{i+1}}(-s)$ para todo s do universo. Nestas condições o intervalo $I^* = \text{supp}\{A_i\} \cap \text{supp}\{A_{i+1}\}$ possui apenas um equilíbrio $\bar{x}$ do sistema p-fuzzy (9.1), que é dado por*

$$\bar{x} = \max_{x \in I^*} [\min(\varphi_{A_i}(x), \varphi_{A_{i+1}}(x))]$$

ou pela solução da equação

$$\varphi_{A_i}(x) = \varphi_{A_{i+1}}(x),$$

quando existir.

Além disso, também vale a seguinte fórmula, útil para estudo de estabilidade

$$\frac{d(\Delta x)}{dx} \Big|_{x=\bar{x}} = \frac{[\varphi_{B_{i+1}}^{-1}(\varphi_{A_i}(\bar{x}))]^2 [\varphi'_{A_i}(\bar{x}) - \varphi'_{A_{i+1}}(\bar{x})]}{4 \int_0^{\varphi_{A_i}(\bar{x})} \varphi_{B_{i+1}}^{-1}(s) ds}. \quad (9.2)$$

onde $\varphi_{B_{i+1}}^+$ é a função de pertinência de B_{i+1} restrita ao lado direito

deste conjunto.

Demonstração. [117]. A ilustração da existência de $\bar{x}$ encontra-se na Figura 9.5. ■

O estudo que apresentaremos a seguir sobre estabilidade de equilíbrios dos sistemas p-fuzzy discretos são feitos a partir do Corolário 8.10 para sistemas discretos clássicos.

Teorema 9.5 (Estabilidade de equilíbrio de sistemas p-fuzzy discretos). *Suponha que $\bar{x}$ seja um equilíbrio do sistema p-fuzzy (9.1). Nestas condições valem*

(a) $\bar{x}$ é assintoticamente estável se

$$\begin{aligned} |F'(\bar{x})| < 1 &\iff \left| 1 + \frac{d(\Delta x)}{dx} \right|_{x=\bar{x}} < 1 \\ &\iff -2 < \frac{d(\Delta x)}{dx} \Big|_{x=\bar{x}} < 0. \end{aligned}$$

(b) $\bar{x}$ é instável se

$$\frac{d(\Delta x)}{dx} \Big|_{x=\bar{x}} < -2 \quad \text{ou} \quad \frac{d(\Delta x)}{dx} \Big|_{x=\bar{x}} > 0.$$

É interessante observar que, dependendo do sinal de $\frac{d(\Delta x)}{dx} \Big|_{x=\bar{x}}$, teremos variadas formas para o comportamento de estabilidade dos sistemas discretos:

- (i) se $-1 < \frac{d(\Delta x)}{dx} \Big|_{x=\bar{x}} < 0$, $\bar{x}$ é assintoticamente estável com convergência monótona;
- (ii) se $-2 < \frac{d(\Delta x)}{dx} \Big|_{x=\bar{x}} < -1$, $\bar{x}$ é assintoticamente estável com convergência oscilatória;

(iii) a instabilidade é oscilatória se $\frac{d(\Delta x)}{dx}|_{x=\bar{x}} < -2$.

O exemplo a seguir ilustra os conceitos vistos acima.

Exemplo 9.1. Considere o sistema p-fuzzy discreto cuja base de regras apresenta autoinibição e é dada pelas regras do Quadro 9.1 e cujos antecedentes e consequentes são dados na Figura 9.3.

Pela base de regras podemos observar oposição semântica nos consequentes B_5 e B_6 . Assim, temos uma única região de equilíbrio que é o intervalo

$$I^* = \text{supp}\{A_5\} \cap \text{supp}\{A_6\} = [200, 210].$$

Como nessa região os consequentes B_5 e B_6 são simétricos e

$$\varphi_{A_5}(x) = \frac{210 - x}{20} \text{ e } \varphi_{A_6}(x) = \frac{x - 200}{20},$$

então, do Teorema 9.4, o único ponto de equilíbrio é a solução da equação

$$\varphi_{A_5}(x) = \varphi_{A_6}(x) \iff \frac{210 - x}{20} = \frac{x - 200}{20} \iff \bar{x} = 205.$$

A estabilidade deste equilíbrio é estudada a partir da fórmula (9.2) para $\frac{d(\Delta x)}{dx}|_{x=\bar{x}}$, no Teorema 9.4.

Como $\varphi_{B_6^+}(x) = 1 - x \implies \varphi_{B_6^+}^{-1}(x) = 1 - x \implies \varphi_{B_6^+}^{-1}(\varphi_{A_5}(\bar{x})) = \frac{3}{4}$.
Também

$$\varphi_{A_5}(\bar{x}) = \frac{1}{4}, \varphi'_{A_5}(\bar{x}) = -\frac{1}{20}, \varphi'_{A_6}(\bar{x}) = \frac{1}{20}$$

e

$$\int_0^{\varphi_{A_5}(\bar{x})} \varphi_{B_6^+}^{-1}(s) ds = \int_0^{\frac{1}{4}} (1 - s) ds = \frac{7}{32}.$$

Então,

$$\frac{d(\Delta x)}{dx}|_{x=205} = \frac{(\frac{3}{4})^2 [(-\frac{1}{20}) - \frac{1}{20}]}{4 \cdot (\frac{7}{32})} = -\frac{9}{240}.$$

Assim,

$$-1 < \left. \frac{d(\Delta x)}{dx} \right|_{x=205} < 0.$$

Portanto, de acordo com o Teorema 9.5(a), $\bar{x} = 205$ é assintoticamente estável.

É possível verificar que pequenas perturbações nos conjuntos da base de regras acarretam alterações qualitativas no tipo de estabilidade do equilíbrio deste sistema (ver [117, Seção 4.1.1] e o Exercício 9.1). Isto significa que o sistema p-fuzzy estudado é estruturalmente instável. Esse fato está em total acordo com o modelo discreto de Verhulst estudado na Seção 8.2.2.

Um aspecto interessante dos sistemas p-fuzzy discretos que pode ser explorado, do ponto de vista prático, é sua utilização para ajustar parâmetros de modelos teóricos. Supondo que o sistema do Exemplo 9.1 represente a dinâmica de uma população com inibição, um modelo determinístico deveria ter as mesmas propriedades que o p-fuzzy. Por exemplo, se quiséssemos ajustar um modelo de Verhulst discreto ao p-fuzzy estudado acima, a capacidade suporte K e a taxa de crescimento intrínseca a devem satisfazer $205 = K - \frac{1}{a}$, já que o equilíbrio do modelo de Verhulst discreto é dado por $\bar{x} = K - \frac{1}{a}$. O ajuste propriamente dito seria feito a partir dos valores gerados pelo sistema p-fuzzy.

Claro que tal metodologia deveria ser aplicada com mais cuidado se quiséssemos ajustar o sistema p-fuzzy discreto a um modelo clássico contínuo, pelos motivos comentados anteriormente – estabilidade estrutural por exemplo. No entanto, se o equilíbrio do sistema p-fuzzy discreto tiver as mesmas propriedades qualitativas que a de um contínuo, ou seja, se o equilíbrio do p-fuzzy for estável, então é possível usar os dados gerados pelo p-fuzzy discreto para ajuste de parâmetros do modelo teórico contínuo. Um estudo para esses casos os leitor pode encontrar em [118].

Exercício 9.1. Faça alterações nos suportes dos antecedentes A_5 e A_6 das regras do Quadro 9.1 que contém o equilíbrio, de modo a obter um equilíbrio estável oscilatório e faça o estudo a partir dos resultados já vistos. Em seguida, faça alterações para obter equilíbrio não nulo instável. (Sugestão: combine a fórmula (9.2) com os resultados do Teorema 9.5).

Vamos encerrar esta seção apresentando uma introdução aos sistemas p-fuzzy bidimensionais.

9.1.3 Modelo tipo presa-predador p-fuzzy discreto

Especificamente nossa abordagem é sobre um modelo tipo presa-predador, no qual simulamos os contingentes populacionais das presas e dos predadores e apresentamos um plano de fase.

Para estudarmos esta dinâmica, por meio de um sistema p-fuzzy discreto, consideramos que as variáveis de entrada são o número de presas (X) e o número de predadores (Y), cujas propriedades qualitativas são: as presas favorecem os predadores e são desfavorecidas por estes. Essas são as principais características desse fenômeno ecológico. As saídas ΔX e ΔY representam, respectivamente, as variações das populações das presas e dos predadores.

Todas as variáveis são consideradas linguísticas e cada uma delas pode ser avaliada qualitativamente através de termos como: *baixa* (B), *média* (M) e *alta* (A) para as variáveis de estado e, *alta positiva* (A^+), *média positiva* (M^+), *baixa positiva* (B^+), *baixa negativa* (B^-), *média negativa* (M^-), e *alta negativa* (A^-) para as respectivas variações.

Suponhamos que tais termos sejam modelados por conjuntos fuzzy, cujas funções de pertinência são obtidas junto a um especialista. Tais funções estão representadas na Figura 9.6.

As funções de pertinência para as variações das populações são ilustradas na Figura 9.7.

A correlação entre as variáveis linguísticas é dada por uma base de




Figura 9.6: Funções de pertinência das populações.




Figura 9.7: Funções de pertinência das variações das populações.

regras que deve ser coerente com as características de um sistema interativo do tipo presa-predador, como comentado acima.

A base de regras, apresentada no Quadro 9.2, pode ser representada graficamente na Figura 9.8, onde as setas indicam as magnitudes e sentidos das variações.

Como no caso unidimensional, aqui também adotaremos o método de inferência de Mamdani com defuzzificação dada pelo centro de massa.

A dinâmica do sistema bidimensional p-fuzzy discreto consiste em

1.	Se	X	é	B	e	Y	é	B	então	ΔX é M^+	e	ΔY é M^-
2.	Se	X	é	B	e	Y	é	M	então	ΔX é B^+	e	ΔY é A^-
3.	Se	X	é	B	e	Y	é	A	então	ΔX é M^-	e	ΔY é M^-
4.	Se	X	é	M	e	Y	é	B	então	ΔX é A^+	e	ΔY é B^+
5.	Se	X	é	M	e	Y	é	A	então	ΔX é A^-	e	ΔY é B^-
6.	Se	X	é	A	e	Y	é	B	então	ΔX é M^+	e	ΔY é M^+
7.	Se	X	é	A	e	Y	é	M	então	ΔX é B^-	e	ΔY é A^+
8.	Se	X	é	A	e	Y	é	A	então	ΔX é M^-	e	ΔY é M^+

Quadro 9.2: Base de regras para um sistema p-fuzzy discreto do tipo presa-predador




Figura 9.8: Representação da base de regras do sistema p-fuzzy (9.3).

obter as populações por meio do sistemas iterativo bidimensional

$$\begin{cases} x_{n+1} = x_n + \Delta_1 [x_n, y_n] \\ y_{n+1} = y_n + \Delta_2 [x_n, y_n] \\ x_0, y_0 \in \mathbb{R} \text{ são dados} \end{cases} \quad (9.3)$$

em que $\Delta_1 [x, y]$ e $\Delta_2 [x, y]$ são as saídas defuzzificadas para as entradas $(X, Y) = (x, y)$.

A solução do sistema p-fuzzy (9.3), com os conjuntos dados nas Figuras 9.6 e 9.7 e $(x_0, y_0) = (70, 10)$, pode ser visualizada na Figura 9.9 e o

plano de fase na Figura 9.10.




Figura 9.9: Solução do sistema.




Figura 9.10: Plano de fase do sistema.

Observamos que existe uma região **E** que não está “coberta” por nenhuma regra. No entanto, como há oposição semântica nos consequentes das regras 4 e 5, que envolvem **E**, espera-se que aí estejam os equilíbrios do sistema.

Se quiséssemos preencher a região **E** de forma “contínua”, a regra deveria relacionar as populações médias.

Por exemplo,

“Se X é M e Y é M então ΔX é B e ΔY é B ”.

Salientamos que quando usamos o termo “População Média” para a variável linguística, na verdade estamos, a priori, considerando a existência de um valor fuzzy de equilíbrio para o sistema real. É como dizer que, com poucas informações como as que temos “as presas favorecem os predadores e são desfavorecidas por estes”, ou seja, *o equilíbrio está sempre em torno da média*.

O leitor interessado em um estudo mais detalhado sobre os sistemas p-fuzzy bidimensionais discretos pode consultar [36, 117].

9.2 Fuzziness Demográfica: modelagem contínua

Como já dissemos na introdução desse capítulo, existem várias abordagens para sistemas dinâmicos fuzzy contínuos (ver Capítulo 8). Aqui reafirmamos nosso interesse naquela do tipo p-fuzzy.

Tais sistemas desempenham papel importante quando deseja-se modelar algum sistema dinâmico contínuo onde o campo de direções é apenas conhecido parcialmente, como discutido na Seção 6.4 do Capítulo 6. Lá comentamos que tais sistemas são bons aproximadores de sistemas teóricos. A exemplo do que fizemos para o caso discreto, aqui não estamos interessados nessa propriedade e, por isso, omitiremos o índice “ r ” do campo f_r que o diferencia do campo teórico. Aqui o modelo matemático para o fenômeno em questão é dado pelo PVI

$$\begin{cases} \frac{dx}{dt} = f(x) \\ x(t_0) = x_0 \end{cases}, \quad (9.4)$$

onde o campo f de direções é dado por um controlador fuzzy.

Os comentários a seguir são feitos no sentido de ressaltar as diferenças entre os sistemas p-fuzzy contínuos e discretos, já que em ambos os casos o que se usa essencialmente são as saídas de um controlador fuzzy.

9.2.1 Características de um sistema p-fuzzy contínuo

Antes de tudo, lembramos que estamos estudando sistemas autônomos (os campos de direções não dependem explicitamente do tempo). Isso significa que as regras co-relacionam as entradas, que são as variáveis de estado, com as variações (para o caso discreto) e/ou taxas de variações (para o caso contínuo) que são as variáveis de saída. Formalmente, a base de regras de um sistema p-fuzzy contínuo é semelhante a de um discreto. A diferença se dá fundamentalmente na formulação de cada regra.

Nos sistemas discretos, as variações são qualificadas em termos absolutos, isto é, as qualificações são formuladas para os intervalos de tempo em que ocorrem as sucessões de gerações (mudanças sucessivas nas entradas).

Para o caso contínuo, as gerações se sobrepõem e as taxas de variações devem ter propriedades qualitativas condizentes com o conceito de derivada. Portanto, as qualificações para as saídas devem ser compatíveis com o conceito de variação por unidade de tempo. Tal unidade nada tem a ver com sucessões de gerações, simplesmente porque essa não está definida aqui. Como dissemos, num modelo contínuo as gerações se sobrepõem.

A metodologia de controladores fuzzy que utilizaremos aqui é novamente a de Mamdani com defuzzificação dada pelo centro de massa. Também, como já frisamos antes, usaremos base de regras bem ordenadas (Definição 9.1). Assim sendo, dependendo das regras, o campo f (que é a saída do controlador) pode ter propriedades que garantam a existência e unicidade de solução para o PVI (9.4). Por exemplo, com as hipóteses do Teorema 9.3, a função f é contínua ou derivável. Se f for conhecida explicitamente, através de métodos tradicionais, pode-se chegar à solução analítica do PVI (9.4). Porém, dependendo da complexidade de f , o que se faz é apelar para métodos numéricos a fim de obter estimativas para a solução do PVI em questão. Esse é nosso interesse aqui pois, pela metodologia dos controladores fuzzy, em geral f é implicitamente conhecida, sendo possível calcular as imagens de todo ponto de seu domínio.

9.2.2 Métodos numéricos para soluções do PVI p-fuzzy contínuo

As estimativas x_n serão obtidas por meio de métodos numéricos para soluções de Equações Diferenciais Ordinárias (E.D.O) como, por exemplo, o de Euler e os de Runge-Kutta, ou por meio de métodos numéricos

de integração (ver [41, 110]).

(a) Método de Euler para E.D.O.

Este método gera as estimativas x_n da seguinte forma:

$$x_{n+1} = x_n + hf(t_n, x_n),$$

onde h é o passo e f é a aplicação produzida pelo controlador fuzzy.

(b) Métodos de Runge-Kutta de segunda ordem para E.D.O.

O método de Runge-Kutta de segunda ordem que adotamos aqui, também conhecido como método de Euler Aperfeiçoado, gera as estimativas

$$x_{n+1} = x_n + \frac{h}{2}[f(t_n, x_n) + f(t_n + h, x_n + hf(t_n, x_n))].$$

Claro que o leitor pode usar qualquer outro método de ordem superior em seu estudo.

(c) Métodos de Integração Numérica

As estimativas x_n podem também ser obtidas por meio de algum método de integração numérica, transformando o PVI (9.4) em um PVI em que a E.D.O. é traduzida na forma de integral, como a regra dos trapézios ou a regra de Simpson. Um estudo com essa formulação o leitor pode encontrar em [101].

Aplicação

A seguir vamos ilustrar a metodologia aqui proposta nos modelos de crescimento populacional com inibição, como o de Verhulst.

O modelo tradicional de Verhulst para crescimento populacional é regido pelo *PVI*

$$\begin{cases} \frac{1}{x} \frac{dx}{dt} = a(K - x) \\ x(t_0) = x_0 \end{cases}, \quad (9.5)$$

onde a é a razão de crescimento intrínseca e K é a capacidade suporte.

As soluções clássicas de (9.5), que representam as populações $x(t)$ em cada instante t , são dadas por

$$x(t) = \frac{K}{\left(\frac{K}{x_0} - 1\right)e^{-at} + 1}. \quad (9.6)$$

Logo,

$$\begin{cases} x \text{ é crescente se } x_0 < K \\ x \text{ é constante se } x_0 = K \\ x \text{ é decrescente se } x_0 > K \end{cases},$$

e tem a forma representada na Figura 9.11.




Figura 9.11: Trajetórias do modelo de Verhulst com $K = 200$ e $x_0 = 25$, 200 e 270.

Lembremos que no exemplo que estamos analisando, a função que modela o campo de direções é dada explicitamente por

$$g(x) = \frac{dx}{dt} = ax(K - x). \quad (9.7)$$

Entretando, para adotar a nossa metodologia não precisamos conhecer explicitamente tal expressão. Aqui ela é apresentada apenas com a finalidade de comparar as propriedades qualitativas das trajetórias clássicas com as produzidas pelo sistema p-fuzzy contínuo.

A seguir vamos obter estimativas para as trajetórias logísticas a partir

da metodologia descrita no início desta seção para E.D.O.

Para traçarmos um paralelo nas formulações das regras com o modelo clássico, re-escreveremos (9.7) como

$$\frac{1}{x} \frac{dx}{dt} = a(K - x) = f(x), \quad (9.8)$$

em que f é linear.

Note que a equação (9.8) está escrita em função da taxa de crescimento específico. Esta formulação facilita a elaboração das regras do sistema p-fuzzy. A “construção” das regras a partir da variação percentual por unidade de tempo pode, em alguns casos, parece ser mais intuitiva que a formulação a partir das variações absolutas. Por esse motivo não usaremos a base de regras do Quadro 9.1.

Apenas para efeito de notação, denotaremos X para a população (entrada) e $\frac{1}{X} \frac{dX}{dt}$ (saída) para a taxa de crescimento relativa por unidade de tempo (ou taxa de crescimento específico).

Base de Regras

R_1 : Se (X) é “muito baixa” (A_1) então a $\frac{1}{X} \frac{dX}{dt}$ é “alta positiva” (B_1)
R_2 : Se (X) é “baixa” (A_2) então a $\frac{1}{X} \frac{dX}{dt}$ é “alta positiva” $(B_2 = B_1)$
R_3 : Se (X) é “média” (A_3) então a $\frac{1}{X} \frac{dX}{dt}$ é “média positiva” (B_3)
R_4 : Se (X) é “média alta” (A_4) então a $\frac{1}{X} \frac{dX}{dt}$ é “média positiva” $(B_4 = B_3)$
R_5 : Se (X) é “alta” (A_5) então a $\frac{1}{X} \frac{dX}{dt}$ é “baixa positiva” (B_5)
R_6 : Se (X) é “altíssima” (A_6) então a $\frac{1}{X} \frac{dX}{dt}$ é “baixa negativa” (B_6)

Quadro 9.3: Regras para o modelo fuzzy contínuo.

Nesta base de regras, os números fuzzy A_i e B_i são os mesmos da base de regras do Quadro 9.1, exceto os suportes de B_i , que devem estar entre -1 e 1 , por razões evidentes.

Assim, utilizando regras do Quadro 9.3, obtemos valores para f e com um dos métodos numéricos anteriores (ver 9.2.2), calculamos as

estimativas para o modelo de Verhulst.

Para efeito de ilustração optamos pelo método numérico de Euler (para a função $xf(x)$, já que a taxa para as regras do Quadro 9.3 é a específica) e chegamos nas estimativas x_n :

$$x_{n+1} = x_n + hx_nf(x_n),$$

cuja representação gráfica pode ser vista na Figura 9.12.




Figura 9.12: Trajetória do modelo p-fuzzy contínuo com $x_0 = 5$ referente ao Quadro 9.3.

As regras do Quadro 9.3 estão de acordo com as principais características de um modelo geral de população com crescimento inibido que seja regulado por uma capacidade suporte. O modelo de Verhulst, estudado por nós acima, é um caso particular. Além desse, com pequenas modificações, a mesma base de regras poderia servir para os modelos inibidos de Gompertz, de Montroll, de von Bertalanffy, etc (ver [22]).

A seguir vamos fazer um breve estudo do modelo geral de Montroll e, supondo que a base de regras (Quadro 9.3) corresponda ao modelo de Verhulst, ilustrar uma maneira de “ajustar” tais regras a fim de levar em conta as particularidades do modelo de Montroll.

9.2.3 Estudo do modelo p-fuzzy de Montroll

A maioria dos modelos autônomos contínuos de crescimento populacionais, formalizados a partir de equações diferenciais, têm a forma

$$\frac{dx}{dt} = x f(x).$$

A função f é denominada crescimento específico da população. Abaixo apresentamos algumas delas que são bastante usadas na literatura.

Modelo de Verhulst

f é linear e dada por

$$f(x) = a(K - x).$$

Modelo de Montroll

$$f(x) = a \left(1 - \left(\frac{x}{K} \right)^s \right), \text{ com } s > 0.$$

Modelo de Gompertz

$$f(x) = -a \ln \frac{x}{K}, x > 0.$$

A Figura 9.13 abaixo ilustra uma base de regras na forma granular e possibilidades para diversos crescimentos específicos (f) com inibição.




Figura 9.13: Grânulos e possibilidades de campos de diversos modelos de crescimento inibido; $\Delta x = \frac{1}{x} \frac{dx}{dt}$.

Embora os modelos comentados acima tenham uma forma geral para suas bases de regras, cada um deles tem sua particularidade. Aqui estamos interessado apenas no “ajuste” da base de regras do Quadro 9.3 para o modelo de Montroll.

Dependendo do parâmetro s no modelo de Montroll tem-se crescimento específico maior ou menor que o modelo de Verhulst (ver Figura 9.13).

- Se $s > 1$, o crescimento específico do modelo de Montroll é maior que o de Verhulst até a capacidade suporte. Depois desse valor, o modelo de Montroll cresce menos.
- Se $0 < s < 1$, tem-se inversão nos crescimento em relação ao parâmetro $s > 1$.

Essas particularidades sugerem as modificações que devem ser feitas na base de regras (Quadro 9.3), supondo que esta represente o de Verhulst, para chegarmos numa outra coerente com o modelo de Montroll.

Exemplo 9.2. A seguir faremos modificações no sentido de incorporar as particularidades do modelo de Montroll, supondo $0 < s < 1$:

Base de regras para o modelo de Montroll com $0 < s < 1$

R_1 : Se (X) é “muito baixa ” (A_1) então a $\frac{1}{X} \frac{dX}{dt}$ é “pouco alta positiva” (pB_1)
R_2 : Se (X) é “baixa” (A_2) então a $\frac{1}{X} \frac{dX}{dt}$ é “alta positiva” ($pB_2 = pB_1$)
R_3 : Se (X) é “média” (A_3) então a $\frac{1}{X} \frac{dX}{dt}$ é “média positiva” (pB_3)
R_4 : Se (X) é “média alta” (A_4) então a $\frac{1}{X} \frac{dX}{dt}$ é “média positiva” ($pB_4 = pB_3$)
R_5 : Se (X) é “alta” (A_5) então a $\frac{1}{X} \frac{dX}{dt}$ é “baixa positiva” (mB_5)
R_6 : Se (X) é “altíssima” (A_6) então a $\frac{1}{X} \frac{dX}{dt}$ é “baixa negativa” (mB_6)

Quadro 9.4: Regras para o modelo fuzzy de Montroll contínuo.

Os antecedentes das regras do Quadro 9.4 são os mesmos que os das regras do Quadro 9.3. Para modelar as modificações especificadas nas regras da Quadro 9.4, vamos utilizar o conceito de modificador fuzzy visto na Seção 4.5 do Capítulo 4.

Para o caso específico que estamos tratando acima, vamos utilizar os modificadores do tipo potência, em que a potência é um parâmetro $0 < \gamma < 1$ ou seu inverso $\frac{1}{\gamma}$. Vamos aplicar os seguintes modificadores nos consequentes das regras do Quadro 9.3 para obter os das regras do Quadro 9.4,

$$\left\{ \begin{array}{l} pB_i = (B_i)^\gamma \iff \varphi_{pB_i}(x) = (\varphi_{B_i}(x))^\gamma, \quad i = 1, 2. \\ pB_i = \begin{cases} (B_i^-)^\gamma \iff \varphi_{pB_i^-}(x) = (\varphi_{B_i^-}(x))^\gamma \\ (B_i^+)^\frac{1}{\gamma} \iff \varphi_{pB_i^+}(x) = (\varphi_{B_i^+}(x))^\frac{1}{\gamma} \end{cases}, \quad i = 3, 4. \\ mB_i = (B_i)^\frac{1}{\gamma} \iff \varphi_{mB_i}(x) = (\varphi_{B_i}(x))^\frac{1}{\gamma}, \quad i = 5, 6. \end{array} \right.$$

onde B_i^- e B_i^+ são respectivamente o lado esquerdo e direito do conjunto fuzzy B_i .

A Figura 9.14 ilustra os consequentes das regras do Quadro 9.3 e do Quadro 9.4.




Figura 9.14: Consequentes das regras do Quadro 9.3 e suas respectivas modificações por potência.

Com essa nova base de regras obtemos uma trajetória para o modelo

p-fuzzy de Montroll que pode ser visualizada na Figura 9.15.




Figura 9.15: Trajetória dos modelos p-fuzzy contínuos para as regras do Quadro 9.3 e regras modificadas ($\gamma = 0,05$) conforme Quadro 9.4.

Exercício 9.2. Refaça o exemplo acima supondo o parâmetro $s > 1$.

Encerraremos esta seção fazendo comentários sobre estimativa de parâmetros a partir do modelo p-fuzzy. Por exemplo, como fizemos no modelo de Verhulst, o equilíbrio no modelo p-fuzzy de Montroll pertence ao intervalo

$$I^* = \text{supp}(A_5) \cap \text{supp}(A_6) = [200, 210],$$

já que há oposição semântica nos consequentes mB_5 e mB_6 . Esse valor será a capacidade suporte (K) do modelo teórico de Montroll em que o campo de direções é dado por $f(x) = a(1 - (\frac{x}{K})^s)$. Como os antecedentes A_5 e A_6 são os mesmos do Exemplo 9.1, o equilíbrio é a solução da equação

$$\varphi_{A_5}(x) = \varphi_{A_6}(x) \implies \bar{x} = 205.$$

Portanto, a capacidade suporte K deve ser igual a 205. O parâmetro a é obtido a partir de um ajuste do tipo quadrados mínimos. Claro que

tanto a como K podem ser obtidos por ajustes, do campo ou da solução clássica do modelo.

Um estudo a respeito de obtenção de parâmetros para modelos p-fuzzy contínuos o leitor pode encontrar em [47]. A estabilidade de tais sistemas são obtidas a partir de resultados semelhantes aos que fizemos para os p-fuzzy discretos.

A sugestão acima, para nos aproximarmos do modelo de Montroll a partir do de Verhulst, não é a única. É apenas uma dentre tantas outras possibilidades, como por exemplo, transladar os consequentes da base de regras ou aplicar o princípio de extensão na função $f(x) = 1 - x^s$.

A seção seguinte encerra esse capítulo e trata dos sistemas p-fuzzy contínuos para modelos bidimensionais.

9.2.4 Modelos Bidimensionais: modelo presa-predador p-fuzzy de Lotka-Volterra

Vamos rapidamente relembrar o modelo clássico de Lotka-Volterra para, em seguida, formular o modelo p-fuzzy correspondente. Queremos salientar que a formulação dada por nós para o modelo p-fuzzy Lotka-Volterra não utiliza as hipóteses dadas por Volterra para o seu modelo clássico. Este é colocado aqui apenas com o intuito de compararmos ambas abordagens: clássica e p-fuzzy.

Modelo presa-predador de Lotka-Volterra

Por volta de 1925, Lotka e Volterra desenvolveram um dos modelos matemáticos de mais largo uso e de destacada importância para representar interações entre presas e seus predadores. Tal modelo é conhecido como Modelo Presa-Predador de Lotka-Volterra.

O modelo criado por Volterra foi bem aceito por explicar as alterações observadas nas populações de pescadas e tubarões no Mar Adriático, por ocasião da paralisação das atividades pesqueiras devido à I Guerra

Mundial e posterior retomada, quando do término da guerra.

O modelo presa-predador clássico de Lotka-Volterra pressupõe que:

1. Tanto as presas como os predadores estão distribuídos uniformemente num mesmo habitat, ou seja, todos os predadores têm a mesma chance de encontrar cada presa;
2. O encontro entre os elementos das duas espécies seja ao acaso, a uma taxa proporcional ao tamanho das duas populações, já que quanto maior o número de presas, mais fácil será encontrá-las e quanto mais predadores, maior o número de ataques;
3. A população de presas cresce exponencialmente na ausência de predadores (crescimento ilimitado por escassez de predadores);
4. A população de predadores decresce exponencialmente na ausência de presas (decrécimo por escassez de alimento);
5. A população de predadores é favorecida pela abundância de presas;
6. A população de presas é desfavorecida pelo aumento de predadores.

Estas seis hipóteses (ver [24, 55]) são resumidas nas equações abaixo, denominadas Modelo de Lotka-Volterra:

$$\begin{cases} \frac{dx}{dt} = ax - \alpha xy \\ \frac{dy}{dt} = -by + \beta xy \end{cases} . \quad (9.9)$$

As variáveis de estado x e y são, respectivamente, quantidade de presas e quantidade de predadores em cada instante t .

Os parâmetros representam:

- a : taxa de crescimento da população de presas na ausência de predadores;

- $\frac{\alpha}{\beta}$: a eficiência de predação, isto é, a eficiência de conversão de uma unidade de massa de presas em uma unidade de massa de predadores, já que α representa a proporção de sucesso dos ataques dos predadores e β a taxa de conversão de biomassa das presas em predadores;
- b : taxa de mortalidade de predadores na ausência de presas;

Os pontos críticos do sistema (9.9) são: $(0,0)$, um ponto de sela instável, e $\left(\frac{b}{\beta}, \frac{\alpha}{\alpha}\right)$ que é um centro estável (ver [24]).

O caráter cíclico das soluções explica as flutuações observadas experimentalmente em população de presas e predadores.




Figura 9.16: Plano de fase do modelo de Lotka-Volterra (9.9).

Modelo presa-predador p-fuzzy

Na subseção anterior apresentamos as hipóteses de Lotka-Volterra que caracterizam um modelo presa-predador, cujos contingentes populacionais oscilam com o tempo. Isso vem ao encontro de observações empíricas nestes ecossistemas [50, 91, 55]. Os resultados, coerentes com o fenômeno

estudado, fizeram com que o modelo de Lotka-Volterra, embora teórico, tenha se tornado um paradigma para os modelos do tipo presa-predador.

Na subseção 9.1.3 procuramos modelar a principal característica de um sistema presa-predador: as presas favorecem o crescimento dos predadores e são desfavorecidas por eles. Como consequência, o plano de fase apresenta trajetórias que oscilam. Aqui queremos ir além disso. Pretendemos reproduzir, por meio de um sistema p-fuzzy bidimensional contínuo, um plano de fase semelhante ao do modelo contínuo de Lotka-Volterra, em que as trajetórias são ciclos (ver Figura 9.16). Para isto é necessário re-interpretarmos as seis hipóteses comentadas acima:

- “1” dentro de cada espécie, o ambiente não privilegia nenhum indivíduo. Portanto é natural que as variáveis de estado sejam apenas quantidades;
- “2” há interação entre as espécies;
- “3” não há auto-inibição nas presas, isto é, para um dado número de predadores, o crescimento específico das presas é constante, podendo ser positivo ou negativo;
- “4” como em “3”, para um dado número de presas, o crescimento específico dos predadores seja constante, podendo ser positivo ou negativo;
- “5” o crescimento específico dos predadores aumenta com o número de presas;
- “6” o crescimento específico das presas diminui com o aumento dos predadores.

Resumidamente, as hipóteses de “3” a “6” indicam que, a interação é típica de presa-predador e que, mantendo-se uma espécie constante, a outra tem crescimento (decrecimento) malthusiano, isto é, tem crescimento específico constante.

Note que se as regras do modelo p-fuzzy malthusiano (Quadro 8.1) tivessem sido enunciadas em termos de crescimento específico, este deveria ter sido classificado com o mesmo adjetivo, isto é, o conseqüente seria o mesmo para todas as regras.

Considerando as observações acima, temos como objetivo elaborar uma base de regras fuzzy que “substitua” as Equações (9.9), para modelar a dinâmica entre as presas e os predadores, por meio de um modelo p-fuzzy contínuo de Lotka-Volterra.

Como no caso unidimensional, temos as variáveis linguísticas de entrada: quantidade de presas (X) e quantidade de predadores (Y), e duas variáveis de saída: variação relativa da quantidade de presas por unidade de tempo, denotada por $\frac{1}{X} \frac{dX}{dt}$, que é o crescimento específico das presas; e variação relativa da quantidade de predadores por unidade de tempo, denotada por $\frac{1}{Y} \frac{dY}{dt}$ – crescimento específico dos predadores. A Figura 9.17 representa um esquema do modelo.




Figura 9.17: Sistema baseado em Regras Fuzzy para (9.9).

Os valores assumidos pela variável X são: *baixa* (A_1), *média baixa* (A_2), *média alta* (A_3) e *alta* (A_4) e pela variável Y são *baixa* (B_1), *média baixa* (B_2), *média alta* (B_3) e *alta* (B_4).

Ambos os crescimentos específicos, $\frac{1}{X} \frac{dX}{dt}$ e $\frac{1}{Y} \frac{dY}{dt}$, assumirão os valores *alto positivo* (P_2), *baixo positivo* (P_1), *baixo negativo* (N_1) e *alto nega-*

tivo (N_2). No esquema acima (Figura 9.17), a base de conhecimentos é traduzida por um conjunto de regras fuzzy que desempenham o papel do campo de direções.

A partir das seis reinterpretações para as hipótese de Lotka-Volterra feitas acima, principalmente a observação após a “6”, propomos a base de regras fuzzy do Quadro 9.5.

Podemos representar graficamente a base de regras considerando que não deve haver variação nos crescimentos específicos, quanto às magnitudes e sentidos, de cada espécie quando mantemos a quantidade da outra constante (crescimento malthusiano para cada espécie, dada a outra espécie). Por exemplo, para uma quantidade fixa de predadores, a variação específica de presas deve ser constante (ver setas horizontais na Figura 9.18). Claro que outra base de regras poderia ser adotada, já que, as magnitudes envolvidas, tanto para as variáveis como para os crescimentos específicos, são incertas.

A Figura 9.18 ilustra a base de regras que está no Quadro 9.5. As setas horizontais representam as magnitudes e sentidos de $\frac{1}{X} \frac{dX}{dt}$ e as verticais representam $\frac{1}{Y} \frac{dY}{dt}$.




Figura 9.18: Representação gráfica das regras do Quadro 9.5 na forma de vetores de direções.

Nós apresentamos a Figura 9.18 para traçarmos um paralelo com a

Se X é A_1 e Y é B_1 então $\frac{1}{X} \frac{dX}{dt}$ é P_2 e $\frac{1}{Y} \frac{dY}{dt}$ é N_2
Se X é A_2 e Y é B_1 então $\frac{1}{X} \frac{dX}{dt}$ é P_2 e $\frac{1}{Y} \frac{dY}{dt}$ é N_1
Se X é A_3 e Y é B_1 então $\frac{1}{X} \frac{dX}{dt}$ é P_2 e $\frac{1}{Y} \frac{dY}{dt}$ é P_1
Se X é A_4 e Y é B_1 então $\frac{1}{X} \frac{dX}{dt}$ é P_2 e $\frac{1}{Y} \frac{dY}{dt}$ é P_2
Se X é A_1 e Y é B_2 então $\frac{1}{X} \frac{dX}{dt}$ é P_1 e $\frac{1}{Y} \frac{dY}{dt}$ é N_2
Se X é A_2 e Y é B_2 então $\frac{1}{X} \frac{dX}{dt}$ é P_1 e $\frac{1}{Y} \frac{dY}{dt}$ é N_1
Se X é A_3 e Y é B_2 então $\frac{1}{X} \frac{dX}{dt}$ é P_1 e $\frac{1}{Y} \frac{dY}{dt}$ é P_1
Se X é A_4 e Y é B_2 então $\frac{1}{X} \frac{dX}{dt}$ é P_1 e $\frac{1}{Y} \frac{dY}{dt}$ é P_2
Se X é A_1 e Y é B_3 então $\frac{1}{X} \frac{dX}{dt}$ é N_1 e $\frac{1}{Y} \frac{dY}{dt}$ é N_2
Se X é A_2 e Y é B_3 então $\frac{1}{X} \frac{dX}{dt}$ é N_1 e $\frac{1}{Y} \frac{dY}{dt}$ é N_1
Se X é A_3 e Y é B_3 então $\frac{1}{X} \frac{dX}{dt}$ é N_1 e $\frac{1}{Y} \frac{dY}{dt}$ é P_1
Se X é A_4 e Y é B_3 então $\frac{1}{X} \frac{dX}{dt}$ é N_1 e $\frac{1}{Y} \frac{dY}{dt}$ é P_2
Se X é A_1 e Y é B_4 então $\frac{1}{X} \frac{dX}{dt}$ é N_2 e $\frac{1}{Y} \frac{dY}{dt}$ é N_2
Se X é A_2 e Y é B_4 então $\frac{1}{X} \frac{dX}{dt}$ é N_2 e $\frac{1}{Y} \frac{dY}{dt}$ é N_1
Se X é A_3 e Y é B_4 então $\frac{1}{X} \frac{dX}{dt}$ é N_2 e $\frac{1}{Y} \frac{dY}{dt}$ é P_1
Se X é A_4 e Y é B_4 então $\frac{1}{X} \frac{dX}{dt}$ é N_2 e $\frac{1}{Y} \frac{dY}{dt}$ é P_2

Quadro 9.5: Regras fuzzy para o modelo presa-predador.

representação do campo de direções de equações diferenciais clássicas. Apenas em título de curiosidade e para nos convenceremos mais sobre o poder da metodologia p-fuzzy, a base de regras de fato “gera” um campo clássico de direções para uma E.D.O. A Figura 9.19 abaixo ilustra o campo produzido pela base de regras do Quadro 9.5.




Figura 9.19: Representação gráfica do campo de direções gerados pelas regras do Quadro 9.5.

Voltando ao nosso exemplo, a Figura 9.18 é bastante útil no estudo da dinâmica do sistema. Por exemplo, através dela é possível localizar a região do plano que contém os possíveis equilíbrios (não nulos) do sistema. No nosso caso essa região é

$$E = [\text{supp}(A_2) \cap \text{supp}(A_3)] \times [\text{supp}(B_2) \cap \text{supp}(B_3)] = I_x \times I_y.$$

Observamos que as oposições semânticas ocorrem nessa região. É possível também sugerir que as intersecções de φ_{A_2} com φ_{A_3} e φ_{B_2} com φ_{B_3} formam as coordenadas de um forte candidato a equilíbrio desse sistema. Isso está em acordo com a Proposição 9.1. Recentemente, Cecconello [36] desenvolveu um procedimento numérico para buscar tais coordenadas. Com tais valores em mãos, poderíamos adotá-los para o equilíbrio de um sistema clássico de Lotka-Volterra (9.9) e, juntamente com ajustes, obter os valores dos parâmetros a , b , α e β desse sistema.

Entretanto, não estudaremos aqui métodos para obtenção de parâmetros de modelos clássicos a partir dos p-fuzzy. O leitor interessado nesse assunto poderá consultar alguns trabalhos feitos recentemente com sistemas p-fuzzy [36, 47, 101, 117].

Nosso interesse aqui é ilustrar o método proposto, no intuito de produzir uma trajetória que represente a evolução do sistema p-fuzzy.

As Figuras 9.20 e 9.21 representam as funções de pertinência de cada um dos valores fuzzy adotados em nosso exemplo.




Figura 9.20: Funções de pertinência dos antecedentes.




Figura 9.21: Funções de pertinência dos consequentes.

Utilizando o Método de Inferência de Mamdani e a defuzzificação do

Centro de Gravidade obtemos os valores $\frac{1}{x} \frac{dx}{dt}$ e $\frac{1}{y} \frac{dy}{dt}$.

Em cada instante t , o número de presas e de predadores é dado pelas fórmulas

$$\begin{cases} x(t) = x(t_0) + \int_{t_0}^t \frac{dx}{dt}(s) ds \\ y(t) = y(t_0) + \int_{t_0}^t \frac{dy}{dt}(s) ds \end{cases} . \quad (9.10)$$

Como as saídas são $\frac{1}{x} \frac{dx}{dt}$ e $\frac{1}{y} \frac{dy}{dt}$, devemos multiplicá-las pelas entradas x e y , respectivamente, para obter $\frac{dx}{dt}$ e $\frac{dy}{dt}$. Porém, as expressões analíticas de cada uma dessas derivadas não são conhecidas.

Para estimar as trajetórias dadas por (9.10), aproximamos $\frac{dx}{dt}(s)$ por $\frac{dx}{dt}(t_{i-1})$ em cada intervalo $[t_{i-1}, t_i]$, de modo que a integral $\int_{t_{i-1}}^{t_i} \frac{dx}{dt}(s) ds$ é aproximada por $(t_i - t_{i-1}) \frac{dx}{dt}(t_{i-1})$.

Assim, os valores de $x(t)$ e $y(t)$ são estimados pelas fórmulas

$$\begin{cases} x(t_i) = x(t_{i-1}) + h x'_{i-1} \\ y(t_i) = y(t_{i-1}) + h y'_{i-1} \end{cases} , \quad (9.11)$$

onde $t_i = t_0 + ih$ enquanto x' e y' são as saídas do controlador correspondentes às entradas $x_{i-1} \approx x(t_{i-1})$ e $y_{i-1} \approx y(t_{i-1})$, respectivamente.

Resultados

As simulações das trajetórias produzidas pelo sistema p-fuzzy acima seguem os passos:

- Para começar o processo, adotamos os valores $x_0 = 100$, $y_0 = 3$, $h = 0,1$ e $t_0 = 0$.
- Dados iniciais para o controlador fuzzy: a população de presas x_0 e a de predadores y_0 ;




Figura 9.22: (a) Evolução dos contingentes populacionais ao longo do tempo; (b) Plano de fase do sistema p-fuzzy para $x_0 = 100$ e $y_0 = 3$.

- As saídas fornecidas pelo controlador fuzzy, multiplicadas pelas entradas, fornecem os valores: x'_0 e y'_0 ;
- Por (9.11), encontramos x_1 e y_1 ;
- x_1 e y_1 são os novos valores de entrada do controlador e assim sucessivamente;

Usando as Equações (9.11), obtemos o plano de fase e as trajetórias ilustradas na Figura ??.

Com os dados iniciais adotados acima e o sistema p-fuzzy dado pelas regras do Quadro 9.5, combinadas com o sistema (9.11), é possível concluir que o ponto de equilíbrio é $P_e = (77, 5; 3, 5)$.

Claro que outros métodos numéricos, como os de Runge-Kutta, podem ser adotados para estimar $x(t)$ e $y(t)$ (ver [47]).

Como já comentamos antes, se estivéssemos interessados em encontrar os parâmetros de um modelo de Lotka-Volterra clássico para produzir as trajetórias representadas na Figura 9.16, poderíamos comparar as coordenadas de P_e com as do equilíbrio teórico, $P = \left(\frac{b}{\beta}, \frac{a}{\alpha}\right)$, para obter relações entre a, b, α e β . Daí, usar ajustes para, finalmente encontrar cada um desses parâmetros.

Os primeiros trabalhos que se utilizaram dos sistemas p-fuzzy contínuos para modelar interação entre espécies o leitor pode encontrar em [101]. Lá a autora usa tal metodologia para modelar a relação entre pulgões e joaninhas no controle biológico de uma doença chamada Morte Súbita dos Citros. O pulgão, supostamente hospedeiro do vírus causador da morte súbita, é a presa e a Joaninha, que se alimenta do pulgão, é o predador. Neste sistema presa-predador o modelo p-fuzzy pressupõe inibição em ambas populações. Portanto as regras devem levar isso em conta, de maneira que as trajetórias deixam de apresentar um caráter cíclico para apresentar ciclos limites. Tal modelo p-fuzzy apresenta propriedades qualitativas coincidentes com as do modelo clássico de Holling–Tanner. A partir daí, um estudo a respeito da estabilidade e ajustes de parâmetros desse modelo é feito.

Um aspecto importante dos sistemas p-fuzzy explorado pela autora é a facilidade em lidar com possíveis heterogeneidades nas populações. Por exemplo, para o caso específico da morte súbita, os predadores apresentam vários níveis de predação, dependendo de seu estágio: larval e adulto. Neste caso, a autora optou, para variáveis de estado, pelo número de pulgões e pontencial de predação, que leva em conta não só o número de predadores, mas também a qualidade dos mesmos.

Capítulo 10

Modelagem em Biomatemática: Fuzziness ambiental

“Quando as leis da matemática se referem à realidade, elas não são certas. E se são certas, não são referentes à realidade.”

(Albert Einstein)

Como já comentamos no Capítulo 9, as maneiras de se incorporar incertezas em modelos matemáticos são bastante variadas. Didaticamente, procuramos separar os casos em que as variáveis que modelam o sistema são incertas – fuzziness demográfica – daqueles em que algum parâmetro de uma equação clássica é incerto – fuzziness ambiental. As terminologias acima adotadas têm origem em dinâmica de população. Nós adotamos o termo fuzziness demográfica em analogia à estocasticidade demográfica que trata de estudar, por exemplo, o número de descendentes dos indivíduos de uma população (ver Turelli [124]). Claramente, o número de descendentes é totalmente incerto. Indivíduos aparentemente idênticos, sob algum aspecto, gêmeos, por exemplo, podem ter números de descendentes totalmente diferentes.

Já a estocasticidade ambiental pressupõe incerteza na previsão do número de indivíduos de uma população devido à perturbações no ambiente. Neste caso o ambiente atua na população como um todo. Exemplos

desta natureza são abundantes na realidade: quando o custo de vida em uma localidade influencia a esperança de vida do grupo; quando num modelo presa-predador o ambiente é favorável à presa ou ao predador; quando em um modelo de competição algum dos competidores é favorecido pelo ambiente etc. Via de regra, a fuzziness ambiental é incorporada aos parâmetros do modelo matemático do fenômeno. Este é o caso das aplicações que estudaremos neste capítulo. Na primeira delas consideramos a pobreza como um fator que supostamente influencia a esperança de vida de um grupo. Tal modelo pode ser encontrado com mais detalhes em [11, 23].

Do ponto de vista matemático, estes modelos podem ser tratados pelos métodos clássicos, sem a necessidade de novos conceitos matemáticos para modelar a evolução da incerteza. Por exemplo, se o fenômeno for modelado por meio de equações diferenciais, o conceito de taxa de variação (ou derivada) é o mesmo dos modelos determinísticos, e a equação diferencial pode ser entendida como uma família de equações diferenciais clássicas, dependentes de parâmetros (na teoria de equações diferenciais estocásticas, estas equações são denominadas *equações aleatórias* (veja [6]).

Na maioria dos fenômenos estão presentes os dois tipos de incertezas e, neste caso, a modelagem não diferencia muito das abordadas neste livro. Porém, dependendo do interesse em questão, mesmo a fuzziness demográfica pode ser tratada com a metodologia da fuzziness ambiental. Para isto deve-se passar toda a incerteza das variáveis de estado para os parâmetros do modelo matemático, desde que tal procedimento faça sentido (veja 10.2).

10.1 Esperança de Vida $\times$ Pobreza

Para modelar a *pobreza*, poderíamos usar qualquer indicador, como por exemplo, consumo de calorias, de vitaminas, saneamento básico etc.

Aqui, usaremos a renda do grupo estudado [11, 23].

10.1.1 O Modelo

Suponha que A seja um grupo fechado com $n(t)$ indivíduos no instante t . Assumindo que a pobreza (aqui avaliada subjetivamente pelo nível de renda) seja um fator de redução no tempo de vida de cada elemento de A , podemos considerar que

$$\begin{cases} \frac{dn}{dt} = -[\lambda_1 + \beta(r)\lambda_2]n \\ n_0 = n(0) \end{cases}, \quad (10.1)$$

onde

λ_1 é a taxa de mortalidade natural (obtida em um grupo que dispõe de condições satisfatórias de sobrevivência);

$\beta(r)\lambda_2$ indica a influência da pobreza no aumento de λ_1 ;

$\beta(r)$ indica o grau com que um indivíduo com renda r pertence ao conjunto fuzzy dos pobres, ou seja, β é uma função de pertinência.

Note que a taxa máxima de mortalidade é $\lambda_1 + \lambda_2$, obtida quando $\beta(r) = 1$

A solução de (10.1) é

$$n(t) = n_0 e^{-[\lambda_1 + \beta(r)\lambda_2]t}.$$

A função de pertinência β pode ser representada por uma função decrescente com r e, aqui, achamos conveniente adotar a família de curvas (ver Exemplo 1.5)

$$\beta_k(r) = \begin{cases} [1 - (\frac{r}{r_0})^2]^k & \text{se } 0 < r < r_0 \\ 0 & \text{se } r \geq r_0 \end{cases}, \quad (10.2)$$

onde k é um parâmetro que fornece alguma característica do grupo.

Lembramos que quanto maior o valor de k , menor será a dependência do indivíduo em relação à renda. Assim, intuitivamente, k revela se o ambiente em que o grupo vive é mais ou menos favorável à vida.

Observamos que (10.1) é uma família de equações diferenciais ordinárias. Assim, $n(t)$ é uma família de soluções da equação diferencial indexada por r , ou seja, para cada r fixo, $n(t)$ é uma solução da equação diferencial correspondente a este r . Este conjunto de soluções forma a solução do problema fuzzy (10.1). Deste modo, supondo que r tenha uma distribuição estocástica, $n(t)$ é uma variável aleatória para cada t fixo.

Se quisermos eleger uma única curva para representar a evolução do número de indivíduos no tempo, uma forte candidata é a que fornece o número médio de $n(t)$ para cada t . Esta curva média é obtida calculando-se a esperança, da mesma forma que se faz no caso estocástico.

Nosso objetivo a seguir é obter a expectativa de vida do grupo por meio das esperanças clássica e fuzzy, conforme os conceitos vistos no Capítulo 7.

10.1.2 Esperança Estocástica: $E[n(t)]$

A esperança estocástica é dada por

$$E[n(t)] = \int_{-\infty}^{\infty} n(t)h(r) dr, \quad (10.3)$$

onde $h(r)$ é a densidade de distribuição da renda.

Para o nosso caso específico, vamos usar a distribuição de Pareto, indicada para países em desenvolvimento (ver [31]) com parâmetros a e b :

$$h(r) = \begin{cases} ab^a r^{-(a+1)} & \text{se } r \geq b \\ 0 & \text{se } r < b \end{cases}.$$

Assim,




Figura 10.1: Densidade de distribuição da renda.

$$E[n(t)] = n(0)e^{-\lambda_1 t} ab^a \int_b^{\infty} e^{-\beta_k(r)\lambda_2 t} r^{-(a+1)} dr$$

ou

$$E\left[\frac{n(t)}{n(0)}\right] = e^{-\lambda_1 t} ab^a \int_b^{\infty} e^{-\beta_k(r)\lambda_2 t} r^{-(a+1)} dr. \quad (10.4)$$

- Se $r_0 \leq b$, então $\beta_k(r) = 0$ para $r \geq b$ e

$$E[n(t)] = n(0)e^{-\lambda_1 t} ab^a \int_b^{\infty} r^{-(a+1)} dr = n(0)e^{-\lambda_1 t}.$$

Isto significa que $E[\frac{n(t)}{n(0)}] = e^{-\lambda_1 t}$, para todo $a > 0$, ou seja, neste caso o valor de b é suficientemente grande para que não haja interferência da pobreza na esperança de vida do grupo.

- Se $r_0 > b$, temos que $ab^a \int_b^{\infty} e^{-\beta_k(r)\lambda_2 t} r^{-(a+1)} dr < 1$, de maneira que $E[n(t)] < n(0)e^{-\lambda_1 t}$. Assim, podemos interpretar o número

$$ab^a \int_b^{\infty} e^{-\beta_k(r)\lambda_2 t} r^{-(a+1)} dr$$

como um fator de redução na expectativa de vida devido à pobreza.

A seguir vamos calcular a esperança fuzzy a fim de compará-la com a esperança estocástica obtida acima.

10.1.3 Esperança Fuzzy: $EF \left[\frac{n(t)}{n(0)} \right]$

Consideramos $Y_t(r) = \frac{n(t)}{n_0}$ a função de pertinência de um conjunto fuzzy, já que $\frac{n(t)}{n_0} \in [0, 1]$. Vamos obter $EF \left[\frac{n(t)}{n(0)} \right]$ usando o Teorema 7.1, aplicado à função

$$\begin{aligned} H(\alpha) &= P\{r : Y_t(r) = \frac{n(t)}{n(0)} \geq \alpha\} = P\{r : e^{-(\lambda_1 + \lambda_2 \beta_k(r))t} \geq \alpha\} \\ &= P\{r : e^{-\lambda_2 \beta_k(r)t} \geq \alpha e^{\lambda_1 t}\}, \end{aligned} \quad (10.5)$$

onde P é a probabilidade definida pela função de densidade da renda $h(r)$.

Assim, $H(\alpha) = 0$ se $\alpha > e^{-\lambda_1 t}$.

Por outro lado, se $\alpha \leq e^{-\lambda_1 t}$,

$$H(\alpha) = P\{r : \alpha \leq e^{-(\lambda_1 + \lambda_2 \beta_k(r))t} < e^{-\lambda_1 t}\} + P\{r : r \geq r_0\}$$

que, com alguma manipulação algébrica, chegamos a


$$H(\alpha) = \begin{cases} 1 & \text{se } 0 \leq \alpha \leq e^{-(\lambda_1 + \lambda_2 \beta_k(b))t} \\ \left[\frac{b}{r_0 \sqrt{1 - \left(-\left(\frac{\ln \alpha}{\lambda_2 t} + \frac{\lambda_1}{\lambda_2}\right)\right)^{\frac{1}{k}}}} \right]^a & \text{se } e^{-(\lambda_1 + \lambda_2 \beta_k(b))t} < \alpha \leq e^{-\lambda_1 t} \\ 0 & \text{se } e^{-\lambda_1 t} < \alpha \leq 1 \end{cases} \quad (10.6)$$

É fácil ver que $H(\alpha)$ é contínua em $[0, 1]$, exceto quando $\alpha = e^{-\lambda_1 t}$, e que o ponto fixo de H está compreendido entre $Y_t(b)$ e $e^{-\lambda_1 t}$, isto é,

$$Y_t(b) = e^{-(\lambda_1 + \lambda_2 \beta_k(b))t} \leq EF \left[\frac{n(t)}{n(0)} \right] \leq e^{-\lambda_1 t}.$$

Algumas conclusões aqui são ligeiramente diferentes das obtidas no caso da esperança estocástica. Especificamente:

Se $\left(\frac{b}{r_0}\right)^a \geq e^{-\lambda_1 t}$, então $EF \left[\frac{n(t)}{n(0)} \right] = e^{-\lambda_1 t} = EF[e^{-\lambda_1 t}]$.

Figura 10.2: $H(\alpha)$ e esperança fuzzy (EF).

Em particular, temos que se $b \geq r_0$, então a pobreza não interfere na esperança de vida. Este foi o caso que obtivemos para a esperança clássica. No entanto, a esperança fuzzy indica mais: para que a pobreza não interfira na expectativa de vida, o que interessa é a relação $\left[\left(\frac{b}{r_0}\right)^a \geq e^{-\lambda_1 t}\right]$ entre a renda do indivíduo e a renda mínima do grupo. Por exemplo, um indivíduo pode ter renda relativamente pequena ($b < r_0$) e, ainda assim, esta não interferir em sua expectativa de vida. Para isto, basta que $\left(\frac{b}{r_0}\right)^a \geq e^{-\lambda_1 t}$. Este é o caso típico de alguém solteiro que tem toda a infra-estrutura para sobreviver.

Queremos ressaltar que, do ponto de vista técnico, é mais difícil obter $E(n(t))$, por não ter primitiva, do que $EF\left[\frac{n(t)}{n(0)}\right]$ cujo valor é o ponto fixo de H , e pode ser obtido via Teorema do Ponto Fixo de Banach (ver [20]).

Se $\left(\frac{b}{r_0}\right)^a < e^{-\lambda_1 t}$, podemos calcular o valor de $EF\left[\frac{n(t)}{n(0)}\right]$ determinando o ponto fixo de H , uma vez que esta função é contínua e decrescente para $\alpha < e^{-\lambda_1 t}$. Observamos que H tem os mesmos pontos fixos que sua inversa, isto é,

$$H^{-1}(\alpha) = \exp\left\{-\left[\lambda_1 + \lambda_2 \beta_k \left(\frac{b}{\alpha^{1/a}}\right)\right]\right\} t, \text{ se } \left(\frac{b}{r_0}\right)^a < \alpha < 1.$$

Este modelo foi usado para avaliar a esperança de vida de um grupo

de metalúrgicos de Recife onde tínhamos algumas informações sobre sua renda e o cálculo da esperança clássica o que nos permitiu comparar o modelo fuzzy com o estocástico.

10.1.4 Aplicação: Esperança de vida de um grupo de metalúrgicos de Recife

Faixa de salário mínimo	Distribuição populacional		% da folha de pagamento
	n^0	%	
até 2	4003	45,0	21,1
2 a 3	2099	23,6	18,8
até 3	6102	68,7	39,9
3 a 4	933	10,5	12,0
4 a 5	670	7,5	11,0
5 a 6	300	3,4	6,0
6 a 7	264	3,0	6,2
7 a 10	367	4,1	11,1
10 a 15	171	1,9	7,8
mais de 15	81	0,9	6,1

Tabela 10.1: Distribuição total dos trabalhadores, por faixas de salários mínimos. Recife, 1988 Fonte: DIEESE.

De acordo com os dados da tabela 10.1 podemos determinar o valor dos parâmetros a e b da variável renda, considerada numa distribuição de Pareto $h(r)$. Consideremos a função de distribuição acumulada da renda

$$F(r) = \int_b^r h(x)dx = \int_b^r ab^a x^{-a-1} dx = 1 - b^a r^{-a} = R.$$

Desta forma,

$$\ln(1 - R) = a \ln b - a \ln r.$$

Fazendo um ajuste linear com os dados da tabela, obtemos $a \cong 2,031$

e $b \cong 1,726$. Assim,

$$h(r) = \begin{cases} 6,15r^{-3031} & \text{se } r \geq 1,726 \\ 0 & \text{se } r < 1,726 \end{cases}.$$

A tabela de esperança de vida no Nordeste em 1977, na zona urbana, onde o salário mínimo era de Cr\$ 156,00, é dada pela Tabela 10.2.

Classe de Renda	Renda Cr\$	Esperança de vida (anos)
1	1 a 150	40,0
2	151 a 300	45,9
3	301 a 500	50,8
4	mais de 500	54,4

Tabela 10.2: Fonte: Carvalho e Wood (1977).

Vamos supor agora que a renda r seja proporcional a uma potência do salário S do grupo estudado: $r = S^m$, sendo m uma constante. Então, temos

$$\beta_k(S^m) = \begin{cases} [1 - (\frac{S}{S_0})^{2m}]^k & \text{se } 0 < S < S_0 \\ 0 & \text{se } S \geq S_0 \end{cases}.$$

A esperança de vida, independente da renda familiar, é 54,4 anos. Logo, a taxa de mortalidade natural é $\lambda_1 = \frac{1}{54,4}$. Por outro lado, $\lambda_1 + \lambda_2$ é a maior taxa de mortalidade do grupo, ou seja, $\lambda_1 + \lambda_2 = 1/40 \implies \lambda_2 = \frac{1}{40} - \frac{1}{54,4} = 6,618 \times 10^{-3}$.

Vamos considerar como nível de renda satisfatório o valor Cr\$ 500,00 que equivale a $S_0 = \frac{500}{156} = 3,2$ salários mínimos. Da Tabela 10.2 ainda temos dois valores de esperança de vida

$$\begin{aligned} \text{Se } S = 1 &\implies \frac{1}{\lambda_1 + \lambda_2 \beta_k(1)} = 45,9 \\ \text{Se } S = 2 &\implies \frac{1}{\lambda_1 + \lambda_2 \beta_k(2^m)} = 50,8 \end{aligned} \implies$$

$$\begin{aligned}\lambda_2 \beta_k(1) &= \frac{1}{45,9} - \frac{1}{54,4} = 3,404 \times 10^{-3} \\ \lambda_2 \beta_k(2^m) &= \frac{1}{50,8} - \frac{1}{54,4} = 1,303 \times 10^{-3}.\end{aligned}$$

Como $\lambda_2 = 6,618 \times 10^{-3}$, temos

$$\begin{aligned}\beta_k(1) &= 0,514 \implies \left[1 - \left(\frac{1}{S_0}\right)^{2m}\right]^k = 0,514 \\ \beta_k(2^m) &= 0,197 \implies \left[1 - \left(\frac{2}{S_0}\right)^{2m}\right]^k = 0,197\end{aligned}$$

Logo, $m = 0,4435$ e $k = 1,51$.

Como $S_0 = 3,2$ tem-se que $r_0 = (3,2)^{0,4435} \simeq 1,68$.

Então, o subconjunto fuzzy $\beta_k(r)$ é dado por

$$\beta_k(r) = \begin{cases} \left[1 - \left(\frac{r}{3,2}\right)^{0,887}\right]^{1,51} & \text{se } 0 < r < 1,68 \\ 0 & \text{se } r \geq 1,68 \end{cases} \quad (10.7)$$




Figura 10.3: Função de pertinência do conjunto dos pobres para $k = 1,51$

10.1.5 Comparação das Esperanças Clássica e Fuzzy

Tendo em mãos a função de pertinência do conjunto dos pobres em questão ($\beta_{1,51}$), podemos calcular o número médio de trabalhadores estudados na Seção 10.1.4, ano a ano, utilizando os resultados das Seções

10.1.2 e 10.1.3. A Tabela 10.3 ilustra esse número.

t	$E \left[\frac{n(t)}{n(0)} \right]$	$EF \left[\frac{n(t)}{n(0)} \right]$	$E \left[\frac{n(t)}{n(0)} \right] - EF \left[\frac{n(t)}{n(0)} \right]$	$\times 10^3$
1	0,9810872	0,9800555	1,0317	
2	0,9625352	0,9605718	1,9634	
3	0,9443294	0,941537	2,7924	
4	0,9264697	0,9229397	3,5300	
5	0,908949	0,9047686	4,1804	
10	0,8261962	0,8199376	6,2486	
20	0,682632	0,6766003	6,0317	
40	0,4660586	0,4687494	2,6908	

Tabela 10.3: Esperanças clássicas e fuzzy do número de trabalhadores. A última coluna mostra a diferença entre as metodologias.

A quarta coluna da Tabela 10.3 nos mostra as diversas diferenças entre as duas metodologias para o cálculo de esperança.

De um modo geral, o Corolário 7.3 nos garante que essas diferenças não ultrapassam 0,25. Para os valores da tabela, a maior diferença para essas esperanças é da ordem de 0,63%.

Ainda, para esse exemplo específico, é fácil ver que $EF \left[\frac{n(t)}{n(0)} \right]$ está compreendida entre $Y(cb^m)$ e $e^{-\lambda_1 t}$. Assim

$$\lim_{t \rightarrow \infty} \left| E \left[\frac{n(t)}{n(0)} \right] - EF \left[\frac{n(t)}{n(0)} \right] \right| = 0,$$

ou seja, $E \left[\frac{n(t)}{n(0)} \right] \simeq EF \left[\frac{n(t)}{n(0)} \right]$ para t suficientemente grande.

Ainda, como exemplificação, vamos supor que as rendas sejam dadas por faixas e usar o Teorema 7.5.

Suponhamos agora que o grupo de trabalhadores A tenha 150 elementos, isto é, $\#A = 150 = n_0$ e as rendas estejam distribuídas da seguinte maneira:

$n_1 = 100$ elementos recebem na faixa de $r = 2,0$ salários mínimos $\mapsto Y(2) = e^{-0,0013t} e^{-\lambda_1 t}$,

$n_2 = 40$ com renda na faixa de $r = 2,5$ salários mínimos $\mapsto Y(2,5) = e^{-0,00057t}e^{-\lambda_1 t}$;

$n_3 = 10$ na faixa de $r = 3,5$ salários mínimos $\mapsto Y(3,5) = e^{-\lambda_1 t}$.

Podemos considerar que

$$P\{n|Y > \alpha\} = \frac{\#\{n|Y > \alpha\}}{\#A}.$$

Então,

$$\text{Se } Y(2,5) < \alpha \leq Y(3,5) \implies \frac{n_2}{\#A} = \frac{40}{150} = 0,2667$$

$$\text{Se } Y(2,0) < \alpha \leq Y(2,5) \implies \frac{n_2+n_1}{\#A} = \frac{50}{150} = 0,333.$$

Se considerarmos o valor esperado fuzzy, num tempo t , de $Y(r)$

$$\begin{aligned} EF[Y_t(r)] &= \sup_{0 \leq \alpha \leq 1} \inf[\alpha, P\{n|Y > \alpha\}] \\ &= \text{med} \left\{ 0,2667; 0,333; e^{-0,0013t}e^{-\lambda_1 t}; e^{-0,00057t}e^{-\lambda_1 t}; e^{-\lambda_1 t} \right\} \\ &= e^{-0,0013t}e^{-\lambda_1 t}. \end{aligned}$$

Observamos que para $t = 1$ temos $EF(Y_1(r)) \approx 0,9987e^{-\lambda_1}$.

Por outro lado, se tomarmos a média clássica para estes mesmos dados, obtemos

$$E[Y_t] = \frac{100Y_1 + 40Y_2 + 10Y_3}{150} = \frac{e^{-\lambda_1 t}}{150}(100e^{-0,0013t} + 40e^{-0,00057t} + 10)$$

Assim, para $t = 1$

$$E[Y_1] \approx 0,9998e^{-\lambda_1}.$$

Os dois exemplos seguintes têm características semelhantes quanto à modelagem e, portanto, serão tratados com ferramentas matemáticas análogas. A principal semelhança entre eles está no fato de que suas incertezas têm origem nas variáveis de estado, tratando-se portanto de fuzziness demográfica. No entanto, de certa forma, tais incertezas serão transferidas para parâmetros dos modelos, o que nos permite usar

técnicas de fuzziness ambiental. Este procedimento objetiva a redução de complexidade nos métodos adotados. Mais especificamente, tratar matematicamente fuzziness demográfica é, via de regra, mais complicado que fuzziness ambiental. Claro que nem sempre podemos empregar este processo de transferência, que depende muito do tipo de situação modelada.

10.2 O Modelo Epidemiológico SI

O modelo clássico mais simples para descrever a dinâmica de doenças transmitidas diretamente, onde há interação entre indivíduos suscetíveis e infectados, é o modelo do tipo SI , representado pelo diagrama compartmental da figura 10.4.




Figura 10.4: Diagrama Compartmental do Modelo SI.

As equações diferenciais clássicas que descrevem essa dinâmica são dadas por:

$$\begin{cases} \frac{dS}{dt} = -\beta SI \\ \frac{dI}{dt} = \beta SI \end{cases}, \quad (10.8)$$

com $S + I = 1$, onde S é a proporção de indivíduos suscetíveis, I é a proporção de indivíduos infectados e β é o coeficiente de transmissão.

Levando-se em conta que o modelo é normalizado, isto é, $S + I = 1$, o número de indivíduos infectados é obtido pela solução da equação logística

$$\frac{dI}{dt} = \beta(1 - I)I.$$

cuja solução é dada por:

$$I = \frac{I_0 e^{\beta t}}{S_0 + I_0 e^{\beta t}}, \quad (10.9)$$

onde S_0 e I_0 são as proporções iniciais de suscetíveis e infectados respectivamente.

O modelo SI 10.8 faz parte do grupo de modelos de transmissão direta. Tais modelos são formulados por equações diferenciais e baseiam-se na *lei de ação de massas* originada do estudo de cinética química. A *lei de ação de massas* postula que a taxa de formação dos compostos é proporcional às concentrações dos reagentes. A aceitação desta lei é baseada no fato de que cada partícula dos reagentes movimenta-se independentemente das demais, o que significa que a mistura é homogênea e portanto todas as partículas têm a mesma chance de encontro com as demais. A tradução desta lei para os modelos matemáticos, é feita considerando o *encontro* entre variáveis como sendo o produto delas. Lotka e Volterra, na mesma época, também usaram esta formulação para modelar interação entre espécies.

A transposição desta lei para a epidemiologia deu-se, inicialmente, com os modelos de Kermack-Mackendric (1926) baseados na hipótese que os indivíduos infecciosos estão distribuídos homogeneamente em toda a população e têm o mesmo poder de transmitir a doença. Esta é uma simplificação considerável para a epidemiologia, já que há muitas fontes de heterogeneidade que interferem na propagação de uma doença, como por exemplo idade e/ou classe social.

No modelo que vamos propor continuaremos admitindo a lei de ação de massas, ou seja, que cada infeccioso tem a mesma chance de encontro com os suscetíveis. Entretanto, vamos considerar que a chance de ocorrer novo caso da doença varie de indivíduo para indivíduo. Uma nova infecção só poderá ocorrer se um número mínimo de vírus (ou outro agente patogênico) for transmitido pelo hospedeiro. Desta forma, vamos

tomar a carga viral como um fator influente na propagação da doença, acreditando que indivíduos com carga viral alta têm mais chance de transmitir a doença que aquele com carga baixa (veja [111]).

O modelo SI fuzzy que descreveremos a seguir leva em consideração a carga viral como característica relevante do indivíduo infeccioso.

10.2.1 O Modelo SI Fuzzy

Os conceitos de suscetível, bem como de infeccioso, são incertos no sentido que há diferentes graus, tanto de suscetibilidade como de infecciosidade.

Visando incorporar essa heterogeneidade populacional no modelo, consideramos que quanto mais um indivíduo estiver infectado, maior será a chance de transmissão da doença. Em outras palavras, assumimos que $\beta = \beta(v)$, onde v é a carga viral, é uma função não decrescente com v . Por outro lado, espera-se que quando a carga viral é muito baixa não há chance de ocorrer a transmissão. Em outras palavras, admitimos que existe uma carga mínima necessária $v_{\min}$ para que haja possibilidade não nula de transmissão da doença. Além disso, a partir de uma certa carga viral v_M , a chance de transmissão é máxima. Admitimos ainda que a carga viral é limitada por um valor máximo $v_{\max}$.

Escolhemos para β a seguinte função

$$\beta(v) = \begin{cases} 0 & \text{se } v \leq v_{\min} \\ \frac{v - v_{\min}}{v_M - v_{\min}} & \text{se } v_{\min} < v \leq v_M \\ 1 & \text{se } v_M < v \leq v_{\max} \\ 0 & \text{se } v > v_{\max} \end{cases} . \quad (10.10)$$

O parâmetro $v_{\min}$ representa a quantidade mínima de vírus necessária para que possa ocorrer a transmissão da doença. Este parâmetro poderia ser interpretado como o valor limiar da suscetibilidade do grupo estudado. De fato, quanto maior for o valor de $v_{\min}$ maior é a quantidade

necessária de vírus para que ocorra a transmissão, e isto significa que o grupo estudado possui uma baixa suscetibilidade à doença. Em outras palavras, quanto maior for $v_{\min}$, maior é a resistência dos indivíduos suscetíveis. Já o parâmetro v_M representa a carga viral a partir da qual a chance de transmissão é máxima, isto é, $\beta(v) = 1$. Obviamente, não significa que de fato ocorra a transmissão da doença quando $\beta(v) = 1$.

Desde que $\beta(v) \in [0, 1]$, podemos interpretar β como a função de pertinência de algum subconjunto fuzzy cujo domínio contém os valores para a carga viral (veja Exemplo 7.6).




Figura 10.5: Coeficiente fuzzy de transmissão β .

Solução Fuzzy

Com a incorporação da carga viral, o sistema 10.8 pode ser visto como uma família de equações diferenciais ordinárias que têm como solução as funções

$$I(v, t) = \frac{I_0 e^{\beta(v)t}}{S_o + I_0 e^{\beta(v)t}} \quad (10.11)$$

para cada v fixo.

Agora, para cada $t > 0$ fixo, $I(v, t)$ é um conjunto de valores reais e isto significa que, para cada instante t , a solução (10.11) do problema fuzzy (10.8) é uma distribuição de possíveis valores para o número de infectados no intervalo $[0, 1]$. Assim, $I(v, t) = I_t(v) \in [0, 1]$ pode ser interpretada como a função de pertinência de um conjunto fuzzy. Se por algum motivo for necessário adotar um único valor real para representar

o número de indivíduos infectados devemos adotar algum procedimento de defuzzificação. Podemos, por exemplo, estimar seu número “médio” em cada instante t , por meio do valor esperado fuzzy $EF[I(V, t)]$, usado aqui como um defuzzificador de $I(v, t)$.

Para fazer uma comparação entre os modelos SI clássico e fuzzy vamos calcular os números médios de infectados, através das esperanças clássica $E[I(V, t)]$ e fuzzy $EF[I(V, t)]$.

Para isto, consideramos que a carga viral V é uma variável linguística que pode ser classificada como *fraca* (V_-), *média* (V_-^+) ou *forte* (V_+), sendo cada uma dessas classificações um conjunto fuzzy que tem forma triangular, de acordo com a função de pertinência da carga viral do grupo estudado:

$$\rho(v) = \begin{cases} 1 - \frac{|v - \bar{v}|}{\delta} & \text{se } v \in [\bar{v} - \delta, \bar{v} + \delta] \\ 0 & \text{se } v \notin [\bar{v} - \delta, \bar{v} + \delta] \end{cases} . \quad (10.12)$$

Note que $\rho(v)$ pode ser visto como a possibilidade de ocorrer $V = v$ e, ρ passa a ser uma distribuição de possibilidades para a variável V . Para uma melhor interpretação de ρ veja Exemplo 7.6 do Capítulo 7.




Figura 10.6: Distribuição de possibilidades da carga viral ρ .

O parâmetro $\bar{v}$ é um valor médio em torno do qual cada um dos conjuntos fuzzy assumidos por V distribui-se, enquanto δ (a metade da base dos triângulos), dá uma idéia da dispersão.

Os conjuntos fuzzy assumidos pela variável linguística V serão classificados baseados nos parâmetros $v_{\min}$ e v_M que aparecem na definição de β .

10.2.2 Esperança fuzzy do número de indivíduos infectados

A seguir iremos calcular o número médio de indivíduos infectados nos distintos casos correspondentes às distribuição de carga viral do grupo.

Como já definido no Capítulo 7, a esperança fuzzy EF do conjunto fuzzy $I(V, t)$ é dada por

$$EF[I(V, t)] = \sup_{0 \leq \alpha \leq 1} \min[\alpha, \mu\{I(v, t) \geq \alpha\}],$$

onde $\mu\{v : I(v, t) \geq \alpha\}$ é uma medida fuzzy do conjunto clássico α -nível de $I(v, t) = [I(V, t)]^\alpha$.

Assim, para cada t , a função $H(\alpha)$, cujo ponto fixo é o valor $EF[I(V, t)]$, de acordo com o Teorema 7.1, é dada por

$$H(\alpha) = \mu\{v : I(v, t) \geq \alpha\} = \int_{[I(v, t)]^\alpha} \rho(v) dv = 1 - \mu\{v : I(v, t) < \alpha\}.$$

Primeiro, observamos que $H(0) = 1$ e $H(1) = 0$. Para $0 < \alpha < 1$, fazendo $k = \frac{S_0}{I_0}$ temos

$$H(\alpha) = 1 - \mu\{v : I(v, t) < \alpha\} = 1 - \mu\{v : \beta(v) < \ln(\frac{\alpha k}{1 - \alpha})^{\frac{1}{t}}\} =$$

$$= \begin{cases} 1 & \text{se } \ln(\frac{\alpha k}{1 - \alpha})^{\frac{1}{t}} \leq 0 \\ \mu\{v \in [0, B)\} & \text{se } 0 < \ln(\frac{\alpha k}{1 - \alpha})^{\frac{1}{t}} < 1 \\ 0 & \text{se } \ln(\frac{\alpha k}{1 - \alpha})^{\frac{1}{t}} \geq 1 \end{cases} =$$

$$= \begin{cases} 1 & \text{se } 0 \leq \alpha \leq I_0 \\ \mu\{v \in [0, B)\} & \text{se } I_0 < \alpha < \frac{I_0 e^t}{S_0 + I_0 e^t} \\ 0 & \text{se } \frac{I_0 e^t}{S_0 + I_0 e^t} \leq \alpha \leq 1 \end{cases},$$

onde $B = v_{\min} + (v_M - v_{\min}) \ln\left(\frac{\alpha k}{1-\alpha}\right)^{\frac{1}{t}}$. Note que $v_{\min} < B \leq v_M$.

Para calcular a esperança fuzzy pode-se usar qualquer medida fuzzy (não necessariamente σ -aditiva). No nosso caso, vamos adotar a medida fuzzy

$$\mu(A) = \frac{1}{\delta} \int_A \rho(v) dv = \int_A \frac{\rho(v)}{\delta} dv,$$

que também é uma medida de probabilidade cuja função densidade de distribuição é $\frac{\rho(v)}{\delta}$. Note que $\int_A \frac{\rho(v)}{\delta} dv = 1$.

A fim de exemplificar os casos onde a carga viral é *fraca*, *média* ou *forte*, vamos calcular a esperança fuzzy $EF[I(V, t)]$ para os três casos distintos, conforme Figura 10.7.




Figura 10.7: Classificações das cargas virais.

- **Carga viral fraca** (V_-): Neste caso, tomamos $v_{\min} > \bar{v} + \delta$.

Como $B > v_{\min}$, temos $\mu\{v \in [0, B]\} = 1$ e assim,

$$H(\alpha) = \begin{cases} 1 & \text{se } 0 \leq \alpha \leq I_0 \\ 0 & \text{se } I_0 < \alpha \leq 1 \end{cases}.$$

Portanto,

$$EF[I(V, t)] = I_0.$$

Neste caso, o número de infectados em cada instante t permanece o

mesmo do instante inicial e portanto, a doença não se propaga. Este resultado está em acordo com o fato de que, nesta faixa, $\beta(v) = 0$.

- **Carga viral forte (V^+):** Neste caso, tomamos $v_M \leq \bar{v} - \delta$.

Para esta situação, como $B \leq v_M$, obtemos $\mu\{v \in [0, B]\} = 0$, logo

$$H(\alpha) = \begin{cases} 1 & \text{se } 0 \leq \alpha \leq \frac{I_0 e^t}{S_0 + I_0 e^t} \\ 0 & \text{se } \frac{I_0 e^t}{S_0 + I_0 e^t} < \alpha \leq 1 \end{cases}$$

e, portanto

$$EF[I(V, t)] = \frac{I_0 e^t}{S_0 + I_0 e^t}.$$

Novamente neste caso, obtemos a solução clássica quando $\beta = 1$.

- **Carga viral média (V^+):** Tomamos $v_{\min} < \bar{v} - \delta < \bar{v} + \delta < v_M$.

Um cálculo direto, porém trabalhoso, nos leva a

$$H(\alpha) = \begin{cases} 1 & \text{se } 0 \leq \alpha \leq I(\bar{v} - \delta, t) \\ 1 - \frac{1}{2} \left(\frac{B - \bar{v}}{\delta} + 1 \right)^2 & \text{se } I(\bar{v} - \delta, t) < \alpha \leq I(\bar{v}, t) \\ \frac{1}{2} \left(\frac{\bar{v} - B}{\delta} + 1 \right)^2 & \text{se } I(\bar{v}, t) < \alpha \leq I(\bar{v} + \delta, t) \\ 0 & \text{se } I(\bar{v} + \delta, t) < \alpha \leq 1 \end{cases}.$$




Figura 10.8: Gráfico da função nível $H(\alpha)$ para carga viral média.

De acordo com a expressão e o gráfico acima conclui-se que $H(\alpha)$ é

contínua e decrescente com $H(0) = 1$ e $H(1) = 0$. Portanto, H tem único ponto fixo que coincide com $EF[I(V, t)]$ (Teorema 7.1). Conhecendo-se os valores de todos os parâmetros δ , $\bar{v}$, $v_{\min}$ e v_M obtemos $EF[I(V, t)]$.

Não é difícil ver que, para cada $t > 0$, se $v \in [v - \delta, v + \delta]$ então $I(\bar{v} - \delta, t)$ e $I(\bar{v} + \delta, t)$ formam, respectivamente, as extremidades inferior e superior de um intervalo da reta. Também temos que, se $v_2 \geq v_1$, então $I(v_2, t) \geq I(v_1, t)$. Deste modo, pelo Teorema do Valor Intermediário (veja [57]), para cada $t > 0$ existe um único $v = v(t) \in [v - \delta, v + \delta]$ tal que

$$EF[I(V, t)] = I(v(t), t) = \frac{I_0 e^{\beta(v(t))t}}{S_0 + I_0 e^{\beta(v(t))t}}.$$

Desta forma, o valor médio das soluções $EF[I(V, t)]$ não coincide com nenhuma das curvas soluções (10.11) do modelo. O que temos é que, para cada t , o valor de $EF[I(V, t)]$ coincide com $I(v, t)$ para algum v . No entanto, mudando o instante t , também mudará a curva $I(v, t)$, já que, $EF[I(V, t)] = I(v(t), t)$ e $v = v(t)$ varia com o tempo.

Em outras palavras, a curva $EF[I(V, t)] = I(v(t), t)$ não é solução da equação diferencial autônoma original

$$\frac{dI}{dt} = \beta(1 - I)I.$$

Do estudo anterior podemos fazer ainda algumas observações:

- Enquanto houver suscetíveis e $\bar{v} - \delta - v_{\min} > 0$, o número médio de infectados $EF[I(V, t)]$ cresce com t , pois

$$\lim_{t \rightarrow \infty} EF[I(V, t)] \geq \lim_{t \rightarrow \infty} I(\bar{v} - \delta, t) = 1.$$

- A doença poderá ser controlada por $I(\bar{v} + \delta, t)$, ou seja, fazendo $\bar{v} + \delta - v_{\min} \leq 0$, o número médio de infectados não crescerá pois

$$\lim_{t \rightarrow \infty} EF[I(V, t)] \leq \lim_{t \rightarrow \infty} I(\bar{v} + \delta, t) = I_0.$$

10.2.3 Esperança clássica do número de infectados

Com o parâmetro β considerado, isto é, $\beta = \beta(v)$, a esperança clássica do número de indivíduos infectados, $E[I(V, t)]$, é dada por

$$E[I(V, t)] = \int_{-\infty}^{+\infty} I(v, t) \frac{\rho(v)}{\delta} dv = \frac{1}{\delta} \int_{\bar{v}-\delta}^{\bar{v}+\delta} I(v, t) \rho(v) dv, \quad (10.13)$$

pois para valores de v fora do intervalo $[\bar{v} - \delta, \bar{v} + \delta]$, temos $\rho(v) = 0$ e assim,

$$I(\bar{v} - \delta, t) \leq E[I(v, t)] \leq I(\bar{v} + \delta, t).$$

Como existem várias possibilidades para calcularmos a esperança em função dos parâmetros, escolhemos os três casos particulares já analisados com a esperança fuzzy:

Carga viral fraca: $v_{\min} > \bar{v} + \delta$.

Nesta situação, para todos os indivíduos infectados o coeficiente de transmissão $\beta(v)$ é nulo. Substituindo $\beta(v) = 0$ e $I(V, t)$ dado por (10.11) em (10.13), obtemos:

$$E[I(V, t)] = \frac{1}{\delta} \int_{\bar{v}-\delta}^{\bar{v}+\delta} I(v, t) \rho(v) dv = I_0.$$

Portanto, como todos os indivíduos infectados apresentam carga viral abaixo de $v_{\min}$ (nenhum indivíduo possui carga viral mínima necessária para que ocorra a transmissão), não ocorre a propagação da doença. Poderíamos interpretar essa situação como a de um grupo altamente resistente ($v_{\min}$ é alto), que faz com que a suscetibilidade seja muito baixa. Neste caso a quantidade de infectados permanece inalterada I_0 .

Carga viral forte: $v_M < \bar{v} - \delta$.

Neste caso, o coeficiente de transmissão é máximo para todos os indivíduos infectados, isto é, $\beta(v) = 1$.

Após efetuar os cálculos, obtemos

$$E[I(V, t)] = \frac{1}{\delta} \int_{\bar{v}-\delta}^{\bar{v}+\delta} I(v, t) \rho(v) dv = \frac{I_0 e^t}{S_0 + I_0 e^t}.$$

Observe que a expressão acima coincide com a solução clássica do modelo quando consideramos o coeficiente de transmissão constante, isto é $\beta = 1$.

Carga viral média: $\bar{v} - \delta > v_{\min}$ e $\bar{v} + \delta < v_M$.

Neste caso, assim como vimos para esperança clássica, aqui também o coeficiente de transmissão é variável para todos os indivíduos infectados. Toda a distribuição de V está na região onde $\beta(v) = \frac{v-v_{\min}}{v_M-v_{\min}}$. Assim, para obter $E[I(V, t)]$ é preciso saber os valores de todos os parâmetros $\delta, \bar{v}, v_{\min}, v_M$ e $v_{\max}$.

Observações análogas em relação à propagação da doença, feitas para esperança fuzzy, valem aqui também, lembrando que

$$I(\bar{v} - \delta, t) \leq E[I(v, t)] \leq I(\bar{v} + \delta, t),$$

$$\lim_{t \rightarrow \infty} E[I(V, t)] \geq \lim_{t \rightarrow \infty} I(\bar{v} - \delta, t) = 1$$

e

$$\lim_{t \rightarrow \infty} E[I(V, t)] \leq \lim_{t \rightarrow \infty} I(\bar{v} + \delta, t) = I_0.$$

Para a esperança clássica tem-se também que

$$E[I(V, t)] = I(v(t), t),$$

para alguma função $v = v(t)$.

Para finalizar esta seção queremos ressaltar que, diferentemente da esperança clássica, poderíamos ter utilizado outras medidas fuzzy para obter a esperança fuzzy. Esta possibilidade de escolher diferentes medidas, de acordo com o fenômeno estudado, é que torna a esperança

fuzzy com grande poder de aplicação. Por exemplo, ao invés de adotar a medida

$$\mu(A) = \frac{1}{\delta} \int \rho(v) dv,$$

poderíamos ter utilizado a seguinte **medida de possibilidade** (ver Capítulo 7)

$$\mu(A) = \sup_{v \in A} \rho(v).$$

A nosso ver, esta é uma medida bem razoável para ser adotada no nosso exemplo uma vez que apresenta um caráter conservador no seguinte sentido: um grupo A de indivíduos infectados é avaliado por aquele indivíduo deste grupo com maior carga viral. O número médio de indivíduos infectados, isto é, $EF[I(V, t)]$ poderia ser avaliado com essa medida conservadora para, a partir daí, se tomar alguma medida de controle da doença. Queremos ressaltar que, especificamente para esta medida de possibilidade, chegamos a conclusões bem semelhantes às dos três casos analisados anteriormente, nos quais a função H passa a ser

$$H(\alpha) = \begin{cases} 1 & \text{se } 0 \leq \alpha \leq I_0 \\ \sup_{v \in [a, v_{\max}]} \rho(v) & \text{se } I_0 < \alpha \leq \frac{I_0 e^t}{S_0 + I_0 e^t} \\ 0 & \text{se } \frac{I_0 e^t}{S_0 + I_0 e^t} < \alpha \leq 1 \end{cases}$$

e $EF[I(V, t)]$ é o ponto fixo da função H .

Com o intuito de explorar um pouco mais este exemplo, vamos fazer um estudo comparativo entre a estratégia aplicada acima e o método determinístico.

10.2.4 Solução das médias ($I(EF[V], t)$) $\times$ Média das soluções ($EF[I(V, t)]$)

Nesta seção vamos comparar a curva $EF[I(V, t)]$ com a trajetória dos 3 casos estudados anteriormente, isto é, $I(EF[V], t) = I(\bar{v}, t)$

Da expressão de H podemos concluir que $H(I(\bar{v}, t)) = \frac{1}{2}$ para todo t .

Por outro lado, uma vez que $EF[I(V, t)]$ é o ponto fixo H temos

Desta forma, a trajetória devido à carga média $I(\bar{v}, t)$, não produz o número médio de indivíduos infectados (dado por $EF[I(V, t)]$) em cada instante. Portanto, a nosso ver, não é correto adotar a carga média ou modal ($\bar{v}$) para estudar a evolução da doença na população como um todo, já que $EF[I(V, t)] = I(\bar{v}, t)$ apenas no instante $\bar{t} = \frac{v_M - v_{\min}}{\bar{v} - v_{\min}} \ln(\frac{S_0}{I_0})$, $S_0 \geq I_0$. Observemos que $\bar{t}$ é o ponto de inflexão de $I(\bar{v}, t)$ e que $I(\bar{v}, \bar{t}) = \frac{1}{2}$, isto é, no instante $\bar{t}$ o incremento da taxa de crescimento de $I(\bar{v}, t)$ é maior que $I(\bar{v}, \bar{t}) = \frac{1}{2}$ (veja Figura 10.9).




Figura 10.9: $EF[I(V, t)]$: média fuzzy e $I(\bar{v}, t)$: determinístico.

A partir da desigualdade de Jensen [68], nós obtemos conclusões semelhantes às comentadas acima para a esperança clássica, $E(I(V, t))$, mudando apenas o instante $\bar{t}$ em que a curva $I(\bar{v}, t)$ supera $E(I(V, t))$.

Estes fatos revelam que, para sistemas heterogêneos, momentos distintos em que as incertezas são retiradas de modelo podem levar a diferentes avaliações para o sistema como um todo.

A adoção do **modelo determinístico** para se estudar a evolução do sistema acima nos leva a adotar $I(\bar{v}, t)$ como solução pois, neste caso,

toda a incerteza deve ser retirada já no início do modelo matemático, no nosso caso, $V = \bar{v}$. Por outro lado, o **modelo fuzzy** permite que as incertezas, neste caso inerente ao fenômeno, sejam retiradas em um momento (futuro) desejado, obtendo-se $EF[I(V, t)]$ ou $E[I(V, t)]$ - o que for mais representativo para o sistema como um todo.

Os modelos matemáticos de epidemias são estudados com a finalidade de se estabelecer políticas ou estratégias de controle da doença. Vamos a seguir exemplificar este fato com o modelo SI fuzzy.

10.2.5 Controle da Epidemia e Valor de Reprodutibilidade Basal

A discussão que faremos nesta seção é baseada nas propriedades do modelo *SI* fuzzy, levando-se em conta a curva dada pela esperança fuzzy $EF[I(V, t)]$. Conclusões semelhantes são obtidas se a curva adotada fosse $E[I(V, t)]$ [16].

Vimos que,

- se $S_0 > I_0$, e enquanto $t < \bar{t} = \frac{v_M - v_{\min}}{\bar{v} - v_{\min}} \ln(\frac{S_0}{I_0})$, então $EF[I(V, t)] > I(\bar{v}, t)$. A partir de $t = \bar{t}$ temos que $EF[I(V, t)] < I(\bar{v}, t)$. Assim podemos dizer que o modelo determinístico subestima o número de indivíduos infectados no início da doença e superestima a partir de $\bar{t}$ (veja Figura 10.9).
- se $S_0 \leq I_0$ então $EF[I(V, t)] \leq I(\bar{v}, t)$ para todo $t > 0$ e, neste caso, o modelo determinístico superestima o número de indivíduos infectados.

Portanto, no início da doença quando $t < \bar{t} = \frac{v_M - v_{\min}}{\bar{v} - v_{\min}} \ln(\frac{S_0}{I_0})$ e $S_0 > I_0$, temos

$$I(\bar{v}, t) \leq EF[I(V, t)] \leq I(\bar{v} + \delta, t)$$

e, assim, $v(t) \in [\bar{v}, \bar{v} + \delta]$.

Uma vez que $EF[I(V, t)] = I(v(t), t)$ cresce com o crescimento de $v(t)$, podemos dizer que quanto maior a carga viral média, maior o número médio de infectados $EF[I(V, t)]$. Também, quanto maior a dispersão δ , maior será $EF[I(V, t)]$ e que quanto maior for $v_{\min}$, menor será $EF[I(V, t)]$.

Para os modelos epidemiológicos clássicos, um parâmetro essencial é o *valor de reprodutibilidade basal* R_0 , que dá o número de casos secundários causados por um indivíduo infectado introduzido numa população inteiramente suscetível [50, 83]. Dessa forma, esse parâmetro indica sob quais condições a doença se propaga na população. Se um indivíduo infectado consegue provocar mais que um novo caso, isto é, se $R_0 > 1$ então a doença se propaga. Por outro lado, quando $R_0 < 1$ a doença se extingue.

Para os modelos epidemiológicos mais simples, a expressão para o parâmetro R_0 pode ser obtida a partir da condição $dI/dt > 0$, que é a condição para que ocorra acréscimo no número de infectados. Desta forma, para o modelo *SI* clássico normalizado onde $I + S = 1$, teríamos

$$\frac{dI}{dt} > 0 \iff \beta SI = \beta(1 - I)I > 0$$

que é satisfeito até que existam indivíduos suscetíveis na população, pois $\beta > 0$. Em outras palavras, teremos $R_0 > 1$ sempre que $\beta > 0$ e $I < 1$.

Entretanto, quando utilizamos um conjunto fuzzy para descrever o parâmetro β isto pode não ocorrer. No nosso caso, de acordo com a análise feita acima, é fácil verificar que a condição suficiente para que não ocorra a transmissão da doença é que nenhum indivíduo infectado possua a carga mínima necessária para transmitir a doença, ou seja, a condição $\bar{v} + \delta < v_{\min}$ deve ser satisfeita.

Poderíamos pois, definir o *valor de reprodutibilidade basal fuzzy* para o nosso modelo como sendo o valor

$$R_0^{\text{fuzzy}} = \frac{\bar{v} + \delta}{v_{\min}}. \quad (10.14)$$

Na modelagem clássica, as medidas de controle e prevenção visam reduzir o valor do parâmetro R_0 (de tal forma que $R_0 < 1$) para que a doença não se propague. Logo, para o modelo clássico SI isso não seria possível, visto que a variação dos indivíduos infectados é sempre positiva, como já foi visto antes.

Porém, se for considerado $\beta = \beta(v)$ fuzzy em (10.8), mesmo este modelo simplista, nos dará informações adicionais à dinâmica da doença. Por exemplo, é possível interferir na sua transmissão reduzindo o valor do parâmetro R_0^{fuzzy} . Isto pode ser feito de duas formas: aumentando-se o valor de $v_{\min}$, o que significa aumentar a resistência dos indivíduos suscetíveis (baixar a suscetibilidade). Isto poderia ser feito, por exemplo, através de vacinação, saneamento básico etc. Nesse sentido, pelo fato do parâmetro $v_{\min}$ estar relacionado aos indivíduos suscetíveis, essa forma de diminuir R_0 refere-se às medidas de **controle**.

A outra opção para reduzir R_0 seria diminuir o valor de $\bar{v} + \delta$, diminuindo $\bar{v}$ ou δ . A diminuição de δ poderia se dar através de medidas de controle na população infectada, como por exemplo, **isolamento**. A diminuição de $\bar{v}$ está relacionada às medidas de **tratamento** dos indivíduos infectados.

Finalizando esta aplicação queremos salientar que, diferentemente do modelo SI clássico que é muito simplista e pouco adequado para a maioria das doenças, o modelo SI fuzzy é mais abrangente e pode ser associado a modelos mais complexos em que a classe dos infecciosos é dividida em subclasses de acordo com seu status de infecciosidade (veja [78]). Um estudo completo do modelo SI fuzzy pode ser encontrado em [15] e do modelo SIS fuzzy em [16, 17]. Para ver outras aplicações em Epidemiologia, o leitor pode consultar [96] e fascículos da revista Biomatemática editada pelo IMECC-UNICAMP desde 1991.

10.3 Modelo Fuzzy da Transferência de Assintomáticos HIV⁺ para Sintomáticos

O modelo que daremos em seguida faz parte da tese de doutorado de Jafelice [65, 67].

Quando se analisa a evolução de uma população de indivíduos HIV⁺ assintomáticos para a classe dos sintomáticos, muitos fatores estão envolvidos no processo. A taxa de transferência está, pois, sujeita a todos os fatores responsáveis pela mudança de estágios. Alguns destes fatores são mais decisivos que outros, por exemplo a carga viral do indivíduo e seu nível de CD4⁺ são fundamentais para predizer seu estado próximo futuro. O que pretendemos neste exemplo é mostrar como podemos estudar um fenômeno, basicamente regido por variáveis inexatas ou incomensuráveis, usando um modelo determinístico com parâmetro subjetivo. Neste caso, consideramos a taxa de transferência subjetivamente dependente da carga viral e do nível de CD4⁺. Assim podemos expressar tal taxa por um conjunto fuzzy, isto é, definido por meio de descrições das variáveis linguísticas, como comentamos no Capítulo 5.

10.3.1 O modelo clássico

Em 1986 Anderson et al. [4] propôs o seguinte modelo para transferência de indivíduos assintomáticos para soropositivos:

$$\begin{cases} \frac{dx}{dt} = -\lambda(t)x & \text{com } x(0) = 1 \\ \frac{dy}{dt} = \lambda(t)x & \text{com } y(0) = 0 \end{cases}, \quad (10.15)$$

onde $\lambda(t)$ é a taxa de transferência de infectados com HIV⁺ para indivíduos soropositivos. A variável de estado x indica a proporção de infectados que ainda não têm sintomas declarados de AIDS e y indica a proporção de elementos que possuem sintomas claros de AIDS.

Em uma primeira aproximação, Anderson propõe que esta taxa deva ser da forma linear

$$\lambda(t) = at, \text{ com } a > 0.$$

Assim, a solução do sistema determinístico é dada por:

$$x(t) = e^{-\frac{at^2}{2}} \text{ e } y(t) = 1 - e^{-\frac{at^2}{2}}.$$

10.3.2 O Modelo Fuzzy

Vamos agora considerar a taxa de transferência subjetivamente dependente da *carga viral* v e do *nível de CD4⁺* c , ou seja,

$$\lambda = \lambda(v, c).$$

Usando formulação análoga a do modelo determinístico de Anderson, podemos escrever:

$$\begin{cases} \frac{dx}{dt} = -\lambda(v, c)x \\ x(0) = 1 \end{cases} \quad (10.16)$$

ou sua equação complementar

$$\frac{dy}{dt} = \lambda(v, c)x = k\lambda(v, c)(1 - y) \text{ com } y(0) = 0.$$

A diferença entre este modelo e o determinístico é que agora a taxa de transferência λ tem uma clara conotação biológica, pois antes era apenas um parâmetro ajustado. A solução do modelo fuzzy é

$$x(t) = e^{-\lambda(v, c)t} \text{ ou } y(t) = 1 - e^{-\lambda(v, c)t}$$

e cada solução pode ser entendida como um elemento da família de curvas que têm a mesma condição inicial:

$$x(t) = e^{-\lambda(v, c)t}, \text{ com } t > 0,$$

onde λ assume valores dependendo da carga viral e nível de $CD4^+$, variáveis estas que são características próprias dos indivíduos da população de infectados. A definição analítica do parâmetro λ é obtida através de combinações linguísticas das variáveis V e $CD4^+$ e base de regras, conforme vimos no Capítulo 5.

De acordo com informações médicas, o parâmetro mais usado para controlar a transferência de assintomáticos HIV^+ para sintomáticos é o valor de $CD4^+$. Desta forma, numa primeira aproximação, poderíamos simplesmente usar $\lambda = \lambda(c)$ como fator de transferência no modelo fuzzy (10.16). Se, para cada valor da carga viral v tomarmos $\lambda = \lambda(c)$, então sua configuração é, aproximadamente, a de curva logística decrescente (Figura 10.10). A equação que define $\lambda = \lambda(c)$ foi escolhida aqui, levando-se em conta argumentações semelhantes àsquelas do modelo anterior (veja Capítulo 5 para uma justificativa mais técnica).

$$\lambda(c) = \begin{cases} 1 & \text{se } c < c_{\min} \\ \frac{c_M - c}{c_M - c_{\min}} & \text{se } c_{\min} \leq c \leq c_M \\ 0 & \text{se } c > c_M \end{cases} \quad (10.17)$$

onde, $c_{\min}$ representa o nível mínimo de $CD4^+$ para que o indivíduo se torne sintomático e c_M representa o nível de $CD4^+$ a partir do qual a chance de se tornar sintomático é mínima.




Figura 10.10: Taxa de transferência λ .

10.3.3 Esperança fuzzy do número de indivíduos assintomáticos

A esperança fuzzy fornece uma espécie de média dos valores de $x(t, c)$ em cada instante, sendo pois um defuzzificador do conjunto dos assintomáticos

$$x(t, c) = e^{-\lambda(c)t}.$$

Como vimos no Capítulo 7, para definir uma esperança fuzzy necessitamos, inicialmente, escolher uma medida fuzzy μ . Então, o valor da esperança fuzzy dos indivíduos assintomáticos $x(t, c)$ é dada por:

$$EF[x] = \sup_{0 \leq \alpha \leq 1} \inf [\alpha, \mu \{x \geq \alpha\}],$$

onde $\{x \geq \alpha\} = \{c : x(c) \geq \alpha\}$ e μ é uma medida fuzzy.

Seja $H(\alpha) = \mu\{c : x(c) \geq \alpha\}$, para cada $t > 0$. Para este caso, um cálculo direto nos leva à seguinte expressão para a função H :


$$H(\alpha) = \begin{cases} \mu[c_M, c_{\max}] & \text{se } \alpha = 1 \\ \mu[B, c_{\max}] & \text{se } e^{-t} \leq \alpha < 1 \\ 1 & \text{se } \alpha \leq e^{-t} \end{cases}, \quad (10.18)$$

onde $B = c_M - (c_M - c_{\min})(\frac{\ln \alpha}{t}) \implies c_{\min} < B \leq c_M$.

Para definir uma medida fuzzy escolhemos uma “distribuição” de níveis de $CD4^+$ com diferentes possibilidades de ocorrer. Podemos considerar que o nível de $CD4^+$ tenha uma *distribuição triangular* dada por:

$$\rho(c) = \begin{cases} 1 - \frac{|c - \bar{c}|}{\delta} & \text{se } c \in [\bar{c} - \delta, \bar{c} + \delta] \\ 0 & \text{se } c \notin [\bar{c} - \delta, \bar{c} + \delta] \end{cases}. \quad (10.19)$$

Aqui, $\bar{c}$ é o valor modal em $[0, c_{\max}]$, com $c_{\max}$ um limite máximo da carga viral em um indivíduo, e δ é a dispersão do nível de $CD4^+$ na população estudada.

Figura 10.11: Distribuição ρ de $CD4^+$.

Agora, sugerimos como medida fuzzy μ a seguinte medida de possibilidade:

$$\mu(A) = \begin{cases} \sup_{c \in A} \rho(c) & \text{se } A \neq \emptyset \\ 0 & \text{se } A = \emptyset \end{cases},$$

onde A é um subconjunto dos números reais.

Como antes no *SI* fuzzy, aqui também os conjuntos A de interesse são os intervalos $A = [B, c_{\max}]$, onde $B = c_M - (c_M - c_{\min})(\frac{-\ln \alpha}{t}) \implies c_{\min} < B \leq c_M$.

Observamos que μ é uma medida otimista no sentido que o nível de $CD4^+$ de um grupo é avaliado como sendo o melhor nível dos indivíduos deste grupo.

Vamos considerar o nível de $CD4^+$ estudado como uma variável linguística com valores *baixa*, *média* e *alta*, sendo cada um desses valores caracterizados por conjuntos fuzzy triangulares, de acordo com a função de pertinência ρ (veja Figura 10.12) [67].

Caso 1: Nível de $CD4^+$ **baixo** (C_-).

Neste caso, tomamos $c_{\min} > \bar{c} + \delta$. Como $B > c_{\min}$ temos que $\mu[c_M, c_{\max}] = 0$ e $\mu[B, c_{\max}] = 0$. Logo,

$$H(\alpha) = \begin{cases} 1 & \text{se } \alpha \leq e^{-t} \\ 0 & \text{se } e^t < \alpha \leq 1 \end{cases}$$




Figura 10.12: Valores da variável linguística “nível de $CD4^+$ ”.

e assim obtemos $EF[x] = e^{-t}$.

Desta forma, o número médio de transferência de assintomático para sintomático tem crescimento exponencial.

Caso 2: Nível de $CD4^+$ **alto** (C^+).

Neste caso, tomamos $c_M \leq \bar{c} - \delta$ e $\bar{c} + \delta \leq c_{\max}$.

Assim, temos $B \leq c_M$ e portanto, $\mu[c_M, c_{\min}] = 1$ e $\mu[B, c_{\max}] = 1$.

Logo,

$$H(\alpha) = \begin{cases} 1 & \text{se } \alpha = 0 \\ 0 & \text{se } \alpha > 0 \end{cases}.$$

Portanto, $FEV[x] = 1$, o que significa que, se no grupo, o nível de $CD4^+$ é alto, então não haverá transferência de assintomáticos para sintomáticos.

Caso 3: Nível de $CD4^+$ **médio** (C^+).

Neste caso, tomamos $\bar{c} - \delta > c_{\min}$ e $\bar{c} + \delta < c_M$ o que implica em $\mu[c_M, c_{\max}] = 1$.

Fazendo alguns cálculos, obtemos:

$$H(\alpha) = \begin{cases} 1 & \text{se } 0 \leq \alpha \leq e^{-\lambda(\bar{c})t} \\ \rho(B) & \text{se } e^{-\lambda(\bar{c})t} < \alpha < e^{-\lambda(\bar{c}+\delta)t} \\ 0 & \text{se } e^{-\lambda(\bar{c}+\delta)t} \leq \alpha \leq 1 \end{cases},$$

onde $\rho(B) = \frac{1}{\delta}[-c_M - (c_M - c_{\min})(\frac{\ln \alpha}{t}) + \bar{c} + \delta]$.

Como $H(\alpha)$ é uma função contínua e decrescente com $H(0) = 1$ e $H(1) = 0$, então H tem um único ponto fixo que coincide com $EF[x]$ (veja Capítulo 7). A Figura 10.13 ilustra este fato.




Figura 10.13: Representação da $EF[x]$.

Assim,

$$e^{-\lambda(\bar{c})t} < EF[x] < e^{-\lambda(\bar{c}+\delta)t}.$$

Observamos que, para os 3 casos estudados, temos sempre a desigualdade

$$e^{-EF[\lambda]t} \leq e^{-\lambda(\bar{c})t} \leq EF[x].$$

Isto significa que o valor esperado da população de assintomáticos, em cada instante, é superior ao valor obtido pelo modelo determinístico, que considera como taxa de transferência o valor constante $\lambda(\bar{c}) = \bar{\lambda}$.

10.4 Dinâmica populacional e migração de moscas varejeiras

Para encerrarmos este capítulo apresentaremos um modelo bidimensional que representa a competição e migração de moscas. Tal modelo foi desenvolvido por Magnano e Castanho em 2003 [35].

O modelo é proveniente de um sistema bidimensional determinístico discreto, onde os parâmetros foram determinados por meio de bases de regras. Nós o consideramos como um caso de fuzziness ambiental porque o tratamento matemático dado leva em consideração que as incertezas estão nos parâmetros do modelo. As incertezas de tais parâmetros são tratadas por meio da teoria fuzzy e seus valores obtidos por meio de controladores fuzzy.

Um modelo determinístico utilizado por Godoy em 2002 [54] para analisar o estabelecimento de colônias de moscas varejeiras, tem sua formulação baseada na incorporação dos modelos determinístico de Prout–McCheney (1985) e estocástico de Roughgarden (1998), ou seja,

$$\begin{cases} N_{1,t+1} = \frac{(1 - m_{12})}{2} F_1 S_1 e^{-(f+s)N_{1,t}} N_{1,t} + \frac{m_{21}}{2} F_2 S_2 e^{-(f+s)N_{2,t}} N_{2,t} \\ N_{2,t+1} = \frac{m_{12}}{2} F_1 S_1 e^{-(f+s)N_{1,t}} N_{1,t} + \frac{(1 - m_{21})}{2} F_2 S_2 e^{-(f+s)N_{2,t}} N_{2,t} \end{cases} \quad (10.20)$$

Este modelo relaciona a dinâmica de uma população de moscas com o processo de migração entre duas colônias. As variáveis de estado são: $N_{1,t}$: população de moscas da colônia i no instante t .

Os parâmetros são:

F_i : fecundidade máxima das moscas quando estas se encontram na colônia i ;

S_i : sobrevivência máxima das moscas em i ;

m_{ij} : taxa de migração da colônia i para j ;

f e s estimam a variação da fecundidade e da sobrevivência, respectivamente.

Sabemos que os parâmetros m_{ij} , F_i e S_i são dependentes de uma série de fatores que muitas vezes são impossíveis de serem avaliados quantitativamente. Neste caso, um estudo do fenômeno através de um sistema fuzzy parece mais adequado.

O processo consiste em substituir os parâmetros da equação determinística por parâmetros subjetivos, obtidos por meio de uma combinação de regras.

Vamos considerar que os parâmetros incertos m_{ij} , F_i e S_i sejam dependentes de duas variáveis de entrada: a *População* ($N_{i,t}$) e o *Ambiente* (A_i) (habitat de cada colônia).

Para a *População*, com os dados experimentais obtidos por Godoy, obtivemos o comportamento para os termos linguísticos: *Pequena*, *Média* e *Grande* conforme a Figura 10.14.

Para o *Ambiente* os termos linguísticos considerados foram: *Hostil*, *Mediano* e *Favorável* com a função de pertinência dada na Figura 10.15.




Figura 10.14: Valores fuzzy da População. Figura 10.15: Valores fuzzy do Ambiente.

Para modelar o parâmetro fuzzy *Taxa de Migração* $\hat{m}$, como variável de saída, dependente da *População* e do *Ambiente*, adotamos a base de regras apresentada no Quadro 10.1. A função de pertinência de $\hat{m}_{ij}$ é baseada em simulações determinísticas.

Usamos os termos linguísticos *pequena*, *média* e *grande* para representar a taxa de migração, conforme o seguinte gráfico (Figura 10.16):

Os gráficos das variáveis de saída, *Fecundidade* fuzzy $\hat{F}$ e *Sobrevivência* fuzzy $\hat{S}$ são propostos intuitivamente, considerando uma certa simetria entre os valores experimentais de máximos e mínimos.

A resolução da equação de Godoy (10.20) com parâmetros fuzzy se

1. **Se** a População é pequena **e** o Ambiente é favorável **então** a Migração é pequena;
2. **Se** a População é pequena **e** o Ambiente é mediano **então** a Migração é pequena;
3. **Se** a População é pequena **e** o Ambiente é hostil **então** a Migração é grande;
4. **Se** a População é média **e** o Ambiente é favorável **então** a Migração é pequena;
5. **Se** a População é média **e** o Ambiente é mediano **então** a Migração é grande;
6. **Se** a População é média **e** o Ambiente é hostil **então** a Migração é grande;
7. **Se** a População é grande **e** o Ambiente é favorável **então** a Migração é média;
8. **Se** a População é grande **e** o Ambiente é mediano **então** a Migração é grande;
9. **Se** a População é grande **e** o Ambiente é hostil **então** a Migração é grande;

Quadro 10.1: Regras para a taxa migração de moscas varejeiras.




Figura 10.16: Valores fuzzy - taxa de migração.

1. **Se** a População é pequena **e** o Ambiente é favorável **então** a Fecundidade é alta;
2. **Se** a População é pequena **e** o Ambiente é mediano **então** a Fecundidade é alta;
3. **Se** a População é pequena **e** o Ambiente é hostil **então** a Fecundidade é média;
4. **Se** a População é média **e** o Ambiente é favorável **então** a Fecundidade é alta;
5. **Se** a População é média **e** o Ambiente é mediano **então** a Fecundidade é grande;
6. **Se** a População é média **e** o Ambiente é hostil **então** a Fecundidade é baixa;
7. **Se** a População é grande **e** o Ambiente é favorável **então** a Fecundidade é média;
8. **Se** a População é grande **e** o Ambiente é mediano **então** a Fecundidade é baixa;
9. **Se** a População é grande **e** o Ambiente é hostil **então** a Fecundidade é baixa;

Quadro 10.2: Regras para fecundidade de moscas varejeiras.





Figura 10.17: Valores fuzzy - fecundidade. Figura 10.18: Valores fuzzy - sobrevivência.

realiza computacionalmente, indicado passo-a-passo, da seguinte forma (ver Capítulo 5):

1. **Se** a População é pequena **e** o Ambiente é favorável **então** a Sobre-
vivência é alta;
2. **Se** a População é pequena **e** o Ambiente é mediano **então** a Sobre-
vivência é média;
3. **Se** a População é pequena **e** o Ambiente é hostil **então** a Sobre-
vivência é baixa;
4. **Se** a População é média **e** o Ambiente é favorável **então** a Sobre-
vivência é média;
5. **Se** a População é média **e** o Ambiente é mediano **então** a Sobre-
vivência é baixa;
6. **Se** a População é média **e** o Ambiente é hostil **então** a Sobre-
vivência é baixa;
7. **Se** a População é grande **e** o Ambiente é favorável **então** a Sobre-
vivência é baixa;
8. **Se** a População é grande **e** o Ambiente é mediano **então** a Sobre-
vivência é baixa;
9. **Se** a População é grande **e** o Ambiente é hostil **então** a Sobre-
vivência é baixa;

Quadro 10.3: Regras para sobrevivência de moscas varejeiras.

i) Entrada

Inicialmente são dadas as condições iniciais, por exemplo,

$$N_{1,0} = 300 \text{ e } N_{2,0} = 700$$

$$A_{1,0} = 0,01 \text{ e } A_{2,0} = 0,3$$

Os valores das condições iniciais são as variáveis de entrada.

ii) Controlador

Os parâmetros fuzzy são obtidos através das bases de regras via processo de Mamdani:

Na colônia **1**, temos:

$\varphi_{P_M}(300) = 0,5$ (grau de pertinência ao conjunto fuzzy *população média/ou grande*);

$\varphi_{A_H}(0,01) = 0,995$ (grau de pertinência ao conjunto fuzzy *ambiente hostil*).

Então,

$$0,5 \wedge 0,995 = 0,5$$

Pela base de regras, temos que *População* média ou grande e *Ambiente* hostil geram o conjunto fuzzy *Migração* grande como variável de saída. O conjunto fuzzy *Migração*, para estes dados iniciais, tem a seguinte configuração (Figura 10.19).




Figura 10.19: Saída fuzzy da Migração.

iii) Defuzzificação

O processo que transforma este conjunto de saída fuzzy em um valor exato é conhecido como defuzzificação.

Como vimos no Capítulo 5, são vários os métodos de defuzzificação.

Utilizamos aqui o método do centro de massa, isto é,

$$m_{12} = \frac{\int_R zm(z) dz}{\int_R m(z) dz},$$

onde R é a região limitada pelo gráfico da função de pertinência da saída $\hat{m}$ (ver Figura 10.19). Observe que o valor da integral do denominador é exatamente a área de R .

Da mesma maneira obtemos os valores dos parâmetros defuzzificados F_1 e S_1 .

iv) Parâmetros críps

Os valores máximos de fecundidade e sobrevivência são constantes que dependem da espécie de varejeira estudada. No caso da *Chrysomya albiceps* estas constantes, determinadas experimentalmente, são $F = 7,03$ e $S = 0,915$.

Fazemos os mesmos cálculos para os parâmetros m_{21} , F_2 e S_2 da colônia 2

v) Solução do sistema

Aplicando todos os valores obtidos ao sistema recursivo (10.20) obtemos os valores numéricos de $N_{1,1}$ e $N_{2,1}$, que serão as novas condições iniciais das respectivas colônias. Com o mesmo procedimento anterior, obtemos novamente os parâmetros e aplicamos ao sistema determinístico recursivo (10.20) para obter os valores de $N_{1,2}$ e $N_{2,2}$. Assim, sucessivamente, teremos os valores das populações das duas colônias em cada instante discreto. Neste caso, vimos que as populações se estabilizam.

Podemos observar que as condições ambientais são mais decisivas do que o valor numérico das populações para o processo de migração destas moscas. Por exemplo, se mantivermos as mesmas populações iniciais ($N_{1,0} = 300$ e $N_{2,0} = 400$) e considerarmos condições ambientais favoráveis nas duas colônias ($A_{1,0} = 1$ e $A_{2,0} = 0,9$), obtemos populações

periódicas em cada colônia (Figura 10.21)

Um estudo de metapopulações de moscas varejeiras com uma abordagem fuzzy na dinâmica populacional foi desenvolvido por Magnago [79] em sua tese de doutorado.




Figura 10.20: Estabilidade das colônias.




Figura 10.21: Populações periódicas.

Referências Bibliográficas

- [1] H. O. Aguiar Jr., *Lógica difusa: Aspectos práticos e aplicações*, Editora Interciência Ltda, 1999.
- [2] M. Z. Ahmad and B. D. Baets, *A predator-prey model with fuzzy initial populations*, Cd-rom, Proceeding of IFSA-EUSFLAT Conference, Lisbon, 2009.
- [3] M. Amendola, A. L. Souza, and L. C. Barros, *Manual do uso da teoria dos conjuntos fuzzy no Matlab 6.5.*, Versão 2005 do manual apresentado no Ciclo de Palestras/2004, realizado na FEAGRI-UNICAMP. Disponível em <http://www.ime.unicamp.br/~laeciocb>, Acesso em 17.8.2005.
- [4] R. M. Anderson, G. F. Medley, R. M. May, and A. M. Johnson, *A preliminary study of the transmission dynamics of the human immunodeficiency virus (HIV), the causative agent of AIDS*, IMA J. Mathematical Medicine and Biology **3** (1986), 229–263.
- [5] T. M. Apostol, *Calculus*, 2 ed., vol. 2, Editorial Reverté, 1975.
- [6] L. Arnold, *Random dynamical systems*, 2 ed., Springer, Verlag-Berlin-Heidelberg – Germany, 2003.
- [7] J. P. Aubin and A. Cellina, *Differential inclusions – set-value maps and a viability theory*, Springer-Verlag, Berlin Heidelberg, 1984.
- [8] J. M. Baetens and B. D. Baets, *Incorporating fuzziness in spatial*

- susceptible-infected epidemic models*, Cd-rom, Proceeding of IFSA-EUSFLAT Conference, Lisbon, 2009.
- [9] V. A. Baidosov, *Fuzzy differential inclusions*, PMM USSR **54** (1990), no. 1, 8–13.
- [10] F. Bando, *Sistemas fuzzy e aproximação universal*, Dissertação de Mestrado, IMECC–UNICAMP, Campinas, 2002.
- [11] L. C. Barros, *Modelos determinísticos com parâmetros subjetivos*, Dissertação de Mestrado, IMECC–UNICAMP, Campinas, 1992.
- [12] ———, *Sobre sistemas dinâmicos fuzzy – teoria e aplicação*, Tese de Doutorado, IMECC–Unicamp, Campinas, 1997.
- [13] L. C. Barros, R. C. Bassanezi, and R. Z. G. Oliveira, *Fuzzy differential inclusion: An application to epidemiology*, Soft Methodology and Random Information Systems (Miguel Lopez-Diaz, Maria A. Gil, Przemyslaw Grzegorzewski, Olgierd Hryniewicz, and Jonathan Lawry, eds.), vol. I, Springer, Warsaw, 2004, pp. 631–637.
- [14] L. C. Barros, R. C. Bassanezi, and P. A. Tonelli, *Fuzzy modelling in population dynamics*, Ecological Modelling **128** (2000), 27–33.
- [15] L. C. Barros, M. B. F. Leite, and R. C. Bassanezi, *The SI epidemiological models with a fuzzy transmission parameter*, Intern. J. Computers & Mathematics with Applications **45** (2003), 1619–1628.
- [16] L. C. Barros, R. Z. Oliveira, and R. C. Bassanezi, *The influence of heterogeneity in the control of diseases*, Frontiers in Artificial intelligence and Applications **85** (2002), 88–95.
- [17] L. C. Barros, R. Z. Oliveira, R. C. Bassanezi, and M. B. F. Leite, *A disease evolution model with uncertain parameters*, Proceedings

- of Joint 9th IFSA world Congress and 20th NAFIPS International Conference (Vancouver, Canada), IFSA, NAFIPS, 2001, pp. 1626–1630.
- [18] L. C. Barros and P. A. Tonelli, *Fuzzy pertubation of vector fields*, Proceedings of Joint 9th IFSA World Congress and 20th NAFIPS International Conference (Vancouver, Canada) (Michael H. Smith, W. A. Gruver, and Lawrence O'Higgins Hall, eds.), NAFIPS, North American Fuzzy Information Processing Society and IFSA, the International Fuzzy Systems Association, IEEE, 2001, pp. 3000–3002.
- [19] L. C. Barros, P. A. Tonelli, and A. P. Julião, *Cálculo diferencial e integral para funções fuzzy via extensão dos operadores de derivação e integração*, Relatório técnico 06-03 www.ime.unicamp.br/rel_pesq/relatorio.html, IMECC - UNICAMP, 2010.
- [20] R. G. Bartle, *The elements of real analysis*, John Wiley & Sons, Inc., New York, 1964.
- [21] R. B. Bassanezi, N. Gimenes-Fernandes, P. T. Yamamoto, and W. C. Jesus Jr., *Manual da morte súbita dos citros*, Manual, Fundecitros, 2004.
- [22] R. C. Bassanezi, *Ensino-aprendizagem com modelagem matemática*, 2 ed., Edit. Contexto, São Paulo, 2004.
- [23] R. C. Bassanezi and L. C. Barros, *A simple model of life expectancy with subjective parameters*, Kybernets **7** (1995), 91–98.
- [24] R. C. Bassanezi and W. C. Ferreira Jr, *Equações diferenciais com aplicações*, Edit. HARBRA, São Paulo, 1998.
- [25] R. C. Bassanezi and H. E. Roman, *Relaciones fuzzy: optimizacion*

- de diagnostico medico*, Anais do Encontro Nacional de Ecologia (Rio de Janeiro), LNCC, 1989, pp. 115–124.
- [26] B. Bede and S. G. Gal, *Generalizations of the differentiability of fuzzy-number-valued functions with applications to fuzzy differential equations*, Fuzzy Sets and Systems **151** (2005), 581–599.
- [27] J. C. Bezdek, *Fuzzy models – what are they, and why?*, Transaction on Fuzzy Systems **1** (1993), no. 1, 1–6, Editorial.
- [28] T. G. Bhasker, V. Lakshmikantham, and V. Devi, *Revisiting fuzzy differential equations*, Nonlinear Analysis **58** (2004), 351–358.
- [29] P. Blinder, *Implementação da lógica fuzzy em redes neurais artificiais e aplicações à biologia*, Dissertação de Mestrado, IMECC–Unicamp, Campinas–SP, 1994.
- [30] J. J. Buckley, *Fuzzy probability and statistics*, Studies in Fuzziness and Soft Computing, Springer, 2006.
- [31] W. O. Bussab and P. A. Morettin, *Estatística básica*, 5 ed., Editora Saraiva, São Paulo, 2002.
- [32] V. M. Cabral and L. C. Barros, *Fuzzy differential equation with parameters completely correlated*, (no prelo).
- [33] B. J. Caraça, *Conceitos fundamentais da matemática*, 4 ed., Gradiva Publicações Ltda, Lisboa, 2002.
- [34] M. J. P. Castanho, *Construção e avaliação de um modelo matemático para predizer câncer de próstata e descrever seu crescimento utilizando a teoria dos conjuntos fuzzy*, Tese de Doutorado, FEEC–UNICAMP, Campinas, 2005.
- [35] M. J. P. Castanho, K. F. Magnago, R. C. Bassanezi, and W. Godoy, *Fuzzy subset approach in coupled population dynamics of blowflies*, Biological Research **39** (2006), no. 2, 341–352.

- [36] M. S. Ceconello, *Modelagem alternativa para dinâmica populacional: Sistemas dinâmicos fuzzy*, Dissertação de Mestrado, IMECC-Unicamp, Campinas, 2006.
- [37] Y. Chalco-Cano, *Algumas contribuições na teoria fuzzy multívoca*, Tese de Doutorado, IMECC-UNICAMP, Campinas, 2004.
- [38] Y. Chalco-Cano, R. C. Bassanezi, M. T. Mizukoshi, and M. Rojas-Medar, *Population dynamics by fuzzy differential inclusion*, Kybernetes (2004).
- [39] G. Choquet, *Theory of capacities*, Ann. Institut Fourier **5** (1955), 131–295.
- [40] M. R. Civanlar and H. J. Trussel, *Constructing membership functions using statistical data*, Fuzzy Sets and Systems **18** (1986), 1–13.
- [41] M. C. C. Cunha, *Métodos numéricos.*, 2 ed., Editora da Unicamp, Campinas, 2000.
- [42] M. De Cock and E. E. Kerre, *Fuzzy modifiers based on fuzzy relations*, Information Sciences **160** (2004), 173–199.
- [43] R. L. Devaney, *An introduction to chaotic dynamical systems*, Benjamin/Cummings, Menlo Park, Califórnia, 1989.
- [44] P. Diamond, *Time-dependent differential inclusions, cocycle attractors and fuzzy differential equation*, IEEE Trans. Fuzzy Sets and Systems **7** (1999), 734–740.
- [45] P. Diamond and P. E. Kloeden, *Metric spaces of fuzzy sets: Theory and applications*, World Scientific Publishing Company, 1994.
- [46] M. R. Dias and L. C. Barros, *Differential equations based on fuzzy rules*, IFSA-EUSFLAT (2009).

- [47] M. R. B. Dias, *Equações diferenciais ordinárias com campo de direções parcialmente conhecido*, Dissertação de Mestrado, IMECC–Unicamp, Campinas–SP, 2006.
- [48] D. Dubois and H. Prade, *Fuzzy sets and systems – theory and applications*, Academic Press, Inc., 1980.
- [49] ———, *Properties of measures of information in evidence and possibility theories*, Fuzzy Sets and Systems **24** (1987), no. 2, 161–182.
- [50] L. Edelstein-Keshet, *Mathematical models in biology*, McGraw-Hill, México, 1988.
- [51] R. Füller and T. Keresztfalvi, *On generalization of Nguyen’ Theorem*, Fuzzy Sets and Systems **41** (1990), 371–374.
- [52] R. Füller and P. Majlender, *On interactive fuzzy numbers*, Fuzzy Sets and Systems **143** (2004), 355–369.
- [53] M. A. Gil, M. López-Díaz, and D. A. Ralescu, *Overview on the development of fuzzy random variable*, Fuzzy Sets and Systems **157** (2006), 2546–2557.
- [54] W. A. C. Godoy, *Dinâmica determinística e estocástica em populações de dípteros califorídeos: acoplamento por migração, extinção local e global.*, Tese de livre docência, UNESP, Botucatu, 2002.
- [55] A. G. Gomes and M. C. Varriale, *Modelagem de ecossistemas: Uma introdução*, vol. 1, Editora UFSM, Santa Maria–RS, 2001.
- [56] L. T. Gomes, *Um estudo sobre o espalhamento da dengue usando equações diferenciais parciais e lógica fuzzy*, Dissertação de mestrado, IMECC–UNICAMP, Campinas, 2009.

- [57] H. L. Guidorizzi, *Um curso de cálculo*, 5 ed., vol. 1, Livros Técnicos e Científicos Editora S. A., Rio de Janeiro, 2001.
- [58] P. Hájek, *Metamathematics of fuzzy logic*, Kluwer Academic Publisher, Dordrecht, 1997.
- [59] J. Hale and H. Koçak, *Dynamics and bifurcations.*, Springer-Verlag, New York, 1991.
- [60] E. Hisdal, *Conditional possibilities independence and noninteraction*, Fuzzy Sets and Systems **1** (1978), no. 4, 283–297.
- [61] C. S. Höning, *Aplicações da topologia à análise*, Projeto Euclides, Edgard Blücher, 1976.
- [62] ———, *A integral de lebesgue e suas aplicações*, 11º Colóquio Brasileiro de Matemática (Poços de Caldas), IMPA – Instituto de Matemática Pura e Aplicada, 1977.
- [63] M. Hukuhara, *Integration des applications mesurables donc la valeur est un compact convexe*, Funkcialaj Ekvacioj **10** (1967), 205–223.
- [64] E. Hüllermeier, *An approach to modelling and simulation of uncertain dynamical systems*, Intern. J. Uncertainty Fuzziness Knowledge-Based Systems **5** (1997), 117–137.
- [65] R. M. Jafelice, *Um estudo da dinâmica de transferência de soropositivos para aidéticos via modelagem fuzzy.*, Tese de Doutorado, FEEC–Unicamp, Campinas, 2003.
- [66] R. M. Jafelice, L. C. Barros, and R. C. Bassanezi, *A fuzzy delay differential equation model for hiv dynamics*, IFSA-EUSFLAT (2009), 265–270.

- [67] R. M. Jafelice, L. C. Barros, R. C. Bassanezi, and F. Gomide, *Fuzzy modeling in symptomatic HIV virus infected population*, Bulletin of Mathematical Biology **66** (2004), 1597–1620.
- [68] B. James, *Probabilidade: um curso de nível intermediário*, Instituto de Matemática Pura e Aplicada, Rio de Janeiro, 1981.
- [69] O. Kaleva, *Fuzzy differential equations*, Fuzzy Sets Systems **24** (1987), no. 3, 301–318.
- [70] A. Kandel, *Fuzzy mathematical techniques with applications*, Addison-Wesley Pu. Co., 1986.
- [71] E. P. Klement, R. Mesiar, and E. Pap, *Triangular norms*, Kluwer Academic Publishers, Netherlands, 2000.
- [72] G. Klir and B. Yuan, *Fuzzy sets and fuzzy logic theory and applications*, Prentice-Hall, 1995.
- [73] P. E. Kloeden, *Chaotic iterations of fuzzy sets*, Fuzzy Sets Syst. **42** (1991), no. 1, 37–42.
- [74] M. C. Koissi and A. F. Shapiro, *Fuzzy formulation of the leecarter model for mortality forecasting*, Insurance: Mathematics and Economics **39** (2006), 287–309.
- [75] A. N. Kolmogorov and S. V. Fomin, *Introductory real analysis*, Prentice-Hall, Englewood Cliffs, New Jersey, 1970.
- [76] B. Kosko, *Fuzzy thinking – the new science of fuzzy logic*, Hyperion, New York, 1993.
- [77] V. Krivan and G. Colombo, *A non-stochastic approach for modeling uncertainty in population dynamics*, Bulletin of Mathematical Biology **60** (1998), 721–751.

- [78] M. B. F. Leite, R. C. Bassanezi, and H. M. Yang, *The basic reproduction ratio for a model of directly transmitted infections considering the virus charge and the immunological response*, IMA J. Maths. Appl. in Medicine and Biology **17** (2000), 15–31.
- [79] K. F. Magnago, *Abordagem fuzzy em modelos populacionais discretos*, Tese de Doutorado, IMECC–UNICAMP, Campinas, 2005.
- [80] D. D. Majumder and K. K. Majumdar, *Complexity analysis, uncertainty management and fuzzy dynamical systems*, Kybernetes **33** (2004), 1143–1184.
- [81] D. Maki and M. Thompson, *Mathematical models and applications*, Prentice-Hall, Englewood Cliffs, N.J., 1973.
- [82] E. H. Mamdani and S. Assilian, *An experiment in linguistic synthesis with a fuzzy logic controller*, Int. J. Man-Machine Studies **7** (1975), 1–13.
- [83] E. Massad, R. Menezes, P. Silveira, and N. Ortega, *Métodos quantitativos em medicina*, Manole, São Paulo, 2004.
- [84] E. Massad, N. R. S. Ortega, L. C. Barros, and C. J. Struchiner, *Fuzzy logic in action: Applications in epidemiology and beyond*, Springer, Berlin, Heidelberg, 2008.
- [85] K. Menger, *Statistical metrics*, Proceedings of the National Academy of Sciences **28** (1942), no. 12, 535–537.
- [86] M. Missio, *Modelos de edp intregados a lógica fuzzy e métodos probabilísticos no tratamento de incertezas: uma aplicação em febre aftosa em bovinos*, Tese de Doutorado, IMECC–UNICAMP, Campinas, 2008.
- [87] M. T. Mizukoshi, *Estabilidade de sistemas dinâmicos fuzzy*, Tese de Doutorado, IMECC–UNICAMP, Campinas, 2004.

- [88] M. Mizumoto, S. Fukani, and K. Tanaka, *Some methods of fuzzy reasoning*, Advances in Fuzzy Sets Theory and Applications (Amsterdam) (M. M. Gupta et al, ed.), North-Holland, 1979.
- [89] M. Mizumoto and H. J. Zimmermann, *Comparison of fuzzy reasoning methods*, Fuzzy Sets and Systems **8** (1986), 253–283.
- [90] T. Murofushi and M. Sugeno, *An interpretation of fuzzy measures and choquet's integral as an integral with respect to a fuzzy measure*, Fuzzy Sets and Systems **29** (1989), 201–227.
- [91] J. Murray, *Mathematical biology*, Springer-Verlog, USA, 1990.
- [92] C. V. Negoita and D. A. Ralescu, *Applications of fuzzy sets to systems analysis*, John Wiley & Sons, New York, 1975.
- [93] H. T. Nguyen, *On conditional possibility distributions*, Fuzzy Sets and Systems **1** (1978), no. 4, 299–309.
- [94] H. T. Nguyen, M. Sugeno, R. Tang, and R. Yager (eds.), *Theoretical aspects of fuzzy control*, New York, IEEE International Conference on Fuzzy Systems 1993, John Wiley & Sons, 1995.
- [95] H. T. Nguyen and E. A. Walker, *A first course of fuzzy logic*, CRC Press, Boca Raton, 1997.
- [96] N. R. S. Ortega, L. C. Barros, and E. Massad, *Fuzzy gradual rules in epidemiology*, Kybernetes **32** (2003), 460–477.
- [97] R. Paiva Sobrinho, *Desenvolvimento de um sistema especialista fuzzy aplicado à previsão de variação da salinidade superficial no estuário lagunar de Cananeia, Iguape e Ilha Comprida*, Relatório técnico, Prefeitura Municipal de Ilha Comprida, 2001.

- [98] H. P. Palaro and L. C. Barros, *Comparação entre esperança fuzzy e esperança estocástica*, Anais do XXIII CNMAC – Congresso Nacional de Matemática Aplicada e Computacional (Santos–SP), SB-MAC – Sociedade Brasileira de Matemática Aplicada e Computacional, 2000.
- [99] W. Pedrycz, *Fuzzy modelling – paradigms and practice*, Kluwer Academic Publishers, 1996.
- [100] W. Pedrycz and F. Gomide, *An introduction to fuzzy sets: Analysis and design*, The MIT Press, Massachusetts, 1998.
- [101] M. S. Peixoto, *Sistemas dinâmicos e controladores fuzzy: Um estudo da dispersão da morte súbita dos cítricos em são paulo*, Tese de Doutorado, IMECC–UNICAMP, Campinas, 2005.
- [102] J. C. R. Pereira, *Análise de dados qualitativos – estratégias metodológicas para as ciências da saúde, humanas e sociais.*, 3 ed., Edusp-Fapesp, São Paulo, 2003.
- [103] J. C. R. Pereira, P. A. Tonelli, L. C. Barros, and N. R. S. Ortega, *Defuzzification in medical diagnosis*, Advances in Logic, Artificial Intelligence and Robotics **85** (2002), 202–207.
- [104] ———, *Clinical sings of pneumonia in children: association with and prediction od diagnosis by fuzzy sets theory*, Brazilian Journal of Medical and Biological Research **37** (2004), 1–9.
- [105] M. L. Puri and D. A. Ralescu, *Differentials of fuzzy functions*, Journ. Math. Analysis and Applications **91** (1983), 552–558.
- [106] ———, *Fuzzy random variables*, Journ. Math. Analysis and Applications **91** (1986), 409–422.

- [107] D. Ralescu, Y. Ogura, and S. Li, *Set defuzzification and choquet integrals*, International J. Uncertainty, Fuzziness and Knowledge-Based Systems **9** (2001), 1–12.
- [108] F. Ribacionka, *Sistemas computacionais baseados em lógica fuzzy*, Dissertação de Mestrado, Engenharia Elétrica – Universidade Presbiteriana Mackenzie, São Paulo, 1999.
- [109] H. Roman-Flores, *A note on transitivity in set-valued discrete systems*, Chaos solitons & fractals **17** (2003), 99–104.
- [110] M. A. G. Ruggiero and V. L. R. Lopes, *Cálculo numérico, aspectos teóricos e computacionais.*, 2 ed., Makron Books, São Paulo, 1997.
- [111] K. Sadegh-Zadeh, *Fundamentals of clinical methodology: 3. nosology*, Artificial Intelligence in Medicine **17** (1999), 87–108.
- [112] ———, *The fuzzy revolution: Goodbye to the aristotelian weltanschauung*, Artificial Intelligence in Medicine **21** (2001), 1–25.
- [113] L. San Martin and M. S. F. Marques, *Cálculo estocástico*, 18o. Colóquio da SBM, IMPA, Rio de Janeiro, 1991.
- [114] E. Sanchez, *Resolution of composite fuzzy relation equations*, Information and Control **30** (1976), 35–47.
- [115] S. Seikkala, *On the fuzzy initial value problem*, Fuzzy Sets Syst. **24** (1987), no. 3, 319–330.
- [116] I. S. Shaw and M. G. Simões, *Controle e modelagem fuzzy*, Editora Edgar Blucher Ltda, São Paulo, 2001.
- [117] J. D. M. Silva, *Análise de estabilidade de sistemas dinâmicos p-fuzzy com aplicações em biomatemática.*, Tese de Doutorado, IMECC–Unicamp, Campinas, 2005.

- [118] J. D. M. Silva and R. C. Bassanezi, *Modelagem em biomatemática: um software aplicativo.*, Programa livre disponível em <http://www.ime.unicamp.br/~biomat>, 2006.
- [119] G. P. Silveira, L. L. Vendite, and L. C. Barros, *Software desenvolvido a partir de um modelo matemático fuzzy para prever o estágio patológico do câncer de próstata*, Biomatemática **18** (2008), 27–36.
- [120] L. Stephane and B. Bobée, *Revision of possibility distributions: A bayesian inference pattern*, Fuzzy Sets and Systems **116** (2000), no. 2, 119–140.
- [121] T. Sudkamp, *On probability-possibility transformations*, Fuzzy Sets and Systems **51** (1992), 73–81.
- [122] M. Sugeno, *Theory of fuzzy integrals and applications*, Tese de Doutorado, Instit. of Technology, Tokyo, 1974.
- [123] T. Takagi and M. Sugeno, *Fuzzy identification of systems and its applications to modeling and control*, IEEE Trans. System Man Cybernetics **15** (1985), 116–132.
- [124] M. Turelli, *Stochastic community theory: A partially guided tour*, Biomathematics **17** (1986), 321–339.
- [125] W. Wangning, *Fuzzy reasoning and fuzzy relational equations*, Fuzzy Sets and Systems **20** (1986), 67–78.
- [126] L. Weber and P. A. T. Klein, *Aplicação da lógica fuzzy em software e hardware*, Ulbra, Canoas-RS, 2003.
- [127] M. Wergenknacht and K. Hartmann, *On the construction of fuzzy eigen solutions in given regions*, Fuzzy Sets and Systems **20** (1996), 55–65.

-
- [128] M. Ying, *Reasonableness of compositional rule of fuzzy inference*, Fuzzy Sets and Systems **36** (1990), 305–310.
- [129] L. A. Zadeh, *Fuzzy sets*, Information and Control **8** (1965), 338–353.
- [130] ———, *Probability measures of fuzzy events*, J. Math. Analysis and Applications **23** (1968), 421–427.
- [131] ———, *Fuzzy sets as a basis for a theory of possibility*, Fuzzy Sets and Systems **1** (1978), 3–28.
- [132] L. K. Zsolt, *Redes neurais artificiais: Fundamentos e aplicações*, 3 ed., Editora Livraria da Física – USP, São Paulo, 1996.

Índice Remissivo

- α -nível, 52
- α -nível, 30
- Aproximação Universal, 174
- Aumann, Integral de, 243
- Base de regras fuzzy, 115
- Bezdek, 197
- Bolzano, Teorema do Anulamento de, 287
- Casos favoráveis
 - número de, 221–223
- Choquet, Integral de, 207
- Controlador fuzzy, 115, 117
- Desigualdade de Chebyshev, 214
- Diamond, 254
- Distribuições
 - binomiais, 233
 - condicionais, 107
 - de Poisson, 235
 - de possibilidades condicionais, 109
 - de possibilidades marginais, 109
 - de probabilidades, 225
 - exponenciais, 236
 - marginais, 107
 - uniformes, 236
- Equações Diferenciais
 - Estocásticas, 241
 - Fuzzy, 241
- Equações Relacionais Fuzzy, 163–169
- Espaço
 - de probabilidades, 220
- Esperança, 224
- Esperança Fuzzy, 213
- Eventos Fuzzy, 220
- Eventos fuzzy, 220, 225
 - Independência de, 227
 - Probabilidade de, 221
- Eventos reais, 225
- Extensão da solução determinística, 241

- Função
 característica, 13, 224
 de pertinência, 14, 32, 221, 224, 225
 densidade de probabilidades, 225
 indicadora, 220
- Fuzziness Ambiental, 321
- Fuzziness Demográfica
 Modelagem contínua, 298
 Modelagem discreta, 283
- Gödel, Implicação de, 88, 90
- Gaines-Rescher, Implicação de, 89
- Goguen, Implicação de, 88, 168
- Gompertz, Modelo de, 304
- Heisenberg, Princípio da Incerteza de, 11
- Hukuhara
 Derivada de, 242
 Diferença de, 57
- Hullermeier, 253
- Implicação fuzzy, 87, 88
- Inclusão diferencial fuzzy, 241
- Independência
 Possibilística, 106
 Probabilística, 106
- Integral
 de Choquet, 207
 de Lebesgue, 204
 de Sugeno, 208, 212
 de Aumann, 243
- Kandel, 281
- Kleene-Dienes, Implicação de, 89
- Lebesgue, Integral de, 204
- Lukasiewicz, Implicação de, 88, 97
- Método de Euler, 300
- Métodos de defuzzificação, 126, 134
 Centro de Gravidade, 126, 285
 Centro de Máximos, 127
 Média dos Máximos, 128
- Métodos de Integração Numérica, 300
- Métrica para conjuntos fuzzy, 245
- Métodos de Runge-Kutta, 300
- Mamdani
 Controlador de, 120, 285
 Método de inferência de, 120–126
- Medida
 de possibilidade, 193, 195, 232
 de probabilidade, 220
 de Sugeno, 190
 Fuzzy, 191
- Modelagem Fuzzy

- Controle de Pulgões, 152
Diagnóstico do câncer de próstata, 201
Diagnóstico Médico, 169
Dinâmica populacional de Moscas Varejeiras, 355–363
Esperança de Vida X Pobreza, 322
 Conjunto fuzzy dos pobres, 18, 25
Lotka-Volterra, 308
Modelo de Malthus, 248
Modelo logístico discreto, 272
Modelo SI Fuzzy, 335–348
Presa-predador p-fuzzy contínuo, 310
Presa-predador p-fuzzy discreto, 294
Previsão de Salinidade, 135
Taxa de crescimento bem determinada, 254
Transferência de Soropositivos, 143
 Assintomáticos para Sintomáticos, 349–355
Modificador fuzzy, 100
Modus Ponens, 93
 Fuzzy, 93
 Fuzzy generalizado, 94, 119
Montroll, Modelo de, 304
Número Fuzzy, 43
 operações com, 48
 sino, 47
 trapezoidal, 46
 triangular, 44
Não-interatividade
 Possibilística, 106
 Probabilística, 107
Negoita e Ralescu
 Teorema da representação, 32
Nguyen, Teorema de, 180
Oposição semântica, 285
Órbitas periódicas fuzzy, 276
Ordenação de regras, 288
Pielou, 280
Problema de Valor Inicial Autônomo, 261
Problema de Valor Inicial Fuzzy, 246
 Generalizado, 252
 via Extensão de Zadeh, 256
 via Inclusão Diferencial Fuzzy, 253
Problema de Valor Inicial p-fuzzy, 264
Produto cartesiano fuzzy, 62
Ralescu, 245
Regra de composição de inferência, 70

- Reichenbach, Implicação de, 89
- Relação Fuzzy, 62
- binária, 62, 71
 - binária inversa, 68
 - Composições Generalizadas, 160–163
- Sistema Baseado em Regras Fuzzy, 115
- Sistema Dinâmico Fuzzy, 239
- Contínuo, 239
 - Condição inicial e parâmetro fuzzy, 258
 - Condição inicial fuzzy, 256
 - Equilíbrio, 260
 - Estabilidade, 260, 262
 - Discreto, 266
 - Equilíbrio, 268
- Sistema p-fuzzy
- Contínuo, 298
 - Métodos numéricos, 299
 - Modelo de Montroll, 304
 - Discreto, 283
 - Bidimensional, 295
 - Estabilidade, 291
- Subconjunto Fuzzy, 14
- normal, 33
 - operações com, 21
 - complementar, 21
 - intersecção, 21
 - união, 21
- Sugeno, 213
- Integral de, 208, 212
- t-conorma, 85
- t-norma, 84
- Takagi-Sugeno, Controlador de, 120
- Takagi-Sugeno-Kang, Método de inferência de, 128
- Variáveis
- aleatórias, 220, 224
 - linguísticas, 92
 - não-correlacionada, 228
- Verhulst, Modelo de, 304
- Wu, Implicação de, 89, 103
- Zadeh, 12
- Implicação de, 89
 - Princípio da Extensão de, 37, 38, 40, 50, 56
 - Princípio da Incompatibilidade, 279