



Universidade Estadual de Santa Cruz
Programa de Pós Graduação em Modelagem Computacional - PPGMC

LISTA 1 DE MÉTODOS NUMÉRICOS I

Igor Sousa dos Santos Santana e
Matheus Santos Silva
Dany Sanches Domingues

Ilhéus
29/03/2025

1. Considere um computador onde a palavra de memória é de 16 bits. Nessa representação utiliza-se um bit para o sinal, 5 bits para o expoente (o primeiro para o sinal do expoente e os 4 restantes para o valor do expoente) e 10 para a mantissa do número. Dado o número de máquina representado abaixo:

Índice	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Valor	0	1	0	0	1	1	1	0	1	0	1	1	0	0	0	1

a) Qual é o número decimal representado?

Bit de sinal: 0

Bit de sinal do expoente: 1

Expoente: 0011

Mantissa: 1010110001

O bit do sinal do número está com valor 0, logo o número é positivo.

O bit do sinal do expoente está com valor 1, logo o expoente é negativo.

Para o expoente, temos:

$$\begin{aligned} \text{expoente} &= (-1)^1 \cdot [0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0] \\ \text{expoente} &= (-1)^1 \cdot 3 = -3 \end{aligned}$$

Assim, temos que o valor do expoente é -3.

Para a mantissa, temos:

$$\begin{aligned} \text{mantissa} &= 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 1 \cdot 2^{-3} + 0 \cdot 2^{-4} + 1 \cdot 2^{-5} + \\ &\quad 1 \cdot 2^{-6} + 0 \cdot 2^{-7} + 0 \cdot 2^{-8} + 0 \cdot 2^{-9} + 1 \cdot 2^{-10} = \\ &= 0,5 + 0 + 0,125 + 0 + 0,03125 + 0,015625 + 0 + 0 + 0 + 0,000976563 = \\ &= 0,5 + 0,125 + 0,03125 + 0,015625 + 0,000976563 = \\ &= 0,68164063 \end{aligned}$$

O número decimal representado é dado por $0,67285156310 \cdot 2^{-3}$.

Portanto, o valor decimal correspondente é 0,084106445.

b) Qual é o número de máquina imediato inferior? Informe seu valor decimal.

O número de máquina imediato inferior é:

0	1	0	0	1	1	1	0	1	0	1	1	0	0	0	0
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

O valor da mantissa é:

$$\begin{aligned} mantissa &= 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 1 \cdot 2^{-3} + 0 \cdot 2^{-4} + 1 \cdot 2^{-5} + \\ &\quad 1 \cdot 2^{-6} + 0 \cdot 2^{-7} + 0 \cdot 2^{-8} + 0 \cdot 2^{-9} + 0 \cdot 2^{-10} = \\ &0,5 + 0 + 0,125 + 0 + 0,03125 + 0,015625 + 0 + 0 + 0 + 0 = \\ &0,5 + 0,125 + 0,03125 + 0,015625 = 0,671875 \end{aligned}$$

O número decimal representado é dado por $0,671875 \cdot 2^{-3}$.

Portanto, o valor decimal correspondente é 0,083984375.

c) Qual é o número de máquina imediato superior? Informe seu valor decimal.

O número de máquina imediato superior é:

0	1	0	0	1	1	1	0	1	0	1	1	0	0	1	0
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

O valor da mantissa é:

$$\begin{aligned} mantissa &= 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 1 \cdot 2^{-3} + 0 \cdot 2^{-4} + 1 \cdot 2^{-5} + \\ &\quad 1 \cdot 2^{-6} + 0 \cdot 2^{-7} + 0 \cdot 2^{-8} + 1 \cdot 2^{-9} + 0 \cdot 2^{-10} = \\ &0,5 + 0 + 0,125 + 0 + 0,03125 + 0,015625 + 0 + 0 + 0,001953125 + 0 = \\ &0,5 + 0,125 + 0,03125 + 0,015625 + 0,001953125 = 0,673828125 \end{aligned}$$

O número decimal representado é dado por $0,673828125 \cdot 2^{-3}$.

Portanto, o valor decimal correspondente é 0,084228516.

d) Qual o intervalo de números reais que podem ser representados na notação de 16 bits?

O maior número que pode ser representado com 16 bits é:

0	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

Assim, temos:

$$\text{expoente} = (-1)^0 \cdot [1 \cdot 2^3 + 1 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0] = 15$$

$$\begin{aligned} \text{mantissa} &= 1 \cdot 2^{-1} + 1 \cdot 2^{-2} + 1 \cdot 2^{-3} + 1 \cdot 2^{-4} + 1 \cdot 2^{-5} + \\ &1 \cdot 2^{-6} + 1 \cdot 2^{-7} + 1 \cdot 2^{-8} + 1 \cdot 2^{-9} + 1 \cdot 2^{-10} = 0,9990234375 \end{aligned}$$

$$\text{maior número} = \text{mantissa} \cdot 2^{\text{expoente}}$$

$$\text{maior número} = 0,9990234375 \cdot 2^{15} = 32736$$

Logo o menor número que pode ser representado com 16 bits é:

1	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

que representa o valor -32736

Assim, o intervalo de números reais que podem ser representados na notação de 16 bits é $[-32736, 32736]$

e) Utilize os resultados anteriores para explicar porque apenas um subconjunto dos números reais pode ser representado pelo computador.

No computador, os números decimais são representados por números binários. Como no computador os recursos são finitos, apenas uma quantidade limitada de bits são utilizados para armazenar os números binários. Essa quantidade limitada de bits faz com que apenas um subconjunto dos números pode ser representado. No caso dos números reais, essa limitação de representação é ainda maior, pois entre dois números reais há uma infinidade de

números. Dessa forma, essa limitação do computador causa descontinuidades na representação dos números reais.

Um exemplo de descontinuidade pode ser visualizado nos resultados obtidos em **a), b) e c)**, onde há um salto na representação do número e seus valores imediato superior e inferior. O número decimal 0,084106445, obtido no item **a)**, tem como imediato superior e inferior, respectivamente, os números 0,084228516 e 0,083984375, o que difere do imediato superior e inferior no conjunto dos números reais.

No resultado do item d) é possível visualizar que apenas alguns números no intervalo de $[-32736, 32736]$ podem ser representados com 16 bits.

- 2. Se $a = 1$, $b = 62,10$ e $c = 1$, obtenemos as raízes aproximadas $x_1 = -0,01610723$, e $x_2 = -62,08390$. Determine $fl(x_1)$ e $fl(x_2)$ com 4 A dígitos arredondados usando as fórmulas:**

$$ax^2 + bx + c = 0, a \neq 0$$

$$\text{i) } fl(x_1) = \frac{-b + \sqrt{b^2 - 4ac}}{2a}$$

$$\text{ii) } fl(x_2) = \frac{-b - \sqrt{b^2 - 4ac}}{2a}$$

$$\text{iii) } fl(x_1) = \frac{-2c}{b + \sqrt{b^2 - 4ac}}$$

$$\text{iv) } fl(x_2) = \frac{-2c}{b - \sqrt{b^2 - 4ac}}$$

- a) Calcule os erros absolutos para cada estimativa.

Reescrevendo a, b e c em notação científica com 4 dígitos arredondados:

$$a = 0,1 \cdot 10^1$$

$$b = 0,621 \cdot 10^2$$

$$c = 0,1 \cdot 10^1$$

Para i) $fl(x_1) = \frac{-b + \sqrt{b^2 - 4ac}}{2a}$, temos:

$$fl(x_1) = \frac{-b + \sqrt{b^2 - 4ac}}{2a} = \frac{-0,621 \cdot 10^2 + \sqrt{(0,621 \cdot 10^2)^2 - (0,4 \cdot 10^1) \cdot (0,1 \cdot 10^1) \cdot (0,1 \cdot 10^1)}}{(0,2 \cdot 10^1) \cdot (0,1 \cdot 10^1)} =$$

$$\frac{-0,621 \cdot 10^2 + \sqrt{0,3852 \cdot 10^4}}{0,2 \cdot 10^1} = \frac{-0,621 \cdot 10^2 + 0,6206 \cdot 10^2}{0,2 \cdot 10^1} = \frac{-0,4 \cdot 10^{-1}}{0,2 \cdot 10^1} = -0,2 \cdot 10^{-1}$$

$$fl(x_1) = -0,2 \cdot 10^{-1}$$

$$E_T = |p - p^*|$$

$$E_T = |-0,01610723 - (-0,2 \cdot 10^{-1})| = |-0,01610723 + 0,02|$$

$$E_T = |0,00389277| = 0,00389277$$

Para ii) $fl(x_2) = \frac{-b - \sqrt{b^2 - 4ac}}{2a}$, temos:

$$fl(x_2) = \frac{-b - \sqrt{b^2 - 4ac}}{2a} = \frac{0,621 \cdot 10^2 - \sqrt{(0,621 \cdot 10^2)^2 - (0,4 \cdot 10^1) \cdot (0,1 \cdot 10^1) \cdot (0,1 \cdot 10^1)}}{(0,2 \cdot 10^1) \cdot (0,1 \cdot 10^1)} =$$

$$\frac{-0,621 \cdot 10^2 - \sqrt{0,3852 \cdot 10^4}}{0,2 \cdot 10^1} = \frac{-0,621 \cdot 10^2 - 0,6206 \cdot 10^2}{0,2 \cdot 10^1} = \frac{-0,1241 \cdot 10^3}{0,2 \cdot 10^1} = -0,6205 \cdot 10^2$$

$$fl(x_2) = -0,6205 \cdot 10^2$$

$$E_T = |p - p^*|$$

$$E_T = |-62,08390 - (-0,6205 \cdot 10^2)| = |-62,08390 + 62,05|$$

$$E_T = |-0,0339| = 0,0339$$

Para iii) $fl(x_1) = \frac{-2c}{b + \sqrt{b^2 - 4ac}}$, temos:

$$fl(x_1) = \frac{-2c}{b + \sqrt{b^2 - 4ac}} = \frac{-(0,2 \cdot 10^1) \cdot (0,1 \cdot 10^1)}{0,621 \cdot 10^2 + \sqrt{(0,621 \cdot 10^2)^2 - (0,4 \cdot 10^1) \cdot (0,1 \cdot 10^1) \cdot (0,1 \cdot 10^1)}} =$$

$$\frac{-0,2 \cdot 10^1}{0,621 \cdot 10^2 + \sqrt{(0,3856 \cdot 10^4) - (0,4 \cdot 10^1)}} = \frac{-0,2 \cdot 10^1}{0,621 \cdot 10^2 + \sqrt{0,3852 \cdot 10^4}} = \frac{-0,2 \cdot 10^1}{0,621 \cdot 10^2 + 0,6206 \cdot 10^2} =$$

$$\frac{-0,2 \cdot 10^1}{0,1241 \cdot 10^3} = -0,1612 \cdot 10^{-1}$$

$$fl(x_1) = -0,1612 \cdot 10^{-1}$$

$$E_T = |p - p^*|$$

$$E_T = |-0,01610723 - (-0,1612 \cdot 10^{-1})| = |-0,01610723 + 0,01612|$$

$$E_T = |0,00001277| = 0,00001277$$

Para iv) $fl(x_2) = \frac{-2c}{b - \sqrt{b^2 - 4ac}}$, temos:

$$\begin{aligned} fl(x_2) &= \frac{-2c}{b - \sqrt{b^2 - 4ac}} = \frac{-(0,2 \cdot 10^1) \cdot (0,1 \cdot 10^1)}{0,621 \cdot 10^2 - \sqrt{(0,621 \cdot 10^2)^2 - (0,4 \cdot 10^1) \cdot (0,1 \cdot 10^1)}} = \\ &= \frac{-0,2 \cdot 10^1}{0,621 \cdot 10^2 - \sqrt{(0,3856 \cdot 10^4) - (0,4 \cdot 10^1)}} = \frac{-0,2 \cdot 10^1}{0,621 \cdot 10^2 - \sqrt{0,3852 \cdot 10^4}} = \frac{-0,2 \cdot 10^1}{0,621 \cdot 10^2 - 0,6206 \cdot 10^2} = \\ &= \frac{-0,2 \cdot 10^1}{0,4 \cdot 10^{-1}} = -0,5 \cdot 10^2 \end{aligned}$$

$$fl(x_2) = -0,5 \cdot 10^2 = 50$$

$$E_T = |p - p^*|$$

$$E_T = |-62,08390 - (-0,5 \cdot 10^2)| = |-62,08390 + 50|$$

$$E_T = |-12,0839| = 12,0839$$

Assim temos que os erros absolutos são:

Equação	Valor Real	Valor calculado	Erro Absoluto
i)	$-0,01610723$	$-0,2 \cdot 10^{-1}$	$0,00389277$
ii)	$-62,08390$	$-0,6205 \cdot 10^2$	$0,0339$

iii)	$-0,01610723$	$-0,1612 \cdot 10^{-1}$	$0,00001277$
iv)	$-62,08390$	$-0,5 \cdot 10^2$	$12,0839$

b) Calcule os erros relativos para cada estimativa.

Para i)

$$\varepsilon_T = \frac{|p-p^*|}{p} \cdot (100)\%$$

$$\varepsilon_T = \frac{|-0,01610723 - (-0,2 \cdot 10^{-1})|}{-0,01610723} = \frac{|-0,01610723 + 0,02|}{-0,01610723}$$

$$\varepsilon_T = \frac{|0,00389277|}{-0,01610723} = -0,241678426$$

$$\varepsilon_T = -0,241678426 \cdot (100)\%$$

$$\varepsilon_T = -24,1678426\%$$

Para ii)

$$\varepsilon_T = \frac{|p-p^*|}{p} \cdot (100)\%$$

$$\varepsilon_T = \frac{|-62,0839 - (-0,6206 \cdot 10^2)|}{-62,0839} = \frac{|-62,0839 + 62,06|}{-62,0839}$$

$$\varepsilon_T = \frac{|-0,0339|}{-62,0839} = \frac{0,0339}{-62,0839}$$

$$\varepsilon_T = -0,000546035 \cdot (100)\%$$

$$\varepsilon_T = -0,0546035\%$$

Para iii)

$$\varepsilon_T = \frac{|p-p^*|}{p} \cdot (100)\%$$

$$\varepsilon_T = \frac{|-0,01610723 - (-0,1612 \cdot 10^{-1})|}{-0,01610723} = \frac{|-0,01610723 + 0,01612|}{-0,01610723}$$

$$\varepsilon_T = \frac{|0,00001277|}{-0,01610723} = - 0,000792812$$

$$\varepsilon_T = - 0,000792812 \cdot (100)\%$$

$$\varepsilon_T = - 0,0792812\%$$

Para iv)

$$\varepsilon_T = \frac{|p-p^*|}{p} \cdot (100)\%$$

$$\varepsilon_T = \frac{|-62,0839 - (-0,5 \cdot 10^2)|}{-62,0839} = \frac{|-62,0839 + 50|}{-62,0839}$$

$$\varepsilon_T = \frac{|-12,0839|}{-62,0839} = \frac{12,0839}{-62,0839}$$

$$\varepsilon_T = - 0.194638223 \cdot (100)\%$$

$$\varepsilon_T = - 19.4638223\%$$

Assim temos que os erros são:

Equação	Valor Real	Valor calculado	Erro Relativo
i)	$- 0,01610723$	$- 0,2 \cdot 10^{-1}$	24,1678426%
ii)	$- 62,08390$	$- 0,6205 \cdot 10^2$	0,0546035%
iii)	$- 0,01610723$	$- 0,1612 \cdot 10^{-1}$	0,0792812%
iv)	$- 62,08390$	$- 0,5 \cdot 10^2$	19,4638223%

c) Considerando os resultados de (a) e (b) qual definição de erro é mais apropriada? Justifique.

A definição de erro mais apropriada para **a)** e **b)** é o cálculo do erro relativo, ou seja, **b)**, que leva em consideração a ordem de grandeza do que está sendo calculado. Os resultados dos cálculos realizados em **a)**, não levaram em consideração a ordem de grandeza e, por isso, os resultados são enganosamente pequenos.

- d) Se compararmos os resultados obtidos pelas expressões (i) e (ii), com os das expressões (iii) e (iv). Porque os resultados são diferentes? Qual das alternativas devemos utilizar?

Os resultados diferentes são devido aos erros causados pela aritmética computacional. Na aritmética computacional certas operações trazem mais erros que outras em determinadas condições. Nas operações realizadas neste exercício, os erros são principalmente causados pelo cancelamento da subtração e por operações com valores absolutos muito grandes ou pequenos. Esses maiores erros podem ser observados nas expressões (i) e (iv) em que há o cancelamento da subtração.

Devemos utilizar (iii) e (iv) pois elas evitam o cancelamento da subtração no numerador, o que reduz os erros provocados pela aritmética computacional.

3. A constante de Euler é definida como

$$e = \lim_{x \rightarrow \infty} \left(1 + \frac{1}{x}\right)^x$$

- a) Utilize a definição anterior para calcular estimativas de e para $x = \{10^0, 10^1, 10^2, 10^3, \dots, 10^{32}\}$.
- b) Para cada estimativa calcule o desvio relativo considerando como valor exato $e = 2,718281828459$.

Resolução para os itens **a)** e **b)**:

Potência	Estimativas de e	Erro Relativo
$x = 10^0$	2,0	0,264241117657
$x = 10^1$	2,593742460100	0,045815473236
$x = 10^2$	2,704813829422	0,004954599960
$x = 10^3$	2,716923932236	0,000499542104
$x = 10^4$	2,718145926825	0,000049995417

$x = 10^5$	2,718268237174	0,000004999954
$x = 10^6$	2,718280469319	0,000000500000
$x = 10^7$	2,718281692544	0,000000500000
$x = 10^8$	2,718281814881	0,000000004995
$x = 10^9$	2,718281827143	0,000000000484
$x = 10^{10}$	2,718281829250	0,000000000291
$x = 10^{11}$	2,718281817584	0,000000004001
$x = 10^{12}$	2,718281817596	0,000000003996
$x = 10^{13}$	2,718281228164	0,000000220836
$x = 10^{14}$	2,718290069678	0,000003031775
$x = 10^{15}$	2,718172185194	0,000040335503
$x = 10^{16}$	2,717288214506	0,000365530146
$x = 10^{17}$	2,711402418634	0,002530793442
$x = 10^{18}$	2,653241115812	0,023927141022
$x = 10^{19}$	2,957079637858	0,087848804675
$x = 10^{20}$	1,0	0,632120558829
$x = 10^{21}$	1,0	0,632120558829
$x = 10^{22}$	1,0	0,632120558829
$x = 10^{23}$	1,0	0,632120558829
$x = 10^{24}$	1,0	0,632120558829
$x = 10^{25}$	1,0	0,632120558829
$x = 10^{26}$	1,0	0,632120558829
$x = 10^{27}$	1,0	0,632120558829
$x = 10^{28}$	1,0	0,632120558829
$x = 10^{29}$	1,0	0,632120558829
$x = 10^{30}$	1,0	0,632120558829
$x = 10^{31}$	1,0	0,632120558829


$x = 10^{32}$	1,0	0,632120558829
---------------	-----	----------------

c) Qual o comportamento do erro com o aumento de x ? Comente os resultados.

Com o aumento de x , o erro se comporta de três formas diferentes. Entre $x = 10^0$ e $x = 10^{10}$ o valor do erro decresce, alcançando o valor mínimo em $x = 10^{10}$. Entre $x = 10^{11}$ e $x = 10^{20}$, o erro volta a crescer. A partir de $x = 10^{21}$, o valor se mantém constante. O valor inicial do erro é 0,264241117657, o valor mínimo é 0,000000000291 e o valor máximo é 0,63212055882.

O comportamento do erro apresentado se dá devido a erros de representação numérica. À medida em que x aumenta, o valor de $\frac{1}{x}$ na expressão se torna cada vez menor. Assim, para valores de x entre 10^{11} e 10^{20} , o resultado da expressão $\frac{1}{x}$ é aproximado para um dos extremos do intervalo dos valores que podem ser representados. Já para $x = 10^{21}$, ocorre *underflow*, e o valor de $\frac{1}{x}$ é aproximado para 0, tornando o erro constante a partir desse ponto.

Apêndice para a questão 3:



```
#include <stdio.h>
#include <stdlib.h>
#include <math.h>

#define BASE 10
#define LIMIT 33
#define EULER 2.718281828459

long double calculate_euler(int);
double calculate_euler_double(int);
float calculate_euler_float(int);

int main(int argc, char **argv) {
    long double euler_hat,
        error = 0;
```

```

    FILE *file = fopen("../output/euler_results_double.txt",
"w");

    if(file == NULL) {
        printf("Error opening file!\n");
        return -1;
    }

    fprintf(file, "Power\tEuler Value\t\tRelative Error\n");
    fprintf(file,
"-----\n");

    for(int i = 0; i < LIMIT; i++) {
        euler_hat = calculate_euler(i);
        error = fabs(EULER - euler_hat) / EULER;
        fprintf(file, "%d\t%.12Lf\t%.12Lf\n", i, euler_hat,
error);
        printf("Euler:  %.12Lf,  Error:  %.12Lf\n", euler_hat,
error);
    }

    fclose(file);
    return 0;
}

long double calculate_euler(int power) {
    long double power_of_ten = (long double) powl(BASE,
power);
    return (long double)powl((1.0L + (1.0L / power_of_ten)),
power_of_ten);
}

double calculate_euler_double(int power) {
    double power_of_ten = (double) pow(BASE, power);

```

```
        return (double) pow((1.0L + (1.0L / power_of_ten)),  
power_of_ten);  
}
```

```
float calculate_euler_float(int power) {  
    float power_of_ten = (float) pow(BASE, power);  
    return (float) pow((1.0f + (1.0f / power_of_ten)),  
power_of_ten);  
}
```