

ROTEIRO

- Motivação
- Algoritmos significativos
- Acurácia e precisão
- Erro absoluto e erro relativo
- Erros de arredondamento
 - Aritmética computacional
 - Representação de inteiros
 - Representação de ponto flutuante
- Erros de truncamento


Aritmética computacional

- A responsável pelos erros de arredondamento é a aritmética computacional
- Aritmética computacional $\neq$ Aritmética matemática
 - Aritmética matemática: números tem quantidade infinita de algarismos
 - Aritmética computacional: cada valor representável tem um número finito de algarismos
 - Inteiros: apenas um subconjunto pode ser representado
 - Ponto flutuante: apenas um subconjunto dos números racionais podem ser representados

Representação numéricas

- As representações numéricas no computador utilizam números binários
- Utilizam como unidade básica de medida uma palavra de memória
- palavra = tamanho do registrador do processador
- palavra de memória = 8, 16, 32, 64 bits
- O aumento do tamanho da palavra diminui os problemas da representação
- Ilustramos a representação de números (inteiros e ponto flutuante) para palavras de 8 bits

Representação de inteiros



■ s , Sinal 1 bit, 0 para números positivos, 1 para números negativos

■ v , valor 7 bits

$$\begin{aligned} decimal &= (-1)^s \left[\sum_{i=2}^8 d_i \times 2^{(8-i)} \right] \\ &= (-1)^s \left[d_2 2^6 + d_3 2^5 + \dots + d_8 2^0 \right] \end{aligned}$$

Representação de inteiros

- **Exemplo 3:** Qual o valor decimal na representação:

0	1	1	0	1	0	0	1
---	---	---	---	---	---	---	---

$$\begin{aligned} v &= (-1)^0 \left[1 \times 2^6 + 1 \times 2^5 + 0 \times 2^4 + 1 \times 2^3 + 0 \times 2^2 + 0 \times 2^1 + 1 \times 2^0 \right] \\ &= 64 + 32 + 8 + 1 = 105 \end{aligned}$$

Representação de inteiros

0	1	1	0	1	0	0	1
---	---	---	---	---	---	---	---

- Qual o valor imediato anterior e imediato posterior na representação?

0	1	1	0	1	0	0	0
---	---	---	---	---	---	---	---

0	1	1	0	1	0	1	0
---	---	---	---	---	---	---	---

$$v = (-1)^0 \left[1 \times 2^6 + 1 \times 2^5 + 0 \times 2^4 + 1 \times 2^3 + 0 \times 2^2 + 0 \times 2^1 + 0 \times 2^0 \right]$$
$$= 64 + 32 + 8 = 104$$

$$v = (-1)^0 \left[1 \times 2^6 + 1 \times 2^5 + 0 \times 2^4 + 1 \times 2^3 + 0 \times 2^2 + 1 \times 2^1 + 0 \times 2^0 \right]$$
$$= 64 + 32 + 8 + 2 = 106$$

Representação de inteiros

- Qual o maior valor possível em uma representação de 8 bits?

0	1	1	1	1	1	1	1
---	---	---	---	---	---	---	---

$$v = (-1)^0 \left[1 \times 2^6 + 1 \times 2^5 + 0 \times 2^4 + 1 \times 2^3 + 1 \times 2^2 + 1 \times 2^1 + 1 \times 2^0 \right]$$
$$= 64 + 32 + 16 + 8 + 4 + 2 + 1 = 127$$

- Qual o menor valor possível em uma representação de 8 bits?

1	1	1	1	1	1	1	1
---	---	---	---	---	---	---	---

$$v = (-1)^1 \left[1 \times 2^6 + 1 \times 2^5 + 0 \times 2^4 + 1 \times 2^3 + 1 \times 2^2 + 1 \times 2^1 + 1 \times 2^0 \right]$$
$$= - \left[64 + 32 + 16 + 8 + 4 + 2 + 1 \right] = -127$$

Representação de inteiros

- Qual o menor valor possível em uma representação de 8 bits ...

0	0	0	0	0	0	0	0
---	---	---	---	---	---	---	---

1	0	0	0	0	0	0	0
---	---	---	---	---	---	---	---

- Os dois valores acima representam o zero decimal
- A segunda representação é utilizada para o valor -128
- Em uma representação 8 bits o intervalo dos inteiros que pode ser representado corresponde a

$$[-128, 127]$$

- Em uma representação de k bits podemos representar:

$$\left[-2^{(k-1)}, 2^{(k-1)} - 1 \right]$$

ROTEIRO

- Motivação
- Algoritmos significativos
- Acurácia e precisão
- Erro absoluto e erro relativo
- Erros de arredondamento
 - Aritmética computacional
 - Representação de inteiros
 - Representação de ponto flutuante
- Erros de truncamento

Representação de ponto flutuante

- A representação de ponto flutuante utiliza a notação científica
- O numero é representado pela mantissa (parte fracionária) e pelo expoente (parte inteira)

$$m \times b^e$$

– m , mantissa

– e , expoente

– b , base

- Exemplos:


$$15.678,1 \rightarrow 0,156781 \times 10^5 \quad m = 0,156781 = 1 \times 10^{-1} + 5 \times 10^{-2} + 6 \times 10^{-3} + \dots$$

$$0,05423 \rightarrow 0,5423 \times 10^{-1} \quad m = 0,5423 = 5 \times 10^{-1} + 4 \times 10^{-2} + 2 \times 10^{-3} + \dots$$

Representação de ponto flutuante

- Note que a mantissa é normalizada
- Não existem zeros a esquerda para “aproveitar” os algarismos significativos
- A consequência da normalização o valor de m deve satisfazer
$$\frac{1}{b} \leq m < 1$$
- Na base 10: $0,1 \leq m < 1$
- Devido ao sistema binários a base 2 é utilizada na representação.
- Na base 2: $0,5 \leq m < 1$

Representação de ponto flutuante



- s**, sinal do numero (0 u 1)
- t**, sinal do expoente (0 ou 1)
- e**, valor do expoente
- m**, valor da mantissa

$$\begin{aligned}
 decimal &= (-1)^s m 2^{[(-1)^t e]} = (-1)^s \left[\sum_{i=5}^8 d_i \times 2^{(4-i)} \right] 2^{[(-1)^t e]} \\
 &= (-1)^s \left[\left(\frac{1}{2} \right) d_5 + \left(\frac{1}{4} \right) d_6 + \left(\frac{1}{8} \right) d_7 + \left(\frac{1}{16} \right) d_8 \right] 2^{[(-1)^t (2^1 d_3 + 2^0 d_4)]}
 \end{aligned}$$

Representação de ponto flutuante

- **Exemplo 4:** Qual o menor valor positivo na representação de ponto flutuante de 8 bits?

- Sinal número (+)
- Sinal do expoente (-)
- Valor do expoente $\uparrow$
- Valor da mantissa $\downarrow$

0	1	1	1	1	0	0	0
---	---	---	---	---	---	---	---

- $s = 0$

- $t = -1$

- $e = 3$

- $m = \left(\frac{1}{2}\right)1 + \left(\frac{1}{4}\right)0 + \left(\frac{1}{8}\right)0 + \left(\frac{1}{16}\right)0 = 0,5$

$$(01111000)_2 = (-1)^0 0,5 \times 2^{[(-1)^1 3]} = 0,5 \times 2^{-3} = (0,0625)_{10}$$

Representação de ponto flutuante

0	1	1	1	1	0	0	0
---	---	---	---	---	---	---	---

 $= (0,0625)_{10}$

- **Exemplo 4:** Qual o seguinte valor que podemos representar em ponto flutuante usando 8 bits?

0	1	1	1	1	0	0	1
---	---	---	---	---	---	---	---

- Qual o valor decimal correspondente?

Representação de ponto flutuante

- Exemplo 4 . . .

0	1	1	1	1	0	0	1
---	---	---	---	---	---	---	---

- $s = 0$

- $t = -1$

- $e = 3$

- $m = \left(\frac{1}{2}\right)1 + \left(\frac{1}{4}\right)0 + \left(\frac{1}{8}\right)0 + \left(\frac{1}{16}\right)1 = 0,5625$

$$(01111001)_2 = (-1)^0 0,5625 \times 2^{[(-1)^1 3]} = 0,5625 \times 2^{-3} = (0,0703125)_{10}$$

- Que acontece com os infinitos valores contidos no intervalo $[0,0625000; 0,0703125]$?
- Estes valores serão aproximados para um dos extremos do intervalo

Representação de ponto flutuante

- **Exemplo 4:** Qual o maior valor positivo na representação de ponto flutuante de 8 bits?

- Sinal número (+)
- Sinal do expoente (+)
- Valor do expoente ↑
- Valor da mantissa ↑

0	0	1	1	1	1	1	1
---	---	---	---	---	---	---	---

- $s = 0$

- $t = 0$


- $e = 3$

- $m = \left(\frac{1}{2}\right)1 + \left(\frac{1}{4}\right)1 + \left(\frac{1}{8}\right)1 + \left(\frac{1}{16}\right)1 = 0,9375$


$$(00111111)_2 = (-1)^0 0,9375 \times 2^{[(-1)^0 3]} = 0,9375 \times 2^3 = (7,5)_{10}$$

Representação de ponto flutuante

- Exemplo 4...
- Coloquemos os valores calculados no raio numérico




- Podemos realizar o mesmo procedimento para os números negativos na representação de 8 bits



- Quais os problemas associados à representação?

Representação de ponto flutuante


- Problemas associados a representação de 8 bits



- Underflow
- Overflow
- Descontinuidades

Representação de ponto flutuante

- Os problemas associados a representação aparecem para qualquer tamanho da palavra de memória
- Para palavras de 32 bits



- Ao aumentar o tamanho da palavra:
 - Aumenta a faixa de valores que podem ser representados
 - Diminuem os espaços entre as descontinuidades

Representação de ponto flutuante

- Outro problema da representação de ponto flutuante é termos um número limitado de algarismos para representar a mantissa
- Quando o número de algarismos da mantissa ultrapassa os disponíveis na representação ocorre truncamento ou arredondamento:
 - truncamento: os algarismos excedentes da mantissa são desconsiderados (cortados)
 - arredondamento: os algarismos excedentes são aproximados usando as regras de arredondamento
- Não confundir os termos truncamento e arredondamento com os tipos de erro em MN

Representação de ponto flutuante

- Suponhamos o número real arbitrário y é representado na base 10 na forma

$$y = \pm 0, d_1 d_2 d_3 \cdots d_{i-1} d_i d_{i+1} d_{i+2} \cdots d_{\infty} \times 10^e$$

$$1 \leq d_1 \leq 9, 0 \leq d_i \leq 9, i \neq 1, i = 2 : \infty.$$

- Números $fl(y)$ são chamados números de máquina de k dígitos
- São representados como

$$fl(y) = \pm 0, d_1 d_2 d_3 \cdots d_{k-1} d_k \times 10^e, 1 \leq d_1 \leq 9, \\ 0 \leq d_i \leq 9, i \neq 1, i = 2 : k.$$

Representação de ponto flutuante

- Obtemos a representação $fl(y)$ do número real arbitrário y limitando a mantissa de y em k dígitos
- **Truncamento:** simplesmente abandonamos os dígitos $d_{i+1}d_{i+2}\dots d_{\infty}$, para $i > k$, obtendo-se

$$fl(y) = \pm 0, d_1 d_2 d_3 \dots d_{k-1} d_k \times 10^{\pm e}$$

- **Arredondamento:** se $d_{k+1} \geq 5$, somamos 1 a d_k , se $d_{k+1} < 5$ truncamos os dígitos $d_{k+1}d_{k+2}\dots d_{\infty}$,

$$fl(y) = \begin{cases} \pm 0, d_1 d_2 d_3 \dots d_{k-1} d_k \times 10^n, & d_{k+1} < 5 \\ \pm 0, d_1 d_2 d_3 \dots d_{k-1} \delta_k \times 10^n, & \delta_k = d_k + 1, \quad d_{k+1} \geq 5 \end{cases}$$

Representação de ponto flutuante

- **Exemplo 5:** O valor do número π na forma decimal expande-se em infinitos dígitos. Qual será a representação $fl(\pi)$ com 5 dígitos usando truncamento ou arredondamento? Mostre os erros da representação.

$$\text{Exato: } \pi = 0,314159265 \times 10^1$$

$$\text{Truncamento: } fl(\pi) = 0,31415 \times 10^1 = 3,1415$$

$$\begin{aligned} \text{Arredondamento: } fl(\pi) &= (0,31415 + 0,00001) \times 10^1 \\ &= 3,1416 \end{aligned}$$

Representação de ponto flutuante

- **Exemplo 5: Erros. . .**

Erro	Truncamento	Arredondamento
Absoluto	$0,9265 \times 10^{-4}$	$0,7350 \times 10^{-5}$
Relativo	$0,2949 \times 10^{-2} (0,03\%)$	$0,2340 \times 10^{-3} (0,002\%)$

- O uso de arredondamento oferece melhores resultados que o truncamento,
- Alguns sistemas ou softwares utilizam truncamento por motivos de eficiência.

Aritmética computacional

- Das seguintes assertivas quais são válidas em aritmética computacional?

$$2 + 2 = 4 \quad \text{SIM}$$

$$4 \times 4 = 16 \quad \text{SIM}$$

$$(20 / 3) \times 3 = 20 \quad \text{NÃO}$$

$$(\sqrt{3})^2 = 3 \quad \text{NÃO}$$

- Como avaliar as assertivas 3 e 4 do exemplo anterior em computação?

Aritmética computacional

- Os problemas de representação e aritmética computacional geralmente levam a resultados aproximados
- Estes resultados aproximados são aceitos, e são satisfatórios na maioria das aplicações práticas,
- Em algumas aplicações surgem problemas em virtude dessas discrepâncias entre o valor real e o valor aproximado

Aritmética computacional

- **Exemplo 6:** Considere os números reais:

$$x=0,714251 \quad y=5/7 \quad z=98765,9$$

- Utilize uma representação de 5 dígitos com truncamento e compute as seguintes operações

$$x-y$$

$$(x-y)z$$

$$x+z$$

- Compute os desvios relativos e absolutos em cada caso.

Aritmética computacional

- **Exemplo 6:** . . .
- Representação de 5 algarismos

$$fl(x)=0,71425 \times 10^0$$

$$fl(y)=0,71428 \times 10^0$$

$$fl(z)=0,98765 \times 10^5$$

- Resultado:

Operação	Aproximado	Exato	E_T	ε_T
$x-y$	$-0,30000 \times 10^{-4}$	$-0,347142 \times 10^{-4}$	$0,471 \times 10^{-5}$	13,6
$[x-y] z$	$-0,29629 \times 10^1$	$-0,34285 \times 10^1$	0,4625	13,6
$x+z$	$0,98765 \times 10^5$	$0,98766 \times 10^5$	$0,161 \times 10^1$	$0,136 \times 10^{-2}$

Aritmética computacional

- Existem algumas operações com as quais devemos ter um cuidado especial
 - Operações com valores absolutos muito grandes ou muito pequenos
 - Adição de um valor muito grande e um valor muito pequeno
 - Cancelamento da subtração, subtração de dois valores muito próximos
 - Divisão por valores muito pequenos
 - Somatórios onde o termo i é muito maior que o valor do somatório (borrão)
- Sempre que possível expressões devem ser re-escritas para evitar os erros provocados pela aritmética computacional

ROTEIRO

- Motivação
- Algoritmos significativos
- Acurácia e precisão
- Erro absoluto e erro relativo
- Erros de arredondamento
 - Aritmética computacional
 - Representação de inteiros
 - Representação de ponto flutuante
- Erros de truncamento

Erros de truncamento

- Para ilustrar o conceito de erro de truncamento em MN utilizamos a Serie de Taylor
- **Teorema de Taylor:** Se a função $f(x)$ e suas primeiras $n+1$ derivadas forem continuas no intervalo $[x, x_0]$, então o valor da função em x é dado por

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \\ f''(x_0) \frac{(x - x_0)^2}{2!} + \dots + f^n(x_0) \frac{(x - x_0)^n}{n!}$$

Erros de truncamento

- Dados os pontos $[x_{i-1}, f(x_{i-1})]$, $[x_i, f(x_i)]$ e $[x_{i+1}, f(x_{i+1})]$, de uma função desconhecida obtenha uma expressão para a segunda derivada da função no ponto i .
- Escrevemos as expansões em serie de Taylor para os pontos $i-1$ e $i+1$, utilizando o ponto i como base
- Serie de Taylor em $i-1$


$$f(x_{i-1}) = f(x_i) + f'(x_i)(x_{i-1} - x_i) + \\ f''(x_i) \frac{(x_{i-1} - x_i)^2}{2!} + f'''(x_i) \frac{(x_{i-1} - x_i)^3}{3!} + \dots$$

Erros de truncamento

- Serie de Taylor em $i+1$

$$f(x_{i+1}) = f(x_i) + f'(x_i)(x_{i+1} - x_i) + \\ f''(x_i) \frac{(x_{i+1} - x_i)^2}{2!} + f'''(x_i) \frac{(x_{i+1} - x_i)^3}{3!} + \dots$$

- Consideremos os pontos uniformemente espaçados



$$h = x_{i+1} - x_i$$

$$h = x_i - x_{i-1}$$

Erros de truncamento

- Substituindo por h e simplificando a notação $f(x_i)=f_i$,

$$f_{i-1} = f_i - f_i' h + f_i'' \frac{h^2}{2} - f_i''' \frac{h^3}{3!} + f_i^{(4)} \frac{h^4}{4!} \dots$$

$$f_{i+1} = f_i + f_i' h + f_i'' \frac{h^2}{2} + f_i''' \frac{h^3}{3!} + f_i^{(4)} \frac{h^4}{4!} \dots$$

- Somando e agrupando

$$f_i'' = \frac{(f_{i-1} - 2f_i + f_{i+1}))}{h^2} + 2f_i^{(4)} \frac{h^2}{4!} + \dots$$

Erros de truncamento

- Finalmente

$$f_i'' \cong \frac{(f_{i-1} - 2f_i + f_{i+1}))}{h^2}$$

- Com resíduo (erro de truncamento)

$$R = 2 f_i^{(4)} \frac{h^2}{4!} + \dots$$

- O cálculo da segunda derivada foi aproximado por operações básicas (soma e subtração)
- Influência do h no erro

Comentários finais

- Importância dos MN
- Estimativas, erro absoluto e erro relativo
- Limitações dos MN
 - Erros de arredondamento
 - Aritmética computacional
 - Erros de truncamento